

中图分类号：TP391.1
UDC 分类号：004.8

★ 学生类型

☐ 工程硕博士专项

☐ 交叉研究方向

☐ 政府项目留学生

融合跨任务跨模态信息交互的情感分析方法研究

作者姓名	贾 奥
学院名称	计算机学院
指导教师	宋大为教授
答辩委员会主席	宋丹丹教授
申请学位	工学硕士
一级学科	计算机科学与技术
学位授予单位	北京理工大学
论文答辩日期	2025 年 6 月

Research on Integrating Cross-Task and Cross-Modal Information Interaction for Sentiment Analysis Methods

Candidate Name:	<u>Ao Jia</u>
School or Department:	<u>Computer Science & Technology</u>
Faculty Mentor:	<u>Prof. Dawei Song</u>
Chair, Thesis Committee:	<u>Prof. Dandan Song</u>
Degree Applied:	<u>Master of Engineering</u>
Major:	<u>Computer Science and Technology</u>
Degree by:	<u>Beijing Institute of Technology</u>
The Date of Defence:	<u>June, 2025</u>

研究成果声明

本人郑重声明：所提交的学位论文是我本人在指导教师的指导下独立完成的研究成果。文中所撰写内容符合以下学术规范（请勾选）：

☒ 论文综述遵循“适当引用”的规范，全部引用的内容不超过 50%。

☒ 论文中的研究数据及结果不存在篡改、剽窃、抄袭、伪造等学术不端行为，并愿意承担因学术不端行为所带来的一切后果和法律责任。

☒ 文中依法引用他人的成果，均已做出明确标注或得到许可。

☒ 论文内容未包含法律意义上已属于他人的任何形式的研究成果，也不包含本人已用于其他学位申请的论文或成果。

☒ 与本人一同工作的合作者对此研究工作所做的任何贡献均已在学位论文中作了明确的说明并表示了谢意。

特此声明。

签 名：贾奥

日 期：2025.6.3

关于学位论文使用权的说明

本人完全了解北京理工大学有关保管、使用学位论文的规定，其中包括：

①学校有权保管、并向有关部门送交学位论文的原件与复印件；

②学校可以采用影印、缩印或其它复制手段复制并保存学位论文；

③学校可允许学位论文被查阅或借阅；

④学校可以学术交流为目的，复制赠送和交换学位论文；

⑤学校可以公布学位论文的全部或部分内容（保密学位论文在解密后遵守此规定）。

签 名：贾奥

日期：2025.6.3

导师签名：宋大为

日期：2025.6.3

摘要

情感分析方法通过深度挖掘数据中的情感倾向、主观态度和潜在诉求等信息，在商业决策、社会治理和公共服务等多个领域发挥着重要作用，展现了广泛的应用价值。然而随着时代发展，信息的种类越来越多样化，这对情感分析方法综合利用各种信息的能力提出了挑战。在实际应用中可以通过信息交互来提升情感分析方法的准确性，主要包括：（1）情感分类任务与情绪识别任务之间的跨任务信息交互；（2）文本模态与视觉模态之间的跨模态信息交互。然而，目前的模型缺少对跨任务与跨模态信息交互的显式建模，导致模型对信息的综合利用率不足。因此，本文主要针对如何促进情感分析方法融合跨任务跨模态信息交互的问题，开展了如下研究工作：

1. 多任务多模态情感分析数据集。针对缺少适合于跨任务跨模态信息交互研究的数据集的问题，构建多任务多模态情感分析数据集 **MSSED**，共包含 9190 个样本，涵盖文本和图像两种模态，可用于情感分类、情绪识别以及欲望检测三类任务。通过实验证明了该数据集具有对情感分析方法融合跨任务跨模态信息交互研究的应用价值；

2. 基于跨任务信息交互的情感分析方法。针对现有研究由于只注意到了情感分类以及情绪识别这两个任务之间的差异而忽视了其共性与联系，从而导致跨任务信息交互不足的问题，本研究提出了一个带有位置编码的多任务交互式图注意力网络 **MIP-GAT**。该模型的核心结构为一个多交互图层，通过构建跨任务连接促进跨任务信息交互。此外，该模块还通过语义依存连接和位置编码，促进了语义信息和时序信息的交互。实验结果表明 **MIP-GAT** 将上述三种信息融合到一个统一的图学习框架后，可以高效协同多种信息之间交互，在两种任务上都达到了最好的效果；

3. 基于跨任务信息与跨模态信息交互的对话情感分析方法。针对现有方法都未能同时考虑跨模态信息、跨任务信息以及上下文信息这三种对话情感分析关键信息之间的交互问题，本研究提出了一个多模态多任务交互式图注意力网络 **M3GAT**，用于多模态对话情感分类与情绪识别联合学习。该模型的核心是一个交互式对话图，其间建立有跨任务连接、跨模态连接与上下文连接，分别促进了模型的跨任务信息交互、跨模态信息交互以及上下文信息交互。实验结果表明，**M3GAT** 依靠融合多种信息交互，更好地理解人类对话中的情感与情绪，并超过了所有的基线模型。

关键词：信息交互；情感分析；多任务学习；多模态学习；图注意力网络

Abstract

Sentiment analysis methods play a crucial role in various fields such as business decision-making, social governance, and public services by deeply mining information related to sentiment tendencies, subjective attitudes, and underlying demands, demonstrating broad application value. However, with the evolution of the times, the types of information have become increasingly diverse, posing challenges to the ability of sentiment analysis methods to comprehensively utilize various types of information. In practical applications, information interaction can be employed to enhance the accuracy of sentiment analysis methods, primarily including: (1) cross-task information interaction between sentiment classification task and emotion recognition task; (2) cross-modal information interaction between textual and visual modalities. Nevertheless, current models lack explicit modeling of cross-task and cross-modal information interaction, resulting in insufficient comprehensive utilization of information. Therefore, this thesis primarily focuses on facilitating the integration of cross-task and cross-modal information interaction for sentiment analysis methods, and conducts the following research work:

1. Multi-Task and Multi-Modal Dataset. To address the lack of datasets suitable for cross-task and cross-modal information interaction research, this study constructs a Multi-Task and Multi-Modal Sentiment, Emotion and Desire Dataset (MSED). This dataset comprises 9,190 samples covering both text and image modalities, and supports three tasks: sentiment classification, emotion recognition, and desire detection. Experimental results demonstrate the practical value of the MSED dataset for advancing research on cross-task and cross-modal information interaction for sentiment analysis methods;

2. Sentiment Analysis Method Based on Cross-Task Information Interaction. This study proposes a Multi-Task Interactive Graph Attention Network with Position Encodings (MIP-GAT) to address the limitation in existing research that focuses solely on differences between sentiment classification and emotion recognition tasks while neglecting their commonalities and connections, resulting in insufficient cross-task information interaction. The core structure of this model is a Multi-Interactive Graph Layer that facilitates

cross-task information interaction by cross-task connections. In addition, the module also facilitates the interaction of syntactic and sequential information through syntactic dependency connections and position encodings. The experimental results demonstrate that by integrating these three information types within a unified graph learning framework, MIP-GAT effectively coordinates multi-information interaction, achieving state-of-the-art performance on both tasks;

3. Sentiment Analysis Method in Conversation Based on Cross-Task Information and Cross-Modal Information Interaction. This study proposes a Multi-Task, Multi-Modal Interactive Graph Attention Network (M3GAT) for joint learning of multi-modal sentiment classification and emotion recognition in conversation to address the limitation that existing methods fail to simultaneously consider the interaction of three key types of information, i.e. cross-modal information, cross-task information, and contextual information, for sentiment analysis in conversation. The core of M3GAT is an Interactive Conversation Graph, which establishes cross-task connections, cross-modal connections, and contextual connections, respectively promoting cross-task information interaction, cross-modal information interaction, and contextual information interaction in the model. The experimental results indicate that M3GAT enables superior understanding of sentiment and emotion in human conversations by integrating multiple information interaction, outperforming all baseline models.

Key Words: information interaction; sentiment analysis; multi-task learning; multi-modal learning; graph attention networks

目录

第 1 章 绪论	1
1.1 研究背景及意义	1
1.2 研究现状及发展趋势	3
1.2.1 情感分析研究历史	3
1.2.2 情感分析领域数据集研究现状	5
1.2.3 跨任务信息交互研究现状	6
1.2.4 跨模态信息交互研究现状	8
1.2.5 图神经网络研究现状	10
1.3 研究内容	10
1.4 学术贡献	11
1.5 本文组织结构	12
第 2 章 相关理论及技术	14
2.1 深度学习基础	14
2.1.1 神经网络基础结构	14
2.1.2 激活函数	15
2.1.3 Dropout 机制	16
2.1.4 位置编码	16
2.2 卷积神经网络	17
2.3 循环神经网络	18
2.4 Transformer	21
2.5 图注意力网络	23
2.6 模型评价指标	25
2.7 本章小结	26
第 3 章 多任务多模态情感分析数据集	27
3.1 引言	27
3.2 数据收集	28

3.3 标签选取与标注	28
3.4 数据集样本结构	31
3.5 实验与分析	31
3.5.1 数据集划分	31
3.5.2 实验设置	32
3.5.3 实验结果与讨论	33
3.5.4 人类实验结果	34
3.6 本章小结	35
第4章 基于跨任务信息交互的情感分析方法	36
4.1 引言	36
4.2 带有位置编码的多任务交互式图注意力网络	37
4.2.1 问题描述	37
4.2.2 任务特定编码器	37
4.2.3 多交互图层	38
4.2.4 解码器	41
4.2.5 模型训练	41
4.3 实验与分析	42
4.3.1 实验设置	42
4.3.2 基线模型	43
4.3.3 实验结果与分析	44
4.3.4 消融实验	46
4.3.5 上下文窗口大小对模型效果的影响	47
4.3.6 层数对模型效果的影响	48
4.3.7 可扩展性	49
4.3.8 对超参的敏感性	49
4.3.9 个案研究	50
4.3.10 与大语言模型的比较	51
4.4 本章小结	53

第 5 章 基于跨任务信息与跨模态信息交互的对话情感分析方法	55
5.1 引言	55
5.2 多模态多任务交互式图注意力网络	56
5.2.1 问题描述	56
5.2.2 整体架构	57
5.2.3 多模态语句编码器	58
5.2.4 交互式对话图	61
5.2.5 解码器	64
5.2.6 模型训练	65
5.3 实验与分析	65
5.3.1 研究问题	65
5.3.2 实验设置	66
5.3.3 基线模型	67
5.3.4 实验结果与分析	69
5.3.5 信息种类变化对模型效果的影响	73
5.3.6 消融实验	75
5.3.7 上下文窗口大小对模型效果的影响	76
5.3.8 层数对模型效果的影响	77
5.3.9 说话人信息对模型效果的影响	78
5.3.10 错误分析	79
5.3.11 注意力可视化	80
5.3.12 与大语言模型的比较	81
5.4 本章小结	83
结论与展望	85
参考文献	87
攻读学位期间发表论文与研究成果清单	98
致谢	99

第 1 章 绪论

1.1 研究背景及意义

近年来，随着人工智能技术的迅速发展，情感分析（Sentiment Analysis）作为自然语言处理领域（Natural Language Processing, NLP）的重要分支，其实现价值与应用广度也随之持续拓展。在互联网发达的今天，数以亿计的用户在各式各样的网络平台上发表着海量数据，这些数据中潜藏着大量实用信息。而情感分析方法可以通过深度挖掘数据中的情感倾向、主观态度和潜在诉求等信息，在商业决策^[1]、社会治理^[2]和公共服务^[3]等多个领域发挥重要作用。比如在商业场景中，企业依托情感分析方法对用户评论进行解析，不仅能精准捕捉消费者对产品的满意度波动，还能预测市场趋势与社会倾向，从而帮助优化营销策略。由此可见，情感分析方法在微观的个体情感与宏观的社会认知之间建立了桥梁，其社会价值日益凸显。

在情感分析方法的发展过程中，大多数模型及算法使用文字数据作为输入数据。这既源于文字作为传统信息载体的天然属性，也因其与当前技术生态的高适配性。一方面，文字自人类远古时代发展而来，早已适配人类在各类场景下的表达需求。在信息化的现代，文字广泛存在于社交媒体、网络百科、新闻资讯等多种线上平台。丰富的数量方便了数据采集，并且具有数据存储成本低的优势；在另一方面，文字通过排列组合有限的字符及符号，能够传递无限的知识与信息，也可以表达显式和隐式的情感态度，这为深度学习语言模型提供了丰富的语义特征挖掘空间。海量的文字信息推动着语言模型的发展，而语言模型又反过来更加精准地提取海量文字中所蕴含的倾向与情感，这种文字数据与深度学习技术的协同进步持续引领着情感分析方法的技术创新与发展方向。

然而，大数据时代的来临改变了情感分析原始的信息单一性。在信息爆炸的浪潮中，模型训练所使用的数据量逐步提升，其信息种类也越来越多样化，这对模型综合利用各种信息的能力提出了挑战。在实际应用中，可以通过不同种类之间的信息交互进一步提升模型对信息的综合利用率。比如在多任务学习中，跨任务信息交互可以帮助模型从多个任务角度学习用户意图与情感倾向；在多模态学习中，跨模态信息交互可以帮助模型从文本、图像、语音等多种模态综合分析样本的真实情感。这些不同种类的信息驱使着情感分析方法从多个维度同时考虑模型及算法的设计与应用。因此，

本文针对如何促进情感分析方法融合不同种类的信息交互问题完成了三项研究工作：多任务多模态情感分析数据集、基于跨任务信息交互的情感分析方法以及基于跨任务信息与跨模态信息交互的对话情感分析方法。

首先，设计了一个多任务多模态情感分析数据集。针对多任务学习目的，每个样本标注多种任务标签，包括粗粒度的情感分类（Sentiment Classification）任务标签：积极（Positive）、中性（Neutral）和消极（Negative）；细粒度的情绪识别（Emotion Recognition）任务标签，比如幸福（Happiness）、快乐（Joy）、愤怒（Anger）以及厌恶（Disgust）等；还包括与人类深层意图相关联的欲望检测（Desire Detection）任务标签，如好奇（Curiosity）、复仇（Vengeance）等。这些不同的任务在人类心理层面相互关联，通过多任务学习框架可以利用跨任务信息帮助模型学习这些具有联系的任务之间的差异与共性，从而在各个任务上达到更好的表现。针对多模态学习目的，每个样本以多种模态储存，模态即信息不同形式的载体，包括文本、图像等多种类型。现实世界的复杂性决定了人类认知本质上是多模态的，其中包括人类沟通交流中的信息传递，涉及自然语言（文本）、面部表情（图像）等表现形式，这种多模态信息的协同作用使得人类能够高效理解对方的说话意图以及内心情感。虽然在情感分析领域中存在多个多任务数据集和多个多模态数据集，但是适用于跨任务跨模态信息交互研究的多任务多模态数据集仍旧稀缺。此类数据集的构建可以促进融合跨任务跨模态信息的情感分析方法研究的进步。

其次，研究了一个基于跨任务信息交互的情感分析方法。情感分类和情绪识别是情感分析领域中的两个不同任务。然而在日常生活中，情感（Sentiment）与情绪（Emotion）经常被混淆使用。实际上，这二者的含义稍有差别。情感反映了人类深刻而长期的主观体验和心理态度，例如爱情、友情等。相比之下，情绪是指因外部刺激而产生的短暂而强烈的生理反应，如愤怒、恐惧等。情感往往是经过很长一段时间所形成的，而情绪短时间内便可产生。除了上述差异，情感与情绪也是相互依存并且密切相关的。情绪根植于相对稳定的情感而产生，情感的变化也受情绪所影响。综上所述，情感分类和情绪识别这两种任务之间既存在着差异，也同样存在着共性。然而，最近的工作大多只关注到了它们之间的差异，并将它们视作两个独立的任务，而忽视了情感与情绪的共性，没有考虑到可以使用跨任务信息交互帮助模型提升对情感与情绪的进一步理解。通过多任务学习框架，可以高效协同跨任务信息交互，并同时考虑情感与情绪的差异与共性，进一步挖掘语言模型的潜力，加深对情感分类和情绪识别

这两种任务的理解。

最后，研究了一个基于跨任务跨模态信息交互的对话情感分析方法。模型在融合跨任务信息交互的基础上，更进一步地增添了跨模态信息交互，并应用于对话场景中。近年来多模态学习逐渐成为人工智能领域的前沿方向，其目标是通过融合不同模态的信息，突破单一模态的认知局限，构建更鲁棒、更通用的智能系统。关于多模态学习的研究虽然已经有特征级融合（Feature-Level Fusion）以及决策级融合（Decision-Level Fusion）等多模态特征融合方法，例如将文本特征与图像特征拼接后输入分类器，然而这些方法难以建模人类对话过程中深层的跨模态信息交互。除此之外，人类在对话中还会综合考虑对话的上下文信息，从而更加准确地感知对话的情感以及情绪。跨任务信息、跨模态信息以及上下文信息都对提升模型的表现有很大的帮助。然而，最近的模型都未能在一个统一的框架中同时考虑这三类信息，这意味着在对话情感分类以及情绪识别任务中总是存在未能被充分利用的信息。所以需要设计一种同时融合跨任务信息交互、跨模态信息交互以及上下文信息交互的联合学习框架，使得多种信息中的知识可以充分传播，从而同时提升模型在对话情感分类以及情绪识别任务上的综合表现。

综上所述，如何在情感分析领域高效地融合多种信息交互成为了本文的研究重点。在神经网络的逐步发展中，图神经网络（Graph Neural Networks）因其在信息交互方面的独特优势而大放异彩，受到了研究者的广泛关注。图神经网络利用其特有的图结构可以显式地建模各种信息之间的关系，为模型提供了高效的信息交互能力，使得模型在面对多种信息时也可以深入挖掘其内在联系并得到准确预测。而图注意力网络（Graph Attention Networks, GAT）通过注意力机制为每个节点的所有邻居分配不同的权重，自适应地学习不同信息节点之间的关联性大小并自动识别关键邻居，从而可以更高效地捕捉信息交互中的关键因素。本文研究旨在克服传统情感分析方法中信息交互程度有限的局限性，利用图注意力网络构建模型中的信息交互框架，融合跨任务跨模态信息交互，从而提高模型对多种信息的利用效率，以建立更加准确、高效和可靠的多任务多模态情感分析方法。

1.2 研究现状及发展趋势

1.2.1 情感分析研究历史

情感分析的任务目标是分析文本中主观情感倾向，用于判断文本表达的观点、态

度。而情感分类和情绪识别是属于情感分析任务的两个子任务，前者专注于情感极性的判别（如积极、消极），后者则面向更加细粒度的情绪类别分辨（如快乐、愤怒）。在本文中，这两个子任务统称为情感分析。

情感分析方法的发展可以分为基于词典的方法（**Lexicon-Based Approach**）阶段、基于机器学习的方法阶段和基于深度学习的方法阶段，这些发展阶段在时间维度上由远及近。

基于词典的情感分析方法使用情感词典记录不同词汇所带有的情感极性，并根据词典为句子中词汇的情感极性打分，最终获得整个句子的分数并根据该分数判断情感极性。如何收集词典一般有两种方式，分别为基于字典的方法（**Dictionary-Based Approach**）和基于语料库的方法（**Corpus-Based Approach**）。基于字典的方法先手动收集一些已知情感极性的词汇，之后再搜索其同义词或反义词来扩展这个集合。接着再对每个新加入的词汇进行下一轮搜索，如此迭代直到没有新的词汇加入集合为止^[4]。然而该方法有着不能适应领域差异以及无法考虑上下文的缺点^[5]。所以可以使用基于语料库的方法在语料库中自动找寻带有情感极性的词汇。比如 Hatzivassiloglou 等人^[6]认为连接词（“并且”、“但是”等）隐含了连接词前后词汇的情感极性关系，提取了语料库中所有以连接词相连接的形容词，并使用对数线性回归模型和聚类算法将语料库中的词汇分为积极与消极。

基于机器学习的方法通过统计学习的策略完成情感分析任务，这其中又细分为有监督学习（**Supervised Learning**）和无监督学习（**Unsupervised Learning**）。在有监督学习中，每个样本都带有标签（**Label**），模型通过学习每一类别标签下样本特征的统计关系来预测未分类样本标签。比如朴素贝叶斯分类器^[7]（**Naive Bayes Classifier, NB**）根据贝叶斯定理，使用先验概率计算出样本的后验概率，获得了具有不同特征的样本的分类概率，并根据概率预测样本的标签；最大熵分类器^[8]（**Maximum Entropy Classifier, ME**）假设熵最大的模型是最好的概率模型，它的目标是在一定的约束条件下，学习一个既满足约束条件又在约束条件之外分布尽可能均匀的分类器；支持向量机^[9]（**Support Vector Machine, SVM**）通过在高维空间中找到一个可以将不同类别的数据以最大化间隔分开的超平面来对样本分类。而在无监督学习中样本不带有标签，无监督学习方法需要解决无标签样本的分类问题。比如 K 均值聚类算法^[10]（**K-means Clustering Algorithm**）首先随机找出样本中 K 个点作为中心点，并将其它样本归类于与其距离最近的中心点形成一个簇（**Cluster**）。之后每个簇将会重新选择簇中到其它

所有样本距离之和最小的样本作为该簇新的中心点。再根据新中心点重新划分聚类以及中心点并开始新一轮的分类。最后迭代上述过程直到达成结束条件。

随着深度学习的不断发展,基于深度学习的方法逐渐成为了情感分析的主流方法。卷积神经网络(Convolutional Neural Network, CNN)使用卷积核进行卷积计算来提取样本特征,虽然该方法被设计用于计算机视觉领域,但同样可以应用于属于自然语言处理领域的情感分析任务,比如 Xi 等人^[11]使用了一个拥有三层卷积层的 CNN 去分析句子的情感。循环神经网络(Recurrent Neural Network, RNN)被证明更适用于处理自然语言,它能保障长文本序列的信息不被遗忘,在处理当前信息时还能同时考虑到历史信息,比如 LSTM^[12]和 GRU^[13]都是经典的 RNN 模型。Murthy 等人^[14]使用 LSTM 对文本进行情感分类, Ali 等人^[15]使用双向 GRU 对句子和关键词进行语义分析,并获取其隐层状态用于方向级情感分析。然而由于结构问题, RNN 模型只能顺序处理输入,难以实现并行,这导致模型运行效率不足。而 Transformer 架构^[16]相比于 RNN 实现了高并行性,并且可以通过自注意力机制建模任意位置之间的语义关系,上下文感知能力更强,从而表现出了优秀的语义表征能力。Kang 等人^[17]通过实验验证了与朴素贝叶斯分类器、支持向量机、双向 LSTM 等模型相比,基于 Transformer 的 BERT 模型表现更加出色。综上所述,基于 Transformer 的语言模型在自然语言处理领域中占据了主导地位,也在情感分析任务中成为了研究与应用的首选。

1.2.2 情感分析领域数据集研究现状

此前,情感分析领域已经创建了许多多模态数据集,为评估情感分析领域模型提供了实验基础,包括 SenTube^[18]、MOUD^[19]、multi-ZOL^[20]和 CMU-MOSI^[21]等数据集。Yu 等人^[22]为创建 CH-SIMS 数据集收集了 2281 个高质量的中文户外视频片段,不仅为多模态样本标注了一个总体的标签,还分别为样本的每一个模态单独标注了标签,这可以帮助研究者研究不同模态之间的交互。Zhang 等人^[23]提出了第一个多模态隐喻数据集,以促进模型理解文本和图像中的隐喻。此外,有关对话情感分析的研究在最近越来越活跃,其中构建有 IEMOCAP^[24]、ScenarioSA^[25]和 MERR^[26]等数据集,以探究如何在对话中辨别复杂的人类情绪。然而,上述数据集每个样本只有一种任务的标签,无法用于多任务学习。虽然目前也有诸如 CMU-MOSEI^[27]和 MELD^[28]的多任务多模态情感分析数据集,但是该种类的数据集依旧稀缺,仍有必要建立一个适用于跨任务跨模态信息交互研究的多任务多模态情感分析数据集。

1.2.3 跨任务信息交互研究现状

跨任务信息（Cross-Task Information）主要指一个样本在不同任务中所展现的多维度信息。每个任务的目标不同，从样本中所提取的信息也各有侧重。然而这些信息往往具有潜在的关联性，因此可以通过一个任务的信息帮助完成另一个任务。比如在情感分类和情绪识别这两个任务中，当一个样本在情感分类任务中被分类为积极时，那么可以利用这个信息大大降低这个样本在情绪识别任务中被分类为愤怒的概率；同样地，如果一个样本在情绪识别任务中被分类为厌恶，那么据此该样本在情感分类任务中被分类为消极的概率将大大增加。通过跨任务信息的交互可以更高效地帮助模型提升在多个任务上的表现，所以多任务学习在近年来得到了许多研究者的青睐。

在传统的前馈网络架构中，多任务学习的架构大部分具有相似的设计：均由一个不同任务所共享的全局特征提取器和多个特定于不同任务的输出分支所组成。Collobert 等人^[29]使用了一个共享的查找表层（Lookup Table Layer）来学习词的表示，而模型其余部分则分别用于不同任务。同样地，Liu 等人^[30]首先使用词哈希^[31]（Word Hashing）的方法生成词的共享语义向量表示，再将其转换为特定于任务的向量表示并分别完成任务。

在神经网络兴起后，Luong 等人^[32]探索了三种不同的参数共享方案，分别为一对多、多对一和多对多。一对多方案共享编码器，解码器是任务特定的，适用于输出格式不同的任务，比如将同一语言翻译为不同语言。多对一方案的编码器是任务特定的，共享解码器，适用于输出格式相同的任务，比如生成图像描述或者将不同语言翻译为同一种语言。而多对多方案则编码器和解码器均共享，比如同时拥有德语的编码器和解码器，以及英语的编码器和解码器，在模型训练的过程中不仅会组合德语编码器与英语解码器训练，也会组合英语编码器与英语解码器训练（此时是无监督的句子复述任务）。Dong 等人^[33]也构建了一个一对多的架构来实现多任务机器翻译。Liu 等人^[34]同样探索了三种多任务学习方案，包括统一层（Uniform-Layer）架构、耦合层（Coupled-Layer）架构和共享层（Shared-Layer）架构。在统一层架构中，词嵌入层有共享的和任务特定的两种，词嵌入由共享词向量和任务特定词向量拼接而成，每一时刻按句中顺序输入一个词嵌入向量至一个共享的 LSTM 层，直到最后一个时刻的隐藏状态用于分类。在耦合层架构中，每个任务都有一个单独的 LSTM 层，但是不同任务之间的 LSTM 都可以在当前时刻读取上一时刻对方的隐藏状态。在共享层架构中，每个任务都有一个单独的 LSTM 层，但是在它们之间还有一个共享的双向 LSTM 层，

用于获取不同任务之间的共享信息。

现在,越来越多的研究使用基于 Transformer 架构的语言模型进行多任务学习。Ji 等人^[35]实现了一种序列标记模型,可以联合抽取方面术语并预测其情感极性。不同于以往的方法要先确定方面术语的边界才能再对其进行情感分类,他们提出的新方法可以同时完成上述两个步骤。该方法以序列标记的形式同时完成两个任务,首先使用预训练语言模型 BERT 以便基于双向上下文信息更好地获得词汇的特征表示,然后使用条件随机场 (Conditional Random Field, CRF) 层来执行序列标记。Peng 等人^[36]提出了一项名为“方面情感三元组抽取”(Aspect Sentiment Triplet Extraction, ASTE)的新任务,以同时抽取方面、观点以及情感标签的三元组。他们提出的框架有两个阶段。在第一阶段,他们按照 Li 等人^[37]的研究同时抽取方面术语并进行情感分类。在第二阶段,他们实现了一个基于多层感知器的分类器,将每个方面与相应的观点配对,以获得最终的三元组。Liang 等人^[38]使用多任务学习来完成端到端的方面级情感分析 (Aspect-Based Sentiment Analysis, ABSA) 任务。他们提出了一种嵌入依赖关系的图卷积网络以充分利用句法知识。他们还设计了一种有效的消息传递机制,使模型可以从多个相关任务中学习信息。Yang 等人^[39]设计了一种多任务学习模型,用于同时抽取方面术语和预测情感标签。该模型使用了多头自注意力机制和局部上下文聚焦机制。在英文、中文和多语言数据集上进行了实验,证明了模型可用性。Lv 等人^[40]引入了一种基于片段的联合学习方法,用于同时确定方面及情感。该模型使用 BERT 和 GRU 获取词嵌入向量,使用一个交互层来提取方面及情感信息。然后他们使用基于片段的方法抽取方面术语,并使用自注意力机制分类情感。Chen 等人^[41]提出了一种分层交互式网络,可以同时处理方面抽取和情感分类。该模型分为两层来联合训练方面抽取器和情感分类器,前一层用于浅层交互,而后一层用于两个任务之间的深层交互。

虽然上述方法都或多或少地考虑到了跨任务信息之间的关联,但是都并未显式地直接建模样本特征的跨任务信息交互,这导致了跨任务信息在这些多任务学习框架中并未得到充分的利用。

此外,最近关于同时解决情感分类和情绪识别的研究中,这两个任务经常被当作两个独立的任务并分开完成,而未考虑到它们之间的相互影响。这些研究只关注到了差异,却忽视了情感与情绪的共性。比如 Zhang 等人^[42]提出了一个量子概率启发的多模态对话情感分析模型,它既可用于情感分类,也可用于情绪识别。Huddar 等人^[43]使用 RNN 获取说话人状态和上下文状态,并使用注意力机制理解模态之间的关系,

之后用于情感分类或情绪识别。上述两项研究均未考虑到情感与情绪的关联。Plaza-del-Arco 等人^[44]提出了一个共享编码器来同时学习用于情感分类与情绪识别的特征表示,然而这种设计太过隐式,以至于不能很好地建模情感与情绪之间的跨任务信息交互。

综上所述,需要在多任务学习框架中显式建模跨任务信息交互,不仅要考虑情感分类任务与情绪识别任务之间的差异,也要同时考虑它们之间的共性。

1.2.4 跨模态信息交互研究现状

跨模态信息(Cross-Modal Information)主要指一个样本在不同模态中所展现的多角度信息。这些不同模态的信息相互关联,且相互补充,提升了信息表达的全面性。比如一个人说的话虽然单从文字的角度来看可能是夸赞对方的,但是我们可以根据说话人讥讽的面部表情(视觉)和说话语气(听觉)来推断出这个人的实际意图是在讽刺对方。由于人类世界的复杂性,信息通过多种模态传递,从单一模态进行分析很有可能会因为信息不完整从而导致误判,所以多模态学习逐渐成为了情感分析领域的重要研究方法。

多模态情感分类(Multi-Modal Sentiment Classification)旨在发现样本中所表达的情感极性,这种方法被众多研究者应用于其研究。Morency 等人^[45]首次使用了三种模态来进行情感分类任务,并展示了模型可以从文本、视觉和音频的多模态联合学习中受益。Zhang 等人^[46]提出了一种受量子理论的启发的多模态情感分类模型,并构建了一个多模态情感数据集。Li 等人^[47]同样经过量子理论的启发构建了样本的多模态表示。Liang 等人^[48]提出了一种面向方面的元学习(Asspect-Focused Meta Learning, AFML)框架,用于小样本方面级情感分类任务。Ju 等人^[49]构建了一个多模态联合学习框架,该框架可以检测跨模态关系,并用于方面级情感分类。

随着深度学习被广泛应用于各种自然语言处理领域任务,基于卷积神经网络、循环神经网络及其变体的多模态情感分类方法被提出。例如,Yakaew 等人^[50]使用 CNN 分别提取面部和音频特征进行多模态情感分类。Ghosal 等人^[51]提出了一种基于 RNN 的多模态注意力框架,该框架利用上下文信息进行对话语句级的情感分类。Zadeh 等人^[52]将 RNN 与张量乘积运算相结合,提出了一种可以将音频和视觉特征张量融合的神经网络模型。Huang 等人^[53]提出了一种基于 RNN 的多模态注意力融合模型,旨在学习加权的多模态表示。近年来,预训练模型也被经常用于提取多模态特征。Xi 等人^[54]

使用预训练的 VGG-16 和 BERT 来分别提取视觉和文本特征，并使用多头注意力机制来对各种特征进行加权融合，融合后的特征将用于多模态情感分类。Wang 等人^[55]使用 Transformer 架构构建模态融合单元，并将文本模态分别与视觉模态与音频模态融合。Peng 等人^[56]旨在降低预训练语言模型的计算成本，并提出了一种多模态情感分类提取模型。Keswani 等人^[57]在 SemEval-2020 任务 8 中使用了 MMBT 模型进行测试，该模型分别使用 BERT 和 ResNet-152 提取文本及视觉特征进行情感分类。

综上所述，多模态情感分类任务目前的主要研究方向在于多模态特征表示和融合，而关于如何将跨模态信息进行交互，或者是与其它种类的信息（如跨任务信息）进行交互的研究还需要进一步的探索。

多模态情绪识别 (Multi-Modal Emotion Recognition) 旨在通过分析各种源样本，如心理信号、多模态文档、对话，来确定人类的基本情绪，如悲伤、惊讶、幸福等。它通常被视为一个细粒度的分类任务。在早期，Chuang 等人^[58]构建了一个基于语音信号和文本文档的多模态情绪识别框架。Rozgić 等人^[59]将 SVM 作为树节点纳入决策树，以解决多类情绪识别问题。Lin 等人^[60]使用两种机器学习方法，即隐马尔可夫模型 (Hidden Markov Model, HMM) 和 SVM，来预测人类的五种情绪。再进一步，深度学习模型如 CNN、RNN 及其各种变体也被广泛引入，用于提取多模态特征并构建多模态情绪识别框架。Fan 等人^[61]采用 CNN 提取外貌和运动特征，再将其输入 RNN 以捕获序列特征，并用于视频情绪识别。Kollias 等人^[62]采用类似的方法，训练一个深度的 CNN 来提取中低层特征，并使用 RNN 进行情绪识别。

目前，对话情绪识别 (Emotion Recognition in Conversation, ERC) 已经成为一个热门的研究课题。在这项任务中同样可以应用多模态的方法，其中模型不仅需要考虑对话中的上下文关系，还需要注意多模态信息融合。Poria 等人^[63]提出了一种基于 LSTM 的模型，该模型能够通过对话时刻附近的视频信息捕获对话的上下文信息，从而有助于分类。Hazarika 等人^[64]设计了一种名为对话记忆网络 (Conversational Memory Network, CMN) 的模型，该模型利用了 ERC 对话历史中的上下文信息。Majumder 等人^[65]提出了一个 DialogueRNN 模型，该模型在整个对话过程中追踪各个个体状态，并将这些信息用于 ERC。更进一步地，还可以在模型中构建对话的图结构来更好地捕捉对话之间的关系。Ishiwatari 等人^[66]就提出了一种基于关系位置编码的图注意力网络 RGAT，它不仅构建了反映关系的图结构，并且还使用位置编码建模序列信息。Ghosal 等人^[67]将每个对话作为节点，并构建了一个对话图。他们将此图输入到图卷积网络中，

最终实现了性能的提升。Lu 等人^[68]提出了一种迭代情绪交互网络，该网络明确地建模了话语之间的情绪交互。Tu 等人^[69]提出了一种上下文和情感感知图注意力(Context-and Sentiment-Aware Graph Attention, CSAGAT)机制，用于在 ERC 任务过程中融入常识性知识，该机制能够保持常识性知识与相关词语的情感一致性并捕捉上下文信息。

综上所述，虽然最近已经开展了许多有关多模态学习的研究工作并取得了很大的进展，但是这些工作只是单独在情感分类任务或情绪识别任务上进行，忽视了跨任务信息的重要性。如果能够在统一的框架中同时实现跨任务信息与跨模态信息交互，可以更有效地帮助模型从多维度多角度利用信息。

1.2.5 图神经网络研究现状

图神经网络将数据表示为图的形式，其中每个节点通过多种类型的连接与其邻居相互关联^[70]。图神经网络使得信息可以通过图的结构进行交互式传播和聚合^[71,72]。自 GNN^[73]出现以来，各种类型的图网络被设计了出来，如 GCN^[74]、GraphSAGE^[75]和 GAT^[76]。这些图网络在许多任务中都有着良好的表现，例如链接预测^[77]、摘要^[78]、情感分析^[79]和图数据增强^[80]。图结构的特点使信息更易于交互和融合。例如，Xing 等人^[81]构建了一个双任务推理时序图，用于交互情感和行为预测任务之间的信息。Meng 等人^[82]在语言模型的顶部应用了图神经网络，以促进上下文信息和检索信息之间的交互。Li 等人^[83]将包含两种不同类型节点的异质图拆分为两个同质图，每个同质图对应一种类型。这种方法有助于相同类型信息在同一知识空间内传播和聚合。

综上所述，图神经网络经常用于建模信息之间的交互，这为本文融合跨任务跨模态信息交互的情感分析方法研究提供了可行性。

1.3 研究内容

如图 1.1，基于上述研究现状，本文的研究内容分为如下三个方面。

首先，开展多任务多模态情感分析数据集的构建工作，重点聚焦于多任务标签的标注与多模态样本的收集。具体地，针对情感分析领域缺少适合于多信息交互研究的数据集的问题，构建多任务多模态情感分析数据集。在多任务构建方面，设置多个任务分类标签并对样本进行标注；在多模态构建方面，同时收集文本及其对应图像的样本数据。数据集构建完成后对样本数据进行统计分析，并使用深度学习模型在数据集上进行测试。

其次，开展研究基于跨任务信息交互的情感分析方法，重点聚焦于跨任务信息交互的研究。具体地，针对现有方法大多只关注到了情感分类与情绪识别之间的差异，并将它们视作两个独立的任务，而没有考虑到情感与情绪之间的共性，从而减少了这两个任务之间信息交互的问题。研究构建可以同时考虑情感与情绪之间的差异与共性的多任务学习图网络框架，高效协同跨任务信息交互。在多种数据集上对所提方法进行实验验证，并进行消融实验、超参选取实验等一系列实验对模型框架展开综合分析。

最后，开展研究基于跨任务信息与跨模态信息交互的对话情感分析方法，重点聚焦于跨模态与跨任务的信息交互。具体地，针对目前缺少一个可以同时考虑跨模态信息、跨任务信息以及上下文信息交互的统一框架的问题，研究同时纳入这三种信息交互的多任务多模态学习图网络框架，以充分传播、交互并融合不同信息知识。在多种数据集上对所提方法进行实验验证，并进行信息种类变化实验、消融实验、超参选取实验等一系列实验对模型框架展开综合分析。

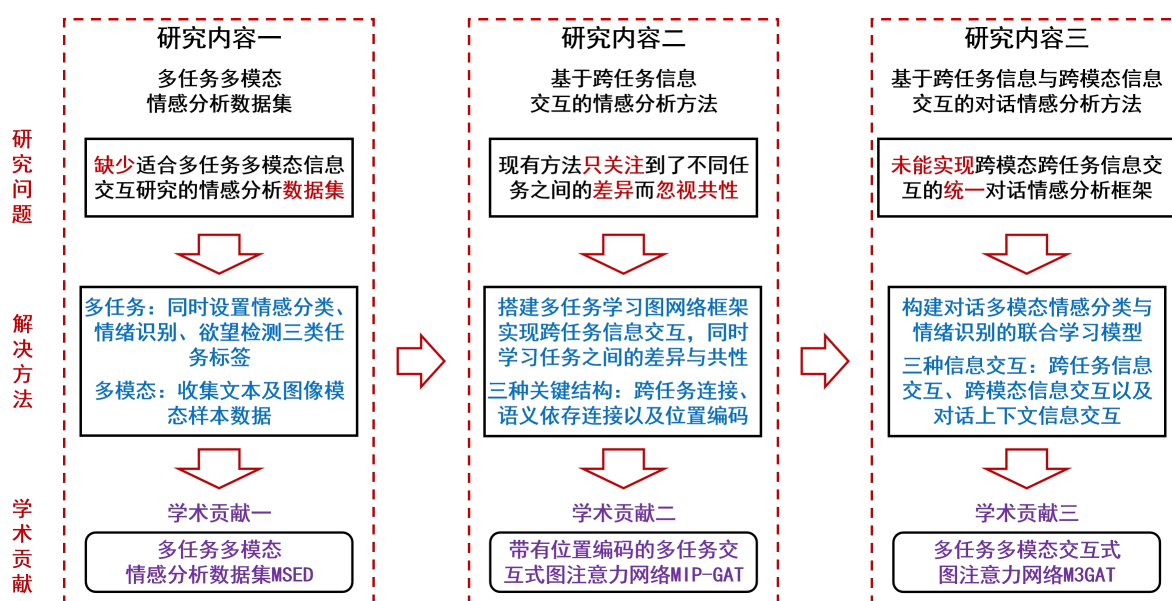


图 1.1 主要研究内容

1.4 学术贡献

针对融合跨任务跨模态信息交互的情感分析方法研究，主要做出了如下三个学术贡献：

首先，在多任务多模态情感分析数据集方面，提出了 MSED (Multi-Task and Multi-Modal Sentiment, Emotion and Desire Dataset) 数据集。该数据集一共包含 9190

个样本，每个样本包含有文本和图像两种模态，并标注有三类任务的标签：情感分类、情绪识别以及欲望检测，既可以应用于多模态学习又可以应用于多任务学习。MSED 数据集是学术界首个可以同时满足情感分类、情绪识别以及欲望检测三种任务的多模态数据集，旨在促进融合跨任务跨模态信息交互的情感分析方法研究。

其次，在基于跨任务信息交互的情感分析方法方面，提出了一个带有位置编码的多任务交互式图注意力网络 MIP-GAT (Multi-Task Interactive Graph Attention Network with Position Encodings)。该方法通过搭建多任务学习图网络框架以保证跨任务信息交互，使得模型可以同时学习情感分类与情绪识别任务的差异与共性。该框架除跨任务信息之外，还额外考虑了语义信息和时序信息的交互，进一步增强了模型对自然语言的理解能力。MIP-GAT 的核心部分是一个多交互图层，它有三个关键结构来保障三种信息交互：（1）跨任务连接保障跨任务信息交互；（2）语义依存连接保障语义依存信息交互；（3）位置编码保障时序信息交互。MIP-GAT 通过显式建模跨任务信息交互以充分考虑任务之间的差异与共性，从而解决了现有方法只关注到差异而忽视共性的问题。

最后，在基于跨任务信息与跨模态信息交互的对话情感分析方法方面，提出了一个多任务多模态交互式图注意力网络 M3GAT (Multi-Task, Multi-Modal Interactive Graph Attention Network)，用于对话中多模态情感分类与情绪识别的联合学习。该模型的核心是一个交互式对话图，由四类子图所构成：情感分类文本对话图、情绪识别文本对话图、情感分类视频对话图和情绪识别视频对话图。同属一个子图或分属不同子图的节点之间建立有跨任务连接、跨模态连接与上下文连接，分别帮助模型进行跨任务信息交互、跨模态信息交互以及对话的上下文信息交互。M3GAT 是学术界首个在统一框架中同时融合这三种信息交互的情感分析方法。

1.5 本文组织结构

本文由以下六个章节所组成：

第一章，绪论。首先介绍了研究背景和意义，指明了信息交互在情感分析领域中的重要性。并对国内外研究现状及不足进行了概述。接下来概括了本文的研究内容以及学术贡献，包括 MSED 数据集、MIP-GAT 模型和 M3GAT 模型。最后梳理了全文的组织结构。

第二章，相关理论及技术。介绍了本文研究所主要涉及到的相关理论和技术，包

括深度学习基础，卷积神经网络，循环神经网络，Transformer 和图注意力网络。还介绍了模型评价指标，包括精确率、召回率和 F1 值。

第三章，多任务多模态情感分析数据集。首先介绍了 MSED 数据集的样本收集以及标注过程。之后应用不同的基线模型在 MSED 数据集上进行实验，证明了该数据集对于情感分析方法融合跨任务跨模态信息交互的研究具有应用价值。

第四章，基于跨任务信息交互的情感分析方法。首先逐一介绍了 MIP-GAT 的各个组成部分，分别为任务特定编码器、多交互图层以及两个独立的解码器。之后在 CMU-MOSEI 数据集、GoEmotions 数据集和 MSED 数据集上进行了实验，与三类基线模型（经典深度学习、图神经网络和预训练语言模型）进行了结果上的比较，并展开了详细的分析。MIP-GAT 超过了所有的基线模型，验证了融合跨任务信息交互的有效性。最后还进行了消融实验、超参选取实验（包括上下文窗口大小以及图网络层数）、可扩展性实验、超参敏感性实验、个案研究以及与大语言模型的比较，从多个方面综合分析了 MIP-GAT 的影响因素以及模型潜力。

第五章，基于跨任务信息与跨模态信息交互的对话情感分析方法。首先总结了 M3GAT 的整体框架，包含一个多模态语句编码器、一个交互式对话图以及两个分别用于情感分类和情绪识别的解码器，并在之后对它们逐一进行了详细介绍。实验在 MELD 数据集、MEISD 数据集以及 MSED 数据集上进行，与 12 种不同的基线模型和 2 个单模态的 M3GAT（Text-M3GAT 和 Video-M3GAT）进行了比较，同时还对实验结果展开了详尽的分析。在实验中 M3GAT 达到了最好的表现，证明了其融合跨任务信息与跨模态信息交互的优越性。最后还进行了信息种类变化实验、消融实验、超参选取实验（包括上下文窗口大小以及图网络层数）、说话人信息影响实验、错误分析、注意力可视化以及与大语言模型的比较，从多个角度研究了 M3GAT 的实际表现。

第六章，结论与展望。对本文工作进行梳理，总结了实验结果与主要贡献，并对未来的研究方向进行了展望。

第 2 章 相关理论及技术

本章将介绍本文研究所主要涉及到的相关理论及技术，它们包括深度学习基础，卷积神经网络，循环神经网络，Transformer 和图注意力网络。此外本章还介绍了情感分析领域用以评价模型表现的指标，包括精确率、召回率和 F1 值。

2.1 深度学习基础

2.1.1 神经网络基础结构

神经网络指的是人工神经网络，它模仿了生物学中动物大脑内的神经网络，用以模拟人类脑中的智能活动，旨在实现人工智能。




图 2.1 单层感知机

最简单的神经网络结构如图 2.1 所示。输入层第 i 个神经元的输入值为 x^i ，将输入层的所有神经元连接到一个输出层的神经元上加权求和，并将结果输入到一个激活函数以得到输出：

$$y = f\left(\sum_{i=1}^n w^i x^i + b^i\right), \quad (2.1)$$

其中 w^i 对应着第 i 个神经元的权值， b^i 为第 i 个神经元的偏置， n 为神经元的数量。 $f(\cdot)$ 为激活函数，通常使用阶跃函数，输出只有 0 和 1 两种状态。

这是一个两层的神经网络，但由于计算只在最后一层上进行，所以也被称为单层感知机^[84]（Single-Layer Perceptron）。然而单层感知机本质上是一个线性模型，它的缺陷在于只能解决线性可分的问题，对于如异或问题等非线性问题则无能为力。

于是为了解决这个问题，多层感知机（Multi-Layer Perceptron, MLP）被提出。多层感知机中每层之间传递所用到的激活函数改为了非线性的 Sigmoid 函数，为神经网络引入了非线性因素，从而改进了单层感知机无法解决非线性问题的缺点，促进了

神经网络的发展。

此外，一种更为有效的神经网络参数学习算法——反向传播（Back Propagation, BP）算法被提出^[85]。反向传播算法利用了梯度下降的方法来更新模型参数，以减小预测值与真实值间的差距，使得预测结果可以更加接近真实值。反向传播算法由于其完备严谨的理论和高效的性能在神经网络的训练中得到了广泛的应用，帮助了神经网络研究的进步，并且至今仍在深度学习领域中发挥着重要的作用。

随着现代互联网的兴起，数据的产生也呈几何式的增长，这为神经网络学习提供了大量的样本，同样促进了现代神经网络的发展。并且随着 GPU 技术的逐代更迭，可以支持更大、更深的神经网络学习，这些都为深度学习的蓬勃发展提供了坚实的基础。

2.1.2 激活函数

从上一小节可以得知激活函数在神经网络中拥有非常重要的作用。激活函数为神经网络引入了非线性因素，从而使得人工神经网络在理论上可以逼近于所有的非线性函数。如果在神经网络中不使用激活函数的话，或者说简单地将激活函数使用为线性函数的话，那么神经网络只相当于一个线性回归模型，它的效率不高，并且可以解决的问题也十分有限。

接下来将介绍一些典型的激活函数。

1. Sigmoid 函数

Sigmoid 函数又叫 Logistic 函数，它拥有一种 S 型的函数曲线。其定义域为全体实数域，值域为(0,1)。Sigmoid 函数具有平滑和易于求导的优点，这使得许多深度学习模型都会采用 Sigmoid 函数作为激活函数。它的公式定义如下：

$$S(x) = \frac{1}{1+e^{-x}} \quad (2.2)$$

Sigmoid 函数也存在缺点，它会导致深度学习中的梯度消失的问题，使得浅层的参数无法得到有效的更新。

2. ReLU 函数

ReLU 函数全称为修正线性单元（Rectified Linear Unit），也叫线性整流函数。它由于可以解决 Sigmoid 函数所导致的反向传播中的梯度消失问题而得到了广泛的应用。在 2012 年，AlexNet 便首次采用了 ReLU 函数作为激活函数。ReLU 函数的定义如下：

$$ReLU(x) = \begin{cases} x, & x > 0 \\ 0, & x \leq 0 \end{cases} \quad (2.3)$$

ReLU 函数的缺点在于可能会导致神经元死亡的问题。当学习率过大时，很可能将权重更新为负值。而负的权重和正的输入相乘后得到的仍是负值，在经过 ReLU 函数后得到的输出为零，梯度也为零。这就导致了这个权重一直不会被更新，从而使得这个神经元死亡。

3. Leaky ReLU 函数

Leaky ReLU 函数是 ReLU 函数的变种，为了解决神经元死亡问题而被设计出来。在 ReLU 函数中，当输入小于等于零时，输出就会为零，梯度也为零。而 Leaky ReLU 函数在输入负值时为其梯度设置了一个常数值 $\lambda \in (0,1)$ ，而当输入正值时，其输出与 ReLU 函数保持一致。Leaky ReLU 函数的公式定义如下：

$$LeakyReLU(x) = \begin{cases} x, & x > 0 \\ \lambda x, & x \leq 0 \end{cases} \quad (2.4)$$

4. ELU 函数

ELU 函数同样没有梯度消失和神经元死亡的问题，并且训练时能在短时间内获得高准确率。此外 ELU 函数还保证了在任何一点上都是可微的。ELU 函数的公式定义如下：

$$ELU(x) = \begin{cases} x, & x > 0 \\ e^x - 1, & x \leq 0 \end{cases} \quad (2.5)$$

2.1.3 Dropout 机制

在深度学习中有个非常容易遇见的问题，那便是过拟合。深度学习会把样本分为训练集、验证集和测试集。过拟合现象便是指模型随着训练的轮数增加，在训练集上的误差越来越小，但是在验证集和测试集上的误差反而增大的现象，从而导致模型的实际表现变差，这表示模型失去了通用性。过拟合现象经常发生在模型的参数非常多，然而训练样本的数量又非常少的情况下。

为了解决这个问题，Dropout 机制被提出，它可以有效地减少深度学习中过拟合现象的发生。Dropout 机制在每一轮训练当中，会以一个提前设置好的概率随机地将神经网络中的神经元删去，即将该神经元的输出设置为零。如此一来，该神经元的梯度也变为了零，在反向传播时其权值便不会更新。在下一轮训练时，首先会将这些被删除的神经元恢复，之后重复上述过程。

2.1.4 位置编码

文本信息是一种时序性的数据，每个词汇的位置信息往往隐含了重要的上下文关

系。当使用卷积神经网络或者循环神经网络对文本信息进行建模的时候，其模型结构本身就天然考虑到了文本的位置信息和时序关系，所以并不需要加入位置编码。而当一些模型对文本的位置信息并不敏感的时候，就需要额外加入位置编码来帮助模型学习到这种位置关系。比如 Transformer 架构在向模型输入词嵌入前就加入了位置编码。这是由于 Transformer 是基于注意力机制所搭建的框架，并未包含诸如卷积结构和循环结构等可以感知到时序信息的结构，所以需要额外加入位置编码以有效利用时序信息。

位置编码主要有两种编码方式，一种是绝对位置编码，另一种是相对位置编码。绝对位置编码中，每个位置对应一个位置向量。绝对位置编码虽然可以帮助模型学习输入的时序信息，但是未能建模位置之间的相对关系，比如如何表达位置 1 和位置 2 的距离相对于位置 1 和位置 3 的距离更近。所以相对位置编码被提出，用以对位置的相对关系进行建模。

位置编码还可以分为固定的位置编码和可学习的位置编码。固定的位置编码不会随着模型训练而改变。而可学习的位置编码会被当作模型参数，随着训练过程一起更新。

2.2 卷积神经网络

卷积神经网络是近年来广泛应用于计算机视觉（Computer Vision, CV）领域的深度学习神经网络，可在多模态学习中用于处理视觉模态信息。该网络通过多层神经网络逐步提取图像浅层到深层特征，从而获取整个图像的特征信息。

Lecun 等人在 1998 年提出了 LeNet-5^[86]，该网络为卷积神经网络提出了一种经典的结构，最终为卷积神经网络的发展奠定了坚实的基础。它包含有一个输入层、两个卷积层、两个池化层和三个全连接层，并用于手写体字符识别。而在 2012 年 AlexNet^[87] 在 ImageNet 图像识别比赛中远超第二名近 11 个百分点，以绝对的优势夺得了第一名的桂冠，从此越来越多的人开始研究卷积神经网络，逐渐将之发展为图像识别任务最流行的技术方法。在 AlexNet 的成功之后，更多种类的卷积神经网络被提出，如 VGG-16^[88]和 GoogLeNet^[89]。此前大部分的模型基本上都是通过深度上扩展卷积神经网络来提升模型表现效果，然而并不是越深的网络效果越好。首先，网络层数越深越容易出现梯度消失和梯度爆炸的问题。其次，还会面临网络退化的问题，也就是随着深度的增加网络的效果首先逐渐上升至饱和，随后迅速下降。为了解决网络退化问

题, He 等人^[90]提出了残差网络 (Residual Network, ResNet), 在残差网络中每几层网络组成一个残差块, 残差块中最后一层的输出和残差块的输入加在一起成为残差块的最终输出。由于这个操作天然包含了恒等映射, 从而可以在一定程度上解决网络退化的问题。

卷积神经网络包含有两个核心的模块: 卷积层和池化层。

卷积层 (Convolutional Layer) 是卷积神经网络中最核心的部分, 在图像领域一般使用的是二维卷积, 即二维滤波器, 也称卷积核, 对图象进行卷积处理。每个卷积核在图像上从上到下、从左到右地滑动, 并使用卷积计算出新的特征图。不同的卷积核可以提取出图像中不同的特征, 比如边缘、圆弧和角。假设卷积层的输入图片大小为 $H \times W \times C$, 则每组卷积核的个数为 C , 卷积核的大小为 $h \times w$, 一共有 D 组卷积核。并且如果输入的填充 (padding) 大小为 P , 卷积核的步长 (stride) 为 S , 则输出的大小为 $H' \times W' \times D$, 其中:

$$H' = \frac{H+2 \times P-h}{S} + 1, \quad (2.6)$$

$$W' = \frac{W+2 \times P-w}{S} + 1. \quad (2.7)$$

在每一层卷积层之后, 都会对输出使用激活函数来进行非线性映射, 卷积神经网络中常使用的激活函数包括 ReLU、Leaky ReLU 等函数。

池化层 (Pooling Layer) 用来对卷积层输出的特征图进行下采样, 在保留原始特征图主要特征的基础之上压缩了特征图的尺寸大小, 从而减少了网络参数和计算量, 大大加快计算速度, 并且还可以在一定程度上防止过拟合现象的产生。常用的池化方式有最大池化和均值池化。最大池化是在池化区域中选取最大值作为结果, 均值池化取池化区域中的均值作为结果。

2.3 循环神经网络

循环神经网络在处理序列信息时具有较大的优势。因为循环神经网络相较于普通的神经网络而言, 最大的不同点在于它有记忆, 即当前计算的结果会受到先前的计算结果的影响。由于文字信息同样是一种序列信息, 这让循环神经网络在自然语言处理领域有着非常广泛的应用, 它能很好地利用文字间的上下文信息。

最基础的循环神经网络在 t 时刻有一个输入 x_t , 由上一时刻的状态和当前时刻的输入生成当前时刻的状态 s_t , 并通过当前时刻状态产生当前时刻输出 o_t , 循环神经网络的结构如图 2.2 所示。




图 2.2 循环神经网络结构

循环神经网络产生输出的过程可用公式表达如下：

$$s_t = f(Ux_t + Ws_{t-1} + b_1), \quad (2.8)$$

$$o_t = g(Vs_t + b_2), \quad (2.9)$$

其中， U 、 V 和 W 是线性变换参数， b_1 和 b_2 是偏置， $f(\cdot)$ 和 $g(\cdot)$ 是非线性激活函数。

然而随着时间的累积，这种最简单的结构存在着梯度消失和梯度爆炸的问题，为了解决这一问题长短期记忆（Long Short-Term Memory, LSTM）模型被提出，它在原有的循环神经网络基础上增添了门结构，包括输入门（Input Gate）、输出门（Output Gate）和遗忘门（Forget Gate）。通过门结构实现的门控机制使得模型可以遗忘无关信息并记住关键信息。在 t 时刻，一个 LSTM 的输入包括输入数据 x_t ，上一时刻的隐藏状态 h_{t-1} 和上一时刻的细胞状态 c_{t-1} ，输出包括当前时刻的隐藏状态 h_t 和当前时刻的细胞状态 c_t 。LSTM 的结构如图 2.3 所示。




图 2.3 LSTM 结构

遗忘门用于决定上一时刻的细胞状态应该遗忘哪些内容，公式如下：

$$f_t = \sigma(x_t W_{xf} + h_{t-1} W_{hf} + b_f), \quad (2.10)$$

其中 f_t 代表遗忘门， f_t 某一维度的数值越接近 1 则代表越要记住上一时刻细胞状态该维度的内容，反之越接近 0 则代表越要忘记， $\sigma(\cdot)$ 代表 Sigmoid 函数， W_{xf} 和 W_{hf} 代表

遗忘门的权重, b_f 代表遗忘门的偏置。

输入门用于决定应当将候选细胞状态 $\tilde{C}_t$ 中的哪些新信息用于更新细胞状态, 公式如下:

$$i_t = \sigma(x_t W_{xi} + h_{t-1} W_{hi} + b_i), \quad (2.11)$$

其中 i_t 代表输入门, i_t 某一维度的数值越接近 1 则代表越要使用候选细胞状态 $\tilde{C}_t$ 该维度的内容更新细胞状态, 反之越接近 0 则代表越不要使用, $\sigma(\cdot)$ 代表 Sigmoid 函数, W_{xi} 和 W_{hi} 代表输入门的权重, b_i 代表输入门的偏置。

候选细胞状态 $\tilde{C}_t$ 由当前时刻输入 x_t 和上一时刻隐藏状态 h_{t-1} 计算得到:

$$\tilde{C}_t = \tanh(x_t W_{xc} + h_{t-1} W_{hc} + b_c), \quad (2.12)$$

其中 W_{xc} 和 W_{hc} 代表权重, b_c 代表偏置。

通过遗忘门和输入门, LSTM 可以获得当前时刻的细胞状态:

$$C_t = f_t \odot C_{t-1} + i_t \odot \tilde{C}_t, \quad (2.13)$$

其中 $\odot$ 代表向量对应维度数值相乘。

最后, 使用输出门来控制输出哪些信息:

$$o_t = \sigma(x_t W_{xo} + h_{t-1} W_{ho} + b_o), \quad (2.14)$$

$$h_t = o_t \odot \tanh(C_t), \quad (2.15)$$

其中 o_t 代表输出门, o_t 某一维度的数值越接近 1 则代表越要输出细胞状态 C_t 该维度的信息, 反之越接近 0 则代表越不要输出, $\sigma(\cdot)$ 代表 Sigmoid 函数, W_{xo} 和 W_{ho} 代表输出门的权重, b_o 代表输出门的偏置, h_t 代表当前时刻的隐藏状态, 也即输出, $\odot$ 代表向量对应维度数值相乘。

在 LSTM 中, 一个句子的信息总是会从前向后地输入, 这意味着 LSTM 未能考虑句子从后到前的上下文信息。为此, 可以使用双向 LSTM (BiLSTM), 它包含一个前向的 LSTM 和一个后向的 LSTM 来分别捕捉从前到后和从后到前的上下文信息, 并将两个 LSTM 在对应位置的输出进行拼接作为 BiLSTM 的输出。

同样地, 门控循环单元 (Gated Recurrent Unit, GRU) 的提出也用于解决梯度消失与梯度爆炸的问题。相比于 LSTM, GRU 只有两个门: 重置门 (Reset Gate) 和更新门 (Update Gate)。这使得 GRU 的计算复杂度相较于 LSTM 降低, 从而加快训练与推理速度。其结构如图 2.4 所示。




图 2.4 GRU 结构

重置门决定如何混合上一时刻隐藏状态与当前时刻输入：

$$r_t = \sigma(x_t W_{xr} + h_{t-1} W_{hr} + b_r), \quad (2.16)$$

其中 r_t 代表重置门， $\sigma(\cdot)$ 代表 Sigmoid 函数， W_{xr} 和 W_{hr} 代表重置门的权重， b_r 代表重置门的偏置。

更新门则同时作用于历史信息 and 当前信息：

$$z_t = \sigma(x_t W_{xz} + h_{t-1} W_{hz} + b_z), \quad (2.17)$$

$$\tilde{h}_t = \tanh(x_t W_{xh} + r_t \odot h_{t-1} W_{rh} + b_h), \quad (2.18)$$

$$h_t = (1 - z_t) \odot h_{t-1} + z_t \odot \tilde{h}_t, \quad (2.19)$$

其中 z_t 代表更新门， $\sigma(\cdot)$ 代表 Sigmoid 函数， W_{xz} 和 W_{hz} 代表更新门的权重， b_z 代表更新门的偏置， $\tilde{h}_t$ 代表候选隐藏状态， W_{xh} 和 W_{rh} 代表权重， b_h 代表偏置， $\odot$ 代表向量对应维度数值相乘， $1 - z_t$ 和 z_t 分别作用于历史信息 h_{t-1} 和当前信息 $\tilde{h}_t$ ，从而获得当前隐藏状态 h_t 。

2.4 Transformer

Transformer 于 2017 年由谷歌团队所提出，它被创立的初衷是用于完成机器翻译任务，之后才被逐渐扩展到其它任务，并衍生出了一系列大模型。如图 2.5 所示，为 Transformer 的模型架构，它是一个由左半部分编码器（Encoder）和右半部分解码器（Decoder）所组成的编码器-解码器架构。编码器和解码器分别由多个结构相同的层所堆叠而成，在原始论文中将其都设置为了 6 层。

在编码器和解码器中，Transformer 都同样对词进行了嵌入，并加上了位置编码。在编码器中，输入首先经过多头注意力层，通过三个矩阵，将输入转化为查询（Query，

Q)、键 (Key, K) 和值 (Value, V)。通过将查询与键相乘便可得到注意力分数, 将注意力分数视作权值与对应值向量相乘再加和便可得到经过注意力机制的输出向量。具体地, 该过程可形式化表示为:

$$Z = \text{Attention}(Q, K, V) = \text{Softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right)V, \quad (2.20)$$

其中 d_k 代表向量长度。




图 2.5 Transformer 模型架构

之后, 向量经过了一层残差加和并归一化。在下一层是一个前馈网络和同样一层残差加和并归一化。

在解码器中, 首先第一层接触到的是掩码多头注意力层, 该层与多头注意力层的区别是每个词与排序在其后的所有词的注意力分数都被设置为了 0, 这遵循了只能根据历史信息生成语言而不能提前看到未来信息的规律一致。在下一个多头注意力层中, K 和 V 来自于编码器, Q 来自于解码器。最后还是同样的前馈网络层和残差加和并归一化。经过多层解码器后, 将最后一个词的输出向量输入至线性层再经过 Softmax 函数便可得到下一个词汇的预测概率分布。

基于 Transformer 架构衍生出了许多预训练语言模型和大语言模型。它们有基于编

码器架构的，也有基于解码器架构的。

BERT(Bidirectional Encoder Representation from Transformers)于2019年被Delvin等人提出^[91]，它是自然语言处理领域中主流的预训练模型，并且在工业界和学术界上都有力地推动了自然语言处理领域的进一步发展。

BERT使用Transformer的编码器作为其模型的基础框架，利用自注意力机制可以很好地捕捉到全局的上下文信息，进而提取到更为准确的文字特征表示。

BERT选择了两种任务来进行预训练，它们分别是掩码语言模型(Masked Language Model, MLM)和下一句预测(Next Sentence Prediction, NSP)。这两个任务分别帮助BERT学习了词语层级的表征能力和句子层级的表征能力。

MLM的训练方法是将句子随机地挖几个空，并让BERT预测每个空被挖去的词汇是什么。具体来讲，对句子中每一个词汇，以15%的概率将其用[MASK]标志来替换掉，之后将整个句子输入BERT，获得BERT在[MASK]位置输出的词向量表示，再将该词向量输入全连接层计算预测的概率分布。但是这种训练方法会让BERT只对[MASK]标志敏感，而不是对所有的词汇都敏感。为了解决这一问题，BERT对这一训练方法进行了优化。当一个词汇以15%的概率被选中之后，它并不会被直接用[MASK]标志替换掉。而是以80%的概率将其用[MASK]标志替换掉，以10%的概率将该单词用一个随机的其它单词替换掉，另外10%的概率将该单词保持不变。如此就可以让BERT对所有词汇都保持敏感。

NSP的训练方法是将两个句子输入至BERT，并让BERT判断第一句话的下一句话是否是第二句话。实际训练过程当中，每一次的判断都会从训练集中挑选出两个句子，并且以50%的概率让第二个句子就是第一句话的下一句话，另外以50%的概率让第二句话是随机的其它句子。

经过预训练，BERT在11个NLP下游任务中均达到了当时的最优效果，这证明了预训练模型在词汇级和句子级的任务中的优秀性能与强大的表征能力。

2.5 图注意力网络

图注意力网络是图神经网络的一种。图神经网络是在图中所有属性(包括节点、边等)上的一种变换，这种变换是可优化的，即可训练的。图神经网络的构建采用一种信息传递的框架，并且它的输入和输出都是一张图，图的信息会以向量的形式加载至图的节点和边上，并且这些嵌入向量会被图神经网络逐步变换，而图的连接性会被

保留。

注意力机制几乎已经成为了许多基于序列的任务的首选方法。注意力机制的好处之一在于它允许处理变长输入，并关注输入中最相关的部分来做出决策。注意力机制在被用来计算单序列表示时，通常被称为自注意力（Self-Attention）。自注意力机制不仅可以用于改进基于循环神经网络或者卷积神经网络的方法，还被证明了它本身也足以构建一个强大的模型，获得最先进的效果。

基于上述两种技术的启发，一种名为图注意力网络（GAT, Graph Attention Networks）的模型被提出。GAT 由图注意力层（Graph Attention Layer）堆叠而成，接下来将分析单层的结构。

每层的输入为一组节点特征向量， $s = \{s_1, s_2, \dots, s_N\}$ ，其中 N 为节点的数量， $s_i \in \mathbb{R}^d$ ， d 为特征向量的维度， $i \in \{1, 2, \dots, N\}$ 。每层都会产生一组新的节点特征向量 $s' = \{s'_1, s'_2, \dots, s'_N\}$ 作为输出，其中 $s'_i \in \mathbb{R}^{d'}$ ， d' 为输出的节点特征向量的维度，可能与输入的维度不同。

为了获得足够将输入特征转换为更高层次特征的表达能力，每层至少需要一个可学习的线性变换。为此，所有节点会共享一个由权重组成的矩阵 $W \in \mathbb{R}^{d' \times d}$ 作为线性变换的参数。之后再对每个节点使用自注意力机制来计算注意力系数，所有节点共享同一个注意力机制 $a: \mathbb{R}^d \times \mathbb{R}^d \rightarrow \mathbb{R}$ 来计算注意力系数：

$$e_{ij} = a(Ws_i, Ws_j), \quad (2.21)$$

这个系数代表了节点 j 的特征对节点 i 的相关性。在实际的代码实现中为了快速计算，通常使用并行的方式一次性计算出所有节点之间的注意力系数，无论两个节点是否相邻。之后再根据图的结构信息对非相邻的节点系数进行处理。

之后的处理需要使用 Masked Attention 机制——每个节点仅保留对其邻居节点 $j \in \mathcal{N}_i$ 或与其本身计算的注意力系数，其中 $\mathcal{N}_i$ 代表节点 i 的邻居节点集合。而对那些非邻居节点，则将其注意力系数设置为负无穷，这样在使用 Softmax 函数对系数进行归一化计算权重时，便可将权重计算为零。Softmax 函数计算权重的公式如下所示：

$$\alpha_{i,j} = \text{softmax}(e_{i,j}) = \frac{\exp(e_{i,j})}{\sum_{k \in \mathcal{N}_i} \exp(e_{i,k})}. \quad (2.22)$$

注意力机制 a 可以有很多种实现方法，GAT 中所使用的是一个单层的前馈神经网络，其参数为向量 $\bar{a} \in \mathbb{R}^{2d'}$ ，再使用 LeakyReLU 作为激活函数，故而使用注意力机制所计算出的注意力权重可被表示为：

$$\alpha_{ij} = \frac{\exp(\text{LeakyReLU}(\bar{a}^\top [Ws_i || Ws_j]))}{\sum_{k \in \mathcal{N}_i} \exp(\text{LeakyReLU}(\bar{a}^\top [Ws_i || Ws_k]))}, \quad (2.23)$$

其中 $||$ 代表纵向拼接操作， $\top$ 代表转置。

当获得了归一化后的注意力权重后，便可通过加权求和的方式来获得节点上最终输出的特征向量：

$$s'_i = \sigma\left(\sum_{j \in \mathcal{N}_i} \alpha_{ij} Ws_j\right), \quad (2.24)$$

其中， $\sigma(\cdot)$ 为非线性化的激活函数。

为了获得稳定的自注意力学习效果，GAT 还引入了多头注意力机制。它包含 H 个头，每个头相互独立地使用上述计算方法对节点特征向量进行变换，并将每个头变换后的结果进行拼接，从而获得多头的输出：

$$s'_i = W^l \parallel \sum_{h=1}^H \sigma\left(\sum_{j \in \mathcal{N}_i} \alpha_{ij}^h W^h s_j\right), \quad (2.25)$$

其中 $||$ 代表拼接操作， α_{ij}^h 代表第 h 个头中节点 i 和节点 j 之间的注意力分数， $W^h \in \mathbb{R}^{d' \times d}$ 是第 h 个头对应的线性变换矩阵， $W^l \in \mathbb{R}^{d' \times Hd'}$ 是线性变换矩阵。

而在最后一层，即预测层，不再使用拼接得到输出，而是使用平均的方式，表达式如下：

$$s'_i = \sigma\left(\frac{1}{H} \sum_{h=1}^H \sum_{j \in \mathcal{N}_i} \alpha_{ij}^h W^h s_j\right), \quad (2.26)$$

2.6 模型评价指标

在情感分析领域中，模型的主要评价指标有精确率（Precision）、召回率（Recall）和 F1 值。

在预测中会出现四种情况：第一种为 TP（True Positive），将正样本判别为正类；第二种为 FN（False Negative），将正样本判断为负类；第三种为 TN（True Negative），将负样本判断负类；第四种为 FP（False Positive），将负样本判断为正类。其中 TP 和 TN 是预测正确的情况，而 FN 和 FP 是预测错误的情况。

精确率指的是在所有预测为正类的样本中，预测正确的比例，公式如下：

$$P = \frac{TP}{TP+FP}. \quad (2.27)$$

召回率指的是在所有正类样本中，预测正确的比例，公式如下：

$$R = \frac{TP}{TP+FN}. \quad (2.28)$$

F1 值是用以评价二分类任务的指标，公式如下：

$$F_1 = \frac{2}{\frac{1}{P} + \frac{1}{R}}. \quad (2.29)$$

对于多分类问题，可以将 F1 值拓展为 macro-F1 来衡量模型的表现。它首先计算每个类中精确率和召回率的平均值，之后再代入到上式中进行计算，公式如下：

$$macro - F_1 = \frac{2}{\frac{n}{\sum_{i=1}^n P_i} + \frac{n}{\sum_{i=1}^n R_i}}, \quad (2.30)$$

其中， n 为类别数量， P_i 和 R_i 分别代表第 i 类样本的准确率和召回率。

2.7 本章小结

本章总结了本文研究所涉及到的相关理论及技术，主要包含了深度学习基础、卷积神经网络、循环神经网络、Transformer 和图注意力网络，其中深度学习基础包括神经网络基础结构、激活函数、Dropout 机制和位置编码。本章最后还介绍了本文研究所要使用的模型评价指标，它们包括精确率、召回率和 F1 值。

第3章 多任务多模态情感分析数据集

3.1 引言

本文研究采取深度学习算法实现情感分析，在深度学习中数据集是必不可少的存在。对于以多种信息交互为方法的研究，涵盖多种信息的数据集同样也是不可或缺的。然而，尽管情感分析领域已经构建有许多先进的数据集，但是适用于跨任务跨模态信息交互研究的多任务多模态数据集仍旧稀缺。为了解决上述问题，本研究首先开展了对多任务多模态情感分析数据的收集任务，并完成了数据集的制作。通过网络爬虫技术，以多个社交媒体（如 X、Getty Images 和 Flickr 等）为资源收集了 9190 个样本，每个样本包含有文字和图像两种模态，并且对样本人工标注了三种标签：情感、情绪以及欲望，最终完成了多任务多模态数据集 MSED（Multi-Task and Multi-Modal Sentiment, Emotion and Desire Dataset）的构建，旨在促进融合跨任务跨模态信息的情感分析方法的研究。

表 3.1 MSED 数据集与其它数据集的对比

数据集	样本量	模态	来源	标签
SenTube	47	文本、图像、语音	YouTube	情感
MOUD	498	文本、图像、语音	YouTube	情感
Multi-ZOL	5,288	文本、图像	Zol.com	情感
CMU-MOSI	2,199	文本、图像、语音	YouTube	情感
CMU-MOSEI	23,453	文本、图像、语音	YouTube	情感、情绪
CH-SIMS	2,281	文本、图像、语音	电影、电视	情感
IEMOCAP	302	文本、图像、语音	表演	情感
MELD	1,433	文本、图像、语音	电视剧	情感、情绪
ScenarioSA	2,214	文本	社交媒体	情感
MUStARD	690	文本、图像、语音	电视剧	情感
MSED	9,190	文本、图像	社交媒体	情感、情绪、欲望

表 3.1 展示了 MSED 数据集与其它情感分析领域数据集的对比。可以看到大部分数据集只有一种任务的标签，只有少数可以应用于多任务学习。而 MSED 数据集是学术界首个可以同时满足情感分类、情绪识别以及欲望检测三种任务的多模态数据集。

这些不同的任务在人类心理层面相互关联,模型可以使用 MSED 数据集同时学习多种任务之间的深层联系,并通过跨任务信息在各个任务上达到更好的表现。此外, MSED 数据集的样本来源于社交媒体,用户一般只会发表文字及图片,因而没有语音模态,但其样本来源于用户的真情实感,因而模型通过此数据集学习到的知识更能贴近于现实与普罗大众的日常生活。

3.2 数据收集

在现代社会,越来越多的人通过网络社交媒体平台发表言论或者分享日常,其中包含大量各种类型的情感信息以及模态信息,人们会在社交媒体中传递自己的喜怒哀乐,也会通过文字、图片等多种形式辅助自己的表达。因此本研究选择在社交媒体平台上收集数据,包括 X、Getty Images 和 Flickr。为了避免不相关的数据所引起的噪声,在收集数据时将设置过滤规则以去除不符合条件的样本数据。

在收集数据时,网络爬虫被设置了一系列具有强烈情感倾向的搜索关键词列表,从而避免搜索到无关数据。并且在社交媒体中搜索关键词时,只获取前十页的搜索结果,以保证最强的相关性。除此之外,在筛选样本时更倾向于保留图像中含有清晰人脸及面部表情的数据,以便更加准确地判别样本主体的情感、情绪与欲望。在初步数据收集过程后,一共获得了超过 11000 份多模态样本数据。

在获得初步数据后,还需要对它们进行进一步处理。对于文本模态,删除所有长度小于 3 的样本,因为过短的文字所蕴含的信息太少,不利于标注与训练。还纠正了所有的拼写错误,去除了所有的非法字符。对于图像模态,去除了所有低像素的样本,并将所有图像都裁剪为相同尺寸。

最终在一系列的筛选与处理过程后,9190 组多模态样本被保留至 MSED 数据集,它们都经过了精心的数据清洗,保证了样本数据的清洁性与完整性。这些样本一共包含有 109570 个单词,样本文字的平均长度为 12。

3.3 标签选取与标注

MSED 数据集每个样本包含有三类任务的标签,分别是情感分类任务、情绪识别任务以及欲望检测任务。对于情感分类任务,包含有三种标签:积极(Positive)、中性(Neutral)以及消极(Negative);对于情绪识别任务,包含有六种标签:幸福(Happiness)、中性(Neutral)、愤怒(Anger)、厌恶(Disgust)、恐惧(Fear)


以及悲伤（Sadness）；对于欲望检测任务，包含有七种标签：家庭（Family）、浪漫（Romance）、复仇（Vengeance）、好奇（Curiosity）、宁静（Tranquility）、社交（Social Contact）以及无欲望（None）。这些欲望类标签来自于 Steven 对于人类的 16 种基本欲望理论^[92]，在本研究中选取了其中与人类情感最相关的六种欲望作为标签，并且还设置了无欲望标签代表样本未表达出任何明显的欲望。对于上述除了无欲望之外的六种欲望标签，表 3.2 解释了其定义。

表 3.2 六种欲望标签的定义


欲望	定义
家庭	照顾后代的需求
浪漫	一种与爱有关的兴奋和神秘的感觉
复仇	向某人反击的欲望
好奇	获得知识或探索未知的欲望
宁静	希望获得安全感、保护以及陪伴的欲望
社交	与他人沟通、交谈以及建立关系的需求

标签选取完成后，使用投票机制进行人工标注，招募五名志愿者对每个样本在三个任务上分别进行标注。这五名志愿者包括三名本科生以及两名研究生，他们受到的教育水平以及专业背景知识都保证了他们对人类情感有着良好的理解。在进行全部样本的标注工作之前，志愿者们首先在指导下标注随机选取出来的 50 个样本。这样做是为了消除对于标签标注的歧义，并且可以加强志愿者的内部一致性。在这个练习过程中，志愿者们的一致性需要达到 90%，这之后便可以正式开始标注。在正式的标注过程中，志愿者根据样本的文本信息以及图像信息标注三种任务的标签。每个样本最后的标签由志愿者选取的比例决定，比例最高的标签即为该样本的最终标签。当存在歧义时，该样本会被跳过并被保留，所有有歧义的样本在最后会被集中讨论并达成一致。若无法达成一致则将其从数据集中删除。图 3.1 描绘了志愿者预测的标签与最终决定的正确标签的混淆矩阵。

可以看到对于欲望类标签，家庭以及社交标签相对容易辨别，预测成功的占比分别可以达到 74%和 71%。而复仇以及宁静标签则更容易被混淆，分别只有 51%和 52%。对于情感类标签，志愿者可以更容易地将积极类的情感从消极类的情感中区分开来，只有 4%的积极类样本被错误预测为消极类。在细粒度的情绪标签中，幸福（79%）标签、中立（78%）标签和恐惧（76%）标签都相对不易混淆。



(a) 欲望类标签



(b) 情感类标签



(c) 情绪类标签

图 3.1 三种任务中志愿者预测标签与正确标签的混淆矩阵

此外，还对志愿者的标注结果计算了 kappa 系数^[93]，用以检验志愿者之间最终标注结果的一致性。对情感分类、情绪识别以及欲望检测这三个任务分别计算得到结果 $\kappa = 0.67$ 、 $\kappa = 0.56$ 和 $\kappa = 0.53$ 。这些计算结果表明，志愿者们在情绪识别和欲望检测任务上达到了中等一致性，而在情感分类任务上达到了高度一致性。

3.4 数据集样本结构

MSED 数据集样本结构如图 3.2 所示。每一条样本在数据集中表示为标题、描述、图片、情感标签、情绪标签以及欲望标签，其中标题是对图片的概括，而描述是对图片更加详细的文字说明。标题、描述、情感标签、情绪标签以及欲望标签以文字的形式保存于 CSV 文件。需要说明的是，MSED 数据集所保存样本的语言文字实际上都是英文，图 3.2 所展示的例子均经过了中文翻译。所有图片以 JPG 格式保存于一个单独的文件夹，每个图片的文件名为其对应文字模态在 CSV 文件中的序号数。

序号	标题	描述	图片	情感	情绪	欲望
1	我们会一起做得很棒!	一位有魅力的年轻女商人白天在办公室竖起着大拇指。		积极	幸福	无
2	小小探险家	一个小男孩和一个小女孩正在观察一只蝴蝶。		积极	幸福	好奇
3	疫情下陷入沉思的老者	一位患有焦虑症的老人正在透过窗户向外看。		消极	悲伤	宁静

图 3.2 MSED 数据集样本结构示例

3.5 实验与分析

3.5.1 数据集划分

为了支持模型训练与测试，将对数据集进行划分。首先随机打乱 MSED 数据集中所有样本的顺序，再将它们按照 70%、10%和 20%的比例分别划分为训练集、验证集

和测试集。表 3.3 展示了 MSED 数据集各个子集的样本数量以及各个任务标签在不同子集中的数量。

表 3.3 MSED 数据集各类别统计数据

任务	标签	训练集	验证集	测试集
情感分类	积极	2,524	419	860
	中性	1,664	294	569
	消极	1,939	308	613
情绪识别	幸福	2,524	419	860
	中立	1,664	294	569
	悲伤	666	102	186
	厌恶	251	44	80
	愤怒	523	78	172
	恐惧	499	84	175
欲望检测	复仇	277	39	75
	好奇	634	118	213
	社交	437	59	138
	家庭	873	152	288
	宁静	245	39	87
	浪漫	692	107	210
	无欲望	2,969	507	1,031

3.5.2 实验设置

评价指标：采用精确率（Precision, P）、召回率（Recall, R）和 macro-F1 (M_a-F1) 作为本章实验的评价指标。

模型架构：使用一系列基线模型作为不同模态输入的编码器，并使用不同的组合方式来实现模态之间的信息融合交互，如图 3.3 所示。

对于文本模态，使用了三种经典的基线模型作为编码器，即：TextCNN^[94]、双向 LSTM（bidirectional LSTM, BiLSTM）以及预训练语言模型 BERT。对于图像模态，使用两种传统的视觉基线模型作为编码器：AlexNet 和 ResNet。通过编码器得到每个模态的特征向量后，使用多头注意力机制来实现多模态信息的交互，并将其融合为一

个多模态特征向量表示。这个多模态特征向量表示将被分别输入至三个线性层，这三个线性层将分别用于预测情感分类任务、情绪识别任务以及欲望检测任务。最后使用 Softmax 函数来获得模型对样本在不同任务上的预测概率。除此之外，本研究还使用了 Multimodal Transformer^[95]作为多模态的基线模型进行实验。




图 3.3 基线模型架构图（输入示例来自 MSSED 数据集）

3.5.3 实验结果与讨论

实验结果如表 3.4 所示，分为单模态的实验与多模态的实验。单模态的实验使用文本编码器（TextCNN、BiLSTM 和 BERT）或图像编码器（AlexNet 和 ResNet）。多模态的实验两两组合不同模态的编码器进行，此外还使用了 Multimodal Transformer。

可以观察到，对于单模态的文本编码器，TextCNN 在三种任务种表现的结果都最不好，并且分别在情感分类、情绪识别和欲望检测任务上得到了最低的 M_a -F1 分数：51.19%、41.60%和 29.55%。通过建模双向上下文信息，BiLSTM 相比于 TextCNN 明显有所提升。而 BERT 因为其出色的语义表示能力，在所有指标上都优于 TextCNN 和 BiLSTM，并且拉开了巨大差距。对于单模态的图像编码器，总体上 ResNet 表现优于 AlexNet，因为它通过残差连接解决了梯度消失问题并加强了输入信号。对于多模态的实验，BERT+ResNet 的组合达到了最佳的 M_a -F1 分数：83.52%、81.95%和 82.28%，相比于文本编码器的 BERT 分别提升了 0.48%、1.05%和 1.73%，相比于图像编码器的 ResNet 分别提升了 18.23%、45.30%和 67.24%，说明了多模态学习的重要性。

接下来将通过分析 BERT+ResNet 组合模型中两个编码器的有效性来探明哪一种模态的贡献更大。比较单模态文本分类的 BERT 模型表现和单模态图像分类的 ResNet 模型表现后，可知文本特征对于情感分析帮助更大，主要原因有：（1）BERT 在整个模型框架中贡献最多，它能有效捕捉文字之间的相互依存关系并挖掘出精炼的特征向

量；（2）文本信息的利用相比于图像信息更加便捷，因为图像包含了更抽象的高维度信息，难以捕获。但是 ResNet 仍旧优于 TextCNN 和 BiLSTM 这两种单模态文本分类模型，证明了视觉模型的有效性。

表 3.4 不同模型的实验结果比较

模态	文本编码器	图像编码器	情感分类			情绪识别			欲望检测		
			P	R	M _a -F1	P	R	M _a -F1	P	R	M _a -F1
文本	TextCNN	-	59.31	53.01	51.19	43.66	41.10	41.60	36.91	31.64	29.55
	BiLSTM	-	78.43	78.75	78.58	73.49	72.17	72.73	73.20	67.82	69.14
	BERT	-	83.26	83.00	83.12	81.76	80.57	81.10	81.74	80.39	80.88
图像	-	AlexNet	68.76	68.21	68.45	56.42	53.29	54.66	51.47	49.33	50.07
	-	ResNet	70.85	70.61	70.64	58.74	54.67	56.40	49.97	49.35	49.20
多模态	TextCNN	AlexNet	71.02	70.09	70.31	49.56	42.77	43.76	59.42	52.02	52.35
	TextCNN	ResNet	74.73	74.73	74.64	62.93	59.12	60.48	56.34	50.64	52.89
	BiLSTM	AlexNet	78.73	79.22	78.89	71.17	70.70	70.89	67.80	68.00	67.67
	BiLSTM	ResNet	75.89	75.27	75.25	63.63	60.80	61.98	54.97	49.94	51.99
	BERT	AlexNet	83.22	83.11	83.16	78.06	78.19	78.10	80.84	75.50	77.17
	BERT	ResNet	83.45	83.60	83.52	82.82	81.27	81.95	83.42	82.43	82.28
	Multimodal Transformer		83.56	83.45	83.50	81.62	81.61	81.53	81.92	80.20	80.92

3.5.4 人类实验结果

本小节实验从 MSED 数据集的测试集中随机挑选出了 50 个样本作为新的测试集，并招募了三名本科生志愿者来对新测试集中样本的情感、情绪与欲望分类。BERT+ResNet 组合模型作为上一小节表现最好的模型也在新测试集上进行测试，并作为机器实验结果与人类实验结果比较。实验结果如表 3.5 所示。

表 3.5 人类实验结果与机器实验结果的比较

实验对象	情感分类	情绪识别	欲望检测
志愿者 1	90.00	86.00	88.00
志愿者 2	88.00	86.00	84.00
志愿者 3	88.00	82.00	84.00
人类平均分数	88.67	84.67	85.33
BERT+ResNet	86.00	82.00	82.00

从实验结果我们可以看出虽然 BERT+ResNet 组合模型在所有基线模型中达到了最好的 M_a -F1 分数，但是它仍旧不及人类平均分数的水平。一个可能的原因在于特征融合时由于信息交互的不充分，在获得多模态特征向量表示时丢失了一些信息。而人类则可以在阅读文字和观察图片后，充分综合这两类信息，并根据一个任务的预测结果来推断另一个任务的预测结果。这就表明了 MSED 数据集对于促进情感分析方法融合跨任务跨模态信息交互的研究具有应用价值。

3.6 本章小结

适用于融合跨任务跨模态信息交互的情感分析方法研究的数据集仍然稀缺。为了解决该问题，本研究构建了 MSED 数据集，该数据集每个样本由文本和图像两种模态所组成，并且带有情感分类、情绪识别以及欲望检测三类任务的标签，既可以应用于多模态学习又可以应用到多任务学习。MSED 数据集是学术界首个可以同时满足情感分类、情绪识别以及欲望检测三种任务的多模态数据集，旨在促进融合跨任务跨模态信息的情感分析方法的研究。模型可以通过 MSED 数据集学习到不同任务在人类心理层面的深层关联，也可学习不同模态之间的相互联系，并通过跨任务信息以及跨模态信息在各个任务上达到更好的表现。并且 MSED 数据集的样本来源于社交媒体用户的真情实感，模型学习到的知识也可以更贴近现实生活。该数据集的数据通过网络爬虫技术在社交媒体上获取，并设置了一系列筛选条件和清洗策略来保证数据的清洁性与完整性。在标签设置方面，情感分类任务包含有积极、中性以及消极三类标签，情绪识别任务包含有幸福、中性、愤怒、厌恶、恐惧以及悲伤六种标签；欲望检测任务包含有家庭、浪漫、复仇、好奇、宁静、社交以及无欲望七种标签。在样本标注过程中，先指导志愿者练习以消除歧义，再在正式标注过程中通过投票机制获取样本最终标签。本研究还使用了一系列基线模型在 MSED 数据集上进行了测试，实验结果表明文本特征在情感分析任务中贡献更大。此外，机器实验结果与人类实验结果的比较表明，机器模型距离人类还有一定差距，需要新的模型来促进跨任务信息以及跨模态信息的交互，MSED 数据集具有促进此类研究发展的应用价值。

第 4 章 基于跨任务信息交互的情感分析方法

4.1 引言

在上一章中所使用的实验方法对每个任务进行单独分类，并未考虑到跨任务信息之间的交互。然而在情感分析领域中，情感分类任务和情绪识别任务是两个密切相关的任务。情感反映人类深刻而长期的主观体验和心理态度，情绪是对外部刺激的短暂但强烈的生理反应。情感往往是很长一段时间内形成的，而情绪则可以瞬时出现。虽然情感与情绪存在上述差异，但它们同时也是相互依存的。稳定的情感根植于情绪并通过情绪表达出来，情绪的变化也由情感所主导，情感与情绪之间也存在着共性。因此可以通过设计一个多任务学习框架来同时解决情感分类任务和情绪识别任务，模型可以通过跨任务信息交互来学习任务之间的共性与差异，从而提高其分类准确性。图 4.1 举了两个例子以展示情感与情绪信息可以互相帮助以提升分类准确性。第一句话通过标红的词汇，比如气愤（mad）、失望（disappointed）和糟糕（terrible），表明说话人对演员的表演和电影的质量难以忍受，从而可以直接判别出说话人此时的情绪应为愤怒。因此，该说话人的情感可由其愤怒情绪推断为消极。同样对于第二句话，通过标黄的词汇可以表达出说话者对于制作视频的积极情感，由此也可推断出说话人幸福的情绪。从上述两个例子可以看出情感与情绪确实关系密切。

序号	语句	情感	情绪
1	It just makes me mad because the actor really disappointed me, and the movie is terrible .	消极	愤怒
2	That's crazy and amazing and i'm just so happy and overwhelmed and excited to make more videos.	积极	幸福

图 4.1 情感与情绪信息可以互相帮助以提升分类准确性的两个例子（来自 CMU-MOSEI 数据集）

然而这两个任务经常被当成两个独立的任务来对待，却忽视了它们之间的共性与联系。为了解决此问题，本研究提出了一个基于跨任务信息交互的情感分析方法——带有位置编码的多任务交互式图注意力网络（Multi-Task Interactive Graph Attention Network with Position Encodings, MIP-GAT）。该方法以文本为输入，并通过一个统一的多任务学习框架保证了跨任务信息交互。此外，它还通过图结构构建了语义依存信息交互，通过位置编码加入了时序信息交互。通过将跨任务信息、语义依存信息和

时序信息这三个关键信息的交互整合到一个统一的图学习框架，可以实现多种信息之间的高效交互与协同，这对于推进情感分类与情绪识别任务的联合学习至关重要。

4.2 带有位置编码的多任务交互式图注意力网络

本小节将具体介绍 MIP-GAT，其模型架构如图 4.2 所示。MIP-GAT 主要由四个核心部件组成，分别为：任务特定编码器（Task-Specific Encoder）、多交互图层（Multi-Interactive Graph Layer）以及两个独立的解码器（Decoder），这两个解码器将分别应用于情感分类以及情绪识别任务。在接下来的小节中，这些核心部件将被逐一介绍。




图 4.2 带有位置编码的多任务交互式图注意力网络模型架构

4.2.1 问题描述

假设数据集中有 N 个样本，第 i 个样本 X_i 可被表示为 $X_i = (T_i, Y_i^A)$ ，其中 T_i 表示第 i 个样本所对应的文字内容， Y_i^A 代表第 i 个样本的情感标签或情绪标签， $A \in \{s, e\}$ ， s 代表情感， e 代表情绪， $i \in \{1, 2, \dots, N\}$ 。

本章的研究问题从而可以描述为：对于给定的文本，如何利用情感与情绪之间的跨任务信息来同时预测这两种任务的结果？该问题可被形式化表示为：

$$\xi = \prod_i p(Y_i^s, Y_i^e | T_i, \mathcal{G}_{s,e}, \Theta), \quad (4.1)$$

其中 $\mathcal{G}_{s,e}$ 代表包含情感与情绪跨任务信息交互的图， Θ 代表模型参数。

4.2.2 任务特定编码器

任务特定编码器首先使用 WordPiece 算法将文本词汇为多个词元（Token），假设第 i 个样本的文字内容 T_i 包含有 M 个词元，则 $T_i = [w_i^1, w_i^2, \dots, w_i^k, \dots, w_i^M] \in \mathbb{R}^{1 \times M}$ ，其中

w_i^k 代表第 k 个词元, $k \in \{1, 2, \dots, M\}$ 。之后, 使用两个预训练语言模型 BERT 来获得每个词元分别在情感分类任务和情绪识别任务上的任务特定词嵌入向量, 即 $S_i^0 = [s_i^{1,0}; s_i^{2,0}; \dots; s_i^{k,0}; \dots; s_i^{M,0}]$, $E_i^0 = [e_i^{1,0}; e_i^{2,0}; \dots; e_i^{k,0}; \dots; e_i^{M,0}]$, 其中 $S_i^0, E_i^0 \in \mathbb{R}^{M \times d}$, $s_i^{k,0}, e_i^{k,0} \in \mathbb{R}^{1 \times d}$, 符号“;”代表纵向拼接, d 代表特征向量维度, 0代表它们是多交互图层的初始化向量。词嵌入过程可被写为:

$$S_i^0 = BERT_s(T_i), \quad (4.2)$$

$$E_i^0 = BERT_e(T_i), \quad (4.3)$$

其中 $BERT_s$ 和 $BERT_e$ 分别代表特定用于情感分类任务和情绪识别任务的两个 BERT 模型。

4.2.3 多交互图层

本研究使用图注意力网络来实现多交互图层, MIP-GAT 的多交互图层堆叠了多层图注意力网络。每层图注意力网络都是一张包含节点和边的有向图, 可被表示为:

$$\mathcal{G} = (\mathcal{V}, \mathcal{E}, \mathcal{W}), \quad (4.4)$$

其中节点 $v_k \in \mathcal{V}$, 边 $\overrightarrow{v_k, v_j} \in \mathcal{E}$, $\alpha_{k,j} \in \mathcal{W}$ 是边 $\overrightarrow{v_k, v_j}$ 的权重, 并且满足 $0 \leq \alpha_{k,j} \leq 1$ 。

多交互图层的每一层对于第 i 个样本构建两个子图, 分别用于情感分类和情绪识别任务。MIP-GAT 旨在依靠图中的跨任务连接、语义依存连接以及位置编码来综合利用跨任务信息、语义依存信息以及时序信息的交互。对图的构建过程描述如下。

节点: 第 i 个样本包含有 M 个词元, 每个词元可以当作图中的一个节点, 即 $w_i^k \in \mathcal{V}$ 。在每一层的图结构中一共有 $2M$ 个节点, 其中 M 个节点属于情感分类子图, 另外 M 个节点属于情绪识别子图。情感分类的节点和情绪识别的节点分别被对应的任务特定编码器输出的词向量所初始化, 即 S_i^0 和 E_i^0 。因此我们可以获得图中所有节点的初始向量序列 $H_i^0 = [S_i^0; E_i^0] = [s_i^{1,0}; \dots; s_i^{M,0}; e_i^{1,0}; \dots; e_i^{M,0}] \in \mathbb{R}^{2M \times d}$ 。

边: 在多交互图层中构建了两种边的连接, 分别是语义依存连接和跨任务连接。

(1) 语义依存连接: 在语义依存连接中每个节点 w_i^k 应该连接至所有与其存在语义依存关系的其它节点, 这个连接为双向连接。为了建立语义依存连接, 首先使用 spaCy^[96] 工具包获得文本 T_i 的语义依存树。之后为了平衡计算成本与计算效率, 将设置一个大小为 D 的上下文窗口, 而不是将节点连接至其在语义依存树中的所有邻居节点。将图的邻接矩阵表示为 $A \in \mathbb{R}^{2M \times 2M}$, 若 w_i^k 和 w_i^j 在语义依存树中的距离不大于上下文窗口大小 D , 则 $A_{k,j} = 1$ 且 $A_{j,k} = 1$ 。需要注意的是, w_i^k 和 w_i^j 应同属于一个子图。

图 4.3 是一个语义依存连接的例子，图 4.3 (a) 是一棵语义依存树，图 4.3 (b) 和图 4.3 (c) 是节点 s_6 在不同上下文窗口大小下的语义依存连接。当上文窗口大小 $D = 1$ 时，节点 s_6 与其在语义依存树中的所有一跳邻居连接，即节点 s_3 、 s_8 和 s_9 。当上文窗口大小 $D = 2$ 时，节点 s_6 还将与其所有二跳邻居连接，即节点 s_1 和 s_5 。




图 4.3 语义依存连接示例

为了避免丢失全局上下文信息，还为每个子图额外设置了一个全局节点，子图中的所有节点都应连接至全局节点，本研究选择语义依存树的根节点作为全局节点。若 w_i^k 和 w_i^g 同属于一个子图，且 w_i^g 是全局节点，则 $A_{k,g} = 1$ 且 $A_{g,k} = 1$ 。




图 4.4 跨任务连接示例

(2) 跨任务连接：为了共享两个相互关联的任务之间的信息并使之充分交互，本研究建立了跨任务连接。不同子图中对应同一个词元的节点将会相互连接，此外还会根据上下文窗口大小 D 连接至对方的邻居节点，比如情感分类任务子图中第 k 个节点 s_i^k

将连接至情绪识别任务子图中的第 k 个节点 e_i^k ，以及所有与 e_i^k 距离不大于 D 的情绪识别任务子图节点。即当 w_i^k 和 w_i^j 在语义依存树中的距离不大于上下文窗口大小 D ，且 w_i^k 和 w_i^j 不同属于一个子图时，则 $A_{k,j} = 1$ 且 $A_{j,k} = 1$ 。如图 4.4 所示，当 $D = 2$ 时，节点 s_6 连接至了图 4.3 (c) 中所有节点在另一子图所对应的节点（语义依存树与图 4.3 相同）。

边的权重：本研究使用图注意力网络 GAT 的计算方法来获得节点之间边的权重。GAT 以图作为输入，使用一个参数可学习的非线性变换和多头注意力机制对每一层节点的向量表示进行更新。经过 L 层更新可以得到信息聚合程度更高的向量表示作为输出，即 $S_i^L = [s_i^{1,L}; s_i^{2,L}; \dots; s_i^{M,L}]$ 与 $E_i^L = [e_i^{1,L}; e_i^{2,L}; \dots; e_i^{M,L}]$ 。第 i 个样本在第 l 层第 k 个情感分类任务子图节点 $s_i^{k,l}$ 的更新过程如下：

$$s_i^{k,l} = \left(W^{l-1} \parallel \sigma \left(\sum_{r \in \mathcal{N}_k} \alpha_{i,h}^{k,r,l-1} W_h^{l-1} (s_i^{r,l-1})^\top \right) \right)^\top, \quad (4.5)$$

$$\alpha_{i,h}^{k,r,l-1} = \frac{\exp \left(\text{LeakyReLU} \left(\bar{a}_h^{l-1} \left[W_h^{l-1} (s_i^{k,l-1})^\top \parallel W_h^{l-1} (s_i^{r,l-1})^\top \right] \right) \right)}{\sum_{q \in \mathcal{N}_k} \exp \left(\text{LeakyReLU} \left(\bar{a}_h^{l-1} \left[W_h^{l-1} (s_i^{k,l-1})^\top \parallel W_h^{l-1} (s_i^{q,l-1})^\top \right] \right) \right)}, \quad (4.6)$$

其中 $l \in \{1, 2, \dots, L\}$ ， H 是多头注意力机制中头的数量， h 代表第 h 个头， $h \in \{1, 2, \dots, H\}$ ， $\parallel$ 代表纵向拼接操作， σ 代表非线性激活函数， $\top$ 代表转置， $\mathcal{N}_k$ 是第 k 个节点的邻居节点集合， $\alpha_{i,h}^{k,r,l-1}$ 是节点向量 $s_i^{k,l-1}$ 和其邻居节点向量 $s_i^{r,l-1}$ 在第 $l-1$ 层第 h 个头的注意力分数， $W^{l-1} \in \mathbb{R}^{d \times Hd}$ 和 $W_h^{l-1} \in \mathbb{R}^{d \times d}$ 是可训练的线性变换参数， $\bar{a}_h^{l-1} \in \mathbb{R}^{1 \times 2d}$ 是第 $l-1$ 层第 h 个头中可训练的注意力向量参数。同样地，情绪识别任务子图节点的向量表示也可由式（4.5）和式（4.6）进行更新计算。


位置编码：标准的 GAT 并未考虑序列信息，因此本研究将使用位置编码来获取时序信息。在第 i 个样本中，若 $j > k$ ，则第 j 个词元 w_i^j 和第 k 个词元 w_i^k 的相对距离为 $j - k$ 。根据相对距离，本研究提出了一种相对位置编码：

$$RP_{kj} = \begin{cases} \max(-t, j - k), & j < k \\ \max(-u, k - j), & j > k \end{cases} \quad (4.7)$$

其中 RP_{kj} 代表 w_i^j 相对 w_i^k 的位置编码，前序窗口大小设置为 t ，后序窗口大小设置为 u ，用于限制位置编码的大小。图 4.5 展示了当 $t = 2$ ， $u = 3$ 时的相对位置编码数值。

加入了位置编码后，式（4.6）将会被修改为：

$$\alpha_{i,h}^{k,r,l-1} = \frac{\exp \left(\text{LeakyReLU} \left(\bar{a}_h^{l-1} \left[W_h^{l-1} (s_i^{k,l-1})^\top \parallel W_h^{l-1} (s_i^{r,l-1})^\top \right] + RP_{kr} \right) \right)}{\sum_{q \in \mathcal{N}_k} \exp \left(\text{LeakyReLU} \left(\bar{a}_h^{l-1} \left[W_h^{l-1} (s_i^{k,l-1})^\top \parallel W_h^{l-1} (s_i^{q,l-1})^\top \right] + RP_{kq} \right) \right)}. \quad (4.8)$$

图 4.5 $t = 2, u = 3$ 时的相对位置编码

对比第 3.5.2 小节基线模型的方法隐式使用跨任务信息, 本方法使用多交互图层显式地建模了跨任务信息、语义依存信息以及时序信息的交互过程, 提示了模型这些信息交互的重要性。

4.2.4 解码器

在经过 L 层的更新后, 将会得到每个词元对于情感分类任务和情绪识别任务的最终向量表示 $H_i^L = [S_i^L; E_i^L] = [s_i^{1,L}; s_i^{2,L}; \dots; s_i^{M,L}; e_i^{1,L}; e_i^{2,L}; \dots; e_i^{M,L}] \in \mathbb{R}^{2M \times d}$ 。之后使用两个 BiLSTM 来学习如何获取整个文本的向量表示, 该过程可被形式化为:

$$S_i = \text{BiLSTM}_s(S_i^L), \quad (4.9)$$

$$E_i = \text{BiLSTM}_e(E_i^L), \quad (4.10)$$

其中 BiLSTM_s 和 BiLSTM_e 分别用于情感分类任务和情绪识别任务的 BiLSTM 模型, $S_i, E_i \in \mathbb{R}^{2d}$ 。

最后, 将 S_i 和 E_i 分别输入至两个独立的线性层, 并使用 Softmax 函数获取最终的预测分布:

$$\hat{y}_i^s = \text{softmax}(W^s S_i + b^s), \quad (4.11)$$

$$\hat{y}_i^e = \text{softmax}(W^e E_i + b^e), \quad (4.12)$$

其中 $\hat{y}_i^s, \hat{y}_i^e \in \mathbb{R}^V$ 分别为对样本情感标签和情绪标签的预测分布, V 代表词表长度, $W^s, W^e \in \mathbb{R}^{V \times 2d}$ 是线性变换参数, $b^s, b^e \in \mathbb{R}^V$ 是偏置。

4.2.5 模型训练

在获得第 i 个样本的情感标签和情绪标签预测分布 $\hat{y}_i^s$ 和 $\hat{y}_i^e$ 后, 分别将其与真实分布进行交叉熵运算并相加以获得最终的损失函数 ζ :

$$\zeta \triangleq - \sum_i \sum_n y_i^{s,n} \log \hat{y}_i^{s,n} - \sum_i \sum_n y_i^{e,n} \log \hat{y}_i^{e,n}, \quad (4.13)$$

其中 $y_i^s, y_i^e \in \mathbb{R}^V$ 分别代表样本情感标签和情绪标签的真实分布, n 代表取向量第 n 维的

数值, $n \in \{1, 2, \dots, V\}$ 。

使用损失函数 ζ 作为 MIP-GAT 模型的训练目标, 可以同时减少模型在情感分类和情绪识别两个任务上的损失。在计算出模型损失后, 使用反向传播算法计算出模型参数的梯度, 使用 Adam 算法^[97]根据梯度更新模型参数, 并使用 ReduceLROnPlateau 策略动态调整学习率。重复上述过程直至训练达到最大轮次或模型收敛。

4.3 实验与分析

4.3.1 实验设置

数据集: 本章研究将在三个数据集上进行实验: CMU-MOSEI 数据集、GoEmotions 数据集^[98]和 MSED 数据集。这三个数据集的详细统计数据如表 4.1 所示。

表 4.1 数据集统计数据

标签		CMU-MOSEI			GoEmotions			MSED		
		训练集	验证集	测试集	训练集	验证集	测试集	训练集	验证集	测试集
情感	积极	8,050	932	2,287	3,633	459	445	2,524	419	860
	中立	3,538	433	1,025	21,952	2,747	2,741	1,664	294	569
	消极	4,739	506	1,350	8,049	998	1,018	1,939	308	613
情绪	幸福	7,789	866	2,229	-	-	-	2,524	419	860
	开心	-	-	-	3,633	459	445	-	-	-
	中立	2,391	302	702	21,952	2,747	2,741	1,664	294	569
	悲伤	2,679	349	703	2,358	310	315	666	102	186
	愤怒	1,911	188	595	2,883	368	356	523	78	172
	恐惧	311	40	99	1,035	117	138	499	84	175
	厌恶	945	88	245	1,773	203	209	251	44	80
	惊讶	301	38	89	-	-	-	-	-	-

CMU-MOSEI 数据集从超过 1000 个来自 YouTube 的影评视频收集了 23453 条语句。每条语句都被同时包含情感和情绪标签。情感标签是范围从-3（非常消极）到 3（非常积极）的分数。情绪标签包含六种基本情绪, 分别为开心(Joy)、悲伤(Sadness)、愤怒(Anger)、恐惧(Fear)、厌恶(Disgust)和惊讶(Surprise)。GoEmotions 数据集从 Reddit 上收集了 58009 条评论, 标签由 28 种极细粒度的情绪所组成。本研究

从中选择了六种基本情绪，即开心（Joy）、中立（Neutral）、愤怒（Anger）、厌恶（Disgust）、恐惧（Fear）和悲伤（Sadness）。由于 GoEmotions 数据集只有情绪标签，本研究为其每个样本自动标注情感标签，规则为：开心情绪标注为积极情感，中立情绪标注为中立情感，其余情绪标注为消极情感。MSD 数据集包含 9190 条多模态样本。情感标签为积极、中立与消极三种。情绪标签为愤怒（Anger）、厌恶（Disgust）、恐惧（Fear）、幸福（Happiness）、中立（Neutral）、悲伤（Sadness）和惊讶（Surprise）六种。

评价指标：采用精确率（Precision, P）、召回率（Recall, R）和 macro-F1 (M_a -F1) 作为评价指标。

超参设置：所有词元使用 BERT 进行词向量嵌入。所有实验都在 NVIDIA RTX A6000 显卡上进行。详细的超参设置列在了表 4.2 中。

表 4.2 模型超参设置

超参	CMU-MOSEI	GoEmotions	MSD
词嵌入向量维度	768	768	768
激活函数	LeakyReLU	LeakyReLU	LeakyReLU
批量大小	16	16	16
学习率	5×10^{-6}	5×10^{-6}	1×10^{-5}
训练轮数	50	30	10
Dropout 率	0.5	0.2	0.2
层数	3	3	3
上下文窗口大小	4	4	4
位置编码前序窗口大小	10	10	10
位置编码后序窗口大小	10	10	10

4.3.2 基线模型

为了验证 MIP-GAT 模型的有效性，本研究将之与一系列基线模型进行了比较：

TextCNN 使用两层卷积层和一个全连接层来抽取文本特征，Dropout 率设置为 0.5，学习率设置为 1×10^{-3} ；

BiGRU+Att^[99] 使用 BiGRU 来抽取每个词元的历史和未来上下文特征，并采用 CNN 抽取每个词元所在位置的局部上下文特征，之后使用注意力机制根据历史、未

来以及局部上下文的特征向量计算出词元的向量表示,最后将所有词元的向量序列输入至 LSTM 以获得整个句子的向量表示,Dropout 率设置为 0.5,学习率设置为 1×10^{-3} ;

GCN 使用 GloVe^[100]作为词向量嵌入,并将语义依存树输入至卷积图神经网络,学习率设置为 3×10^{-7} ;

GAT 使用 GloVe 作为词向量嵌入,并将语义依存树输入至标准的图注意力网络,学习率设置为 5×10^{-6} ;

SVM+BERT 使用 BERT 获得词嵌入向量并使用支持向量机来对向量进行分类,学习率设置为 1×10^{-3} ,批量大小为 16;

BiSGRU+MSA^[101]使用双向 SGRU^[102]和多头自注意力(Multi-Head Self-Attention, MSA)机制来进行文本分类,学习率设置为 1×10^{-5} ;

AMM-MTL^[103]是一个基于注意力的多任务模型,用于同时分类情感与情绪,学习率设置为 5×10^{-7} 。

4.3.3 实验结果与分析

实验结果如表 4.3 所示,所有基线被分为三类:经典深度学习框架、图神经网络框架和预训练语言模型框架。

在 CMU-MOSEI 数据集中,根据 M_a -F1 分数图神经网络的表现最不好。GAT 和 GCN 表现不好的一个主要可能原因在于它们只关注了语义依存信息,从而导致上下文信息交互不足。SVM+BERT 的 M_a -F1 分数在情感分类任务上稍优于 GAT 而稍逊于 GCN,在情绪识别任务上均优于两个图神经网络,这归功于 BERT 可以获得语义信息更加丰富的词嵌入向量。然而它仍然弱于 TextCNN 和 BiGRU+Att。这可能是由于 SVM 无法很好应对多分类问题,且深度学习模型能更好地考虑上下文信息。BiSGRU+MSA 比上述所有模型表现更好,这得益于预训练语言模型和 MSA 机制的应用。在所有基线模型中,AMM-MTL 达到了最高的 M_a -F1 分数。相较于 BiSGRU+MSA, AMM-MTL 融合了不同任务的信息交互,这种跨任务信息交互帮助了 AMM-MTL 得到了性能上的优势。而本研究提出的 MIP-GAT 模型在情感分类和情绪识别两类任务的 M_a -F1 分数分别达到了 62.74%和 24.86%,超越了所有的基线模型。它相比于 AMM-MTL 分别提升了 2.88%和 7.67%,这证明了带有位置编码的多任务学习框架的有效性。表现最优的三个模型(即 BiSGRU+MSA、AMM-MTL 和 MIP-GAT)的结果如图 4.6 所展示。

表 4.3 不同模型的实验结果

数据集	模型	情感分类			情绪识别		
		P	R	M _a -F1	P	R	M _a -F1
CMU-MOSEI	TextCNN	56.01	50.99	49.54	20.36	16.00	13.44
	BiGRU+Att	55.28	52.81	51.89	24.74	15.66	11.93
	GCN	60.13	48.83	45.38	13.98	14.29	9.32
	GAT	55.60	45.62	41.69	24.89	14.40	9.53
	SVM+BERT	55.37	46.97	43.58	19.14	15.17	11.09
	BiSGRU+MSA	64.49	61.69	62.52	26.29	21.52	21.62
	AMM-MTL	62.70	62.48	62.56	25.75	23.21	23.09
	MIP-GAT	63.54	62.80	62.74	27.91	24.91	24.86
GoEmotions	TextCNN	66.69	54.68	58.16	32.98	25.67	26.75
	BiGRU+Att	66.75	58.94	61.79	37.95	28.47	29.98
	GCN	68.28	63.45	65.46	56.32	45.88	49.95
	GAT	67.29	60.39	63.04	54.60	38.78	43.71
	SVM+BERT	61.30	56.85	58.35	54.06	30.33	32.81
	BiSGRU+MSA	67.89	68.27	68.06	51.72	51.12	51.41
	AMM-MTL	67.53	68.74	68.09	53.06	52.89	52.90
	MIP-GAT	70.84	67.10	68.76	56.44	51.73	53.79
MSED	TextCNN	74.58	74.79	74.67	46.34	42.04	41.23
	BiGRU+Att	78.55	79.02	78.73	59.22	57.63	58.21
	GCN	79.08	79.31	79.19	72.58	72.49	72.48
	GAT	79.13	79.42	79.22	72.34	71.80	71.94
	SVM+BERT	67.46	66.49	66.53	61.87	49.91	52.40
	BiSGRU+MSA	83.53	82.42	82.98	80.05	79.73	79.50
	AMM-MTL	83.08	81.97	82.38	80.16	78.14	78.65
	MIP-GAT	83.69	83.74	83.71	80.88	80.80	80.82

在 GoEmotions 数据集中，所有模型相较于在 CMU-MOSEI 数据集中的表现都明显变好。其原因最有可能在于 GoEmotions 数据集的训练集大小相较于 CMU-MOSEI 数据集的训练集明显增加，因此在某种程度上减少了过拟合问题。两个图神经网络框

架模型表现优于 TextCNN、BiGRU+Att 和 SVM+BERT，这证明了图学习的有效性。与 CMU-MOSEI 数据集的实验结果一致，AMM-MTL 和 BiSGRU+MSA 在所有基线模型中分别达到了第一和第二高的 M_a -F1 分数。MIP-GAT 在 GoEmotions 数据集中同样证明了其优越性，超过了表现最好的基线模型 AMM-MTL，分别提升了 0.98%和 1.68%。

同样地，在 MSED 数据集中 MIP-GAT 的表现在两个任务上也同样超越了所有的基线模型，且相比于最好的 BiSGRU+MSA 分别提升了 0.88%和 1.66%，这归功于以下三点：（1）使用跨任务连接帮助不同任务之间的跨任务信息交互；（2）使用语义依存连接促进语义信息交互以帮助模型理解文本；（3）使用位置编码弥补图神经网络所缺少的时序信息交互。




图 4.6 CMU-MOSEI 数据集上表现最优的三个模型效果展示

4.3.4 消融实验

本小节将探究 MIP-GAT 四种结构（跨任务连接、全局连接、图结构以及位置编码）对其性能表现的贡献进行探究。因此本小节修改了 MIP-GAT 的结构，得到四种变体进行消融实验：（1）无跨任务连接：去除了多交互图层中的所有跨任务连接；（2）无全局连接：去除了所有与全局节点的连接；（3）无图结构：去除了 MIP-GAT 的多交互图层；（4）无位置编码：去除了位置编码。

实验结果如表 4.4 所示。可以注意到无图结构模型的表现下降得最多，说明 MIP-GAT 模型中图结构的贡献是最大的。在去除多交互图层后，CMU-MOSEI 数据集的情感分类任务 M_a -F1 分数下降了 1.77%，情绪识别任务 M_a -F1 分数下降了 12.07%，GoEmotions 数据集的情感分类任务 M_a -F1 分数下降了 5.00%，情绪识别任务 M_a -F1 分数下降了 11.64%，MSED 数据集的情感分类任务 M_a -F1 分数下降了 1.09%，情绪识别任务 M_a -F1 分数下降了 2.05%。跨任务连接是第二重要的结构，MIP-GAT 在失去跨

任务连接后,其性能表现在 CMU-MOSEI 数据集的情感分类和情绪识别任务上分别下降了 4.40%和 5.79%,在 GoEmotions 数据集分别下降了 3.87%和 6.88%,在 MSED 数据集分别下降了 0.96%和 2.08%。因此消融实验证明了 MIP-GAT 最得益于其图结构和跨任务连接,跨任务信息交互可以同时帮助两种相关联的任务提升分类准确性。

表 4.4 消融实验结果

数据集	模型	情感分类		情绪识别	
		P	M _a -F1	P	M _a -F1
CMU-MOSEI	无跨任务连接	62.35	59.98	25.32	23.42
	无全局连接	62.91	61.05	31.64	23.78
	无位置编码	62.46	60.60	26.00	22.43
	无图结构	63.25	61.63	24.93	21.86
	MIP-GAT	63.54	62.74	27.91	24.86
GoEmotions	无跨任务连接	68.95	66.10	53.02	50.09
	无全局连接	67.82	66.72	55.21	50.62
	无位置编码	69.84	66.89	55.19	50.36
	无图结构	67.82	65.32	54.71	47.53
	MIP-GAT	70.84	68.76	56.44	53.79
MSED	无跨任务连接	83.07	82.91	79.57	79.14
	无全局连接	82.97	82.99	79.89	79.83
	无位置编码	83.09	83.09	79.64	79.62
	无图结构	82.71	82.80	79.08	79.16
	MIP-GAT	83.69	83.71	80.88	80.82

4.3.5 上下文窗口大小对模型效果的影响

本小节将探索不同的上下文窗口大小对 MIP-GAT 的表现效果的影响。模型默认的上下文窗口大小 D 为 4。为了找出合适的上下文窗口大小,本小节将 D 分别设置为 1、2、3、4 和 ∞ ,当 $D = \infty$ 时说明每个节点将与同一子图中所有其它节点相连接。实验结果如表 4.5 所示。

除 $D = \infty$ 外, MIP-GAT 的表现总体上随着上下文窗口的增大而上升,这说明了在

一定程度上扩大上下文窗口可以帮助模型提升性能。当 $D = 1$ 时 MIP-GAT 的表现效果最不好, 而当 $D = 4$ 时在两个数据集上都达到了最高的 M_a -F1 分数, 证明增加上下文信息的交互可以有效帮助模型提高分类准确性。而当 $D = \infty$ 时表现下降, CMU-MOSEI 数据集的情感分类任务 M_a -F1 分数下降了 1.42%, 情绪识别任务 M_a -F1 分数下降了 1.45%, GoEmotions 数据集的情感分类任务 M_a -F1 分数下降了 1.19%, 情绪识别任务 M_a -F1 分数下降了 5.24%, MSSED 数据集的情感分类任务 M_a -F1 分数下降了 0.80%, 情绪识别任务 M_a -F1 分数下降了 1.66%。这很可能是因为当节点连接了所有其它节点后, 本来距离较远的无关信息影响了特征提取, 反而导致模型效果变差。

表 4.5 改变上下文窗口大小的实验结果

数据集	上下文窗口大小	情感分类		情绪识别	
		P	M_a -F1	P	M_a -F1
CMU-MOSEI	$D = 1$	62.65	61.33	29.89	23.88
	$D = 2$	62.28	59.78	25.82	23.03
	$D = 3$	62.81	61.29	30.52	23.37
	$D = 4$	63.54	62.74	27.91	24.86
	$D = \infty$	62.87	61.85	26.60	24.50
GoEmotions	$D = 1$	68.74	66.81	52.99	50.55
	$D = 2$	69.55	67.13	54.46	50.77
	$D = 3$	68.40	67.10	54.86	50.52
	$D = 4$	70.84	68.76	56.44	53.79
	$D = \infty$	68.84	67.94	55.44	50.97
MSSED	$D = 1$	82.57	80.66	79.45	79.31
	$D = 2$	83.21	82.95	79.69	79.33
	$D = 3$	83.55	83.10	80.30	79.98
	$D = 4$	83.69	83.71	80.88	80.82
	$D = \infty$	83.17	83.04	80.05	79.48

4.3.6 层数对模型效果的影响

MIP-GAT 的多交互图层包含 L 层 GAT, 为了探索层数对模型效果的影响, 分别将层数 L 设置为 1、2、3 并获取实验结果, 如表 4.6 所示。

可以注意到当 $L = 3$ 时 MIP-GAT 在三个数据集上的表现效果都最优。随着层数的增加, MIP-GAT 可以在更多维度对跨任务信息进行交互, 将不同任务之间的信息进行更深层次的聚合, 同时也可以掌握更全面的全局信息, 这就帮助了模型提升分类准确性。

表 4.6 改变层数的实验结果

数据集	层数	情感分类		情绪识别	
		P	M _a -F1	P	M _a -F1
CMU-MOSEI	$L = 1$	62.56	61.08	26.47	21.90
	$L = 2$	63.05	61.27	27.40	23.53
	$L = 3$	63.54	62.74	27.91	24.86
GoEmotions	$L = 1$	69.76	66.23	55.46	48.15
	$L = 2$	68.61	66.97	54.88	49.60
	$L = 3$	70.84	68.76	56.44	53.79
MSED	$L = 1$	82.58	82.39	80.31	80.10
	$L = 2$	82.98	82.69	80.57	80.39
	$L = 3$	83.69	83.71	80.88	80.82


4.3.7 可扩展性

为了验证 MIP-GAT 在其它领域的数据集上的可扩展性, 本小节进一步将 MIP-GAT 应用到 EmoContext^[104]数据集进行测试, 该数据集属于对话领域而非文本分类领域。EmoContext 数据集包含有 30160 条对话, 并且有四种标签: 快乐、悲伤、愤怒和其它。在情感分类任务上 MIP-GAT 的 M_a-F1 分数可以达到 89.76%, 情绪识别任务的 M_a-F1 分数可以达到 85.02%。该实验结果反映了即使数据集领域不同, MIP-GAT 仍可达到很好的效果, 证明了其可扩展性。


4.3.8 对超参的敏感性

为了探索 MIP-GAT 在训练时对超参的敏感性, 本小节在 CMU-MOSEI 数据集上对训练轮数和批量大小这两个超参进行了额外的实验。对于训练轮数, 测试了模型从 10 到 100 每 10 轮的模型训练效果。对于批量大小, 选择了 2、4、8、16 和 32 进行测试。实验结果如图 4.7 所示。当训练轮数增加时, 模型在情感分类和情绪识别任务上

的表现越来越好。而随着批量大小的变化，模型效果是动荡的，且在批量大小为 16 时表现最好。实验结果说明模型的训练对超参的变化具有敏感性，在训练时需要挑选合适的超参让模型达到最优的训练结果。



(a) MIP-GAT在不同训练轮数下的训练效果



(b) MIP-GAT在不同批量大小下的训练效果

图 4.7 MIP-GAT 在不同训练轮数和批量大小下的表现效果

4.3.9 个案研究

为了综合分析 MIP-GAT 的能力，本小节以一个例子进行了个案研究。

在许多实际场景中，即使一个句子包含积极的词汇，它的整体情感仍可能倾向于消极。在这种情况下，模型会纠结于如何做出正确决定。以 GoEmotions 数据集中的

一段文字为例：“Thanks for your kind words. They made me tear up a bit.” 其中文翻译为：“谢谢您暖心的话语，让我不禁眼眶湿润。” 它的情感标签为消极，情绪标签为悲伤。人类的情感是复杂的，人们有时可能会因为他人的善意而引起内心的悲伤，而显然这种情况会让模型困惑。在测试中，MIP-GAT 和 AMM-MTL 都成功地预测了这句话的情感为消极。然而，AMM-MTL 却将句子的情绪标签误判为快乐。这说明虽然 AMM-MTL 考虑了跨任务信息，但是模型的设计不足以让跨任务信息充分交互，从而导致了分类错误。相比之下，MIP-GAT 可以通过模型内部的跨任务连接使得跨任务信息得以充分交互，并成功地根据其消极情感推断出正确的情绪标签应该是悲伤。

4.3.10 与大语言模型的比较

本小节将本研究所提出 MIP-GAT 与大语言模型进行了比较。LLaMA-2^[105]是 Meta 推出的大语言模型，它基于 Transformer 架构，性能强大且代码开源。此外，因其模型架构透明、训练数据相对公开，且参数量覆盖广泛（70 亿到 700 亿），被广泛应用于自然语言处理领域的大语言模型相关研究。因此，本小节选择使用 LLaMA-2 与 MIP-GAT 进行比较，并在 MSSED 数据集上进行测试。

在实验设置方面，使用 PyTorch 在 1 台服务器的 2 张 NVIDIA RTX A6000 显卡上进行单机多卡分布式训练。使用 LoRA 方法^[106]对参数量为 70 亿的 LLaMA-2 进行微调，秩设置为 8，缩放因子 α 设置为 16，dropout 设置为 0.1，微调轮数为 10 轮，每张显卡的批量大小为 1，学习率大小为 5×10^{-4} ，学习率预热比例为 0.03，梯度累计步数为 64，权重衰减为 0，使用余弦衰减动态调整学习率。

在每一轮微调中，使用提示（Prompt）与文本进行拼接，并输入至 LLaMA-2 以生成模型的预测答案。表 4.7 分别展示了用于情感分类任务的提示模板和用于情绪识别任务的提示模板，待分类的文本将会替换至提示模板中的 {sentence} 处。再将提示模板与文本的情感或情绪标签相拼接，即可得到模型输出的标准答案。之后计算预测答案与标准答案之间的损失，通过反向传播计算梯度并更新参数，直到结果收敛或达到最大训练轮数。

经过微调，LLaMA-2 在 MSSED 数据集上的实验结果如表 4.8 所示。对于情感分类任务，LLaMA-2 的 M_a -F1 为 86.56%，优于 MIP-GAT 的 83.71%。其主要原因可能是由于 LLaMA-2 是在 2 万亿的词元上进行训练的，并且模型参数量也很大（70 亿），能更好地捕捉语言统计规律和世界知识。而 MIP-GAT 使用的是 BERT 预训练语言模

型，在训练规模（33 亿个词元）和参数量（1.1 亿）上都不如 LLaMA-2。但是 LLaMA-2 的部署需要 13GB 左右的空间。相比之下，本研究所提出的模型只需要 1GB 的部署空间，是 LLaMA-2 所需空间的 7.69%，然而性能上却只落后了 3.29%。这说明 MIP-GAT 是一个更加轻量化且部署更高效的模型，可以直接部署在如树莓派等小型硬件上实现本地运行，无需云端即可完成任务处理，既能保护隐私又减少网络依赖，其可应用范围比大语言模型要广。

表 4.7 大语言模型提示模板

任务	提示模板
情感分类	Below is an instruction that asks for sentiment classification, paired with a sentence to be classified. Write an answer that appropriately completes the request. ### Instruction: Given the following sentence, please choose its sentiment ONLY from the following options: positive, neutral, negative. ### Sentence: {sentence} ### Sentiment:
情绪识别	Below is an instruction that asks for emotion recognition, paired with a sentence to be classified. Write an answer that appropriately completes the request. ### Instruction: Given the following sentence, please choose its emotion ONLY from the following options: happiness, neutral, anger, disgust, fear, sadness. ### Sentence: {sentence} ### Emotion:

对于情绪识别任务, MIP-GAT 的 M_a-F1 分数达到了 80.82%, 该结果优于 LLaMA-2 的 M_a-F1 分数 71.07%。这是因为 MIP-GAT 相比于 LLaMA-2 增加了跨任务信息的交互, 在判别情绪时可以利用来自情感分类任务的信息进行辅助, 从而增加了情绪识别的准确性。该实验结果进一步验证了跨任务信息交互的有效性。

表 4.8 与大语言模型比较的实验结果

模型	情感分类			情绪识别		
	P	R	M_a-F1	P	R	M_a-F1
LLaMA-2	88.16	85.84	86.56	70.23	72.06	71.07
MIP-GAT	83.69	83.74	83.71	80.88	80.80	80.82

4.4 本章小结

情感分类和情绪识别是情感分析领域中的两个密切相关的任务, 然而大多数工作只将它们当作了两个独立的任务, 忽视了其相互关联性, 从而导致跨任务信息交互不足。为了解决这个问题, 本章提出了一种带有位置编码的多任务交互式图注意力网络 MIP-GAT, 这是一个基于跨任务信息交互的情感分析方法。MIP-GAT 的核心部分是一个多交互图层, 它有三个关键结构来保障多信息交互: (1) 使用跨任务连接保障跨任务信息交互; (2) 利用语义依存树构建语义依存连接, 保障语义依存信息交互; (3) 加入位置编码保障时序信息交互。本章主要使用 CMU-MOSEI 数据集、GoEmotions 数据集和 MSSED 数据集进行了全面的实验。结果表明 MIP-GAT 相比于各数据集最优的基线模型分别提升了 2.88%(CMU-MOSEI 数据集情感分类任务)、7.67%(CMU-MOSEI 数据集情绪识别任务)、0.98%(GoEmotions 数据集情感分类任务)、1.68%(GoEmotions 数据集情绪识别任务)、0.88%(MSSED 数据集情感分类任务)和 1.66%(MSSED 数据集情绪识别任务)。这证明了 MIP-GAT 充分利用了跨任务信息交互以提升自身的有效性。在消融实验中, 验证了 MIP-GAT 中贡献最大的结构分别为图结构和跨任务连接, 这说明跨任务信息交互在多任务学习框架中具有重要作用。本章还进行了一系列对于超参的实验, 包括上下文窗口大小、层数等, 这些实验保证 MIP-GAT 设置了最优的超参。除此之外, 本章还将 MIP-GAT 与大语言模型进行了比较, 虽然情感分类任务表现不如大语言模型, 但情绪识别任务表现优于大语言模型, 且其所需空间仅为大语言模型的 7.69%, 情感分类性能却只落后了 3.29%, 说明了 MIP-GAT 更轻量化且部署更高效。最后 MIP-GAT 还存在一些局限性, 它虽然考虑了

跨任务信息交互，但是仅使用了文本模态，而忽略了跨模态信息交互。文本和图像之间的跨模态信息也同样存在着密切关系^{[107],[108]}。在跨模态信息交互的帮助下，模型可以分辨出更加复杂的情感与情绪，这个问题将在下一章的研究中解决。

第 5 章 基于跨任务信息与跨模态信息交互的对话情感分析方法

5.1 引言

第 4 章所提出的情感分类与情绪识别的多任务学习框架虽然有效利用了跨任务信息交互，但是仅使用了文字模态信息，并未考虑到跨模态信息。然而，人类之间不仅仅只通过文字对话交流，这实际上是一个多模态的过程，涉及了自然语言（文字）、面部表情（视觉）等不同模态的信息源。因此想要完全理解人类对话中的情感与情绪，模型必需考虑跨模态信息。




图 5.1 跨任务、跨模态与上下文信息共同帮助对话情感情绪理解（示例来自 MELD 数据集）

在对话情感分析中有三个关键因素：跨任务信息、跨模态信息以及上下文信息，如图 5.1 所示。在这段多模态对话中，第一句 Ross 首先询问 Joey 是想去找吃的还是想看他们能来回扔球多久。这句话从文字上来看是一个普通的问句，并未使用任何带有感情色彩的词汇，同时从视觉上来看 Ross 的面部也并未呈现任何明显的表情特征，从而根据文字与视觉上的跨模态信息可以得出 Ross 说话时的情感与情绪都是中立。之后第二句 Joey 的回答选择了扔球，根据之前 Ross 询问中的情感和情绪都是中立，那么此时 Joey 的情感与情绪也有相当的概率是中立，此即上下文信息。再后来第四个句子 Joey 突然问 Ross 如果他们能坚持连续两个小时不让球落地会不会很棒，Ross 此时的情感是积极的，根据积极的情感可以推断出 Joey 现在的情绪大概率是开心，在这种推断中跨任务信息发挥了作用。通过上述例子可以说明综合考虑这三类关键因素至关重要。

然而，目前仍然缺少一个可以同时解决这三个关键因素的统一框架，这意味着总是会有有一种或者两种信息会被丢弃，在模型更新过程中无法传播足够的知识。这就提出了本章研究的问题：能否在一个统一的框架内同时考虑跨模态信息、跨任务信息以及上下文信息，使它们可以充分交互？

为了回答上述问题，本研究提出了一个多任务多模态交互式图注意力网络（Multi-Task, Multi-Modal Interactive Graph Attention Network, M3GAT），用于多模态对话情感分类任务与情绪识别任务的联合学习。该模型的核心是一个交互式对话图，该图由三个核心连接组成：跨任务连接、跨模态连接与上下文连接。在 M3GAT 中这三种连接将共同更新，显式地帮助模型对跨模态信息、跨任务信息以及上下文信息进行交互，从而在对话情感分类任务与情绪识别任务中有效提升模型能力。

5.2 多模态多任务交互式图注意力网络

本小节将详细介绍所提出的 M3GAT 模型，其整体框架如图 5.2 所示。




图 5.2 M3GAT 整体模型框架

5.2.1 问题描述

假设数据集中有 N 个样本，第 i 组对话 D_i 包含有 R 条多模态语句，则可以将其表示为 $D_i = (M_{i,k}^A, C_{i,k}^A, Y_{i,k}^A)$ ，其中 $M_{i,k}^A$ 代表对话中第 k 条待分类的多模态目标语句， $C_{i,k}^A$ 代表

$M_{i,k}^A$ 的多模态上下文语句, $Y_{i,k}^A$ 代表第 k 条语句的情感(S)标签和情绪(E)标签, A 代表情感分类或情绪识别这两类任务, 即 $A \in \{S, E\}$, 且 $i \in \{1, 2, \dots, N\}$, $k \in \{1, 2, \dots, R\}$ 。目标语句 $M_{i,k}^A$ 和上下文语句 $C_{i,k}^A$ 都包含有文本模态(U)和图像模态(I), 它们可以进一步表示为 $M_{i,k}^A = [U_{i,k}^A, I_{i,k}^A]$, $C_{i,k}^A = [U_{C_{i,k}}^A, I_{C_{i,k}}^A]$, 其中 $U_{i,k}^A, I_{i,k}^A \in \mathbb{R}^d$, $U_{C_{i,k}}^A, I_{C_{i,k}}^A \in \mathbb{R}^{d \times l_{C_{i,k}}}$, d 代表特征向量维度, $l_{C_{i,k}}$ 代表上下文语句的序列长度。

本章的研究问题可被总结为: 给定一个包含 R 条多模态语句的多主体对话, 如何利用跨任务信息、跨模态信息以及上下文信息来联合完成情感分类任务和情绪识别任务? 该问题可被形式化表示为:

$$\xi = \prod_i \prod_k p(Y_{i,k}^S, Y_{i,k}^E | C_{i,k}^S, C_{i,k}^E, M_{i,k}^S, M_{i,k}^E, \theta), \quad (5.1)$$

其中 θ 代表模型参数, $M_{i,k}^S$ 代表用于情感分类任务的第 k 条目标语句, $M_{i,k}^E$ 代表用于情绪识别任务的第 k 条目标语句, $M_{i,k}^S$ 和 $M_{i,k}^E$ 代表同一条目标语句但服务的任务不同, $C_{i,k}^S$ 代表用于情感分类任务的第 k 条目标语句的上下文, $C_{i,k}^E$ 代表用于情绪识别任务的第 k 条目标语句的上下文, $C_{i,k}^S$ 和 $C_{i,k}^E$ 代表同一条目标语句的上下文但服务的任务不同。

5.2.2 整体架构

M3GAT 由四个组件构成: 一个多模态语句编码器(Multi-Modal Utterance Encoder)、一个交互式对话图(Interactive Conversation Graph)以及两个分别用于情感分类和情绪识别的解码器(Decoder)。

多模态语句编码器: 多模态语句编码器由文本编码器(Text Encoder)和视频编码器(Video Encoder)组成, 分别处理词向量和像素向量。之后将处理后的两种模态向量分别输入至 BiLSTM 和 CNN 以获得语句的文本和视频初始向量表示。对于第 i 组对话第 k 条语句, 最终将获得 $U_{i,k}^{S(0)}$ 、 $I_{i,k}^{S(0)}$ 、 $U_{i,k}^{E(0)}$ 和 $I_{i,k}^{E(0)}$ 四类维度为 d 的向量, 其中 0 代表它们是交互式对话图的初始化向量。

交互式对话图: 交互式对话图通过多层 GAT 实现, 每层都由四类对话图组成, 分别为: 情感分类文本对话图、情绪识别文本对话图、情感分类视频对话图和情绪识别视频对话图。该部分旨在通过图中的跨任务连接、跨模态连接和上下文连接促进多种信息的交互。此外, 还额外在每类图中都构建了说话人节点, 其中包括了说话人的职业、性别以及性格信息。在经过 L 层的交互后, 最终将获得每条语句的多模态向量表示: $X_{i,k}^S = [U_{i,k}^{S(L)}; I_{i,k}^{S(L)}] \in \mathbb{R}^{2d}$ 和 $X_{i,k}^E = [U_{i,k}^{E(L)}; I_{i,k}^{E(L)}] \in \mathbb{R}^{2d}$ 。

解码器: 将 $X_{i,k}^S$ 和 $X_{i,k}^E$ 分别输入至情感分类解码器和情绪识别解码器, 并通过

Softmax 函数计算模型对第 k 条语句的情感及情绪预测分布。

在接下来的小节将会更详细地介绍每一个部分。需要注意的是，图中每个节点都有一条环，即自己连接自己的边，但为了简洁性并未在插图中画出。

5.2.3 多模态语句编码器

多模态语句编码器被情感分类和情绪识别两个任务所共享，它的目标是将语句的文本转为文本向量表示，将视频转为视频向量表示。该编码器由两个子模块组成：文本编码器和视频编码器，如图 5.3 所示。文本编码器首先使用 BERT 将语句的每个词汇嵌入为词向量，之后将每个词向量作为节点构建一个文本子图（Text Sub-Graph），使得节点之间的语义信息可以充分交互，最后使用一个 BiLSTM 考虑文本的时序信息并获得整个语句的文本向量表示。视频编码器使用视频子图（Video Sub-Graph）以视频一帧的每个像素点为节点，每个节点的向量维度为 3，以像素的 RGB 值初始化。视频子图可以使得像素之间进行空间位置信息交互。之后再使用一个 CNN 来捕获视觉特征，并获得整个语句的视频向量表示。




图 5.3 多模态语句编码器整体结构框架（输入示例来自 MELD 数据集）

多模态语句编码器的有向图 $\mathcal{G}$ 可被形式化表示为：

$$\mathcal{G} = (\mathcal{V}, \mathcal{E}, \mathcal{W}), \quad (5.2)$$

其中 $\mathcal{V}$ 代表节点的集合， $\mathcal{E}$ 代表边的集合， $\mathcal{W}$ 代表边的权重的集合。

(1) 文本编码器

文本编码器构建文本的有向图 $\mathcal{G}_u$ 并将其输入至 GAT，以第 i 组对话 D_i 的第 k 条语句为例，具体构建过程如下。

节点：假设语句包含 G 个词汇，每个词元将被看作一个节点，满足 $w_j \in \mathcal{V}^{\mathcal{G}_u}$ ，其中 $j \in \{1, 2, \dots, G\}$ 。每个节点 w_j 由一个词嵌入向量所表示。本研究使用 BERT 将每个词汇嵌入为词向量，并将其作为节点的初始特征向量。

边：使用 spaCy 工具包建立文本语句的语义依存树，并根据语义依存树构建词汇节点之间的有向边 $\mathcal{E}^{\mathcal{G}_u}$ ，构建方法与 4.2.3 小节的语义依存连接一致，且其上下文窗口大小为 1。

边的权重：使用 GAT 来计算节点与其所有邻居的边的权重。文本第 j 个词汇节点 w_j 将被嵌入向量 $\vec{x}_{w_j}^{\mathcal{G}_u(0)} = (\tau_{w_j}^1, \tau_{w_j}^2, \dots, \tau_{w_j}^{d_u})^\top \in \mathbb{R}^{d_u}$ 所初始化，其中 d_u 为向量维度，则文本图节点的初始化集合表示为 $\mathcal{V}^{\mathcal{G}_u(0)} = \{\vec{x}_{w_1}^{\mathcal{G}_u(0)}, \vec{x}_{w_2}^{\mathcal{G}_u(0)}, \dots, \vec{x}_{w_G}^{\mathcal{G}_u(0)}\}$ 。之后将图输入至 GAT，每层 GAT 使用可学习的线性变换和多头注意力机制帮助节点向量聚合信息。经过 L 层的语义信息交互和向量计算，每个节点都会更新为信息聚合度更高的向量，节点集合表示为 $\mathcal{V}^{\mathcal{G}_u(L)} = \{\vec{x}_{w_1}^{\mathcal{G}_u(L)}, \vec{x}_{w_2}^{\mathcal{G}_u(L)}, \dots, \vec{x}_{w_G}^{\mathcal{G}_u(L)}\}$ 。第 l 层第 j 个词汇节点的更新过程为：

$$\vec{x}_{w_j}^{\mathcal{G}_u(l)} = W^{l-1} \parallel_{h=1}^H \sigma \left(\sum_{w_r \in \mathcal{N}_{w_j}} \alpha_{w_j, w_r}^{l-1, h} W^{l-1, h} \vec{x}_{w_r}^{\mathcal{G}_u(l-1)} \right), \quad (5.3)$$

$$\alpha_{w_j, w_r}^{l-1, h} = \frac{\exp \left(\text{LeakyReLU} \left(\bar{a}^{l-1, h} [W^{l-1, h} \vec{x}_{w_j}^{\mathcal{G}_u(l-1)} \parallel W^{l-1, h} \vec{x}_{w_r}^{\mathcal{G}_u(l-1)}] \right) \right)}{\sum_{w_s \in \mathcal{N}_{w_j}} \exp \left(\text{LeakyReLU} \left(\bar{a}^{l-1, h} [W^{l-1, h} \vec{x}_{w_j}^{\mathcal{G}_u(l-1)} \parallel W^{l-1, h} \vec{x}_{w_s}^{\mathcal{G}_u(l-1)}] \right) \right)}, \quad (5.4)$$

其中 $l \in \{1, 2, \dots, L\}$ ， H 是多头注意力机制中头的数量， h 代表第 h 个头， $h \in \{1, 2, \dots, H\}$ ， $\parallel$ 代表纵向拼接操作， σ 代表非线性激活函数， $\mathcal{N}_{w_j}$ 是第 j 个词汇节点 w_j 的邻居节点集合， $\alpha_{w_j, w_r}^{l-1, h}$ 是节点 w_j 和其邻居节点 w_r 在第 $l-1$ 层第 h 个头的注意力分数， $W^{l-1} \in \mathbb{R}^{d_u \times H d_u}$ 和 $W^{l-1, h} \in \mathbb{R}^{d_u \times d_u}$ 是可训练的线性变换参数， $\bar{a}^{l-1, h} \in \mathbb{R}^{1 \times 2 d_u}$ 是第 $l-1$ 层第 h 个头中可训练的注意力向量参数。为了简洁性上述更新过程可缩略为：

$$\mathcal{V}^{\mathcal{G}_u(l)} = \text{TextGAT}(\mathcal{V}^{\mathcal{G}_u(l-1)}, \mathcal{E}^{\mathcal{G}_u}, \Theta^{\mathcal{G}_u(l-1)}), \quad (5.5)$$

其中 $\Theta^{\mathcal{G}_u(l-1)}$ 是文本编码器第 $l-1$ 层的模型参数。

经过 L 层更新后可以获得最终的节点向量表示集合 $\mathcal{V}^{\mathcal{G}_u(L)} = \{\vec{x}_{w_1}^{\mathcal{G}_u(L)}, \vec{x}_{w_2}^{\mathcal{G}_u(L)}, \dots, \vec{x}_{w_G}^{\mathcal{G}_u(L)}\}$ ，将其输入至 BiLSTM 以获得第 i 组对话第 k 条语句的文本向量表示 $U_{i,k}^{A(0)}$ ：

$$U_{i,k}^{A(0)} = W^u \cdot \text{BiLSTM}(\vec{x}_{w_1}^{\mathcal{G}_u(L)}, \vec{x}_{w_2}^{\mathcal{G}_u(L)}, \dots, \vec{x}_{w_G}^{\mathcal{G}_u(L)}), \quad (5.6)$$

其中 $U_{i,k}^{A(0)} \in \mathbb{R}^d$ ， $A \in \{S, E\}$ ，即 $U_{i,k}^{S(0)}$ 和 $U_{i,k}^{E(0)}$ 将分别用于情感分类任务和情绪识别任务，并且此时这两个向量在数值上是相等的，BiLSTM 的输出为维度 $2d_u$ 的列向量， $W^u \in$

$\mathbb{R}^{d \times 2d_u}$ 是可训练的线性变换参数。对于一组有 R 条语句的对话 D_i ，集合 $\{U_{i,1}^{A(0)}, U_{i,2}^{A(0)}, \dots, U_{i,R}^{A(0)}\}$ 将会成为交互式对话图中情感分类文本对话图和情绪识别文本对话图的输入。

(2) 视频编码器

假设第 i 组对话第 k 条语句的视频由 Q 帧组成，即 $I = (f_1, f_2, \dots, f_Q)$ ，每一帧是一张固定的图像，且尺寸一致。视频编码器对每一帧构建有向图 $\mathcal{G}_f$ ，并使用 GAT 提取帧的特征向量，具体构建过程如下。

节点：假设第 γ 张图像（即第 γ 帧）一共包含 T 个像素，则 $f_\gamma = (v_1, v_2, \dots, v_T)$ ，其中 $\gamma \in \{1, 2, \dots, Q\}$ 。需要注意的是每一帧的尺寸相同，即每一张图像都包含相同数量的像素。将每一个像素当作图中的一个节点，满足 $v_j \in \mathcal{V}^{\mathcal{G}_{f_\gamma}}$ 。节点的向量维度为 3，以像素的 RGB 值初始化，节点 v_j 的初始向量可以表示为 $\vec{x}_{v_j}^{\mathcal{G}_{f_\gamma(0)}} = (\tau_{v_j}^1, \tau_{v_j}^2, \tau_{v_j}^3)^\top$ 。

边：像素与其相邻的像素有所关联，所以基于像素的相邻关系构建边的连接 $\mathcal{E}^{\mathcal{G}_{f_\gamma}}$ 。每个像素与其周围一圈的像素建立双向连接，非边界像素与周围 8 个像素相互连接，不在角上的边界像素与周围 5 个像素相互连接，在角上的像素与周围 3 个像素相互连接。

边的权重：使用 GAT 初始视频子图来计算节点与其所有邻居的边的权重。视频子图节点的初始输入序列为 $\mathcal{V}^{\mathcal{G}_{f_\gamma(0)}} = \{\vec{x}_{v_1}^{\mathcal{G}_{f_\gamma(0)}}, \vec{x}_{v_2}^{\mathcal{G}_{f_\gamma(0)}}, \dots, \vec{x}_{v_T}^{\mathcal{G}_{f_\gamma(0)}}\}$ ，在经过 L 层更新后得到输出 $\mathcal{V}^{\mathcal{G}_{f_\gamma(L)}} = \{\vec{x}_{v_1}^{\mathcal{G}_{f_\gamma(L)}}, \vec{x}_{v_2}^{\mathcal{G}_{f_\gamma(L)}}, \dots, \vec{x}_{v_T}^{\mathcal{G}_{f_\gamma(L)}}\}$ 。像素向量更新的过程与式(5.3)和式(5.4)一致，并可缩略为：

$$\mathcal{V}^{\mathcal{G}_{f_\gamma(L)}} = \text{VideoGAT}(\mathcal{V}^{\mathcal{G}_{f_\gamma(L-1)}}, \mathcal{E}^{\mathcal{G}_{f_\gamma}}, \Theta^{\mathcal{G}_{f_\gamma(L-1)}}), \quad (5.7)$$

其中 $\Theta^{\mathcal{G}_{f_\gamma(L-1)}}$ 是视频编码器第 $l-1$ 层的模型参数。

之后，使用 CNN 捕捉图像的特征。该 CNN 由五层卷积层组成，每层分别具有 4、8、16、32 和 64 个卷积核，每层卷积核的大小分别为 7×7 、 7×7 、 5×5 、 3×3 和 3×3 。可以得到每一帧图像的特征向量 $f_\gamma^{A(0)}$ ：

$$f_\gamma^{A(0)} = \text{CNN}(\vec{x}_{v_1}^{\mathcal{G}_{f_\gamma(L)}}, \vec{x}_{v_2}^{\mathcal{G}_{f_\gamma(L)}}, \dots, \vec{x}_{v_T}^{\mathcal{G}_{f_\gamma(L)}}). \quad (5.8)$$

最后，可以通过将视频所有 Q 个帧的特征向量加和再求平均的方式来获得第 i 组对话第 k 条语句的视频向量表示 $I_{i,k}^{A(0)}$ ：

$$I_{i,k}^{A(0)} = \frac{1}{Q} \sum_{\gamma=1}^Q f_\gamma^{A(0)}, \quad (5.9)$$

其中 $I_{i,k}^{A(0)} \in \mathbb{R}^d$ ， $A \in \{S, E\}$ ，即 $I_{i,k}^{S(0)}$ 和 $I_{i,k}^{E(0)}$ 将分别用于情感分类任务和情绪识别任务，并且此时这两个向量在数值上是相等的。对于一组有 R 条语句的对话 D_i ，序列

$\{I_{i,1}^{A(0)}, I_{i,2}^{A(0)}, \dots, I_{i,R}^{A(0)}\}$ 将会成为下一模块中情感分类视频对话图和情绪识别视频对话图的输入。

5.2.4 交互式对话图

本小节将详细介绍交互式对话图，它包括四个子图：情感分类文本对话图、情绪识别文本对话图、情感分类视频对话图和情绪识别视频对话图，如图 5.4 所示。交互式对话图是 M3GAT 的核心结构，包含了跨任务连接、跨模态连接和上下文连接，旨在促进跨任务信息、跨模态信息和上下文信息的交互。对比第 4 章的方法，交互式对话图多考虑到了跨模态信息的交互，这为模型提供了一种新的信息来源，增多了判别样本的线索。交互式对话图还可以感知说话人信息，它在图中构建了说话人节点，其中包括了说话人的职业、性别以及性格信息，说话人节点与所有出自该说话人的语句节点相互连接。模型通过了解说话人信息可以更好地理解说话人的情感与情绪。




图 5.4 交互式对话图整体结构框架

交互式对话图的具体构建过程如下。

节点：假设第 i 组对话 D_i 包含有 R 条多模态语句，即 R 条文本语句和 R 条视频语句。每条文本语句和视频语句分别用于情感分类和情绪识别两个任务。每一个用于情感分类或情绪识别的文本和视频向量表示被视作一个节点，从而得到 $4R$ 个节点。此外，考虑到说话者的情绪和情感状态会受其本人职业、性别以及性格所影响，还在每个子

图中为每个说话人设置了三个说话人信息节点（分别对应说话人的职业、性别和性格）以及一个说话人节点。属于同一个说话人的说话人信息节点相互连接，并与说话人节点相互连接。说话人节点除了说话人信息节点，只与出自该说话人的语句节点相互连接。本研究在实验部分所使用的其中两个对话数据集 MELD 和 MEISD 都是从著名的电视节目中收集而来。因此尽管这两个数据集都只提供了说话者的姓名，仍可以在网络上根据其姓名检索职业、性别和性格信息。若第 i 组对话 D_i 共有 T 个说话人，则交互式对话图共有 $4R + 16T$ 个节点。

使用来自多模态语句编码器的输出向量 $U_{i,k}^{A(0)}$ 和 $I_{i,k}^{A(0)}$ 来初始化第 k 条文本语句节点和视频语句节点。为了可读性，本章接下来将这两种模态的语句节点统一表示为 $M_{i,k}^{A(0)}$ ，其中 $M \in \{U, I\}$ 。

说话人信息节点的职业（job）、性别（sex）和性格（character）由文本描述，并使用 BERT 将描述文字嵌入为词向量，则可得到第 t 个说话人的说话人信息节点向量 $M_{job_t}^{A(0)}, M_{sex_t}^{A(0)}, M_{cha_t}^{A(0)} \in \mathbb{R}^d$ ，其中 $t \in \{1, 2, \dots, T\}$ 。通过加和平均这三条向量的方式来初始化第 t 个说话人（speaker）节点的向量表示 $M_{sp_t}^{A(0)} = \frac{1}{3} (M_{job_t}^{A(0)} + M_{sex_t}^{A(0)} + M_{cha_t}^{A(0)}) \in \mathbb{R}^d$ 。

综上所述，交互式对话图的节点包括语句节点、说话人信息节点以及说话人节点。

边：第 i 组对话 D_i 的对话图构建了三种边：上下文连接、跨任务连接和跨模态连接。

(1) 上下文连接：上下文连接分为局部上下文连接和全局上下文连接。

每条文本或视频语句都与其邻近的上下文相关，所以构建了局部上下文连接。为了平衡计算成本与计算效率，在局部上下文连接中设置了上下文窗口 Z ，同一子图中在对话里距离不大于 Z 的语句节点之间将会建立局部上下文连接，当 $Z < k \leq R - Z$ 时，节点 $M_{i,k}^{A(0)}$ 将与集合 $\{M_{i,k-Z}^{A(0)}, \dots, M_{i,k-2}^{A(0)}, M_{i,k-1}^{A(0)}, M_{i,k+1}^{A(0)}, M_{i,k+2}^{A(0)}, \dots, M_{i,k+Z}^{A(0)}\}$ 中所有节点建立局部上下文连接。本研究 Z 默认设置为 3。

全局上下文信息影响着对话中的每条语句，所以构建了全局上下文连接以避免丢失全局信息。每个子图有唯一的一个全局节点。本研究认为全局节点应有如下特点：如果想要将信息传播到图中的每一个节点，全局节点应该是所有节点中传播速度最快的。所以全局节点应该是所有节点中到其它节点最短距离之和最小的节点。据此，可以通过计算子图中每个节点的紧密中心度^[109]（closeness centrality）来找到全局节点。节点 $M_{i,k}^{A(0)}$ 的紧密中心度计算方式如下：

$$Cen(M_{i,k}^{A(0)}) = \frac{1}{\sum_r Dis(M_{i,k}^{A(0)}, M_{i,r}^{A(0)})}, \quad (5.10)$$

其中 $Dis(M_{i,k}^{A(0)}, M_{i,r}^{A(0)})$ 代表节点 $M_{i,k}^{A(0)}$ 和 $M_{i,r}^{A(0)}$ 在子图中的最短距离。由于紧密中心度是

最短距离之和的倒数，所以紧密中心度最高的节点将被设置为全局节点。

(2) **跨任务连接:** 为了促进跨任务信息交互，让不同任务之间的节点进行知识共享，建立了跨任务连接。在跨任务连接中，如果节点 1 和节点 2 对应同一条语句，且分别处于任务不同模态相同的两个子图中，则节点 1 和节点 2 及其上下文窗口不大于 Z 的邻居相互连接。比如对话中第 i 组对话第 k 条语句对应的用于情感分类的文本语句节点 $U_{i,k}^{S(0)}$ 处于情感分类文本对话图，对应的用于情绪识别的文本语句节点 $U_{i,k}^{E(0)}$ 处于情绪识别文本对话图，则 $U_{i,k}^{S(0)}$ 与 $U_{i,k}^{E(0)}$ 之间会建立一条跨任务连接，且当 $Z < k \leq R - Z$ 时，节点 $U_{i,k}^{S(0)}$ 还会与集合 $\{U_{i,k-Z}^{E(0)}, \dots, U_{i,k-2}^{E(0)}, U_{i,k-1}^{E(0)}, U_{i,k+1}^{E(0)}, U_{i,k+2}^{E(0)}, \dots, U_{i,k+Z}^{E(0)}\}$ 中所有节点建立跨任务连接。

(3) **跨模态连接:** 为了促进跨模态信息交互，让模型从多种角度考虑对话的情感与情绪，建立了跨模态连接。在跨模态连接中，如果节点 1 和节点 2 对应同一条语句，且分别处于模态不同任务相同的两个子图中，则节点 1 和节点 2 及其上下文窗口不大于 Z 的邻居相互连接。比如对话中第 i 组对话第 k 条语句对应的用于情感分类的文本语句节点 $U_{i,k}^{S(0)}$ 处于情感分类文本对话图，对应的用于情感分类的视频语句节点 $I_{i,k}^{S(0)}$ 处于情感分类视频对话图，则 $U_{i,k}^{S(0)}$ 与 $I_{i,k}^{S(0)}$ 之间将会建立一条跨模态连接，且当 $Z < k \leq R - Z$ 时，节点 $U_{i,k}^{S(0)}$ 还会与集合 $\{I_{i,k-Z}^{S(0)}, \dots, I_{i,k-2}^{S(0)}, I_{i,k-1}^{S(0)}, I_{i,k+1}^{S(0)}, I_{i,k+2}^{S(0)}, \dots, I_{i,k+Z}^{S(0)}\}$ 中所有节点建立跨模态连接。

边的权重: 使用 L 层 GAT 对节点向量更新，每一层节点向量更新完毕后将所有节点向量输入下一层，直到最后一层。情感分类文本对话图节点的初始向量集合为 $\mathcal{V}_u^{S(0)} = \{U_{i,1}^{S(0)}, U_{i,2}^{S(0)}, \dots, U_{i,R}^{S(0)}, U_{job_1}^{S(0)}, U_{sex_1}^{S(0)}, U_{cha_1}^{S(0)}, U_{sp_1}^{S(0)}, \dots, U_{job_T}^{S(0)}, U_{sex_T}^{S(0)}, U_{cha_T}^{S(0)}, U_{sp_T}^{S(0)}\}$ ，若第 k 条文本语句对应第 t 个说话人，则第 l 层情感分类文本对话图节点 $U_{i,k}^{S(l)}$ 的更新过程为：

$$U_{i,k}^{S(l)} = W^{l-1} \parallel_{h=1}^H \sigma \left(\sum_{r \in \mathcal{C}_{U_{i,k}^S}} \alpha_{k,r}^{l-1,h} U_{i,r}^{S(l-1)} + \sum_{p \in \mathcal{M}_{U_{i,k}^S}} \alpha_{k,p}^{l-1,h} I_{i,p}^{S(l-1)} + \sum_{q \in \mathcal{T}_{U_{i,k}^S}} \alpha_{k,q}^{l-1,h} U_{i,q}^{E(l-1)} + \alpha_{k,sp_t}^{l-1,h} U_{sp_t}^{S(l-1)} \right), \quad (5.11)$$

其中 $\mathcal{C}_{U_{i,k}^S}$ 代表所有与 $U_{i,k}^S$ 构建了上下文连接的节点的集合， $\alpha_{k,r}^{l-1,h}$ 是节点 $U_{i,k}^{S(l-1)}$ 和节点 $U_{i,r}^{S(l-1)}$ 在第 $l-1$ 层第 h 个头的注意力分数， $\mathcal{M}_{U_{i,k}^S}$ 代表所有与 $U_{i,k}^S$ 构建了跨模态连接的节点的集合， $\alpha_{k,p}^{l-1,h}$ 是节点 $U_{i,k}^{S(l-1)}$ 和节点 $I_{i,p}^{S(l-1)}$ 在第 $l-1$ 层第 h 个头的注意力分数， $\mathcal{T}_{U_{i,k}^S}$ 代表所有与 $U_{i,k}^S$ 构建了跨任务连接的节点的集合， $\alpha_{k,q}^{l-1,h}$ 是节点 $U_{i,k}^{S(l-1)}$ 和节点 $U_{i,q}^{E(l-1)}$ 在第 $l-1$ 层第 h 个头的注意力分数， $\alpha_{k,sp_t}^{l-1,h}$ 是节点 $U_{i,k}^{S(l-1)}$ 和第 t 个说话人节点 $U_{sp_t}^{S(l-1)}$ 在第 $l-1$ 层第 h 个头的注意力分数， σ 代表非线性激活函数， $W^{l-1} \in \mathbb{R}^{d \times Hd}$ 和 $W^{l-1,h} \in \mathbb{R}^{d \times d}$ 是可训练的线性变换参数。

同样地，第 l 层第 k 个情感分类视频对话图的视频语句节点 $I_k^{S(l)}$ 、情绪识别文本对话

图的文本语句节点 $U_k^{E(l)}$ 和情绪识别视频对话图的视频语句节点 $I_k^{E(l)}$ 更新过程为:

$$I_{i,k}^{S(l)} = W^{l-1} \parallel \sigma \left(W^{l-1,h} \left(\sum_{r \in \mathcal{C}_{i,k}^S} \alpha_{k,r}^{l-1,h} I_{i,r}^{S(l-1)} + \sum_{p \in \mathcal{M}_{i,k}^S} \alpha_{k,p}^{l-1,h} U_{i,p}^{S(l-1)} + \sum_{q \in \mathcal{T}_{i,k}^S} \alpha_{k,q}^{l-1,h} I_{i,q}^{E(l-1)} + \alpha_{k,sp_t}^{l-1,h} I_{sp_t}^{S(l-1)} \right) \right), \quad (5.12)$$

$$U_{i,k}^{E(l)} = W^{l-1} \parallel \sigma \left(W^{l-1,h} \left(\sum_{r \in \mathcal{C}_{i,k}^E} \alpha_{k,r}^{l-1,h} U_{i,r}^{E(l-1)} + \sum_{p \in \mathcal{M}_{i,k}^E} \alpha_{k,p}^{l-1,h} I_{i,p}^{E(l-1)} + \sum_{q \in \mathcal{T}_{i,k}^E} \alpha_{k,q}^{l-1,h} U_{i,q}^{S(l-1)} + \alpha_{k,sp_t}^{l-1,h} U_{sp_t}^{E(l-1)} \right) \right), \quad (5.13)$$

$$I_{i,k}^{E(l)} = W^{l-1} \parallel \sigma \left(W^{l-1,h} \left(\sum_{r \in \mathcal{C}_{i,k}^E} \alpha_{k,r}^{l-1,h} I_{i,r}^{E(l-1)} + \sum_{p \in \mathcal{M}_{i,k}^E} \alpha_{k,p}^{l-1,h} U_{i,p}^{E(l-1)} + \sum_{q \in \mathcal{T}_{i,k}^E} \alpha_{k,q}^{l-1,h} I_{i,q}^{S(l-1)} + \alpha_{k,sp_t}^{l-1,h} I_{sp_t}^{E(l-1)} \right) \right), \quad (5.14)$$

此外, 第 l 层第 t 个说话人的说话人信息节点 $M_{job_t}^{A(l)}$ 、 $M_{sex_t}^{A(l)}$ 、 $M_{cha_t}^{A(l)}$ 的更新过程可写为:

$$M_{\mu_t}^{A(l)} = W^{l-1} \parallel \sigma \left(\sum_{r \in \mathcal{S}} \alpha_{\mu_t,r_t}^{l-1,h} W^{l-1,h} M_{r_t}^{A(l-1)} + \alpha_{\mu_t,sp_t}^{l-1,h} W^{l-1,h} M_{sp_t}^{A(l-1)} \right), \quad (5.15)$$

其中 $\mathcal{S} = \{job, sex, cha\}$ 且 $\mu \in \mathcal{S}$, $\alpha_{\mu_t,r_t}^{l-1,h}$ 是节点 $M_{\mu_t}^{A(l-1)}$ 和节点 $M_{r_t}^{A(l-1)}$ 在第 $l-1$ 层第 h 个头的注意力分数, $\alpha_{\mu_t,sp_t}^{l-1,h}$ 是节点 $M_{\mu_t}^{A(l-1)}$ 和节点 $M_{sp_t}^{A(l-1)}$ 在第 $l-1$ 层第 h 个头的注意力分数。说话人节点 $M_{sp_t}^{A(l)}$ 的更新过程可写为:

$$M_{sp_t}^{A(l)} = W^{l-1} \parallel \sigma \left(\sum_{r \in \mathcal{S}} \alpha_{sp_t,r_t}^{l-1,h} W^{l-1,h} M_{r_t}^{A(l-1)} + \sum_{q \in \mathcal{E}} \alpha_{sp_t,q}^{l-1,h} W^{l-1,h} M_{i,q}^{A(l-1)} \right), \quad (5.16)$$

其中 $\mathcal{E}$ 为所有对应第 t 个说话人的语句节点集合, $\alpha_{sp_t,r_t}^{l-1,h}$ 是节点 $M_{sp_t}^{A(l-1)}$ 和节点 $M_{r_t}^{A(l-1)}$ 在第 $l-1$ 层第 h 个头的注意力分数, $\alpha_{sp_t,q}^{l-1,h}$ 是节点 $M_{sp_t}^{A(l-1)}$ 和节点 $M_{i,q}^{A(l-1)}$ 在第 $l-1$ 层第 h 个头的注意力分数。

最后, 对于包含 R 条语句的对话 D_i , 交互式对话图输出用于情感分析的文本语句向量序列 $\{U_{i,1}^{S(L)}, U_{i,2}^{S(L)}, \dots, U_{i,R}^{S(L)}\}$, 用于情感分析的视频语句向量序列 $\{I_{i,1}^{S(L)}, I_{i,2}^{S(L)}, \dots, I_{i,R}^{S(L)}\}$, 用于情绪识别的文本语句向量序列 $\{U_{i,1}^{E(L)}, U_{i,2}^{E(L)}, \dots, U_{i,R}^{E(L)}\}$, 用于情绪识别的视频语句向量序列 $\{I_{i,1}^{E(L)}, I_{i,2}^{E(L)}, \dots, I_{i,R}^{E(L)}\}$ 。

5.2.5 解码器

解码器的整体结构框架如图 5.5 所示。




图 5.5 解码器整体结构框架

首先使用拼接操作获得分别用于情感分类任务和情绪识别任务的第 i 组对话第 k 条

多模态语句向量表示 $X_{i,k}^S$ 和 $X_{i,k}^E$:

$$X_{i,k}^S = [U_{i,k}^{S(L)}; I_{i,k}^{S(L)}], \quad (5.17)$$

$$X_{i,k}^E = [U_{i,k}^{E(L)}; I_{i,k}^{E(L)}]. \quad (5.18)$$

再将多模态语句向量表示 $X_{i,k}^S$ 和 $X_{i,k}^E$ 分别输入至两个线性层，再用 Softmax 函数获得模型对第 i 组对话第 k 条语句的情感预测分布和情绪预测分布：

$$\hat{y}_{i,k}^S = \text{softmax}(W^S X_{i,k}^S + b^S), \quad (5.19)$$

$$\hat{y}_{i,k}^E = \text{softmax}(W^E X_{i,k}^E + b^E), \quad (5.20)$$

其中 $X_{i,k}^S, X_{i,k}^E \in \mathbb{R}^{2d}$, $\hat{y}_{i,k}^S, \hat{y}_{i,k}^E \in \mathbb{R}^V$ 分别是对情感分类任务和情绪识别任务的预测分布， V 代表词表长度， $W^S, W^E \in \mathbb{R}^{V \times 2d}$ 是线性变换参数， $b^S, b^E \in \mathbb{R}^V$ 是偏置。

5.2.6 模型训练

在获得第 i 组对话第 k 条语句情感和情绪的预测分布 $\hat{y}_{i,k}^S$ 和 $\hat{y}_{i,k}^E$ 后，分别使用交叉熵构造损失函数 ζ_S 和 ζ_E ：

$$\zeta_S \triangleq - \sum_i \sum_k y_{i,k}^S \log \hat{y}_{i,k}^S, \quad (5.21)$$

$$\zeta_E \triangleq - \sum_i \sum_k y_{i,k}^E \log \hat{y}_{i,k}^E, \quad (5.22)$$

其中 $y_{i,k}^S, y_{i,k}^E \in \mathbb{R}^V$ 代表真实分布。

之后使用不同的权重对 ζ_S 和 ζ_E 进行加权求和，获得最终的损失函数 ζ ：

$$\zeta \triangleq w_S \zeta_S + w_E \zeta_E, \quad (5.23)$$

其中 w_S 和 w_E 代表权重。

使用损失函数 ζ 作为 M3GAT 模型的训练目标，可以同时提升模型在情感分类和情绪识别两个任务上的表现。每一训练轮次在计算出模型损失后，使用反向传播算法计算出模型参数的梯度，使用 AdamW 算法^[110]根据梯度更新模型参数，并使用 ReduceLROnPlateau 策略动态调整学习率。重复上述过程直至训练达到最大轮次或模型收敛。

5.3 实验与分析

5.3.1 研究问题

研究问题一：同时构建跨任务连接、跨模态连接和上下文连接的 M3GAT 模型是否有效？

研究问题二：跨任务信息的信息交互与跨模态信息的信息交互能否帮助模型提升

任务表现？

研究问题三：M3GAT 的哪一个组件贡献最大？

为了回答研究问题一，第 5.3.4 小节将 M3GAT 与一系列前沿基线模型在三个数据集上进行比较。为了回答研究问题二，第 5.3.5 小节通过在模型中调整是否考虑跨任务信息或跨模态信息，以探究信息种类变化对模型表现的影响。为了回答研究问题三，第 5.3.6 小节将进行消融实验，分别去除 M3GAT 的跨任务连接、跨模态连接和上下文连接以探究它们的贡献程度。

5.3.2 实验设置

数据集：使用了两个多模态对话数据集 MELD 和 MEISD^[111]，它们都包含情感与情绪标签。此外，还使用了第 3 章所构建的 MSSED 数据集。三个数据集的统计数据如表 5.1 所示。

表 5.1 数据集统计数据

标签		MELD			MEISD			MSSED		
		训练集	验证集	测试集	训练集	验证集	测试集	训练集	验证集	测试集
情感	积极	2,334	233	521	4,968	800	1,489	2,524	419	860
	中立	4,710	470	1,256	3,417	318	929	1,664	294	569
	消极	2,945	406	833	5,717	983	1,579	1,939	308	613
情绪	幸福	1,743	163	402	2,589	331	533	2,524	419	860
	悲伤	683	111	208	1,433	268	460	666	102	186
	中立	4,710	470	1,256	1,417	208	429	1,664	294	569
	厌恶	271	22	68	1,723	301	471	251	44	80
	愤怒	1,109	153	345	2,145	294	577	523	78	172
	惊讶	1,205	150	281	2,216	315	587	-	-	-
	恐惧	268	40	50	1,067	170	451	499	84	175
	接受	-	-	-	1,562	214	439	-	-	-

MELD 数据集：包含 1433 组对话，一共 13708 条多模态语句，收集自电视剧《老友记》。情感标签有三种，分别为积极（Positive）、中立（Neutral）和消极（Negative）。情绪标签有七种，分别为愤怒（Anger）、厌恶（Disgust）、恐惧（Fear）、开心（Joy）、中立（Neutral）、悲伤（Sadness）和惊讶（Surprise）。

MEISD 数据集：包含 1000 组对话，一共 20000 条多模态语句，收集自 10 部不同体裁的电视节目，包括《生活大爆炸》、《权力的游戏》等。情感标签为积极、中立和消极三种。情绪标签有八种，分别为开心（Joy）、悲伤（Sadness）、愤怒（Anger）、恐惧（Fear）、惊讶（Surprise）、厌恶（Disgust）、接受（Acceptance）和中立（Neutral）。其中接受情绪来自 Plutchik 情绪轮盘^[112]，它是敬佩（Admiration）与信任（Trust）情绪的淡化。

MSED 数据集：包含 9190 条多模态语句。情感标签为积极、中立与消极三种。情绪标签为愤怒（Anger）、厌恶（Disgust）、恐惧（Fear）、幸福（Happiness）、中立（Neutral）、悲伤（Sadness）和惊讶（Surprise）六种。在本实验中，幸福标签与开心标签都被视为幸福标签。

评价指标：采用精确率（Precision, P）、召回率（Recall, R）和 macro-F1（ $M_a\text{-}F1$ ）作为评价指标。

超参设置：词嵌入向量维度为 768。视频编码器像素的邻接矩阵初始化为单位矩阵。损失函数 ζ 的权重 w_S 和 w_E 均设置为 1。并为所有图网络的输出添加了残差连接。更详细的超参设置列在了表 5.2 中。

表 5.2 模型超参设置

超参	MELD	MEISD	MSED
词嵌入向量维度	768	768	768
批量大小	2	2	16
BERT 学习率	4×10^{-7}	4×10^{-7}	1×10^{-5}
其它参数学习率	3×10^{-6}	3×10^{-6}	1×10^{-5}
训练轮数	50	100	50
Dropout 率	0.5	0.5	0.5
文本编码器层数	3	3	1
视频编码器层数	3	3	1
交互式对话图层数	3	3	1
上下文窗口大小	3	3	-

5.3.3 基线模型

为了验证 M3GAT 模型的有效性，将之与一系列基线模型进行了比较：

MM-CNN^[113] (Multimodal CNN) 使用两个 CNN 来提取文本和视觉特征, 并将其合并在一起用于分类;

BiGRU+Att 对于文本模态, 为每个词汇使用 BiGRU 来抽取每个词汇的历史和未来上下文特征, 并采用 CNN 抽取每个词汇所在位置的局部上下文特征, 之后它使用注意力算法根据历史、未来以及局部上下文的特征向量计算出词汇的向量表示, 最后将所有词汇的向量序列输入至 LSTM 以获得语句的文本向量表示, 对于视频模态先将语句对应的视频图像提取为特征向量, 再使用相同的算法获得语句的视频向量表示, 最后将两个模态的向量合并进行分类;

SVM+BERT^[114] 使用 BERT 提取语句的文本向量表示, 并使用 SVM 进行情感分类和情绪识别;

GRU+RoBERTa 使用预训练语言模型 RoBERTa^[115] 来获取语句每个词汇的向量表示, 而非 BERT, 并将词汇向量序列输入 GRU 来获得语句的文本向量表示以进行分类任务;

EfficientNet^[116] 是一个预训练视觉模型, 在获得语句的视频向量表示后输入至线性层分类;

UPB-MTL^[117] 使用 ALBERT^[118] 获得语句的文本向量表示, 使用 VGG-16 获得语句的视频向量表示, 将这两种向量拼合后分别输入至多个线性层进行多任务学习;

MMBT^[119] (Multimodal Bitransformers) 分别使用 BERT 和 ResNet-152 来获得文本和视频向量表示;

A-MTL^[120] 使用 Inter-Segment Inter-Modal Attention 和 Intra-Segment Intra-Modal Attention 这两种注意力机制来进行多任务学习;

CIM^[121] 使用 BiGRU 获取上下文信息, 并在不同模态之间使用注意力机制来交互跨模态信息;

MM-RNN^[43] (Multimodal RNN) 依次使用三个 RNN 获取当前时刻每个模态的说话人状态、累计上下文和情感或情绪状态, 之后使用注意力机制将每个模态的特征向量融合在一起进行分类;

MM-GAT (Multimodal GAT) 使用两个 GAT 来分别使语句的文本向量和视频向量进行交互, 在 MELD 和 MSED 数据集的实验中 MM-GAT 的文本特征向量由 GloVe 获得, 而在 MEISD 数据集中由 BERT 获得;

Co-GAT^[122] 在图中使用跨语句连接和跨任务连接来进行多任务学习。

5.3.4 实验结果与分析

实验结果如表 5.3、表 5.4 与表 5.5 所示。所有基线被分为两类，分别为深度学习模型和图网络模型。此外，Text-M3GAT 和 Video-M3GAT 分别代表只使用了文本模态和只使用了视频模态的 M3GAT。

表 5.3 不同模型在 MELD 数据集上的实验结果

数据集	模型	情感分类			情绪识别		
		P	R	M _a -F1	P	R	M _a -F1
MELD	MM-CNN	54.72	46.99	41.78	13.65	21.95	16.79
	BiGRU+Att	55.66	53.68	53.56	24.50	24.29	21.44
	SVM+BERT	64.13	62.91	63.24	59.65	33.79	33.33
	GRU+RoBERTa	62.89	60.77	61.52	33.63	34.61	33.69
	EfficientNet	65.76	65.86	65.72	41.94	39.40	39.43
	UPB-MTL	61.61	61.67	61.44	33.10	34.66	33.38
	MMBT	62.74	62.76	62.33	43.03	38.97	39.55
	A-MTL	63.94	64.27	64.04	33.07	33.49	33.21
	CIM	60.23	61.14	60.55	32.47	31.69	32.16
	MM-RNN	58.22	58.74	58.36	29.67	30.13	29.86
	MM-GAT	58.23	57.45	57.75	32.50	29.11	28.99
	Co-GAT	66.93	66.88	66.89	42.35	40.33	39.73
	Text-M3GAT	67.42	67.86	67.54	39.97	41.09	39.81
	Video-M3GAT	64.41	65.56	64.84	51.81	40.03	38.48
	M3GAT	68.68	68.29	68.15	43.15	41.35	40.53

接下来将分别对每个数据集上的模型表现进行分析。

MELD 数据集：从表 5.3 中可以观察到在情感分类和情绪识别两类任务中，MM-CNN 在所有基线中表现得最不好，它在这两个任务中所有指标上的分数都是最低的。一个主要原因是 MM-CNN 忽略了语句之间的信息交互，导致模型无法学习到上下文信息，从而导致一定的性能损失。通过对上下文信息交互建模，BiGRU+Att 在这两项任务中都比 MM-CNN 取得了更好的进展。SVM+BERT 在两个任务上的

M_a -F1 得分分别比 MM-CNN 增长了 51.36%和 98.51%，这一显著提升很有可能在于 BERT 强大的语义表征能力。而 SVM+BERT 在情绪识别任务的精确率 (P) 在所有模型中达到了最高，可能是因为 SVM 将大部分样本都预测为标签占比最多的中立标签，从而可以使得精确率很高，但并无实际应用价值。与 SVM+BERT 相比，GRU+RoBERTa 在情感分类方面的得分稍低，但在情感识别任务方面的 R 和 M_a -F1 得分稍高，一个可能的原因是使用 GRU 可以更加综合上下文信息。UPB-MTL 和 MMBT 也显示出了类似的现象。原因可能在于情绪识别更依赖于上下文信息的交互，而 SVM 并不能帮助上下文信息交互。A-MTL 在情感分类任务上优于上述模型，但在情绪识别任务上却并没有，这说明 Inter-Segment Inter-Modal Attention 和 Intra-Segment Intra-Modal Attention 这两种注意力机制可能无法有效捕捉到足够的细粒度情绪特征。CIM 和 MM-RNN 在两个任务上的效果都不如 A-MTL 和 MMBT，可能的原因有两个：（1）CIM 只考虑了跨模态信息和上下文信息；（2）MM-RNN 和 CIM 都未使用预训练语言模型，导致词嵌入向量语义表征不足。在所有的深度学习模型中，EfficientNet 的表现最佳，它内部的 SE^[123] (Squeeze-and-Excitation) 模块可以自适应地调整各通道的权重，增加了模型对不同输入的适应度。

为了测试图网络模型在多模态情感分类和情绪识别中的潜力，本小节还对两个 GAT 基线进行了实验，即 MM-GAT 和 Co-GAT。根据实验结果来看，MM-GAT 表现不佳，不如大部分深度学习模型。一个可能的原因是 MM-GAT 并未使用 BERT 嵌入词向量。但它仍比 MM-CNN 和 BiGRU+Att 效果好。Co-GAT 对跨任务信息交互和跨语句信息交互进行了建模，并在两个任务上都达到了所有基线模型中最好的表现，证明了图网络模型的有效性。

Text-M3GAT 和 Video-M3GAT 用于验证跨模态信息交互的有效性。Text-M3GAT 的表现比 Co-GAT 稍有进步，这得益于 M3GAT 健全的图网络架构。然而，Video-M3GAT 的表现并未达到预期，因为文本信息对情感分析的帮助更大，这在第 3 章中已经过实验证明。但实际上视觉信息在对话中也提供了补充知识，例如面部表情。在实验结束后，经检查 MELD、MEISD 和 MSED 的测试集中分别有 225、137 和 91 个样本被 Text-M3GAT 错误分类，但被带有多模态信息的 M3GAT 正确分类。相比之下，MELD、MEISD 和 MSED 的测试集中分别有 46、14 和 25 个样本被 M3GAT 错误分类，但被 Text-M3GAT 正确分类，数量明显减少，M3GAT 相比 Text-M3GAT 纠正了更多错误。这表明仅使用文本信息提高分类性能是不够的，多模态信息比单模态更丰富、更全面、

更准确。因此本研究所提出的 M3GAT 融入了多模态信息，使用了跨模态连接促进跨模态信息交互，表现出了更大的潜力。

在情感分类和情绪识别任务中，M3GAT 的 M_a -F1 分数分别为 68.15%和 40.53%，而表现最好的基线模型 Co-GAT 的 M_a -F1 分数为 66.89%和 39.73%，M3GAT 分别提升了 1.88%和 2.01%。这表明本研究成功利用了跨任务连接、跨模态连接以及上下文连接使得多种不同的信息在模型中充分交互，帮助 M3GAT 对人类对话中的情感与情绪有了进一步的理解。

表 5.4 不同模型在 MEISD 数据集上的实验结果

数据集	模型	情感分类			情绪识别		
		P	R	M_a -F1	P	R	M_a -F1
MEISD	MM-CNN	34.02	33.41	17.57	6.63	11.87	5.37
	BiGRU+Att	22.91	33.19	18.60	4.29	11.23	4.55
	SVM+BERT	49.26	42.01	36.78	32.45	23.73	17.86
	GRU+RoBERTa	48.02	48.48	48.04	29.14	27.91	27.90
	EfficientNet	47.52	47.81	47.15	27.60	26.89	25.84
	UPB-MTL	24.70	31.85	23.62	9.48	17.29	9.92
	MMBT	46.76	47.30	46.63	26.66	26.08	25.97
	A-MTL	49.25	50.01	49.74	28.46	28.72	28.57
	CIM	44.58	45.15	45.02	25.31	25.36	25.31
	MM-RNN	39.22	41.51	40.67	24.19	25.40	25.13
	MM-GAT	53.65	53.47	51.95	42.85	27.69	24.67
	Co-GAT	47.25	47.72	47.07	26.66	26.00	25.91
	Text-M3GAT	55.26	54.63	54.46	33.75	30.27	28.04
	Video-M3GAT	52.13	53.59	52.02	30.80	29.86	26.77
	M3GAT	55.86	56.17	54.74	32.40	30.96	28.92

MEISD 数据集：MEISD 数据集的样本相较于 MELD 数据集更加平衡，因此模型的表现出现了一些变化。表 5.4 中最容易观察到的变化是所有模型的测试结果都下降了，其原因在于数据集样本量越大，其学习难度越大。MM-CNN、BiGRU+Att 和 UPB-MTL 的表现大体处于同一水平，并且明显弱于其它基线模型。UPB-MTL 模型相比于 MELD 数据集中的表现明显下降，很有可能是因为 UPB-MTL 获得多模态特征向

量后只是将其拼接就输入至线性层，这样简单的处理方法在样本量更大的 MEISD 数据集中已经不能很好地适用。GRU+RoBERTa 和 MMBT 在两个任务的 M_a -F1 分数上都优于 SVM+BERT，可能因为 SVM 不能有效地处理大规模样本。A-MTL 在两个任务上的表现优于上述模型，并在情绪识别任务上取得了所有基线模型中最佳的 M_a -F1 分数，这表明了基于注意力机制的多任务学习方法的有效性。CIM 和 MM-RNN 由于缺乏语义丰富的文本特征表示，仍然表现不如 A-MTL 和 MMBT。EfficientNet 在所有的深度学习模型中表现不再是最佳的了，因为它缺少了文本信息的辅助。

对于两个图网络模型，MM-GAT 相比其它基线模型，其表现明显变好，并在情感分类任务上达到了基线模型中最好的表现，这是因为在 MEISD 数据集中 MM-GAT 使用了 BERT 来获得文本的特征向量。Co-GAT 在两项任务中的表现也不错，图网络模型的有效性进一步得到了验证。

Text-M3GAT 的表现两个任务上都优于 Video-M3GAT，并且在情感分类任务上也略优于表现最好的基线模型 MM-GAT，说明了 M3GAT 结构设计的有效性。最后，在两个任务中，M3GAT 比表现最好的基线模型（MM-GAT 和 A-MTL）有了进一步的提升，分别提升了 5.37% 和 1.23% 的 M_a -F1 分数。通过引入跨模态连接，它的性能也优于 Text-M3GAT。MEISD 数据集与 MELD 数据集一样都是多主体对话，但 MEISD 数据集的样本量远大于 MELD 数据集。而 M3GAT 在 MEISD 数据集上同样达到了最好的表现，体现了该模型的鲁棒性。

MSED 数据集：由于 MSED 数据集并非对话数据集，每条语句并不存在对话上下文，从而样本在 M3GAT 中也没有了上下文连接，每个样本视作只有一条语句的对话。

从表 5.5 中可以观察到，所有模型在 MSED 数据集上的表现与其在 MELD 数据集上的表现相一致。MM-CNN 和 BiGRU+Att 仍然表现最不好。其余 8 类深度学习模型的分数明显增加，其中 GRU+RoBERTa 在情感分类任务上表现最好，MMBT 在情绪识别任务上表现最好。两个图网络模型 MM-GAT 和 Co-GAT 也取得了良好的分数。相比于 MELD 数据集，Text-M3GAT 在 MSED 数据集中与 Video-M3GAT 之间的差距更大了，这再次证明了文本信息的重要性。最后 M3GAT 的 M_a -F1 分数同样超过了所有的基线模型，分别为 84.85% 和 81.97%，实现了最优性能。虽然 M3GAT 在 MSED 数据集上缺少了上下文信息的交互，但是它仍能展现出自身的优势，M3GAT 不仅可以应用于对话的情感和情绪感知，还可以应用于非对话的场景，体现了其泛用性。

综合上述三个数据集的实验结果，证明了同时构建跨任务连接、跨模态连接和上下文连接的 M3GAT 模型的有效性，从而回答了研究问题一。

表 5.5 不同模型在 MSED 数据集上的实验结果

数据集	模型	情感分类			情绪识别		
		P	R	M _a -F1	P	R	M _a -F1
MSED	MM-CNN	36.52	45.65	39.10	25.01	23.38	15.10
	BiGRU+Att	53.29	48.07	46.09	27.49	23.12	21.22
	SVM+BERT	67.81	66.35	66.38	62.45	50.25	53.03
	GRU+RoBERTa	84.63	84.76	84.69	80.41	80.51	80.41
	EfficientNet	73.29	74.24	73.42	59.88	60.57	59.89
	UPB-MTL	81.48	81.93	81.68	67.17	66.07	66.27
	MMBT	83.32	83.59	83.44	81.51	82.51	81.86
	A-MTL	83.38	84.23	83.57	80.27	80.75	80.51
	CIM	81.52	82.41	82.04	78.77	79.23	78.94
	MM-RNN	74.29	75.63	75.18	64.24	64.29	64.25
	MM-GAT	81.59	71.64	74.91	78.31	64.25	65.50
	Co-GAT	82.54	82.51	82.52	80.05	79.49	79.74
	Text-M3GAT	83.28	83.49	83.38	80.12	78.94	79.45
	Video-M3GAT	70.83	71.52	70.97	56.10	56.40	56.10
	M3GAT	84.66	85.15	84.85	82.53	81.51	81.97

5.3.5 信息种类变化对模型效果的影响

本小节将对输入 M3GAT 的信息种类进行变换，包括模态信息的变换和任务信息的变换。具体实验结果如表 5.6 所示，其中 MTL 代表多任务学习（Multi-Task Learning）使用跨任务信息，STL 代表单任务学习（Single-Task Learning）不使用跨任务信息，Text-M3GAT 代表只使用了文本模态，Video-M3GAT 代表只使用了视频模态，M3GAT 同时使用两种模态。

首先对于情感分类任务，MTL 的模型在三个数据集上都比 STL 的模型的表现好。这表明模型可以通过跨任务信息交互有效地利用跨任务知识。情绪识别任务中的细粒度情绪信息有助于模型对情感的分类。对于只使用了视频模态信息的 Video-M3GAT，

同样可以观察到其在三个数据集上 MTL 的模型相较于 STL 的模型均有提升, 这表明当没有文本模态时, 跨任务信息可以弥补跨模态信息的缺失。

其次对于情绪识别任务, MTL 的模型在三个数据集上仍然都比 STL 的模型表现好。这表明宏观的情感信息也能有效地指导情绪的识别。相比于情感分类任务, 情绪识别任务中 MTL 的模型相比 STL 的模型在大部分实验情况下提升更大, 这可能是因为情绪识别任务的类别更多、难度相对更高, 更加简单的情感分类准确度更高, 这些正确的知识更能帮助模型提升情绪识别任务的表现。

表 5.6 信息种类变化对模型效果的影响实验

任务	数据集	STL/MTL	Text-M3GAT		Video-M3GAT		M3GAT	
			M _a -F1	P	M _a -F1	P	M _a -F1	P
情感分类	MELD	STL	67.02	67.13	63.89	63.71	67.26	67.25
		MTL	67.54	67.42	64.84	64.41	68.15	68.68
		Δ	(+0.78%)	(+0.43%)	(+1.49%)	(+1.10%)	(+1.32%)	(+2.13%)
	MEISD	STL	53.54	53.67	50.46	51.15	52.64	52.76
		MTL	54.46	55.26	52.02	52.13	54.74	55.86
		Δ	(+1.72%)	(+2.96%)	(+3.09%)	(+1.92%)	(+3.99%)	(+5.88%)
	MSD	STL	83.07	83.08	70.61	70.41	84.45	84.34
		MTL	83.38	83.28	70.97	70.83	84.85	84.66
		Δ	(+0.37%)	(+0.24%)	(+0.51%)	(+0.60%)	(+0.47%)	(+0.38%)
情绪识别	MELD	STL	39.19	39.79	38.08	38.31	38.82	41.67
		MTL	39.81	39.97	38.48	51.81	40.53	43.15
		Δ	(+1.58%)	(+0.45%)	(+1.05%)	(+35.24%)	(+4.40%)	(+3.55%)
	MEISD	STL	27.53	32.77	26.16	30.01	28.21	31.70
		MTL	28.04	33.75	26.77	30.80	28.92	32.40
		Δ	(+1.85%)	(+2.99%)	(+2.33%)	(+2.63%)	(+2.52%)	(+2.21%)
	MSD	STL	78.47	79.90	54.61	55.40	80.91	81.24
		MTL	79.45	80.12	56.10	56.10	81.97	82.53
		Δ	(+1.25%)	(+0.28%)	(+2.73%)	(+1.26%)	(+1.31%)	(+1.59%)

最后对于跨模态信息, 无论是 MTL 的模型还是 STL 的模型, 使用了文本和视频

两种模态的 M3GAT，都比只使用了单模态的 Text-M3GAT 或 Video-M3GAT 的表现要好。这说明了跨模态信息的交互也有效地帮助了模型提升任务表现。

综上所述，通过对本小节实验结果的分析可以对研究问题二进行回答了：跨任务信息的信息交互与跨模态信息的信息交互可以帮助模型提升任务表现。

5.3.6 消融实验

本小节将探究 M3GAT 三种结构（上下文连接、跨模态连接以及跨任务连接）对其性能表现的贡献进行探究。为此，本小节提出了三种 M3GAT 的消融模型：（1）无上下文连接：去除了交互式对话图中的所有上下文连接，其中 M3GAT 在 MSED 数据集上本身无上下文连接故无实验结果；（2）无跨模态连接：去除了交互式对话图中的所有跨模态连接（不等同于 Text-M3GAT 或 Video-M3GAT）；（3）无跨任务连接：去除了交互式对话图中的所有跨任务连接，并对两个任务分别进行预测（等同于 STL）。

实验结果如表 5.7 所示。在三个消融模型中，无跨任务连接模型在各个数据集和各个任务中 M_a -F1 分数最低的模型中占比最高，这意味着去除跨任务连接对分类性能的影响最大。因此跨任务连接对 M3GAT 的贡献最大，其次则是跨模态连接。

表 5.7 消融实验结果

数据集	模型	情感分类		情绪识别	
		M_a -F1	P	M_a -F1	P
MELD	无上下文连接	67.91	67.73	39.48	38.39
	无跨模态连接	67.79	67.97	39.48	44.80
	无跨任务连接	67.26	67.25	39.57	44.62
	M3GAT	68.15	68.68	40.53	43.15
MEISD	无上下文连接	54.05	55.08	26.72	31.28
	无跨模态连接	53.58	54.36	26.88	31.08
	无跨任务连接	53.64	52.76	28.21	31.70
	M3GAT	54.74	55.86	28.92	32.40
MSED	无上下文连接	-	-	-	-
	无跨模态连接	84.65	84.51	81.26	81.38
	无跨任务连接	84.45	84.34	80.91	81.24
	M3GAT	84.85	84.66	81.97	82.53

通过观察情绪识别任务中消融模型的表现,还可另有发现。跨任务连接在 MELD 数据集和 MEISD 数据集上对 M3GAT 的贡献最小,但在 MSED 数据集贡献最大。一个可能的原因是对话上下文和模态信息对情绪识别有很大影响。MELD 数据集和 MEISD 数据集的样本都是多主体对话,在这些对话中,上下文和模态信息往往包含大量的与情绪有关的线索。而 MSED 数据集的样本只包含了非对话的文本和静态图像,所以跨任务连接的贡献最大。

通过消融实验的结果与分析,可以对研究问题三进行回答:跨任务连接和跨模态连接的贡献最大。

5.3.7 上下文窗口大小对模型效果的影响

本小节将探索不同的上下文窗口大小对 M3GAT 的表现效果的影响。模型默认的上下文窗口大小 Z 为 3。为了找出合适的上下文窗口大小,本小节将 Z 分别设置为 1、2、3 和 4。实验结果如表 5.8 所示。由于 MSED 数据集不是对话数据集,没有对话上下文,故本小节没有在 MSED 数据集上进行实验。

表 5.8 改变上下文窗口大小的实验结果

数据集	上下文窗口大小	情感分类		情绪识别	
		M_a -F1	P	M_a -F1	P
MELD	$Z = 1$	67.29	67.10	38.83	37.66
	$Z = 2$	68.01	68.16	39.29	38.25
	$Z = 3$	68.15	68.68	40.53	43.15
	$Z = 4$	67.26	67.18	38.92	37.67
MEISD	$Z = 1$	54.45	54.53	28.15	32.43
	$Z = 2$	54.05	53.68	27.76	33.90
	$Z = 3$	54.74	55.86	28.92	32.40
	$Z = 4$	53.65	53.38	27.64	34.71

可以观察到,当 $Z = 1$ 和 $Z = 4$ 时 M3GAT 在 MELD 数据集上的两个任务表现最不好。这表明:(1)只考虑最相近的对话上下文不足以提高模型分类性能;(2)考虑太多的上下文可能会导致噪声干扰模型做出正确判断。 $Z = 3$ 的 M3GAT 比 $Z = 1$ 的 M3GAT 获得了更好的效果,分别提高了 1.28%、2.35%、4.38%和 14.58%。这意味着对话上下文窗口大小设置为 3 是一个合适的选择。

相比之下在 MEISD 数据集上, $Z = 2$ 和 $Z = 4$ 的 M3GAT 的表现最不好。而 $Z = 1$ 的 M3GAT 表现比 $Z = 2$ 的好, 要探究该原因需要意识到 $Z = 1$ 时, 其上下文大概率是他人说的话, 而非出自自身, 而当 $Z = 2$ 时还要额外考虑自身说的上一句和下一句话。所以出现该现象的原因可能在于 MEISD 数据集中的对话中, 他人的话语对自身情感和情绪的影响更大。这也解释了为什么 $Z = 3$ 时 M3GAT 的表现又变好了。

M3GAT 在两个数据集上的两个任务中都是在 $Z = 3$ 时获得了最高的 M_a -F1 分数, 这意味着将上下文窗口 Z 设置为 3 是一个较为合适的选择。

5.3.8 层数对模型效果的影响

M3GAT 的文本编码器、视频编码器和交互式对话图都包含 L 层 GAT, 为了探索层数对模型效果的影响, 将层数 L 从 1 到 5 进行改变并获取在三个数据集上的实验结果, 如表 5.9 所示。

表 5.9 改变层数的实验结果

数据集	层数	情感分类		情绪识别	
		M_a -F1	P	M_a -F1	P
MELD	$L = 1$	68.14	67.73	38.43	39.45
	$L = 2$	67.86	68.20	37.96	38.36
	$L = 3$	68.15	68.68	40.53	43.15
	$L = 4$	29.54	31.44	13.75	15.04
	$L = 5$	31.96	36.48	12.76	15.04
MEISD	$L = 1$	54.50	56.79	26.05	32.33
	$L = 2$	55.62	55.36	25.85	32.26
	$L = 3$	54.74	55.86	28.92	32.40
	$L = 4$	33.74	33.02	8.35	8.18
	$L = 5$	31.27	27.86	9.61	10.93
MSD	$L = 1$	84.85	84.66	81.97	82.53
	$L = 2$	85.51	85.38	80.52	81.15
	$L = 3$	84.93	85.23	81.93	82.40
	$L = 4$	85.12	85.17	80.81	81.62
	$L = 5$	84.93	84.85	54.43	55.49

在 MELD 数据集上可以观察到当 $L = 3$ 时 M3GAT 在两个任务上的表现达到了最好。在 MEISD 数据集上 $L = 2$ 的 M3GAT 达到了最高的情感分类 M_a -F1 分数, $L = 3$ 的 M3GAT 达到了最高的情绪识别 M_a -F1 分数。在 MSED 数据集上 $L = 2$ 的 M3GAT 在情感分类任务上表现最好, $L = 1$ 的 M3GAT 在情绪识别任务上表现最好。对于 MELD 和 MEISD 这两个对话数据集, 每组对话包含复杂的信息, 随着层数增多, M3GAT 能让图中的节点更有机会交互、聚合信息。然而当层数过多后会引起过平滑 (Over-Smoothing) 问题^[124], 即图中的节点向量表示随着层数增加会越来越趋于一致, 使得不同节点之间的特征区分度降低, 从而导致了模型性能急剧下降。而 MSED 数据集的样本只包含一段文字和一个图像, 层数低的 M3GAT 就已经可以有效挖掘出样本中的情感和情绪信息。此外, 根据第 3 章的表 3.4 可以看出, 不同模型在 MSED 数据集上进行情感分类任务时表现相对较好且稳定, 即使是传统的深度学习基线模型 BiLSTM+AlexNet 也可以达到 78.89% 的 M_a -F1 分数。相比之下, 在进行情绪识别任务时模型的表现差异性很大, 其多模态基线模型的 M_a -F1 分数在 43.76% 到 81.95% 之间波动, 这表明情绪识别任务比情感分类任务更加对模型敏感。因此当堆叠太多层 GAT 时, M3GAT 在情绪识别任务上的表现会变差, 而在情感分类任务上的表现变化不大。

最后根据实验结果综合来看, M3GAT 在 MELD 数据集和 MEISD 数据集上设置 $L = 3$ 最合适, 在 MSED 数据集上设置 $L = 1$ 最合适。

5.3.9 说话人信息对模型效果的影响

M3GAT 的交互式对话图包含有多类说话人信息, 包括性别、职业和性格, 本小节将探索不同说话人信息对模型效果的影响。为此, 提出了四个消融模型来进行实验:

(1) 无性别信息: 删除交互式对话图中的性别节点; (2) 无职业信息: 删除交互式对话图中的职业节点; (3) 无性格信息: 删除交互式对话图中的性格节点; (4) 无说话人信息: 删除交互式对话图中的性别节点、职业节点、性格节点以及说话人节点。

实验结果如表 5.10 所示。由于 MSED 数据集不是对话数据集没有说话人, 所以本小节只在 MELD 数据集和 MEISD 数据集上进行实验。可以注意到无性别信息相对于无职业信息和无性格信息表现最不好, 这表明性别信息是最重要的说话人信息。无职业信息与 M3GAT 的实验结果最为相近, 这表明职业信息在说话人信息中作用最小 (但也有作用)。此外还可以注意到职业信息和性格信息对模型的影响很小, 可能有以下两个原因: (1) 难以获得最准确的对说话人职业以及性格的描述; (2) 一个节

点对应一条向量，所以能携带的信息有限，下游模型可能无法准确反映其变化。最后在所有消融模型中，无说话人信息的得分最低，这说明了加入说话人信息的有效性，说话人的性别、职业和性格等信息均可能会对其情感和情绪的变化产生一定的影响。

表 5.10 去除说话人信息的实验结果

数据集	模型	情感分类		情绪识别	
		M _a -F1	P	M _a -F1	P
MELD	无性别信息	67.62	68.01	39.56	42.45
	无职业信息	68.04	68.55	40.49	43.14
	无性格信息	67.71	68.27	40.04	42.89
	无说话人信息	67.17	67.83	38.87	41.26
	M3GAT	68.15	68.68	40.53	43.15
MEISD	无性别信息	54.22	55.19	28.05	31.78
	无职业信息	54.69	55.85	28.74	32.22
	无性格信息	54.41	55.35	28.56	32.07
	无说话人信息	53.26	54.68	27.24	30.77
	M3GAT	54.74	55.86	28.92	32.40

5.3.10 错误分析

为了更好地了解 M3GAT 的分类表现，本小节从 MELD 和 MEISD 数据集中收集并展示了一些 M3GAT 错误分类例子，如图 5.6 所示。左侧的蓝框包含了 STL 分类错误但是 MTL 分类正确的例子，或者 STL 和 MTL 都分类错误的例子。右侧的黄框包含了 Text-M3GAT 分类错误但 M3GAT 分类正确的例子，或者 Text-M3GAT 和 M3GAT 都分类错误的例子。

对于情感分类任务，当语句中包含一些看似积极的单词，例如“helpful”和“glad”，且情感为中性时，STL 将其错误分类至积极情感。而通过利用跨任务的情绪信息，MTL 可以得到正确的分类。然而对于一些复杂的例子需要外部信息来解决，比如说话人的性格或文化背景，MTL 可能会遇到困难。此外，对于一些疑问句它也未能正确预测其情感。

对于情绪识别任务，当 STL 分类错误时，MTL 可以在跨任务的情感信息的指导下分辨细粒度情绪。还可以看到当在说话者在表达含蓄或者很微妙的情绪时，比如语

句中没有明显带有情绪色彩的词汇或者视频中说话者的面部没有明显表情时，MTL 和 STL 都会分类失败。这是因为 MTL 无法获得有效的情感信息，所以导致了错误的分类。



图 5.6 典型的错误分类示例（来自 MELD 数据集与 MSED 数据集）

最后对于右侧黄框中的例子，Text-M3GAT 未能正确分类图（a）和图（c），而使用了多模态信息的 M3GAT 能将它们正确分类。这是因为语句中的文本信息“How are you doing”和“Never mind”只表达了中性的情感和情绪，所以 Text-M3GAT 分类错误。而 M3GAT 可以利用视频中的视觉信息，通过说话者的面部表情做出了正确判断。这突出了跨模态信息对于理解人类情感与情绪的重要性。然而在图（b）和图（d）中，无论是 Text-M3GAT 还是 M3GAT 都无法做出正确的分类，因为说话者通过隐喻表达了一种讽刺的态度，他们说的话与做出的表情与其的真实内心想法不同。因此会让模型做出错误的判断。

5.3.11 注意力可视化

本小节在图 5.7 中展示了 M3GAT 的注意力分数热图。

为了作图，首先随机挑选了一组多模态对话，被挑选出来的对话包含有 8 条语句。每条语句分别对应一个文本模态向量和一个视频模态向量，而每个模态的向量又将分别用于情感分类任务和情绪识别任务。所以会有 8 个用于情感分类的文本向量、8 个用于情绪识别的文本向量、8 个用于情感分类的视频向量和 8 个用于情绪识别的视频向量。之后在图（a）中画出了文本模态用于不同任务的向量之间的注意力分数热图，

在图 (b) 中画出了视频模态用于不同任务的向量之间的注意力分数热图, 第 0 到 7 行代表用于情感分类的模态向量, 第 8 到 15 行代表用于情绪识别的模态向量。热图可以表示出不同向量对聚合的贡献程度大小, 颜色越浅贡献程度越大。比如在图 8 (a) 的第 0 到 7 行、第 0 到 7 列中可以看出, 第 0、1 和 2 条情感文本向量对所有的情感文本向量贡献最大, 即它们向其它节点传播了更多的信息。从图 (b) 可以看出其第 0 到 7 行、第 8 到 15 列的部分黑块较多, 说明视频模态的跨任务信息交互较少。

图 (c) 和图 (d) 画出了同任务不同模态的向量之间的注意力分数热图。从图 (c) 可以观察到情感分类任务中文本模态向量为视频模态向量提供了更多的信息。从图 (d) 可以看出, 在情绪识别任务中, 文本模态向量对视频模态向量的贡献和视频模态向量对文本模态向量的贡献都很大, 说明了此时的跨模态信息交互是非常活跃的。




图 5.7 注意力分数热图

5.3.12 与大语言模型的比较

本小节将本研究所提出的 M3GAT 与大语言模型进行了比较。与 4.3.10 小节相同, 选择大语言模型 LLaMA-2 在 MSSED 数据集上的实验结果进行比较, M3GAT 与

LLaMA-2 的对比如表 5.11 所示。

表 5.11 与大语言模型比较的实验结果

模型	情感分类			情绪识别		
	P	R	M _a -F1	P	R	M _a -F1
LLaMA-2	88.16	85.84	86.56	70.23	72.06	71.07
M3GAT	84.66	85.15	84.85	82.53	81.51	81.97

可以观察到，M3GAT 虽然在情感分类任务上的表现不如 LLaMA-2，但是在情绪识别任务上实现了反超。究其原因，前者是由于 LLaMA-2 训练规模、计算资源与参数量上的优势，而后者是由于 M3GAT 考虑到了视觉模态，多种信息之间信息交互可以进一步帮助模型增加准确性。在面对需要额外视觉信息辅助才能得出正确答案的情况下，M3GAT 更能综合利用不同种类的信息交互以得出准确预测。比如带有讽刺的话语经常带有反语或比喻，因此仅根据单一文本模态判断说话人是否含有讽刺态度的难度较高，需要说话人面部表情等视觉模态作为辅助来降低讽刺识别的难度。为证明 M3GAT 相比于大语言模型 LLaMA-2 多考虑了视觉模态的优越性，本小节额外在 MUSTARD 数据集^[125]上进行了实验以做对比。

MUSTARD 数据集是一个用于讽刺识别的多模态对话数据集，包含有文本和视频模态，样本收集自电视剧，一共包含有 690 条样本，每个样本包括一条标注了是否含有讽刺的语句以及若干条该语句的历史对话信息。

对于 M3GAT，同时输入待分类的语句及其历史对话信息的文本模态和视频模态，训练多模态的 STL 模型。在一张 NVIDIA RTX A6000 显卡上进行训练，训练轮数为 30，批量大小为 16，学习率大小为 1×10^{-5} ，dropout 率为 0.5，图网络层数均为 1，上下文窗口大小为 3，使用 Adam 算法更新模型参数，并使用 ReduceLROnPlateau 策略动态调整学习率。

对于 LLaMA-2，使用 PyTorch 在 1 台服务器的 2 张 NVIDIA RTX A6000 显卡上进行单机多卡分布式训练。使用 LoRA 方法对参数量为 70 亿的 LLaMA-2 进行微调，秩设置为 8，缩放因子 α 设置为 16，dropout 设置为 0.1，微调轮数为 10 轮，每张显卡的批量大小为 1，学习率大小为 5×10^{-4} ，学习率预热比例为 0.03，梯度累计步数为 64，权重衰减为 0，使用余弦衰减动态调整学习率。在每一轮微调中，使用提示与文本进行拼接，并输入至 LLaMA-2 以生成模型的预测答案。如表 5.12 所示为用于讽刺识别任务的提示模板，待分类的文本将会替换至 {sentence} 处。若语句含有讽刺，则提示

与“yes”相拼接，反之则与“no”相拼接，即可得到模型输出的标准答案。之后计算预测答案与标准答案之间的损失，通过反向传播计算梯度并更新参数，直到结果收敛或达到最大训练轮数。

表 5.12 讽刺识别提示模板

任务	提示模板
讽刺识别	Below is an instruction that asks for sarcasm detection, paired with a sentence to be checked. Write an answer that appropriately completes the request. ### Instruction: Given the following sentence, please check if the sentence contains sarcasm. If yes, please answer yes. If no, please answer no. You can only answer yes or no. ### Sentence: {sentence} ### Answer yes or no:

实验结果如表 5.13 所示，可以观察到 M3GAT 在精确率 P、召回率 R 和 M_a -F1 三个评价指标上均超过了 LLaMA-2，且分别高出了 4.50%、12.81%和 9.82%。该实验结果展示了 M3GAT 在跨模态信息交互的帮助之下可以更加准确地识别出语句中的讽刺情感，从而证明了 M3GAT 相比于只使用了单模态的大语言模型 LLaMA-2 的优势之处，即 M3GAT 在复杂条件下更能综合利用不同种类的信息交互以得出准确预测。

表 5.13 M3GAT 与 LLaMA-2 在 MUsTARD 数据集上的实验结果

模型	讽刺识别		
	P	R	M_a -F1
LLaMA-2	69.12	62.67	64.45
M3GAT	72.23	70.70	70.78

5.4 本章小结

人类之间的对话实际上是一个多模态的过程，不仅涉及了语言上的文字，还会与

视觉信息有关，比如说话者的面部表情。所以想要充分挖掘对话之中的情感与情绪信息，就需要全面考虑不同模态的信息。在多任务多模态对话情感分析任务中有三个关键的因素，即跨任务信息、跨模态信息以及上下文信息，然而目前缺少一个可以同时解决这三个关键因素的统一框架。为了解决这个问题，本研究提出了一个多任务多模态交互式图注意力网络 M3GAT，这是一个基于跨任务信息与跨模态信息交互的对话情感分析方法，用于多模态情感分类与情绪识别的联合学习。M3GAT 的核心部分是一个交互式对话图，由三个核心子模块组成：（1）用于交互情感分类任务信息与情绪识别任务信息的跨任务信息；（2）用于交互文本模态信息与视频模态信息的跨模态连接；（3）用于交互对话上下文信息的上下文连接。本章在三个数据集上进行了实验，分别为 MELD 数据集、MEISD 数据集和 MSED 数据集。在 MELD 数据集上，M3GAT 的情感分类和情绪识别任务 M_a -F1 分数分别为 68.15% 和 40.53%，比最优的基线模型 Co-GAT 分别提升了 1.88% 和 2.01%；在 MEISD 数据集上，M3GAT 比情感分类任务表现最好的基线模型 MM-GAT 和情绪识别任务表现最好的基线模型 A-MTL 分别提升了 5.37% 和 1.23% 的 M_a -F1 分数；在 MSED 数据集上，M3GAT 的 M_a -F1 分数同样超过了所有的基线模型，分别为 84.85% 和 81.97%。这些实验结果证明了 M3GAT 构建跨任务连接、跨模态连接和上下文连接的有效性，说明了跨任务信息、跨模态信息与上下文信息的交互有助于模型更好地理解人类对话中的情感与情绪。本章还探究了信息种类变化对模型表现的影响，实验表明了多任务学习的 MTL 比单任务学习的 STL 有效，以及多模态学习的 M3GAT 比单模态学习的 Text-M3GAT、Video-M3GAT 有效，从而证明了跨任务信息交互与跨模态信息交互可以帮助模型提升任务表现。在本章中还进行了消融实验以验证交互式对话图中不同模块对 M3GAT 的贡献程度。实验结果表明跨任务连接和跨模态连接的贡献最大，证明了跨任务信息与跨模态信息交互的重要性。最后进行了 M3GAT 与大语言模型 LLaMA-2 的比较实验。M3GAT 在情感分类任务上的表现虽不如 LLaMA-2，但在情绪识别任务上实现了反超。为了验证 M3GAT 相较于 LLaMA-2 多使用了跨模态信息交互的优越性，还额外在 MUsTARD 数据集上进行了讽刺识别实验，该任务仅根据单一文本模态判断说话人是否含有讽刺态度难度较高。实验结果表明 M3GAT 的 M_a -F1 分数可以达到 70.78%，相比 LLaMA-2 的 64.45% 提升了 9.82%，从而证明了 M3GAT 的优越性。

结论与展望

情感分析方法在智能化决策中具有重要的应用价值，然而大数据时代多样化的信息类型导致模型综合利用各类信息的能力受到了挑战。该问题可以通过促进信息交互来缓解。本文针对如何促进情感分析方法融合不同种类的信息交互问题，开展了三项研究工作：多任务多模态情感分析数据集、基于跨任务信息交互的情感分析方法以及基于跨任务信息与跨模态信息交互的对话情感分析方法。

对于多任务多模态情感分析数据集，构建了 MSED 数据集。使用网络爬虫收集数据并用投票机制来人工标注样本。MSED 数据集一共包含 9190 个样本，每个样本包含文本和图像两种模态，以及情感分类、情绪识别以及欲望检测三类任务的标签。在实验部分，使用两种模态的编码器对模态进行编码，又使用多头注意力机制将两种模态的特征向量融合。在所有的基线模型中 BERT+ResNet 达到了最佳的 M_a -F1 分数，但仍不及人类的平均分数，证明了 MSED 数据集对于情感分析方法融合跨任务跨模态信息交互的研究具有应用价值。

对于基于跨任务信息交互的情感分析方法，提出了一个带有位置编码的多任务交互式图注意力网络 MIP-GAT。该模型的核心结构为一个多交互图层，该结构通过构建跨任务连接、语义依存连接和位置编码，促进了跨任务信息、语义信息和时序信息的交互。实验在 CMU-MOSEI 数据集、GoEmotions 数据集和 MSED 数据集上进行。对于 CMU-MOSEI 数据集，MIP-GAT 情感分类和情绪识别的 M_a -F1 分数分别达到了 62.74% 和 24.86%，相比最好的基线模型 AMM-MTL 分别提升了 2.88% 和 7.67%。对于 GoEmotions 数据集，MIP-GAT 分别达到了 68.76% 和 53.79%，相比最好的基线模型 AMM-MTL 分别提升了 0.98% 和 1.68%。对于 MSED 数据集，MIP-GAT 分别达到了 83.71% 和 80.82%，相比最好的基线模型 BiSGRU+MSA 分别提升了 0.88% 和 1.66%。该实验结果说明了 MIP-GAT 融合跨任务信息交互的有效性。此外，消融实验还证明了跨任务信息交互对 MIP-GAT 的表现贡献最大。

对于基于跨任务信息与跨模态信息交互的对话情感分析方法，提出了一个多任务多模态交互式图注意力网络 M3GAT。该模型的核心是一个交互式对话图，通过跨任务连接保障了情感分类任务与情绪识别任务之间的信息交互，通过跨模态连接保障了文本模态与视频模态之间的信息交互，通过上下文连接保障了语句与对话上下文之间的信息交互。在三个数据集上进行了实验，分别为 MELD 数据集、MEISD 数据集和

MSED 数据集。在 MELD 数据集中，M3GAT 情感分类和情绪识别的 M_a -F1 分数分别为 68.15% 和 40.53%，比表现最好的基线模型 Co-GAT 提升了 1.88% 和 2.01%。在 MEISD 数据集中，M3GAT 的情感分类分数为 54.74%，比表现最好的基线模型 MM-GAT 提升了 5.37%，情绪识别分数为 28.92%，比表现最好的基线模型 A-MTL 提升了 1.23%。在 MSED 数据集中，M3GAT 的分数为 84.85% 和 81.97%，同样超越了所有基线模型。此外，还通过信息种类变化对模型效果的影响实验和消融实验证明了跨任务信息交互和跨模态信息交互可以有效帮助模型理解人类对话中的情感与情绪。

在未来的工作中，将聚焦于共情对话生成方法。借助基于信息交互所感知到的更准确的情感与情绪信息作为控制因子，指导大语言模型生成更加具有感情的回复，从而解决大语言模型共情能力弱的问题，推动人工智能与人类之间建立更自然、有温度的情感联结。

参考文献

- [1] Ducange P, Fazzolari M, Petrocchi M, et al. An Effective Decision Support System for Social Media Listening Based on Cross-Source Sentiment Analysis Models[J]. Engineering Applications of Artificial Intelligence, 2019, 78: 71-85.
- [2] Etter M, Colleoni E, Illia L, et al. Measuring Organizational Legitimacy in Social Media: Assessing Citizens' Judgments with Sentiment Analysis[J]. Business & Society, 2018, 57(1): 60-97.
- [3] Verma S. Sentiment Analysis of Public Services for Smart Society: Literature Review and Future Research Directions[J]. Government Information Quarterly, 2022, 39(3): 101708.
- [4] Medhat W, Hassan A, Korashy H. Sentiment Analysis Algorithms and Applications: A Survey[J]. Ain Shams Engineering Journal, 2014, 5(4): 1093-1113.
- [5] Mao Y, Liu Q, Zhang Y. Sentiment Analysis Methods, Applications, and Challenges: A Systematic Literature Review[J]. Journal of King Saud University-Computer and Information Sciences, 2024: 102048.
- [6] Hatzivassiloglou V, McKeown K. Predicting the Semantic Orientation of Adjectives[C]. 35th Annual Meeting of the Association for Computational Linguistics and 8th Conference of the European Chapter of the Association for Computational Linguistics, 1997: 174-181.
- [7] Rish I. An Empirical Study of the Naive Bayes Classifier[C]. IJCAI 2001 Workshop on Empirical Methods in Artificial Intelligence, 2001, 3(22): 41-46.
- [8] Nigam K, Lafferty J, McCallum A. Using Maximum Entropy for Text Classification[C]. IJCAI-99 Workshop on Machine Learning for Information Filtering, 1999, 1(1): 61-67.
- [9] Cortes C, Vapnik V. Support-Vector Networks[J]. Machine Learning, 1995, 20: 273-297.
- [10] MacQueen J. Some Methods for Classification and Analysis of Multivariate Observations[C]. Proceedings of the Fifth Berkeley Symposium on Mathematical Statistics and Probability, Volume 1: Statistics, 1967, 5: 281-298.
- [11] Ouyang X, Zhou P, Li C H, et al. Sentiment Analysis Using Convolutional Neural Network[C]. 2015 IEEE International Conference on Computer and Information Technology; Ubiquitous Computing and Communications; Dependable, Autonomic and Secure Computing; Pervasive Intelligence and Computing, 2015: 2359-2364.

- [12] Hochreiter S, Schmidhuber J. Long Short-Term Memory[J]. *Neural Computation*. 1997, 9(8): 1735-1780.
- [13] Cho K, Van Merriënboer B, Gulcehre C, et al. Learning Phrase Representations Using RNN Encoder-Decoder for Statistical Machine Translation[C]. In *Proceedings of the 2014 Conference on Empirical Methods in Natural Language Processing (EMNLP)*, 2014: 1724-1734.
- [14] Murthy G S N, Allu S R, Andhavarapu B, et al. Text Based Sentiment Analysis Using LSTM[J]. *International Journal of Engineering Research & Technology*, 2020, 9(05): 299-303.
- [15] Ali W, Yang Y, Qiu X, et al. Aspect-Level Sentiment Analysis Based on Bidirectional-GRU in SIoT[J]. *IEEE Access*, 2021, 9: 69938-69950.
- [16] Vaswani A, Shazeer N, Parmar N, et al. Attention Is All You Need [J]. *Advances in Neural Information Processing Systems*, 2017: 5998-6008.
- [17] Kang H W, Chye K K, Ong Z Y, et al. The Science of Emotion: Malaysian Airlines Sentiment Analysis Using BERT Approach[C]. *International Conference on Digital Transformation and Applications*, 2021, 25: 26.
- [18] Uryupina O, Plank B, Severyn A, et al. SenTube: A Corpus for Sentiment Analysis on YouTube Social Media[C]. *LREC*, 2014: 4244-4249.
- [19] Pérez-Rosas V, Mihalcea R, Morency L P. Utterance-Level Multimodal Sentiment Analysis[C]. *Proceedings of the 51st Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*, 2013: 973-982.
- [20] Xu N, Mao W, Chen G. Multi-Interactive Memory Network for Aspect Based Multimodal Sentiment Analysis[C]. *Proceedings of the AAAI Conference on Artificial Intelligence*, 2019, 33(01): 371-378.
- [21] Zadeh A, Zellers R, Pincus E, et al. MOSI: Multimodal Corpus of Sentiment Intensity and Subjectivity Analysis in Online Opinion Videos[J]. *arXiv preprint arXiv: 1606.06259*, 2016.
- [22] Yu W, Xu H, Meng F, et al. CH-SIMS: A Chinese Multimodal Sentiment Analysis Dataset with Fine-Grained Annotation of Modality[C]. *Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics*, 2020: 3718-3727.
- [23] Zhang D, Zhang M, Zhang H, et al. MultiMET: A Multimodal Dataset for Metaphor Understanding[C]. *Proceedings of the 59th Annual Meeting of the Association for Computational Linguistics and the 11th International Joint Conference on Natural Language Processing (Volume 1:*

Long Papers), 2021: 3214-3225.

[24] Busso C, Bulut M, Lee C C, et al. IEMOCAP: Interactive Emotional Dyadic Motion Capture Database[J]. Language Resources and Evaluation, 2008, 42: 335-359.

[25] Zhang Y, Song L, Song D, et al. Scenariosa: A Large Scale Conversational Database for Interactive Sentiment Analysis[J]. arXiv preprint arXiv: 1907.05562, 2019.

[26] Cheng Z, Cheng Z Q, He J Y, et al. Emotion-LLaMA: Multimodal Emotion Recognition and Reasoning with Instruction Tuning[J]. Advances in Neural Information Processing Systems, 2024, 37: 110805-110853.

[27] Zadeh A A B, Liang P P, Poria S, et al. Multimodal Language Analysis in the Wild: CMU-MOSEI Dataset and Interpretable Dynamic Fusion Graph[C]. Proceedings of the 56th Annual Meeting of the Association for Computational Linguistics, 2018: 2236-2246.

[28] Poria S, Hazarika D, Majumder N, et al. MELD: A Multimodal Multi-Party Dataset for Emotion Recognition in Conversations[C]. Proceedings of the 57th Annual Meeting of the Association for Computational Linguistics. Association for Computational Linguistics, 2019: 527-536.

[29] Collobert R, Weston J. A Unified Architecture for Natural Language Processing: Deep Neural Networks with Multitask Learning[C]. Proceedings of the 25th International Conference on Machine Learning, 2008: 160-167.

[30] Liu X, Gao J, He X, et al. Representation Learning Using Multi-Task Deep Neural Networks for Semantic Classification and Information Retrieval[C]. Proceedings of the 2015 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies, 2015: 912-921.

[31] Huang P S, He X, Gao J, et al. Learning Deep Structured Semantic Models for Web Search Using Clickthrough Data[C]. Proceedings of the 22nd ACM International Conference on Information & Knowledge Management, 2013: 2333-2338.

[32] Luong M T, Le Q V, Sutskever I, et al. Multi-Task Sequence to Sequence Learning[C]. International Conference on Learning Representations, 2016.

[33] Dong D, Wu H, He W, et al. Multi-Task Learning for Multiple Language Translation[C]. Proceedings of the 53rd Annual Meeting of the Association for Computational Linguistics and the 7th International Joint Conference on Natural Language Processing (Volume 1: Long Papers), 2015: 1723-1732.

- [34] Liu P, Qiu X, Huang X. Recurrent Neural Network for Text Classification with Multi-Task Learning[C]. Proceedings of the Twenty-Fifth International Joint Conference on Artificial Intelligence. 2016: 2873-2879.
- [35] Ji Q, Lin X, Ma Y, et al. A Unified Labeling Model for Open-Domain Aspect-Based Sentiment Analysis[C]. 2020 IEEE Fifth International Conference on Data Science in Cyberspace (DSC), 2020: 186-189.
- [36] Peng H, Xu L, Bing L, et al. Knowing What, How and Why: A Near Complete Solution for Aspect-Based Sentiment Analysis[C]. Proceedings of the AAAI Conference on Artificial Intelligence, 2020, 34(05): 8600-8607.
- [37] Li X, Bing L, Li P, et al. A Unified Model for Opinion Target Extraction and Target Sentiment Prediction[C]. Proceedings of the AAAI Conference on Artificial Intelligence, 2019, 33(01): 6714-6721.
- [38] Liang Y, Meng F, Zhang J, et al. A Dependency Syntactic Knowledge Augmented Interactive Architecture for End-to-End Aspect-Based Sentiment Analysis[J]. Neurocomputing, 2021, 454: 291-302.
- [39] Yang H, Zeng B, Yang J, et al. A Multi-Task Learning Model for Chinese-Oriented Aspect Polarity Classification and Aspect Term Extraction[J]. Neurocomputing, 2021, 419: 344-356.
- [40] Lv Y, Wei F, Zheng Y, et al. A Span-Based Model for Aspect Terms Extraction and Aspect Sentiment Classification[J]. Neural Computing and Applications, 2021, 33: 3769-3779.
- [41] Chen W, Lin P, Zhang W, et al. Hierarchical Interactive Network for Joint Aspect Extraction and Sentiment Classification[J]. Knowledge-Based Systems, 2022, 256: 109825.
- [42] Zhang Y, Song D, Li X, et al. A Quantum-Like Multimodal Network Framework for Modeling Interaction Dynamics in Multiparty Conversational Sentiment Analysis[J]. Information Fusion, 2020, 62: 14-31.
- [43] Huddar M G, Sannakki S S, Rajpurohit V S. Attention-Based Multi-Modal Sentiment Analysis and Emotion Detection in Conversation Using RNN[J]. International Journal of Interactive Multimedia and Artificial Intelligence, 2021, 6(6): 112-122.
- [44] Plaza-del-Arco F M, Halat S, Padó S, et al. Multi-Task Learning with Sentiment, Emotion, and Target Detection to Recognize Hate Speech and Offensive Language[C]. Working Notes of FIRE 2021: Forum for Information Retrieval Evaluation, 2021.
- [45] Morency L P, Mihalcea R, Doshi P. Towards Multimodal Sentiment Analysis: Harvesting Opinions from the Web[C]. Proceedings of the 13th International Conference on Multimodal Interfaces, 2011:

169-176.

[46] Zhang Y, Song D, Zhang P, et al. A Quantum-Inspired Multimodal Sentiment Analysis Framework[J]. Theoretical Computer Science, 2018, 752: 21-40.

[47] Li Q, Melucci M. Quantum-inspired Multimodal Representation[C]. Proceedings of the Italian Information Retrieval Workshop, 2019.

[48] Liang B, Li X, Gui L, et al. Few-Shot Aspect Category Sentiment Analysis via Meta-Learning[J]. ACM Transactions on Information Systems, 2023, 41(1): 1-31.

[49] Ju X, Zhang D, Xiao R, et al. Joint Multi-Modal Aspect-Sentiment Analysis with Auxiliary Cross-Modal Relation Detection[C]. Proceedings of the 2021 Conference on Empirical Methods in Natural Language Processing, 2021: 4395-4405.

[50] Yakaew A, Dailey M N, Racharak T. Multimodal Sentiment Analysis on Video Streams Using Lightweight Deep Neural Networks[C]. Proceedings of the 10th International Conference on Pattern Recognition Applications and Methods, 2021: 442-451.

[51] Ghosal D, Akhtar M S, Chauhan D, et al. Contextual Inter-Modal Attention for Multi-Modal Sentiment Analysis[C]. Proceedings of the 2018 Conference on Empirical Methods in Natural Language Processing, 2018: 3454-3466.

[52] Zadeh A, Chen M, Poria S, et al. Tensor Fusion Network for Multimodal Sentiment Analysis[C]. Proceedings of the 2017 Conference on Empirical Methods in Natural Language Processing, 2017: 1103-1114.

[53] Huang F, Zhang X, Zhao Z, et al. Image-Text Sentiment Analysis via Deep Multimodal Attentive Fusion[J]. Knowledge-Based Systems, 2019, 167: 26-37.

[54] Xi C, Lu G, Yan J. Multimodal Sentiment Analysis Based on Multi-Head Attention Mechanism[C]. Proceedings of the 4th International Conference on Machine Learning and Soft Computing, 2020: 34-39.

[55] Wang Z, Wan Z, Wan X. TransModality: An End2End Fusion Method with Transformer for Multimodal Sentiment Analysis[C]. Proceedings of the web conference 2020, 2020: 2514-2520.

[56] Peng W, Hong X, Zhao G. Adaptive Modality Distillation for Separable Multimodal Sentiment Analysis[J]. IEEE Intelligent Systems, 2021, 36(3): 82-89.

[57] Keswani V, Singh S, Agarwal S, et al. IITK at SemEval-2020 Task 8: Unimodal and Bimodal Sentiment Analysis of Internet Memes[C]. Proceedings of the Fourteenth Workshop on Semantic Evaluation, 2020: 1135-1140.

- [58] Chuang Z J, Wu C H. Multi-Modal Emotion Recognition from Speech and Text[C]. International Journal of Computational Linguistics & Chinese Language Processing, Volume 9, Number 2, August 2004: Special Issue on New Trends of Speech and Language Processing, 2004: 45-62.
- [59] Rozgić V, Ananthakrishnan S, Saleem S, et al. Ensemble of SVM Trees for Multimodal Emotion Recognition[C]. Proceedings of the 2012 Asia Pacific Signal and Information Processing Association Annual Summit and Conference, 2012: 1-4.
- [60] Lin Y L, Wei G. Speech Emotion Recognition Based on HMM and SVM[C]. 2005 International Conference on Machine Learning and Cybernetics, 2005, 8: 4898-4901.
- [61] Fan Y, Lu X, Li D, et al. Video-Based Emotion Recognition Using CNN-RNN and C3D Hybrid Networks[C]. Proceedings of the 18th ACM International Conference on Multimodal Interaction, 2016: 445-450.
- [62] Kollias D, Zafeiriou S. Exploiting Multi-CNN Features in CNN-RNN Based Dimensional Emotion Recognition on the OMG in-the-wild Dataset[J]. IEEE Transactions on Affective Computing, 2020, 12(3): 595-606.
- [63] Poria S, Cambria E, Hazarika D, et al. Context-Dependent Sentiment Analysis in User-Generated Videos[C]. Proceedings of the 55th Annual Meeting of the Association for Computational Linguistics (volume 1: Long papers), 2017: 873-883.
- [64] Hazarika D, Poria S, Zadeh A, et al. Conversational Memory Network for Emotion Recognition in Dyadic Dialogue Videos[C]. Proceedings of the 2018 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies, Volume 1 (Long Papers), 2018: 2122.
- [65] Majumder N, Poria S, Hazarika D, et al. DialogueRNN: An Attentive RNN for Emotion Detection in Conversations[C]. Proceedings of the AAAI Conference on Artificial Intelligence, 2019, 33(01): 6818-6825.
- [66] Ishiwatari T, Yasuda Y, Miyazaki T, et al. Relation-Aware Graph Attention Networks with Relational Position Encodings for Emotion Recognition in Conversations[C]. Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing (EMNLP), 2020: 7360-7370.
- [67] Ghosal D, Majumder N, Poria S, et al. DialogueGCN: A Graph Convolutional Neural Network for Emotion Recognition in Conversation[C]. Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing and the 9th International Joint Conference on Natural Language

Processing (EMNLP-IJCNLP), 2019: 154-164.

[68] Lu X, Zhao Y, Wu Y, et al. An Iterative Emotion Interaction Network for Emotion Recognition in Conversations[C]. Proceedings of the 28th International Conference on Computational Linguistics, 2020: 4078-4088.

[69] Tu G, Wen J, Liu C, et al. Context- and Sentiment-Aware Networks for Emotion Recognition in Conversation[J]. IEEE Transactions on Artificial Intelligence, 2022, 3(5): 699-708.

[70] Wu Z, Pan S, Chen F, et al. A Comprehensive Survey on Graph Neural Networks[J]. IEEE Transactions on Neural Networks and Learning Systems, 2020, 32(1): 4-24.

[71] Zhou J, Cui G, Hu S, et al. Graph Neural Networks: A Review of Methods and Applications[J]. AI open, 2020, 1: 57-81.

[72] Hao Q, Wang C, Xiao Y, et al. Simplicies-Based Higher-Order Enhancement Graph Neural Network for Multi-Behavior Recommendation[J]. Information Processing & Management, 2024, 61(5): 103790.

[73] Gori M, Monfardini G, Scarselli F. A New Model for Learning in Graph Domains[C]. Proceedings. 2005 IEEE International Joint Conference on Neural Networks, 2005, 2005, 2: 729-734.

[74] Kipf T N, Welling M. Semi-Supervised Classification with Graph Convolutional Networks[C]. International Conference on Learning Representations, 2017.

[75] Hamilton W, Ying Z, Leskovec J. Inductive Representation Learning on Large Graphs[J]. Advances in Neural Information Processing Systems, 2017, 30.

[76] Veličković P, Cucurull G, Casanova A, et al. Graph Attention Networks[C]. International Conference on Learning Representations, 2018.

[77] Wang Y, Hu X, Gan Q, et al. Efficient Link Prediction via GNN Layers Induced by Negative Sampling[J]. IEEE Transactions on Knowledge and Data Engineering, 2024.

[78] Chen J. An Entity-Guided Text Summarization Framework with Relational Heterogeneous Graph Neural Network[J]. Neural Computing and Applications, 2024, 36(7): 3613-3630.

[79] Yin S, Zhong G. Textgt: A Double-View Graph Transformer on Text for Aspect-Based Sentiment Analysis[C]. Proceedings of the AAAI Conference on Artificial Intelligence, 2024, 38(17): 19404-19412.

[80] Wu Z, Chen J, Al-Sabri R, et al. Asymmetric Augmented Paradigm-Based Graph Neural Architecture Search[J]. Information Processing & Management, 2025, 62(1): 103897.

[81] Xing B, Tsang I. DARER: Dual-Task Temporal Relational Recurrent Reasoning Network for Joint

Dialog Sentiment Classification and Act Recognition[C]. Findings of the Association for Computational Linguistics: ACL 2022, 2022: 3611-3621.

[82] Meng Y, Zong S, Li X, et al. GNN-LM: Language Modeling Based on Global Contexts via GNN[C]. ICLR 2022 Workshop on Deep Learning on Graphs for Natural Language Processing, 2022.

[83] Li D, Gao Y, Wang Z, et al. Homogeneous Graph Neural Networks for Third-Party Library Recommendation[J]. Information Processing & Management, 2024, 61(6): 103831.

[84] Rosenblatt F. The Perceptron: A Probabilistic Model for Information Storage and Organization in the Brain[J]. Psychological Review, 1958, 65: 386-408.

[85] Rumelhart D E, Hinton G E, Williams R J. Learning Representations by Back Propagating Errors[J]. Nature, 1986, 323(6088): 533-536.

[86] Lecun Y, Bottou L, Bengio Y, et al. Gradient-Based Learning Applied to Document Recognition[J]. Proceedings of IEEE, 1998, 86(11): 2278-2324.

[87] Krizhevsky A, Sutskever I, Hinton G E. ImageNet Classification with Deep Convolutional Neural Networks[J]. Advances in Neural Information Processing Systems, 2012, 25.

[88] Simonyan K, Zisserman A. Very Deep Convolutional Networks for Large-Scale Image Recognition[C]. International Conference on Learning Representations, 2015.

[89] Szegedy C, Liu W, Jia Y, et al. Going Deeper with Convolutions[C]. IEEE Conference on Computer Vision and Pattern Recognition, 2015:1-9.

[90] He K, Zhang X, Ren S, et al. Deep residual learning for image recognition[C]. Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, 2016: 770-778.

[91] Devlin J, Chang M-W, Lee K, et al. BERT: Pre-Training of Deep Bidirectional Transformers for Language Understanding [C]. In Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies, Volume 1 (Long and Short Papers), 2019: 4171-4186.

[92] Reiss S. Multifaceted Nature of Intrinsic Motivation: The Theory of 16 Basic Desires[J]. Review of General Psychology, 2004, 8(3): 179-193.

[93] Fleiss J and Cohen J. The Equivalence of Weighted Kappa and the Intraclass Correlation Coefficient as Measures of Reliability[J]. Educational and Psychological Measurement, 1973, 33(3): 613-619.

[94] Chen Y. Convolutional Neural Network for Sentence Classification[D]. Waterloo: University of

Waterloo, 2015.

[95] Gabeur V, Sun C, Alahari K, et al. Multi-Modal Transformer for Video Retrieval[C]. European Conference on Computer Vision, 2020: 214-229.

[96] Vasiliev Y. Natural Language Processing with Python and spaCy: A Practical Introduction[M]. No Starch Press, 2020.

[97] Kingma D P, Ba J. Adam: A method for stochastic optimization[C]. International Conference on Learning Representations, 2015.

[98] Demszky D, Movshovitz-Attias D, Ko J, et al. GoEmotions: A Dataset of Fine-Grained Emotions[C]. Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics, 2020: 4040-4054.

[99] Zhang Y, Meng J E, Venkatesan R, et al. Sentiment Classification Using Comprehensive Attention Recurrent Models[C]. International Joint Conference on Neural Networks, 2016: 1562-1569.

[100] Pennington J, Socher R, Manning C D. GloVe: Global Vectors for Word Representation[C]. Proceedings of the 2014 Conference on Empirical Methods in Natural Language Processing (EMNLP), 2014: 1532-1543.

[101] Zhang X, Wu Z, Liu K, et al. Text Sentiment Classification Based on BERT Embedding and Sliced Multi-Head Self-Attention Bi-GRU[J]. Sensors, 2023, 23(3): 1481.

[102] Yang Q, Zhou J, Cheng C, et al. An Emotion Recognition Method Based on Selective Gated Recurrent Unit[C]. 2018 IEEE International Conference on Progress in Informatics and Computing (PIC), 2018: 33-37.

[103] Zhang Y, Li X, Rong L, et al. Multi-Task Learning for Jointly Detecting Depression and Emotion[C]. 2021 IEEE International Conference on Bioinformatics and Biomedicine (BIBM), 2021: 3142-3149.

[104] Chatterjee A, Narahari K N, Joshi M, et al. SemEval-2019 Task 3: EmoContext Contextual Emotion Detection in Text[C]. Proceedings of the 13th International Workshop on Semantic Evaluation, 2019: 39-48.

[105] Touvron H, Martin L, Stone K, et al. LLaMA 2: Open Foundation and Fine-Tuned Chat Models[J]. arXiv preprint arXiv: 2307.09288, 2023.

[106] Hu E J, Shen Y, Wallis P, et al. LORA: Low-Rank Adaptation of Large Language Models[C]. International Conference on Learning Representations, 2022.

- [107] Khan M, El Saddik A, Alotaibi F S, et al. AAD-Net: Advanced End-to-End Signal Processing System for Human Emotion Detection & Recognition Using Attention-Based Deep Echo State Network[J]. Knowledge-Based Systems, 2023, 270: 110525.
- [108] Kwon S. 1D-CNN: Speech Emotion Recognition System Using a Stacked Network with Dilated CNN Features[J]. Computers, Materials & Continua, 2021, 67(3).
- [109] Daly E M, Haahr M. Social Network Analysis for Information Flow in Disconnected Delay-Tolerant MANETs[J]. IEEE Transactions on Mobile Computing, 2008, 8(5): 606-621.
- [110] Loshchilov I, Hutter F. Decoupled Weight Decay Regularization[C]. International Conference on Learning Representations, 2019.
- [111] Firdaus M, Chauhan H, Ekbal A, et al. MEISD: A Multimodal Multi-Label Emotion, Intensity and Sentiment Dialogue Dataset for Emotion Recognition and Sentiment Analysis in Conversations[C]. Proceedings of the 28th International Conference on Computational Linguistics, 2020: 4441-4453.
- [112] Plutchik R. A General Psychoevolutionary Theory of Emotion[M]. Theories of Emotion. Academic Press, 1980: 3-33.
- [113] Cai G, Xia B. Convolutional Neural Networks for Multimedia Sentiment Analysis[C]. Natural Language Processing and Chinese Computing, 2015: 159-167.
- [114] Zhang Y, Liu Y, Li Q, et al. CFN: A Complex-Valued Fuzzy Network for Sarcasm Detection in Conversations[J]. IEEE Transactions on Fuzzy Systems, 2021, 29(12): 3696-3710.
- [115] Liu Y, Ott M, Goyal N, et al. RoBERTa: A Robustly Optimized BERT Pretraining Approach[J]. arXiv preprint arXiv: 1907.11692, 2019.
- [116] Tan M, Le Q. EfficientNet: Rethinking Model Scaling for Convolutional Neural Networks[C]. International Conference on Machine Learning, 2019: 6105-6114.
- [117] Vlad G A, Zaharia G E, Cercel D C, et al. UPB at SemEval-2020 Task 8: Joint Textual and Visual Modeling in a Multi-Task Learning Architecture for Memotion Analysis[C]. Proceedings of the Fourteenth Workshop on Semantic Evaluation, 2020: 1208-1214.
- [118] Lan Z, Chen M, Goodman S, et al. ALBERT: A Lite BERT for Self-Supervised Learning of Language Representations[C]. International Conference on Learning Representations, 2020.
- [119] Kiela D, Bhooshan S, Firooz H, et al. Supervised Multimodal Bitransformers for Classifying Images and Text[C]. Proceedings of the NeurIPS 2019 Workshop on Visually-Grounded Interaction and Language (ViGIL), 2019.

- [120] Chauhan D S, Dhanush S R, Ekbal A, et al. Sentiment and Emotion Help Sarcasm? A Multi-Task Learning Framework for Multi-Modal Sarcasm, Sentiment and Emotion Analysis[C]. Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics, 2020: 4351-4360.
- [121] Akhtar M S, Chauhan D, Ghosal D, et al. Multi-Task Learning for Multi-Modal Emotion Recognition and Sentiment Analysis[C]. Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies, Volume 1 (Long and Short Papers), 2019: 370-379.
- [122] Qin L, Li Z, Che W, et al. Co-GAT: A Co-Interactive Graph Attention Network for Joint Dialog Act Recognition and Sentiment Classification[C]. Proceedings of the AAAI Conference on Artificial Intelligence, 2021, 35(15): 13709-13717.
- [123] Hu J, Shen L, Sun G. Squeeze-and-Excitation Networks[C]. Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, 2018: 7132-7141.
- [124] Chen D, Lin Y, Li W, et al. Measuring and Relieving the Over-Smoothing Problem for Graph Neural Networks from the Topological View[C]. Proceedings of the AAAI Conference on Artificial Intelligence, 2020, 34(04): 3438-3445.
- [125] Castro S, Hazarika D, Pérez-Rosas V, et al. Towards Multimodal Sarcasm Detection (An Obviously Perfect Paper)[C]. Proceedings of the 57th Annual Meeting of the Association for Computational Linguistics, 2019: 4619-4629.

攻读学位期间发表论文与研究成果清单

- [1] Jia A, He Y, Zhang Y, et al. Beyond Emotion: A Multi-Modal Dataset for Human Desire Understanding[C]. Proceedings of the 2022 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies, 2022: 1512-1522. (第一作者, CCF B, 自然处理领域顶级会议)
- [2] Jia A, Zhang Y, Uprety S, et al. MIP-GAT: A Multi-Task Interactive Graph Attention Network with Position Encodings for Joint Sentiment Classification and Emotion Recognition[C]. Proceedings of the Annual Meeting of the Cognitive Science Society, 2023, 45(45). (第一作者, CCF B 类会议)
- [3] Zhang Y, Jia A, Wang B, et al. M3GAT: A Multi-Modal, Multi-Task Interactive Graph Attention Network for Conversational Sentiment Analysis and Emotion Recognition[J]. ACM Transactions on Information Systems, 2023, 42(1): 1-32. (共同第一作者, CCF A 类期刊, SCI 二区)
- [4] Jia A, Zhang Y, Uprety S, et al. Learning Interactions Across Sentiment and Emotion with Graph Attention Network and Position Encodings[J]. Pattern Recognition Letters, 2024, 180: 33-40. (第一作者, CCF C 类期刊, SCI 三区)

致谢

感谢我的导师宋大为。在您的指导下我才能在三年的研究生生活中不断精进，您充分培育了我的学术精神和思辨能力。在您的带领下实验室科研氛围自由浓厚，我们可以选择自己感兴趣的研究方向探索钻研。最后还要感谢您理解我找工作时的困难，减少了我的工作负担，托您的福我最后才找到了满意的工作。

感谢我的师兄张亚洲。可以说是您带我入门了科研之路，在我对科研一无所知的情况下如果没有您的帮助与鼓励，我肯定无法拥有现在的成绩。

感谢我的师兄吴海明。无论是在科研上还是在生活上，您都给予了我无微不至的照顾与建议。我是独生子，却能在您这里感受到如兄长般的关怀。

感谢我的父母。二十五年来您们对我的付出如寸草春晖，毕业参加工作让我终于有了可以独当一面的机会，今后我必竭尽所能，用一生回报您们的昊天罔极之恩。

感谢我的辅导员陈相老师，您在工作上认真负责，广受同学们爱戴。

感谢我的实验室同门：刘卓睿、李泽林、安睿泽、随艺、张寒青、张辰、赵天宇、姚国辉、左友慧、张辰辰、孟令昂，和我一起科研的道路上相互勉励。

感谢我的朋友与同学们：冯士伦、吴都、周尤庆、周杰烜、张铭源、张庚辰、林乾烨、赵冠淇、刘书航、董家暄、李明嘉、赵益祺、赵祉瑜、徐正斐、钱海、柳思涵、陈泳名、高祺、闫泽、宋博文、张子轩、赵宜男、汪梓博、杨一乐、王岳、周子瑜，陪伴我度过了开心又充实的学生生涯。

感谢每一位曾经帮助过我的人，你们的善举如繁星点点，照亮着我的前行之路。

感谢国家和党，当今世界冲突不断、战争频发，我深知自己并非生于和平，而是在祖国的庇护下才能心无旁骛地完成学业。毕业后我一定要用自身所学回报国家，做出自己的贡献。我衷心祝愿我们的祖国越来越强大，也真诚希望世界和平。

感谢看到最后的你，愿意看完我的毕业论文，不知对你是否有些许帮助？无论你是谁，我都希望你未来诸事顺遂、幸福安康。