

北京理工大学

本科生毕业设计（论文）

北京理工大学本科生毕业设计（论文）题目

The Subject of Undergraduate Graduation Project (Thesis) of
Beijing Institute of Technology

学 院： 计算机学院

专 业： 软件工程

班 级： 07822201

学生姓名： 姜现日

学 号： 1820191086

指导教师： 张哈希

2026 年 5 月 6 日

原创性声明

本人郑重声明：所呈交的毕业设计（论文），是本人在指导老师的指导下独立进行研究所取得的成果。除文中已经注明引用的内容外，本文不包含任何其他个人或集体已经发表或撰写过的研究成果。对本文的研究做出重要贡献的个人和集体，均已在文中以明确方式标明。

特此申明。

本人签名：

日期：

年

月

日

关于使用授权的声明

本人完全了解北京理工大学有关保管、使用毕业设计（论文）的规定，其中包括：①学校有权保管、并向有关部门送交本毕业设计（论文）的原件与复印件；②学校可以采用影印、缩印或其它复制手段复制并保存本毕业设计（论文）；③学校可允许本毕业设计（论文）被查阅或借阅；④学校可以学术交流为目的，复制赠送和交换本毕业设计（论文）；⑤学校可以公布本毕业设计（论文）的全部或部分内容。

本人签名：

日期：

年

月

日

指导老师签名：

日期：

年

月

日

北京理工大学本科生毕业设计（论文）题目

摘 要

本文……。

摘要正文选用模板中的样式所定义的“正文”，每段落首行缩进 2 个字符；或者手动设置成每段落首行缩进 2 个汉字，字体：宋体，字号：小四，行距：固定值 22 磅，间距：段前、段后均为 0 行。阅后删除此段。

摘要是一篇具有独立性和完整性的短文，应概括而扼要地反映出本论文的主要内容。包括研究目的、研究方法、研究结果和结论等，特别要突出研究结果和结论。中文摘要力求语言精炼准确，本科生毕业设计（论文）摘要建议 300-500 字。摘要中不可出现参考文献、图、表、化学结构式、非公知公用的符号和术语。英文摘要与中文摘要的内容应一致。阅后删除此段。

关键词：北京理工大学；本科生；毕业设计（论文）——请在“main.tex”开头设置

The Subject of Undergraduate Graduation Project (Thesis) of Beijing Institute of Technology

Abstract

In order to study……

Abstract 正文设置成每段落首行缩进 2 字符，字体：Times New Roman，字号：小四，行距：固定值 22 磅，间距：段前、段后均为 0 行。阅后删除此段。

Key Words: BIT; Undergraduate; Graduation Project (Thesis)

目 录

摘 要	I
Abstract	II
第 1 章 绪论	1
1.1 研究背景	1
1.2 研究意义	3
1.3 研究现状及发展趋势	4
1.3.1 语音情绪识别研究的发展历程	4
1.3.2 语音情绪识别数据集的研究现状	5
1.3.3 声学特征与信号处理方法的研究现状	6
1.3.4 基于深度学习的语音情绪识别模型研究现状	6
1.3.5 注意力机制与 Transformer 研究现状	7
1.3.6 低资源、噪声环境及跨语料库泛化研究现状	8
1.4 现有研究的总结与不足	9
1.4.1 评估方法论现状与局限	9
1.4.2 模型复杂度与数据规模	10
1.4.3 声学特征与语言特征的融合	11
1.5 研究内容	12
1.6 本文组织结构	13
第 2 章 音频情绪数据集与信号处理方法	15
2.1 音频情绪数据集的类型与选择	15
2.2 信号处理技术	17
2.2.1 信号预处理	17
2.2.2 时频变换与频谱分析	20
2.2.3 感知特征提取	26
2.2.4 特征后处理与序列长度处理	29
2.3 面临难点	32
2.3.1 语音信号的非平稳性与时间非均匀性	32
2.3.2 发话长度的可变性	33
2.3.3 外部环境因素的干扰	33
2.3.4 情绪线索的多层性与特征表示的复杂性	34
2.3.5 用户、语言及数据集的分布差异	34

2.3.6 情绪数据的规模限制与类别不平衡	35
2.4 现有技术	35
2.5 本文采用的信号处理流程	37
2.6 本章小结	37
第3章 模型结构	38
3.1 现有基础模型结构	38
3.1.1 全连接神经网络模型	38
3.1.2 卷积神经网络模型	39
3.1.3 循环神经网络模型及其变体	41
3.2 注意力机制	42
3.2.1 注意力机制的基本概念与核心要素	43
3.2.2 代表性的注意力分数计算方式	45
3.2.3 注意力的结构类型与扩展方式	46
3.2.4 注意力机制在语音情绪识别中的作用与局限	48
3.3 Transformer 结构	49
3.3.1 Transformer 的整体架构	49
3.3.2 位置编码机制	51
3.3.3 Transformer 层中的关键组成结构	52
3.3.4 Transformer 的主要特点及其适用边界	54
3.4 本章小结	55
第4章 实验设计与实验分析	56
4.1 实验参数与设置	56
4.1.1 数据集与任务设置	56
4.1.2 输入表示与预处理流程	56
4.1.3 比较模型的结构设计	58
4.1.4 训练参数与评价指标	64
4.1.5 实验环境与实现平台	64
4.2 综合实验	65
4.2.1 各比较模型的综合实验结果	65
4.2.2 CNN-Conformer 模型的结构优化路径	67
4.2.3 CNN-Conformer 模型的代表配置与结果观察	68
4.2.4 综合讨论	69

4.3 噪声条件实验	70
4.3.1 实验目的与评价流程	71
4.3.2 噪声条件设计	71
4.3.3 结果与现象分析	73
4.4 跨语料库实验	77
4.4.1 实验协议与评价流程	78
4.4.2 实验结果与现象分析	80
4.5 本章小结	83
结 论	84
参考文献	85
致 谢	89

第1章 绪论

1.1 研究背景

随着近年来人工智能技术的快速发展，人机交互系统从显式执行用户指令，转向对用户状态与意图进行隐式感知^[1-2]。用户情绪状态的感知是这种人机交互范式转型中的核心环节之一^[1-2]。系统解析用户“说了什么”这一显式信息，同时识别用户“在何种情绪状态下说话”的隐式线索。在人类决策过程中，情绪不仅映射个体的行为方式，也影响着人机交互实际表现。具备情绪理解能力的人机交互系统，能够基于用户语音中的隐式情绪线索，动态调整交互策略，从而提升交互的自然度与用户体验^[2]。情绪识别技术已应用于教育、心理咨询、医疗辅助、客户服务及数字内容交互等领域，并有潜力提升系统交互性能^[1]。快速识别用户情绪有望成为下一代人机交互系统提升人机协作效率的关键能力之一^[1-2]。

情绪可通过多种媒介进行表示，其中语音因同时承载文字语义与非文字语义，成为人机交互中情绪感知的重要媒介^[3-4]。语音凭借这种对文字语义与非文字语义的双重承载能力，在人机交互系统中承担着传递情绪信息的主要媒介角色，从而实现用户情绪与系统响应之间的有效连接^[3-4]。语音作为人类日常交流的媒介，在人机交互系统中具有一定的工程优势。第一，语音采集成本较低，无需复杂外部设备即可高效获取。第二，语音中不仅包含文字语义，还承载着语调、语速、重音、节奏、能量及音色等非文字语义要素，这些非文字语义要素为识别用户的情绪状态提供了重要的信息依据^[4]。第三，即便是相同的句子，因语速、音高、发音力度及呼吸等非文字语义要素的差异，也会呈现出具有一定差异的情绪状态。第四，这些非文字语义要素共同构成了语音传递情绪信息的多维结构，使语音情绪识别技术成为人机交互的重要研究方向之一^[3-4]。

基于语音的情绪识别研究有着较长的历史。语音情绪识别研究的重心正从特征工程向深度表示学习转变。首先，早期研究主要采用人为设计的声学特征，如梅尔频率倒谱系数 (Mel-Frequency Cepstral Coefficients, MFCC)、音高、能量及韵律等。隐马尔可夫模型 (Hidden Markov Model, HMM)、高斯混合模型 (Gaussian Mixture Model, GMM) 及支持向量机 (Support Vector Machine, SVM) 等传统机器学习分类器被用于情绪分类^[1]。上述人为设计的特征与机器学习分类器方法的主要优点在于模型解释

性较强且实现直观清晰，但在充分表征情绪这种界限模糊且具有强时间序列依赖性的信息时，仍暴露出一定的局限性。为此，为解决上述人为设计的特征的传统机器学习方法的局限性，卷积神经网络模型 (Convolutional Neural Network, CNN)、循环神经网络模型 (Recurrent Neural Network, RNN)、长短期记忆网络模型 (Long Short-Term Memory, LSTM) 及双向长短期记忆网络模型 (Bidirectional LSTM, BiLSTM) 等深度学习架构被引入语音情绪识别研究^[5-8]。研究重心逐渐转向模型自动学习语音时频特征的方向。在此基础上，近年来，研究者们的关注点逐渐从堆叠更深的网络架构转向将注意力机制与骨干架构结合，从而使模型能够更具选择性地聚焦于语音中对情绪表达的关键时间段与局部特征。这一转变标志着语音情绪识别正从传统的以特征工程为中心的阶段，向以模型结构为中心的精细表示学习与关键特征选择阶段发展。

然而，当前语音情绪识别仍面临一系列挑战。首先，情绪本身的模糊性与主观性是其主要难题之一。人类的情绪并非总是以边界分明的类别存在，且即便是同一种情绪，在跨用户身上也可能表现出截然不同的语音特征。例如，愤怒与兴奋、快乐与惊讶等紧密相邻的情绪类别，往往共享着相似的声学特性，导致分类边界趋于模糊。第二，语音情绪识别的性能在一定程度上受限于数据集的分布特性、样本质量、用户构成、录音环境及语言背景等因素。当数据集分布差异较大时，在一个数据集上训练的模型可能在其他数据集或跨用户条件下出现性能下降。这一问题在跨用户及跨语料库设定下更为常见。第三，实际应用场景中的噪声环境、多输入、信道差异及设备特征差异等因素，均可能干扰情绪线索的稳定提取。最后，带有情绪标注的语音数据规模远小于普通语音数据，且收集成本高昂，因此复杂模型并不总能取得更优效果。因此，在持续优化网络架构的基础上，本研究应侧重探索如何在数据受限及多变环境下获取稳定、可靠的情绪表示。

基于上述背景，当前语音情绪研究主要体现在两个方面：一方面注重探索更具表示能力的特征提取方法；另一方面则聚焦于设计能够在受限数据规模及实际应用场景约束下稳定运行的模型架构。特别是，情绪信息往往并非均匀分布于语音片段，而是集中于特定时间段或声学模式中。在此背景下，通过对关键情绪区间赋予更高权重以缓解非均匀分布问题的注意力机制，成为语音情绪识别的一个重要研究方向之一。因此，本文聚焦于基于语音信号的情绪识别问题，综合考量声学特征与模型架构的关系，进而探索一种能在受限数据条件下较为稳定地学习情绪特征的注意力机制情绪识别系统。上述内容为本文后续的数据集选取、信号处理流程制定、模型

架构设计及实验分析提供了研究动机。

1.2 研究意义

情绪识别技术作为识别人类状态与意图的核心技术之一，在心理健康辅助诊断、客户服务系统、教育类智能导学及基于情绪的内容生成等多个领域，持续展现出应用潜力。语音作为承载情绪特征的核心媒介，具备易获得即可采集的固有优势，能以较低成本对接实际交互场景。基于上述分析，本研究侧重于人机交互系统层面的设计与验证，旨在为相关技术从实验环境向实际应用场景的转化提供方案。

本研究致力于构建一套系统化、分层次的语音情绪识别技术方案，进一步拓展语音在人机交互领域的研究实践。首先，本研究将围绕标准化数据输入与预处理环节，设计面向语音情绪识别的数据处理流程。本研究拟设计包含重采样、长度对齐、声学特征提取与归一化处理的预处理流水线，以减少输入差异对特征分布的干扰，并为后续模型提供相对稳定的非文字语义特征。在受限数据规模下，上述预处理流程有助于提高模型训练的一致性，并为语音情绪特征提取与结果复现能提供较为稳定的输入条件。

第二，基于卷积神经网络模型与 Transformer 模型的对比架构，本研究分别构建卷积神经网络基线模型与 Transformer 模型，以比较两类模型在语音情绪识别中的表现差异。在语音情绪识别中，情绪信息往往集中于特定时间区间或声学模式之内，对关键区间赋予更高权重的注意力机制是语音情绪识别领域的研究方向^[9-11]。Transformer 模型凭借自注意力机制，可用于捕捉语音信号中的长程依赖关系，在建模全局上下文方面具有一定潜力。本研究通过对比实验，分析卷积神经网络模型与 Transformer 模型在数据受限条件下的识别能力、稳定性及计算效率，为人机交互系统中模型结构的选择提供依据。

第三，拟构建适用于受限数据规模下的稳定评估框架。针对语音情绪识别中数据规模受限、情绪类别边界模糊及模型性能易受数据划分影响等问题，本研究拟引入差异化实验、交叉验证及混淆矩阵深度分析等策略。通过上述多维度评估策略，构建相应的评估方法。上述稳定评估框架旨在突破单一准确率指标的局限，为模型的科学评价与结果解释提供更为可靠的依据。

最后，本研究将基于上述评估框架，进一步考察模型在实际应用场景下的泛化能力。为此，本研究将引入噪声环境、多输入等环境干扰，以及跨用户、跨语料库等

数据分布变化，从而验证模型在非理想条件下的稳定性与可靠性。上述探索旨在评估模型从实验环境向实际应用场景迁移的可行性，为语音情绪识别技术的工程化落地提供实证依据。

随着大模型与注意力机制在文本等时序信息处理中的发展，Transformer 在情绪识别任务中展现出一定潜力。语音情绪识别中，情绪信息往往并非均匀分布于整个语音片段，而是集中于特定时间段或声学模式。因此，对关键信息赋予更高权重的注意力机制成为语音情绪识别领域的重要研究方向之一^[9-11]。Transformer 凭借自注意力机制，能够更有效地处理长期依赖关系并把握全局上下文，从而被视为弥补传统卷积神经网络模型与循环神经网络模型固有缺陷的重要方案之一^[6,10-11]。此外，利用大规模无标注数据的自监督预训练已成为应对标签稀缺问题的重要研究方向之一^[12-13]。与上述自监督预训练方向不同，本研究则更侧重于从模型架构维度深入探究注意力机制与 Transformer 对捕获关键情绪信息的具体贡献。

1.3 研究现状及发展趋势

1.3.1 语音情绪识别研究的发展历程

本文将语音情绪识别的发展演进大致划分为以下四个阶段：传统的基于特征工程阶段、基于机器学习阶段、基于深度学习阶段，以及利用注意力机制、Transformer 与预训练模型的新兴阶段。在早期研究中，主流方法主要依赖于人为设计的声学特征，并以此为依据进行情绪分类。该阶段的研究核心在于探究如何从语音信号中提取特征以更好地反映情绪差异，其中梅尔频率倒谱系数、音高、能量、共振峰及韵律等特征被广泛研究^[1]。上述人为设计的特征与分类器方法的优势在于具有较强的可解释性，且能在数据规模较小的条件下进行实验。然而，上述人为设计的特征与分类器方法难以充分刻画情绪的复合性及其时序动态变化，仍存在一定局限^[6-7]。

基于机器学习的方法不仅关注特征工程本身，也开始注重提升分类算法的性能。由此，支持向量机 (SVM)、隐马尔可夫模型 (HMM)、高斯混合模型 (GMM)、K 近邻算法 (K-Nearest Neighbors, KNN) 及随机森林 (Random Forest, RF) 等多种机器学习分类器陆续被引入，研究者们广泛开展了基于人为设计的特征与各类分类器组合的情绪分类性能比较研究^[1]。特征选择、数据归一化及降维等辅助技术也得到研究者的关注，语音情绪识别从而被系统化为典型的模式分类问题^[1]。尽管如此，上述基于人为设计的特征的传统机器学习方法仍很大程度上受限于研究人员的先验判断，难以

充分捕捉情绪表达中固有的非线性特征与长期依赖关系^[1,6-7]。

深度学习技术的引入成为语音情绪识别研究的关键转折点。卷积神经网络模型被广泛用于从语谱图或对数梅尔谱等时频表示中自动学习局部模式^[6,8]。循环神经网络模型、长短期记忆网络模型等则被用于对语音信号内部的时间连续性及其上下文依赖关系进行建模^[7,9]。在此基础上，结合卷积神经网络模型与循环神经网络模型的混合架构被提出，进一步促进了同时学习局部特征与时序信息的研究趋势^[5-6,8]。最终，语音情绪识别研究逐渐从人为设计的特征转向表示学习的范式。

随着大模型与注意力机制在文本等时序信息处理中的发展，Transformer 在情绪识别任务中展现出一定潜力。语音情绪识别中，情绪信息往往并非均匀分布于整个语音片段，而是集中于特定时间段或声学模式。因此，对关键信息赋予更高权重的注意力机制成为语音情绪识别领域的重要研究方向之一^[9-11]。Transformer 凭借自注意力机制，能够更有效地处理长期依赖关系并把握全局上下文，从而被视为弥补传统卷积神经网络模型与循环神经网络模型固有缺陷的重要方案之一^[6,10-11]。此外，利用大规模无标注数据的自监督预训练已成为应对标签稀缺问题的重要研究方向之一^[12-13]。与上述自监督预训练方向不同，本研究则更侧重于从模型架构维度深入探究注意力机制与 Transformer 对捕获关键情绪信息的具体贡献。

1.3.2 语音情绪识别数据集的研究现状

数据集一直是语音情绪识别研究的出发点，同时也是评估模型性能的基准要素。目前语音情绪识别研究中常用的数据集包括 RAVDESS、IEMOCAP、EMO-DB、SAVEE、TESS、CREMA-D、MSP-Podcast、MSP-IMPROV 及 CASIA 等^[1,14]。这些数据集在语种、用户规模、情绪类别划分、录音环境、发音模式及标注范式等维度上均存在一定差异^[1,14]。此类差异不仅体现在样本数量上，更与模型所能习得的情绪特征及泛化能力密切相关。

当前主流的语音情绪识别数据集主要可分为表演型数据集与自发型或自然型数据集^[14]。诸如 RAVDESS、EMO-DB、CASIA 等表演型数据集，多收录了在受控环境下由演员演绎的情绪语音；这类数据集的主要优势在于情绪标注相对明确，实验具有较高的可重复性。相比之下，IEMOCAP、MSP-IMPROV 等数据集则融入了对话、即兴或自然发音等元素，能够更真实地反映实际交互场景中的情绪表达^[1,14]。然而，自然型数据集也面临着情绪边界模糊、标注一致性不足及预处理难度较大等挑

战^[1,14]。数据集的选择并非仅取决于规模或被引频次，而是与研究目标（关注界限清晰的基准测试验证，或更重视实际应用场景下的泛化能力）密切相关。

对于情绪标注方式而言，数据集可划分为离散标签（如愤怒、快乐）与连续维度（如效价、唤醒度）两类。前者主要适用于离散类别分类任务，后者则能更细腻地刻画情绪。然而，离散标签数据集往往难以充分反映情绪的复合性与渐变性，而连续维度标注在实验设计与评价体系构建方面也面临一定的技术困难^[1,14]。

1.3.3 声学特征与信号处理方法的研究现状

在语音情绪识别中，输入信号质量及信号处理具有重要作用。早期研究主要基于先验知识手工提取具有情绪区分度的声学特征，例如梅尔频率倒谱系数、音高、能量、过零率等。这些特征既可单独使用，也可组成综合特征集。基于 OpenSMILE 工具提取的 eGeMAPS、ComParE 等特征集，长期作为情绪识别领域的重要基准之一，为后续研究提供了稳定的基线^[1,14]。

随着深度学习的发展，输入表示从定长特征向量转向以语谱图、对数梅尔谱图等时频表示为主。这些时频表示能有效保留语音内在的时序动态与频谱特征，与卷积神经网络模型及 Transformer 等深度学习架构具有良好的协同性^[6,8,10]。近期研究不仅比较同一音频的多种表示，并探讨表示融合技术，表明输入特征成为决定模型感知情绪的核心设计维度之一^[6,8,10]。

信号处理方法也朝着精细化方向发展。在信号处理方面，针对变长序列的填充 (padding)、滑动窗口分割、序列分割等技术受到研究者的关注。此外，噪声消除、数据增强等方法也逐渐成为研究热点^[7,15]。近年来，诸多研究指出仅凭实验室环境难以验证模型的泛化能力，需要考察包含噪声或多输入等干扰情景下的识别性能^[15-18]。声学特征提取与信号处理技术是语音情绪识别的主要基础。这些信号处理技术在输入特征与模型的深度融合中起到重要作用，成为连接数据预处理与模型构建的主要环节之一，为系统识别能力提供了支撑^[1,14]。

1.3.4 基于深度学习的语音情绪识别模型研究现状

基于深度学习的语音情绪识别技术，最初是为了解决传统人为设计特征方法的局限性而提出，现已成为人机交互领域的重要研究方向之一。早期的深度学习研究主要围绕卷积神经网络模型与循环神经网络模型展开。卷积神经网络模型能够从时频特征中有效提取局部模式，而循环神经网络模型、长短期记忆网络模型等则适用

于对语音信号中的时间连续性与序列上下文进行建模^[5-7]。在此基础上，结合卷积神经网络模型与循环神经网络模型优势的混合架构被广泛探索，以同时学习局部特征与时序信息^[5-6,8]。

相较于传统机器学习分类器，这些深度学习架构不仅具有较强的非线性映射能力，更能够自动学习无需人为设计的深层特征。卷积神经网络模型可以有效提取特定频段上的能量集中区域与语谱图中的局部结构差异，而长短期记忆网络模型则能够对整段语音中的音高变化及能量变化轨迹进行建模^[6-8]。随着近期各类一维、二维卷积神经网络模型变体以及其与循环神经网络模型的融合机制被相继提出，语音情绪识别被视为一项复杂的序列学习任务^[4-6,8]。

然而，深度学习架构也存在一定局限性。卷积神经网络模型受限于局部感受野，难以建模长程时序的全局依赖关系^[6-10]。而循环神经网络模型的顺序计算机制往往导致并行效率较低，且在处理超长序列时可能面临较高的计算开销^[7,9]。带有情绪标注的训练数据通常规模较小，因此单纯增加模型参数容易导致过拟合问题。过拟合使得模型仅能记忆特定训练集的特征，难以学习到情绪的通用特征，从而影响模型的泛化能力^[7,15,19]。因此，当前研究不局限于单纯增加网络深度，而是在保证性能的前提下，积极探索引入注意力机制等优化架构来强化全局特征捕捉。这些探索旨在控制模型复杂度的同时提升识别性能^[6,10-11]。

1.3.5 注意力机制与 Transformer 研究现状

语音情绪识别中，情绪信息并非均匀分布于整个语音片段，这成为注意力机制被引入语音情绪识别的重要背景之一。现有的卷积神经网络模型与循环神经网络模型在处理输入时通常对所有输入特征赋予相近的权重，然而实际的情绪线索往往更集中地体现于特定时间段、特定词汇或特定频段^[6,8,19]。为充分反映情绪信息在语音片段中的非均匀分布特性，近年来研究者们广泛探索注意力机制，使模型对关键情绪信息赋予更高权重^[9-11]。此外，加性注意力 (Additive Attention)、多头注意力机制 (Multi-Head Attention)、局部注意力机制 (Local Attention)、交叉注意力机制 (Cross-Attention) 及通道注意力机制 (Channel Attention) 等多种衍生结构相继被提出^[9-10,20-21]。

Transformer 以自注意力机制为核心，能够直接对序列内部的全局关系进行建模，在语音情绪识别研究中逐步成为核心方法之一^[6,10-11]。不同于传统循环神经网络模型的串行处理机制，Transformer 不仅支持并行计算，更能直接建模长距离依赖关系，从

而在解析复杂语音结构时展现出一定优势^[6,10-11]。在此背景下，研究者们相继提出了多种基于 Transformer 的情绪识别模型。其中包括纯 Transformer 架构、卷积神经网络模型与 Transformer 的混合架构、将窗口 Transformer(Swin Transformer) 应用于语谱图分析的模型，以及结合移位窗口或动态窗口的改进架构^[10-11]。Transformer 在全局上下文建模与长时依赖处理方面具有一定优势，结合注意力机制可更精准地捕捉关键情绪特征^[10-11]。

然而，基于注意力机制与 Transformer 的方法并非在所有场景下均适用。此类结构通常伴随较大的参数规模与计算开销，并对训练数据量提出较高要求。在数据受限条件下，模型容易因过度参数化而难以获得相应的泛化能力^[15,22-23]。因此，当前研究不再局限于单纯扩大 Transformer 规模，转而深入探索在卷积神经网络模型中嵌入轻量级注意力模块，或引入较为简洁的辅助注意力架构^[10-11,20]。上述研究趋势表明，注意力机制与 Transformer 不仅是重要的技术手段，更需要根据实际数据规模与计算资源进行权衡与选择。

1.3.6 低资源、噪声环境及跨语料库泛化研究现状

在当前的语音情绪识别研究中，相比于单一数据集上的准确率，模型在实际应用场景中的鲁棒性与泛化能力正逐渐成为更重要的衡量标准之一。这一发展趋势主要源于以下两项客观因素：其一，带有情绪标注的音频数据收集成本相对较高，相关数据集规模通常较小，使得许多研究仍面临低资源条件的限制^[8,13,15]。其二，在实际应用场景中，环境噪声、多输入干扰、信道差异、跨用户的发音习惯以及预训练数据集与目标任务之间的数据分布差异等因素相互交织，容易导致同一模型在不同测试环境下出现稳定性下降^[15-18]。

在针对噪声环境的相关研究中，噪声添加、多输入模拟、端到端语音增强以及数据增强等技术逐渐成为研究重点^[7,15,24-25]。相关研究指出，仅凭实验室环境难以有效评估模型的实际应用性能，因此在多种噪声条件下进行鲁棒性评估尤为重要^[15-16,18]。针对跨用户及跨语料库问题，研究者们正积极探索降低模型对特定源领域或用户样本较强依赖的去相关方法^[16-18,23]。领域自适应、迁移学习、域泛化策略、多条件混合训练及特征归一化等方法，已成为应对该问题的重要技术途径^[14,16-17,23]。

另一方面，利用自监督预训练语音模型的低资源情绪识别研究呈较快增长趋势^[12-13,26-28]。以 Wav2Vec2、HuBERT、WavLM 及 DistilHuBERT 等为代表的自监督预

训练模型，能够从无标注数据中学习通用声学特征^[29-31]。这些模型可为标注数据不足的情绪分析提供深层特征，相关研究已在 IEMOCAP 等数据集上验证了冻结特征、全量微调、说话人归一化及下游迁移等策略的有效性^[26-28,32]。此类大规模模型的运行成本仍较高，微调的稳定性仍有待提高；围绕参数高效微调的研究正尝试缓解部署与迁移成本^[13,33-34]。此外，预训练领域与目标情绪数据集之间的数据分布差异仍存在一定挑战^[12-13,18]。因此，融合低资源条件、噪声环境及跨语料库的综合问题，已成为一项综合性挑战，需要研究者们从输入特征、模型结构、学习策略到评估框架进行系统的重新思考与设计。

1.4 现有研究的总结与不足

尽管语音情绪识别技术在模型架构与特征表示等方面取得了进展，现有研究在评估方法、模型设计及多模态融合等层面仍存在若干有待研究的方向。第一，当前评估体系多依赖单一数据集上的准确率指标，对模型在实际应用中的泛化能力、置信度校准及跨场景鲁棒性的考量仍显不足^[6,19]。第二，以 Transformer 为代表的复杂模型虽在性能上表现出一定优势，但其对数据规模与计算资源的要求较高，在数据受限条件下易出现过拟合问题，模型效率与表达能力的平衡仍待探索^[6,10]。第三，声学特征与语言特征的融合虽被认为是提升情绪识别性能的重要方向，但现有方法在特征对齐、模态交互及低资源场景下的适应性等方面仍面临诸多挑战^[3,35]。上述问题的存在，制约了语音情绪识别技术从实验环境向实际应用场景的转化，也为本研究的改进方向提供了切入点。

1.4.1 评估方法论现状与局限

近年来，语音情绪识别研究在模型架构与特征表示等方面取得了一定进展，然而在评估体系的构建与泛化能力的考量上，现有研究仍存在一定的局限性^[6,16,19]。当前多数研究主要依赖于单一数据集上的准确率作为核心评价指标。然而，不同研究在数据预处理、特征提取及实验设置等环节存在一定的差异。这些差异导致不同模型之间的性能结果难以有效比较^[1,6-7,19]。特定数据集上取得的优异表现往往难以充分反映模型在实际应用场景中的泛化能力。这种评估体系的不完善已成为制约语音情绪识别领域进一步发展的关键因素^[1,6,16]。

在泛化能力的评估方面，现有研究往往面临跨用户、跨语料库及跨场景下的能力

下降问题。相关研究指出，在特定数据集上表现良好的模型，在面对跨用户、不同语言背景或噪声环境时，这些模型的识别准确率往往出现一定程度的下降。这种性能下降现象与由跨用户差异引起的领域偏移密切相关^[15-17,22]。除了准确率与泛化能力，模型的置信度校准也是评估体系的重要维度。置信度校准旨在使模型的预测置信度与实际准确性相匹配，避免模型出现过于自信或信心不足的情况。部分模型往往倾向于表现出较高自信度，但其置信度与预测准确性之间的一致性仍有待提高^[6,19,22]。已有研究尝试将置信度校准方法引入语音情绪识别技术。然而这些置信度校准方法在实际应用中的效果可能仍存在一定局限性，且在跨用户、跨语料库等复杂场景下可能对模型性能产生一定影响^[6-7,22]。

针对评估体系不完善、泛化能力不足及置信度校准等问题，未来的研究可从方法论层面进行系统性探索与设计。首先，已有研究指出，多样化评估指标体系对提升评估可靠性具有一定作用^[1,6,19]。该体系可在准确率之外纳入对模型置信度、稳定性及跨场景泛化能力的综合考量。其次，相关研究也强调推动评估协议标准化的重要性，明确数据预处理、特征提取及实验设置的规范，有助于提高不同研究之间结果的可比性^[19]。此外，相关研究进一步强调在多种噪声条件、跨用户及跨语料库等复杂场景下进行模型性能评估的重要性，通过构建更具挑战性的测试基准，更真实地反映模型在实际应用中的鲁棒性与可靠性^[1,6]。构建系统化的评估框架，有助于为语音情绪识别技术的工程化落地提供更为可靠的实证依据。

1.4.2 模型复杂度与数据规模

近年来，语音情绪识别研究在模型架构方面取得了一定进展，其中以 Transformer 为代表的预训练模型在语音情绪识别技术中表现出一定性能提升^[6,10-11]。然而，以 Transformer 为代表的预训练模型参数量通常较大，这些模型的训练与推理过程对计算资源与数据规模提出了较高要求^[6,10-11]。相关研究指出，在语音情绪识别技术中，标注数据的获取成本较高，使得现有数据集规模相对较小，一定程度上制约了复杂模型的泛化能力^[8,13,22]。在数据受限条件下，模型参数过度增加往往导致过拟合问题，使得模型倾向于记忆特定训练集的特征，而难以学习到具有泛化能力的情绪表征^[6-8,10-11,13,19,22]。

在模型设计层面，当前研究对计算效率与资源消耗的考量仍有待进一步探索^[15,23]。标准的自注意力机制具有随输入序列长度呈二次增长的计算复杂度，而语音信号往

往持续时间较长且存在一定程度的时序冗余，这种计算特性使得 Transformer 在语音情绪识别技术中的部署面临一定挑战^[6,10-11]。为缓解这一问题，近年来出现了多种高效注意力机制变体，例如窗口注意力机制、动态窗口注意力机制及通道注意力机制等，这些机制旨在降低计算开销的同时保持模型性能^[8,10-11,20-21]。然而，相关研究指出，这些高效注意力机制在语音情绪识别领域的系统性评估仍较为有限，这些方法在实际部署中的表现仍有待进一步验证^[6,8]。

针对预训练模型在计算资源受限条件下的部署问题，相关研究已通过模型压缩技术探索效率与性能的平衡^[15-16,22]。编码器层剪枝、知识蒸馏及量化等方法，可使压缩后的模型在保持一定识别准确率的同时，有效降低参数量与推理时延^[15-16]。然而，压缩过程中往往伴随一定程度的信息损失，如何在模型表达能力与计算效率之间实现有效平衡，仍是当前研究面临的主要挑战^[15-16,22-23]。

1.4.3 声学特征与语言特征的融合

传统的语音情绪识别研究主要关注声学特征，例如梅尔频率倒谱系数、音高、能量等。这些特征能够捕捉语音中的韵律、音质等非文字语义信息，在一定程度上反映用户的情绪状态。然而，语音信号中除声学信息外，还包含文字语义信息这一重要维度，但现有研究对此关注相对较少。语言内容承载的语义信息，可为情绪表达提供重要线索，例如特定的情绪词汇、句式及表达方式^[2-3]。相关研究指出，声学特征与语言特征具有互补性，这两种特征的有效融合有望提升情绪识别的准确性与鲁棒性^[3,36-38]。

声学特征主要反映语音表达方式（即“怎么说”），如语调、语速、音高等。语言特征则主要反映表达内容（即“说什么”），如词汇、句法、语义等。人类在表达情绪时，通常会同时通过声学特征与语言特征传递信息。例如，同样一句话“真是太好了”，用不同的语调可表达真诚的高兴，也可能传递讽刺意味。因此，仅依靠声学或语言特征往往难以全面捕捉复杂情绪。近年来，研究者们逐步探索声学特征与语言特征的融合方法，以期综合利用这两种特征的优势，有望提升情绪识别的性能^[3,36,39-40]。

声学特征提取通常采用人为设计的特征（如梅尔频率倒谱系数、韵律特征）或基于深度学习的自动特征学习方法（如语谱图、预训练声学模型 Wav2Vec 2.0 等）^[10,26-27,29]。语言特征提取则多基于词嵌入（word embeddings）或预训练语言模型（如 BERT、RoBERTa）得到文本的高维语义表示^[3,36,40]。在语音情绪识别技术中，通常需要对语

音进行语音识别（ASR）获得文本转录，这一过程可能带来语音识别错误的风险，从而影响融合效果^[36,40-41]。

声学特征与语言特征融合方法主要分为三类：早期融合（特征级融合）、中期融合（隐藏层融合）和晚期融合（决策级融合）。早期融合将声学特征与语言特征拼接后输入分类器；中期融合在多模态模型的中间层交互；晚期融合则分别训练两个单模态模型后融合输出^[3,37-38]。随着注意力机制的发展，基于跨模态注意力（cross-modal attention）的融合方法逐渐成为主流，能够动态加权交互不同模态的信息，更有效地捕捉模态间的关联^[36,39-40,42]。此外，一些研究提出基于 Transformer 架构的多模态模型，在 IEMOCAP 等数据集上表现出一定潜力^[36,39-40]。

尽管声学特征与语言特征融合方法表现出一定潜力，但仍面临一定挑战。首先，语音识别（ASR）的错误可能影响语言特征的质量，特别是在噪声环境或非正式口语场景中，ASR 性能下降可能使融合效果受到一定影响^[40-41]。其次，声学特征与语言特征之间的对齐问题仍需解决：词与文本的时序粒度差异，使得如何有效融合仍有待探索^[3,36,39]。此外，现有融合模型往往依赖大量标注数据，在低资源场景下泛化能力可能受到一定限制^[2-3,40]。最后，一些融合方法在特定数据集上表现良好，但这些方法在不同语言、文化和情境下的鲁棒性仍有待验证^[42-43]。

针对声学特征与语言特征融合方法面临的挑战，未来研究可从以下几个方向进行探索：一是探索具有更强鲁棒性的语音识别技术，以降低语音识别错误对融合效果的影响；二是发展无监督或自监督的多模态预训练方法，以减少对标注数据的依赖；三是研究更精细的跨模态对齐机制，以期实现声学特征与语言特征的深度融合；四是在更多实际应用场景和不同语言环境中进一步考察模型的泛化能力。上述四个方向的探索，有望推动声学特征与语言特征融合在语音情绪识别中的发展^[2-3,40,42]。

1.5 研究内容

本研究聚焦于构建一个基于语音情绪识别系统。本文聚焦于以下四个主要维度展开研究：数据筛选与输入处理流程的构建、基于卷积神经网络模型的基线模型设计、轻量级注意力机制的引入，以及面向受限数据规模的鲁棒性评估框架的搭建。

第一，设计面向语音情绪识别技术的数据集筛选与输入处理流程。本研究以公开且结构相对清晰的语音情绪数据集为主，梳理这些数据集的基础属性，包括标签构成、用户分布、情绪类别、录音时长及噪声情况等，旨在为后续模型的输入表示提

供稳定的基础。在梳理数据基础属性的基础上，设计整合重采样、长度对齐、特征提取、归一化处理及数据质量控制的输入处理流水线，以为后续模型提供稳定的输入表示。此项工作的主要意义，不仅在于对数据本身的梳理，更在于对可能影响结果的输入变量进行预先控制，从而为提升后续模型训练的稳定性与结果的复现性提供可靠基础。

第二，面向语音情绪识别技术，设计基于卷积神经网络模型的基线模型。本研究选取对数梅尔谱图或梅尔频率倒谱系数等时频表示作为输入特征，以帮助卷积神经网络模型学习语音信号中的局部时空模式^[6,8]。设计该基线模型的主要目的在于，为后续融合注意力机制的扩展模型提供清晰的性能基准。

第三，基于卷积神经网络模型与 Transformer 模型的对比架构，本研究构建卷积神经网络基线模型与 Transformer 模型，以比较两类模型在语音情绪识别中的表现差异。在语音情绪识别中，情绪信息可能集中于特定时间区间或声学模式之内。基于上述观察，对关键时间区间赋予更高权重的注意力机制，被视为语音情绪识别领域的研究方向。Transformer 模型凭借自注意力机制，可用于捕捉语音信号中的长程依赖关系，在建模全局上下文方面具有一定潜力。本研究通过对比实验，分析卷积神经网络模型与 Transformer 模型在数据受限条件下的识别能力、稳定性及计算效率，为人机交互系统中模型结构的选择提供基础。

第四，拟构建兼顾受限数据规模与结果可解释性的鲁棒性评估框架。鉴于多数语音情绪数据集规模受限、情绪类别边界模糊，且模型能力容易受数据划分影响，本研究将避免仅依赖单一实验准确率的简单评价方式。在可行范围内，研究将引入差异化实验、交叉验证、混淆矩阵分析及相似情绪类别间的细粒度错误分析等方法，以构建更为多维的验证体系。在此过程中，还将同步考察噪声环境、跨用户及验证集划分变化对评估结果的影响，以提升实验结果的泛化能力与科学可解释性。

上述研究过程包括从数据提取到模型构建的主要阶段，各模块及执行顺序如图 1-1 所示。

1.6 本文组织结构

本文共分为四章，各章的具体内容安排如下：

第一章介绍本文的绪论。首先阐述语音情绪识别研究的背景与现实需求，并总结研究的理论价值与实际意义。其次，梳理语音情绪识别领域的研究现状与主要




图 1-1 总体研究流程图：涵盖数据预处理、卷积神经网络模型与 Transformer 并行对比及结果分析

趋势，并阐述本文拟开展的核心研究内容。

第二章主要介绍语音数据集的选择与语音信号的处理方法。首先，对比分析当前语音情绪识别领域常用公开数据集的类型与特点，并说明本研究在数据集选择上的标准与考量。其次，梳理语音信号处理中的主要问题及现有技术对策，并说明本研究所采用的输入处理流程与特征表示方法。为后续模型训练与实验验证提供可靠的数据基础与特征表示方法。

第三章介绍面向语音情绪识别的模型架构设计。首先，对全连接神经网络、卷积神经网络模型及循环神经网络模型等传统网络结构的功能特征与局限性进行梳理。其次，介绍注意力机制，阐明该机制在使模型聚焦于语音信号中关键情绪信息方面的优势，并分析 Transformer 架构的基本原理与架构特点。

第四章介绍本研究的实验设计与结果分析。首先，说明实验软硬件配置、数据集规模、训练集与验证集的划分、损失函数及优化手段选择等主要实验参数设定。其次，呈现包含基线模型与融合注意力的增强模型在内的综合评估结果，并对比能力及分析其机理。最后，通过开展噪声环境实验、跨语料库验证、细粒度错误分析及基于用户维度的针对性评估等扩展验证，全面且客观地审视本文所提模型架构的实际效用界限与局限性。

第2章 音频情绪数据集与信号处理方法

2.1 音频情绪数据集的类型与选择

语音情绪识别系统的性能不仅取决于模型结构本身，还与所采用数据集的类型、标签构成方式以及输入语音的处理流程密切相关。不同语音情绪数据集在语种、用户构成、情绪类别、采集环境、交互形式及公开访问性等多个维度上存在一定差异，这些差异与后续的特征提取、模型训练、实验条件设定及结果解读密切相关。在设计语音情绪识别方法时，不应该仅关注模型本身，而应将数据集的基础属性与输入处理流程一并纳入考量。

本节梳理当前语音情绪识别研究中常用的代表性公开数据集，比较与分析其基础属性。将以各数据集的语言、采集方式、情绪表达特点、用户构成、情绪标签结构、数据规模、公开访问性及可用性为中心进行比较，并在此基础上尝试归纳适合本研究的数据集选择标准。详细对比见表 2-1。

从表 2-1 可见，代表性语音情绪数据集首先根据情绪采集方式与情绪表达性质被较为明确地区分。RAVDESS、EMO-DB、SAVEE、TESS、CREMA-D、CASIA 等数据集属于在受控环境下由演员表达情绪的表演型基准数据集，这些数据集的共同特点是情绪标签相对明确、实验条件较为稳定。这类数据集较为便于模型间性能比较与算法基线构建，并有助于保障基础实验的可重复性，因此在语音情绪识别研究中作为代表性基准数据集之一使用。相比之下，IEMOCAP 与 MSP-IMPROV 包含对话与即兴互动，比表演型基准数据集具有相对更为复杂的情绪表达；而 MSP-Podcast、FAU Aibo、EMOVOME、CNSCED 等数据集则包含自然语音或实际环境因素，具有更接近实际应用场景的特性。然而，这类自然型数据集也同时面临情绪边界模糊、标签一致性以及数据整理难度较高等问题。

语音情绪数据集还可以根据标签构成方式与问题定义方式进行区分。RAVDESS、EMO-DB、SAVEE、TESS、CREMA-D、CASIA 等数据集提供愤怒、快乐、悲伤、恐惧、中性等离散标签，较为便利地应用于基于多分类实验。相比之下，RECOLA、MSP-Podcast、EMOVOME 等数据集则同时提供效价、唤醒度、支配度等连续维度，因此较为适用于将情绪作为回归问题或维度情绪模型处理的研究。此外，对于 IEMOCAP、MELD 这类对话上下文重要的数据集，除了发话的声学特征外，还可以进一步考虑

表 2-1 语音情绪识别常用公开数据集比较

类别	数据集	语言	规模	标签构成	对话上下文	多模态
表演型	RAVDESS	英语	7,356 条	离散类 (8)	低	是
表演型	EMO-DB	德语	约 535 条	离散类 (7)	低	否
表演型	SAVEE	英语	480 条	离散类 (7)	低	是
表演型	TESS	英语	2,800 条	离散类 (7)	低	否
表演型	CREMA-D	英语	7,442 条	离散类 (6)	低	是
表演型	CASIA	汉语	约 1,200 条	离散类 (6)	低	否
对话型	IEMOCAP	英语	约 12 小时	离散 + 连续类	高	是
诱导型	MSP-IMPROV	英语	约 9 小时	离散类	高	是
自然型	MSP-Podcast	英语	409 小时	离散 + 连续类	中-高	否
对话型	MELD	英语	1.3 万条	离散类	高	是
自然型	FAU Aibo	德语	约 9 小时	离散类	中等	否
交互型	RECOLA	法语	多模态	连续类	高	是
诱导型	eNTERFACE	英语	音视频	离散类	低	是
半自然	ShEMO	波斯语	3,000 条	离散类	低	否
现实自然	EMOVOME	西班牙语	999 条	离散 + 连续类	中等	否
自然型	CNSCED	汉语	14 小时	多维度离散类 (6)	中等	否

用户交替、上下文流程、对话结构等附加因素。上述分析表明，数据集之间的差异不仅体现在规模上，也与研究如何定义情绪以及设定何种任务存在一定关联^[1,44]。

另一方面，语言、用户构成、公开访问性也是用于比较数据集时的主要标准。英语数据集不仅包括 RAVDESS、TESS、CREMA-D、SAVEE 等表演型基准数据集，还较为常用 IEMOCAP、MSP-IMPROV、MSP-Podcast、MELD 等对话型、自然型数据集。德语方面有 EMO-DB 与 FAU Aibo，汉语方面有 CASIA 与 CNSCED，波斯语方面有 ShEMO，西班牙语方面有 EMOVOME，均为代表性示例。用户数与人口统计信息在不同数据集之间也存在一定差异。例如，TESS 仅包含两名女性用户，SAVEE 仅包含男性用户，而 CREMA-D 则包含 91 名具有不同年龄和人口统计信息的用户。MSP-Podcast 在用户数与发话多样性方面属于较为大规模的自然语音数据集，因而在

一定程度上区别于其他基准数据集。此外，部分数据集相对易于公开访问，部分则需要许可证注册或单独审批程序，部分数据集仅选择性使用原始多模态资料中的音频子集。数据集在语言、人口统计信息与公开访问性上的差异，不仅体现在附加信息层面，也与研究的可重复性与泛化能力密切相关。

代表性语音情绪数据集在情绪采集方式、标签构成方式、语言、用户构成、公开访问性等方面存在一定差异。这些差异不仅体现在数据规模上，也与后续的特征提取、模型设计、实验条件设定及结果解读密切相关。数据集的选择取决于引用频次或使用便利性，同时也应考虑是否符合研究目的。为此，本研究在数据集选择时重点考虑了以下几项标准。其一，数据集应该具备公开访问性或在研究过程中可稳定获取，且应该具备支持后续实验可重复性的形式。其二，标签构成方式应该相对明确，能够直接应用于分类实验。其三，用户数与性别分布不应该过度偏斜，应该具备基本的平衡性与代表性。其四，数据规模应该能够支撑基础实验，同时预处理与模型验证不应该过于复杂。其五，数据集应该具备基准数据集性质，即在已有研究中较为常用，以便后续进行结果比较与实验分析。基于上述标准，本研究在初期实验阶段，相比于结构复杂的对话型数据集或连续维度的数据集，可优先考虑适用于分类实验且结构较为清晰的数据集。数据集选择标准的制定，不仅是对研究范围的明确，也为构建可验证的研究设计提供了基础。

基于上述标准，本研究首先选择 RAVDESS 作为基础实验数据集。RAVDESS 具有公开访问，性别分布较为均衡，情绪类别构成清晰，因此较为适合进行基础分类实验。此外，RAVDESS 在语音情绪识别相关现有研究中较为常用，属于代表性基准数据集之一，较为便于后续实验结果的分析与比较。RAVDESS 属于在受控环境下由专业演员演绎情绪的表演型基准数据集，与实际应用场景中的自然语音存在差异。然而，综合考量数据访问性、标签稳定性、实验可重复性、输入处理流程的清晰度等因素，该数据集被认为适合在本研究的初期实验阶段使用。

2.2 信号处理技术

2.2.1 信号预处理

(1) 输入格式统一：重采样与通道统一

不同语音数据集或录音设备采集的音频文件可能具有不同的采样频率和通道配置。部分文件以 8 kHz、16 kHz、22.05 kHz、44.1 kHz 或 48 kHz 等不同采样频率存

储，且单声道与立体声格式也可能混用。这些差异对可分析的频率范围、时间分辨率以及后续特征的统计分布可能产生一定影响，因此为稳定应用相同的特征提取流程，在特征提取前，可能需要进行重采样与通道统一。

重采样（resampling）是将原始采样频率下的离散信号重新表达为目标采样频率的过程。在概念上可理解为先从原离散信号恢复连续时间信号，再按目标采样频率重新采样，理想化情况下可表示为：

$$x_r[m] = x_c\left(\frac{m}{F'_s}\right) \quad (2-1)$$

其中 $x_r[m]$ 为重采样后的离散信号， $x_c(t)$ 为恢复的连续时间信号， F'_s 为目标采样频率， m 为新采样索引。

实际实现中并不直接计算连续时间信号，而是通过插值与抗混叠滤波相结合的数字化处理完成。尤其在下采样时，超出奈奎斯特频率的成分可能引发混叠，通常需通过低通滤波器抑制高频成分后再进行重采样。对于立体声或多声道输入信号，为保持特征提取的一致性，常将其转换为单声道。一种常见的方法是取左右声道平均值，可表示为：

$$x_{\text{mono}}[n] = \frac{x_L[n] + x_R[n]}{2} \quad (2-2)$$

其中 $x_L[n]$ 和 $x_R[n]$ 分别为左右声道信号， $x_{\text{mono}}[n]$ 为转换后的单声道信号。该方法实现简单，较为适用于多数语音情绪识别实验，当某些声学信息仅集中于特定声道时，可能因平均化导致信息损失^[7,15]。

重采样与通道统一虽不直接产生情绪线索，但对于保证后续特征提取输入条件的一致性较为重要。若采样频率与通道格式未统一，即便采用相同的短时傅里叶变换（Short-Time Fourier Transform, STFT）或梅尔滤波器组（Mel filterbank）参数，也可能得到分布不同的特征，从而增加模型误将设备差异或存储格式差异作为情绪信息学习的风险。统一输入格式有助于保障后续处理可重复性与实验可比性的基础环节。

(2) 振幅归一化

不同语音文件在用户的发声音量、麦克风灵敏度、录音距离、设备增益、存储格

式等方面可能存在一定差异。这种差异可能源于情绪表达本身的差别，但在许多情况下也可能反映录音条件的不同。若保留这种振幅差异直接进行特征提取，模型可能过度学习与情绪无关的振幅变化，从而影响识别性能^[7,45]。因此需要对输入信号进行振幅归一化（**amplitude normalization**），使其振幅范围保持一致。

峰值归一化（**peak normalization**）是一种简单且常用的方法之一。该方法以整个信号中绝对值最大的样本为基准进行缩放，可表示为：

$$x_{\text{peak}}[n] = \frac{x[n]}{\max_{0 \leq n < N} |x[n]| + \varepsilon} \quad (2-3)$$

其中 $x[n]$ 为原始信号， $x_{\text{peak}}[n]$ 为峰值归一化后的信号， N 为总样本数， ε 为防止分母为零的极小常数。经此归一化的信号，其最大绝对振幅通常较为接近 1。峰值归一化的优点在于计算简单、直观，可较为快速地将信号动态范围调整到统一水平。峰值归一化的缺点在于，若信号中存在较大的瞬时峰值，其余部分的相对强度可能被过度压缩^[7]。

均方根归一化（**RMS normalization**）也是一种常用的方法之一。均方根（**RMS**）反映信号的平均强度水平，定义为：

$$\text{RMS}(x) = \sqrt{\frac{1}{N} \sum_{n=0}^{N-1} x[n]^2} \quad (2-4)$$

据此，RMS 归一化可表示为：

$$x_{\text{rms}}[n] = \frac{x[n]}{\text{RMS}(x) + \varepsilon} \quad (2-5)$$

其中 $\text{RMS}(x)$ 为原始信号的均方根值， $x_{\text{rms}}[n]$ 为归一化后的信号。若需要指定目标 RMS 值 r_t ，可表示为：

$$x_{\text{target-rms}}[n] = \frac{r_t}{\text{RMS}(x) + \varepsilon} x[n] \quad (2-6)$$

其中 r_t 为目标 RMS 值。RMS 归一化以信号的均方根值为基准，相较于峰值归一化，通常可提供较为稳定的幅度调节效果^[7,14-15]。

在语音情绪识别中，振幅归一化有助于减少因录音条件差异带来的无关振幅变化。然而，情绪表达本身也包含发声强度、响度等重要线索，过度归一化可能削弱这

些与情绪相关的强度信息。例如，愤怒、喜悦常伴随较高发声强度，而悲伤、疲惫则可能呈现较低且平缓的强度分布。应用振幅归一化时，应该在减少录音条件差异与保留情绪相关的强度信息之间取得平衡^[7,14,45]。

此外，振幅归一化并非适用于所有情况。将整个信号缩放至统一振幅范围时，噪声环境也会被同步放大或缩小。振幅归一化可视为信号振幅统一的基础步骤，噪声消除与鲁棒性增强应该结合后续的数据增强或鲁棒性策略共同实现。

2.2.2 时频变换与频谱分析

(1) 分帧与帧重叠：时间分辨率与频率分辨率的权衡

语音信号整体上具有随时间变化的统计特性，属于非平稳信号，但在极短的时间区间内，语音信号的统计特性可近似为平稳，即准平稳信号。上述准平稳假设是多数经典语音信号处理及特征提取方法的基础，也为将长语音划分为短时分析单元提供了依据。在实际语音情绪识别系统中，需要对原始波形进行分帧处理，将其划分为固定长度的短时分析区间。

设离散语音信号长度为 N ，记作 $x[n]$ ，帧长为 L ，帧移（hop size）为 H ，则第 m 帧可表示为：

$$x_m[n] = x[mH + n], \quad 0 \leq n < L \quad (2-7)$$

其中 $x[n]$ 为原始离散语音信号， $x_m[n]$ 为第 m 帧， L 为帧长（样本数）， H 为帧移， m 为帧索引。总帧数 M 通常按下式计算：

$$M = \left\lfloor \frac{N - L}{H} \right\rfloor + 1 \quad (2-8)$$

其中 $\lfloor \cdot \rfloor$ 为向下取整函数。上述公式表示从长度为 N 的信号中以帧移 H 滑动提取长度为 L 的帧所能得到的帧数。

例如，当采样频率 $F_s = 16 \text{ kHz}$ 时，25 ms 帧对应约 400 个样本，10 ms 帧移对应约 160 个样本。帧重叠是指相邻帧之间存在公共区间，即 $H < L$ 的情形。重叠率可表示为：

$$r = 1 - \frac{H}{L} \quad (2-9)$$

例如 $L = 400$ 、 $H = 160$ 时，重叠率为 60%。采用帧重叠的目的是避免相邻帧之间

信息断裂，使时间轴上的变化更为平滑稳定。重叠率过小可能导致帧间连续性不足，过大则会增加计算量并引入过多冗余信息。

帧长与帧移共同决定了时间分辨率与频率分辨率之间的权衡。通常，帧移越小，时间轴上的分析越密集，时间分辨率越高，上述关系可近似表示为：

$$\Delta t \approx \frac{H}{F_s} \quad (2-10)$$

其中 Δt 为相邻分析点的时间间隔。频率分辨率则与快速傅里叶变换（Fast Fourier Transform, FFT）长度相关：

$$\Delta f \approx \frac{F_s}{N_{\text{FFT}}} \quad (2-11)$$

其中 Δf 为频率 bin 间隔， N_{FFT} 为快速傅里叶变换长度。帧长过短虽能提升时间分辨率，但会降低频率分辨率，难以刻画精细的频谱结构；帧长过长虽能提高频率分辨率，但可能破坏帧内信号的准平稳性。帧长与重叠率应该根据语音信号特性及特征提取目标合理选择。

从语音情绪识别的视角来看，分帧与重叠不仅涉及计算层面的处理，更直接关系到情绪信息的保留。情绪表达通常并非均匀分布于整段语音，而往往集中于特定的时间区间（如抑扬变化、能量突增、停顿等）^[7-9]。合理设定帧参数有助于保留这些时间相关的情绪线索，并为后续的时频变换提供稳定的基础^[7,9]。

(2) 窗函数：频谱泄漏抑制与频率分辨率权衡

对分帧后的信号直接进行傅里叶变换，会在帧的起始与结束位置产生不连续性。这种不连续性是由于实际信号被截断为有限长度所致。这种边界不连续会导致频谱泄漏，使得频谱展宽并引起相邻频率成分的相互干扰。为减轻这一影响，需要对每一帧乘以窗函数，这一过程称为加窗。

将窗函数 $w[n]$ 作用于第 m 帧 $x_m[n]$ ，得到加窗后的信号：

$$x_m^{(w)}[n] = x_m[n] \cdot w[n], \quad 0 \leq n < L \quad (2-12)$$

其中 $x_m[n]$ 为原第 m 帧， $w[n]$ 为长度为 L 的窗函数， $x_m^{(w)}[n]$ 为加窗后的帧。

在时域乘以窗函数等价于在频域进行卷积，即：

$$X_m^{(w)}(\omega) = X_m(\omega) * W(\omega) \quad (2-13)$$

其中 $X_m(\omega)$ 为原帧的频谱， $W(\omega)$ 为窗函数的频谱， $*$ 为卷积运算。窗函数的形状决定了其主瓣宽度与旁瓣衰减特性，从而影响泄漏抑制程度与频率分辨率。

最简单的窗是矩形窗，在窗内取 1，窗外取 0：

$$w_{\text{rect}}[n] = 1, \quad 0 \leq n < L \quad (2-14)$$

矩形窗本质相当于不加窗，其频率分辨率较高，但旁瓣较大，泄漏抑制能力较弱。

汉明窗定义为：

$$w_{\text{Ham}}[n] = 0.54 - 0.46 \cos\left(\frac{2\pi n}{L-1}\right), \quad 0 \leq n < L \quad (2-15)$$

汉宁窗定义为：

$$w_{\text{Hann}}[n] = 0.5 \left(1 - \cos\left(\frac{2\pi n}{L-1}\right)\right), \quad 0 \leq n < L \quad (2-16)$$

其中 L 为窗长， n 为窗内样本索引。这两类窗函数能平滑帧两端，有效抑制频谱泄漏，较矩形窗在频谱泄漏抑制方面更为有效。汉明窗在泄漏抑制与频率分辨率之间取得较好平衡，在语音特征提取中较为常见。汉宁窗同样具有平滑特性，且窗端衰减更平缓。

窗函数的选择通常没有绝对规则。矩形窗主瓣窄、频率分辨率高，但泄漏严重；汉明窗与汉宁窗以牺牲部分频率分辨率为代价换取更强的泄漏抑制。实际应用中需根据信号特性和分析目标权衡。对于语音情绪识别，相较于精确跟踪单一频谱峰值，整体声学模式的稳定性更为重要，因此汉明窗在相关任务中较为常见。

加窗不仅是数学处理，也是影响后续短时傅里叶变换、谱图（spectrogram）、梅尔滤波器组及梅尔频率倒谱系数等特征质量的关键技术。若窗函数选择不当，频谱泄漏会扭曲能量分布，进而影响特征表示。分帧与加窗应该视为实现稳定时频分析的连续过程。

(3) 傅里叶变换：从时域到频域的基础

分析语音信号的频率结构，常用的方法之一是傅里叶变换。时域波形包含发声强度、周期性、共振特性、频带能量分布等信息，但仅从时域难以直观解读这些内容。在语音情绪识别中，基频、共振峰、频谱斜率、频带能量分布等频域线索具有一定作用，因此将时域信号转换为频域表示是需要关注的基础步骤之一。傅里叶变换为后续的短时傅里叶变换、谱图以及梅尔系列特征提取提供了理论基础。

对于长度为 N 的离散信号 $x[n]$ ，其离散傅里叶变换（Discrete Fourier Transform, DFT）定义为：

$$X[k] = \sum_{n=0}^{N-1} x[n] e^{-j2\pi kn/N}, \quad 0 \leq k < N \quad (2-17)$$

其中 $x[n]$ 为时域离散信号， $X[k]$ 为第 k 个频率 bin 的复数谱值， N 为变换长度， j 为虚数单位， k 为频率 bin 索引。

复数谱包含幅度与相位信息。幅度谱可由下式计算：

$$|X[k]| = \sqrt{\Re(X[k])^2 + \Im(X[k])^2} \quad (2-18)$$

其中 $\Re(X[k])$ 、 $\Im(X[k])$ 分别为 $X[k]$ 的实部与虚部。

功率谱通常定义为：

$$P[k] = |X[k]|^2 \quad (2-19)$$

频率 bin k 对应的实际频率近似为：

$$f_k = \frac{kF_s}{N} \quad (2-20)$$

其中 F_s 为采样频率。上述公式表明离散傅里叶变换将时域信号分解为频率轴上的离散分量。

直接计算离散傅里叶变换的计算复杂度为 $O(N^2)$ ，对于长信号或多帧处理负担较大。为此，实际应用中通常采用快速傅里叶变换算法，其计算复杂度可降至 $O(N \log N)$ ，且计算结果与离散傅里叶变换一致。在语音处理中提及傅里叶变换时，往往指使用快速傅里叶变换实现。

在语音情绪识别中，离散傅里叶变换与快速傅里叶变换是获取频域信息的基础方法之一。但离散傅里叶变换对整个信号进行一次变换，难以直接反映频率结构随时间的变化。例如，同一段语音中，起始与结尾的基频、能量分布可能不同，而单次离散傅里叶变换会将这些差异平均化。与对整段语音进行一次傅里叶变换相比，采用短时傅里叶变换进行逐帧分析相对更为重要。傅里叶变换是解析语音频率结构的基本工具，快速傅里叶变换则是其实用化计算的核心算法。

(4) 短时傅里叶变换：时频分析的桥梁

前文所述的离散傅里叶变换能够揭示信号的频率构成，但难以直接反映频率结

构随时间的变化。语音信号具有时变特性，情绪表达体现在特定时间区间的语调变化、能量转移、共振结构演变等方面。在语音情绪识别中，不仅需要获取频率信息，还需要了解其随时间的变化趋势。短时傅里叶变换为此目的而引入，通过对短时区间逐段进行傅里叶变换，同时呈现信号的时间与频率分布。

短时傅里叶变换可理解为对信号施加滑动窗，并对每个窗内分段进行傅里叶变换。该变换的一般形式可表示为：

$$X(m, k) = \sum_{n=-\infty}^{\infty} x[n] \cdot w[n - mH] \cdot e^{-j2\pi kn/N} \quad (2-21)$$

其中 $x[n]$ 为原始离散信号， $w[n - mH]$ 为移动至第 m 个时间位置的窗函数， H 为帧移， N 为快速傅里叶变换长度， m 为时间帧索引， k 为频率 bin 索引。

结合前述分帧处理，短时傅里叶变换也可按帧表示为：

$$X(m, k) = \sum_{n=0}^{L-1} x_m[n] \cdot w[n] \cdot e^{-j2\pi kn/N} \quad (2-22)$$

其中 $x_m[n]$ 为第 m 帧信号， L 为帧长， $w[n]$ 为窗函数， N 为快速傅里叶变换长度。由此可见，短时傅里叶变换可视为“分帧—加窗—逐帧快速傅里叶变换”的连续过程。

短时傅里叶变换能够同时提供时间与频率信息，但该变换的时间分辨率与频率分辨率之间往往存在权衡。采用较短的窗函数可获得较好的时间分辨率，但频率分辨率可能相应降低；采用较长的窗函数则可获得更精细的频率结构，但对时间变化的响应能力相对较弱。上述时间分辨率与频率分辨率之间的权衡关系与帧移、快速傅里叶变换长度及采样频率等因素密切相关。

在语音情绪识别中，短时傅里叶变换可同时保留随时间演变的声学模式。例如，愤怒或喜悦可能伴随特定区间的能量聚集与快速的语调变化，而悲伤则可能表现为相对平缓的频谱演变。短时傅里叶变换可同时保留这些时变模式，从而为后续的谱图、对数梅尔谱（log-Mel spectrogram）及梅尔频率倒谱系数等特征提取提供基础。短时傅里叶变换是连接语音时域与频域分析的重要中间表示之一，能够在一定程度上反映情绪表达中的时变特性。

(5) 频谱图：时频表示的三种形式

短时傅里叶变换的输出为复数矩阵，该矩阵的维度分别为时间索引 m 与频率索引 k 。该复数表达在数学上是完整的，但在实际语音分析或模型输入中，通常将其转

换为幅度或能量形式。谱图（spectrogram）即为此类时间-频率表示，同时呈现时间轴、频率轴以及各时频位置的强度，可较为清晰地展示语音信号的结构变化。

一种基本形式是幅度谱图，使用短时傅里叶变换结果的绝对值：

$$S_{\text{mag}}(m, k) = |X(m, k)| \quad (2-23)$$

其中 $X(m, k)$ 为短时傅里叶变换结果， $S_{\text{mag}}(m, k)$ 为幅度谱图值。幅度谱图反映各时频位置的振幅大小，可较为清晰地观察不同频带的相对强度差异。

功率谱图（power spectrogram）则使用幅度的平方，从能量角度进行表示：

$$S_{\text{pow}}(m, k) = |X(m, k)|^2 \quad (2-24)$$

功率谱图与信号的能量分布较为密切地相关，在许多声学特征提取中作为基础输入使用。在语音处理中，功率形式往往比幅度形式较为常见，后续的梅尔滤波器组（Mel filterbank）运算也通常基于功率谱图进行。

对数谱图（log spectrogram）通过对功率谱图取对数，压缩动态范围，使其更接近人耳听觉感知特性。最简单的对数表达形式为：

$$S_{\text{log}}(m, k) = \log(S_{\text{pow}}(m, k) + \varepsilon) \quad (2-25)$$

其中 ε 为极小常数，用于避免对零取对数引起的数值不稳定。实际实现中有时采用 dB 刻度，即：

$$S_{\text{dB}}(m, k) = 10 \log_{10}(S_{\text{pow}}(m, k) + \varepsilon) \quad (2-26)$$

或以幅度谱图为基础的 dB 表示为：

$$S_{\text{dB-mag}}(m, k) = 20 \log_{10}(S_{\text{mag}}(m, k) + \varepsilon) \quad (2-27)$$

对数刻度能够压缩大动态范围，使得微弱频率成分相对更易被观测。

谱图是语音情绪识别中较为常用的输入表示之一^[8-10]。不同情绪状态下，特定频带的能量分布、谱包络、共振结构及发声强度的时变模式可能有所不同，谱图能够较为清晰地呈现这些差异。在卷积神经网络类模型中，常将谱图视作二维图像，自动学习具有情绪判别性的时频模式^[5,8,11]。此外，对数谱图是后续梅尔滤波器组、对数梅尔谱及梅尔频率倒谱系数等特征构建的基础。

然而，谱图本身并不总是适合直接作为最终输入。线性频率轴难以直接反映人耳的非线性感知特性，高频区域分布了较多频率 bin^[10]。同时，谱图的分辨率与分布受短时傅里叶变换参数、窗长、帧移及变换长度等因素影响^[8]。谱图虽然为重要的中间表示，但在实际应用中可进一步转换为梅尔尺度或倒谱系数等更具感知适应性的特征^[8,44]。

2.2.3 感知特征提取

(1) Mel 尺度与梅尔滤波器组

前文所述的谱图是时频结构的重要中间表示，但其频率轴为线性刻度。然而，人耳听觉系统对频率的感知并非线性，通常对低频变化更为敏感，对高频变化相对迟钝。若直接使用线性频率轴上的功率谱图，可能会过度强调与听觉感知不直接对应的高频细节。

为弥补线性频率轴无法直接反映人耳听觉特性的不足，常采用梅尔尺度（Mel scale）。这是一种模拟人耳听觉感知的非线性频率刻度。线性频率 f （单位 Hz）与梅尔频率 m 之间的典型转换关系为：

$$m = 2595 \log_{10} \left(1 + \frac{f}{700} \right) \quad (2-28)$$

该转换在低频区域保持相对较高的分辨率，在高频区域逐渐压缩，从而构建出更贴近听觉感知的频率轴。在语音情绪识别中，梅尔尺度有助于以类人耳的方式重构语调、共振、频带能量分布等情绪相关线索^[8,44]。

梅尔滤波器组是将梅尔尺度应用于特征提取的具体方法。通常在线性频率轴上按梅尔间隔布置多个三角形滤波器，每个滤波器对相应频带的能量进行汇总。设第 p 个梅尔滤波器为 $H_p[k]$ ，则第 m 帧第 p 个梅尔频带的能量为：

$$E_p(m) = \sum_{k=0}^{N-1} |X(m, k)|^2 H_p[k] \quad (2-29)$$

其中 $|X(m, k)|^2$ 为第 m 帧第 k 个频率 bin 的功率谱值， N 为频率 bin 总数。

梅尔滤波器组的核心在于将相邻频率区间按听觉感知特性进行整合，从而将原始精细的线性频谱压缩为相对稳定、具有感知意义的频带能量表示^[8,10]。该过程具有多个优点：一是提供更贴近人耳感知的频域表达；二是通过频带能量聚合，能在一定程度上降低噪声敏感性；三是作为对数梅尔谱和梅尔频率倒谱系数等特征的基础，

可较为便捷地与后续处理结合。

但与此同时，梅尔滤波器组也会丢失部分精细的频率结构，对于需要精确分析窄带成分的任务可能存在局限。尽管如此，在语音情绪识别中，整体能量分布与听觉相似性往往更为关键，因此梅尔特征仍较为常见^[8,20,44]。

(2) 对数梅尔谱图：听觉感知与时频表示的融合

对梅尔滤波器组输出的各帧频带能量取对数，即得到对数梅尔谱图。可理解为将基于短时傅里叶变换的功率谱映射至梅尔刻度后，再通过对数运算压缩动态范围。对数梅尔谱图既模拟了人耳的非线性听觉特性，又通过对数变换使能量分布更为平稳。

设梅尔滤波器组输出能量为 $E_p(m)$ ，其定义如下：

$$E_p(m) = \sum_{k=0}^{N-1} |X(m, k)|^2 H_p[k] \quad (2-30)$$

对该能量取对数，得到第 m 帧第 p 个梅尔频带的对数能量：

$$M_p(m) = \log(E_p(m) + \varepsilon) \quad (2-31)$$

其中 $M_p(m)$ 为对数梅尔谱值， ε 为极小常数，用于避免对零取对数。

实际应用中，也可采用 dB 刻度，即：

$$M_p^{(\text{dB})}(m) = 10 \log_{10}(E_p(m) + \varepsilon) \quad (2-32)$$

语音信号的能量动态范围较广。原始功率谱或梅尔滤波器组输出中，某些频带能量可能远大于其他频带，若未经处理直接使用，模型可能过度关注大值区域。对数变换可压缩动态范围，使小能量差异也能被有效保留，同时与人耳的对数响度感知特性有一定关联。对数梅尔谱不仅是数值上的处理，也是连接物理信号与听觉感知的常用表示之一^[8,11,21]。

在语音情绪识别中，对数梅尔谱图是较为常用的输入特征之一^[8,44]，其原因在于：第一，梅尔刻度模拟了人耳的非线性频率感知；第二，对数变换稳定了能量分布；第三，该谱图的二维时频结构可方便地作为卷积神经网络的输入。该谱图能够同时反映不同情绪的频谱结构与能量演化模式^[8,10]。

例如，愤怒或喜悦常伴随能量聚集与快速语调变化，而悲伤则可能表现为相对平缓的频谱演变。对数梅尔谱图能够以较为清晰的二维形式呈现这些差异，适合卷

积神经网络或注意力机制学习局部模式与关键区域^[5,8,11]。尽管近年来也出现未经处理直接使用原始波形的端到端方法，但对数梅尔谱图仍是目前较为稳定、较为常用的基线特征之一^[8,44]。

然而，对数梅尔谱图也存在一定的局限。梅尔刻度的信息压缩会损失部分线性频率轴的细节，而滤波器数量、快速傅里叶变换长度、帧移、窗长等参数的选择也会影响最终特征的分辨率与分布^[8,10]。实际应用中需根据具体数据集与模型结构对参数进行合理设置。

(3) 梅尔频率倒谱系数：从谱包络到紧凑特征

前文所述的对数梅尔谱图虽能反映人耳听觉特性，但仍保留了各梅尔频带的能量值。然而，在传统语音处理中，相较于未经处理直接使用频带能量，将整体谱包络压缩为低维表示往往更为有利。梅尔频率倒谱系数为此目的而较为常用的倒谱特征，通过对梅尔滤波器组输出的对数能量进行离散余弦变换（Discrete Cosine Transform, DCT）得到。梅尔频率倒谱系数可视为将对数梅尔谱进一步压缩为紧凑系数向量的结果。

设第 m 帧第 p 个梅尔频带的对数能量为 $M_p(m)$ ，则第 q 个梅尔频率倒谱系数通常计算如下：

$$c_q(m) = \sum_{p=1}^P M_p(m) \cos \left[\frac{\pi q}{P} \left(p - \frac{1}{2} \right) \right], \quad 0 \leq q < Q \quad (2-33)$$

其中 $c_q(m)$ 为第 m 帧第 q 个梅尔频率倒谱系数， P 为梅尔滤波器总数， Q 为保留的系数个数。

在语音处理实践中，常保留前若干阶系数。低阶系数主要反映谱包络的整体形状，而高阶系数对细节变化和噪声相对更为敏感^[1,8,44]。

梅尔频率倒谱系数中采用离散余弦变换的主要原因有两点：一是相邻梅尔频带能量之间存在一定相关性，离散余弦变换可起到去相关的作用，使系数更加紧凑；二是可将对数梅尔谱的分布形态（即谱包络）用较低维度表示。梅尔频率倒谱系数在语音识别、用户识别、情绪识别等任务中作为基准特征之一使用。

在语音情绪识别中，梅尔频率倒谱系数是较为常用的特征之一：不同情绪状态下的共振结构、谱斜率、能量分布等特征可能不同，该特征可将这些变化归纳为相对稳定的低维表示，从而在小规模数据条件下也能提供较为可靠的基线。近年来，梅尔频

率倒谱系数仍较为常见地用于基准对比或作为卷积神经网络的二维输入之一^[1,8,44]。

然而，梅尔频率倒谱系数也存在局限。作为一种谱包络的压缩表示，该特征往往难以保留对数梅尔谱图中保留的部分精细时频结构。此外，该特征的最终表现受滤波器个数、系数阶数、帧长、帧移等参数影响，高阶系数的取舍需根据具体任务合理设置。梅尔频率倒谱系数在一定条件下可作为有效特征，但其适用性取决于数据规模、模型结构及任务特点^[8,10]。

2.2.4 特征后处理与序列长度处理

(1) 特征归一化：方法、统计量范围与权衡

在语音情绪识别中，特征归一化被视为缩小不同维度特征之间尺度差异、提高学习过程中数值稳定性与收敛性的重要步骤^[1,7,15]。不同类别的语音特征在数值范围与分布上可能存在较大差异。例如，对数梅尔能量、梅尔频率倒谱系数、基频、能量、时长等特征的量纲与分布特性各不相同^[1,8,44]。若未经归一化处理，某些维度的数值差异可能对模型训练产生较大影响^[7,14-15]。归一化可视为在数值调整的基础上，将不同特征维度重新映射至可比且可学习范围的过程^[1,7,14]。

Z-score 归一化（Z-score normalization）是语音情绪识别中较为常用的归一化方法之一^[14-15]。该方法将各特征值线性变换为均值为 0、标准差为 1 的分布，定义如下：

$$z = \frac{x - \mu}{\sigma + \varepsilon} \quad (2-34)$$

其中 x 为原始特征值， μ 为均值， σ 为标准差， z 为归一化后的值， ε 为防止分母为零的极小常数。

该变换将输入特征进行中心化与尺度统一。在使用基于梯度的学习模型时，若输入分布存在一定偏斜或各维度尺度差异较大，训练过程可能出现不稳定的情况。在此类场景下，Z-score 归一化被视为语音处理中较为常用的预处理方式之一^[7,14-15]。

此外，min-max 归一化（min-max normalization）是另一种常用的归一化方式^[7,15]。该方式将数值映射至固定区间，如 $[0, 1]$ ，可表示为：

$$x' = \frac{x - x_{\min}}{x_{\max} - x_{\min} + \varepsilon} \quad (2-35)$$

其中 $x_{\min}$ 、 $x_{\max}$ 分别为特征的最小值与最大值。**min-max** 归一化可较为清晰地限定特征范围，但在某些情况下可能对异常值较为敏感。相比之下，**Z-score** 归一化以整体分布的均值和标准差为基准，在数值范围变化较大的语音特征中相对更常被采用。基于上述分析，本节以 **Z-score** 归一化为重点，并讨论其不同应用范围对特征分布的影响^[7,14-15]。

在语音情绪识别中，除归一化公式外，统计量的计算范围同样值得关注。通常可将归一化分为 **utterance-wise**、**corpus-wise** 和 **speaker-wise** 三种方式^[7,14-15]。

utterance-wise 归一化是针对每个发话单元独立计算均值和标准差，再对该发话内的特征进行归一化。设发话 u 的特征序列为 $x_u[t]$ ，可表示为：

$$z_u[t] = \frac{x_u[t] - \mu_u}{\sigma_u + \varepsilon} \quad (2-36)$$

其中 μ_u 、 σ_u 为该发话内计算的均值和标准差。该方式有助于突出发话内部的相对变化，并在一定程度上减少录音音量等绝对尺度差异，但若过度使用，可能弱化发话间具有情绪意义的绝对强度差异^[7,14-15]。

corpus-wise 归一化是在整个数据集（或特定划分）上计算全局均值和标准差，并对所有样本应用相同的归一化参数，可表示为：

$$z[t] = \frac{x[t] - \mu_{\text{corp}}}{\sigma_{\text{corp}} + \varepsilon} \quad (2-37)$$

其中 μ_{corp} 、 σ_{corp} 为全局统计量。该方式有助于使模型接收分布更一致的输入，但需注意使用训练集的统计量对验证集与测试集进行归一化；若未遵循此原则，则可能引入数据泄露风险^[7,14-15]。

speaker-wise 归一化是按用户分别计算均值和标准差，可表示为：

$$z_s[t] = \frac{x_s[t] - \mu_s}{\sigma_s + \varepsilon} \quad (2-38)$$

其中 μ_s 、 σ_s 为用户 s 的统计量。该方式有助于在一定程度上减少用户间的个体差异，但可能将具有情绪意义的绝对特征一并削弱，且在测试时若无法获得用户信息，则应用难度较大。

从语音情绪识别的角度看，归一化有助于缓解特征分布失配、提升训练稳定性，但若选择不当，也可能对与情绪相关的绝对差异（如发话强度、平均能量水平、基频范围等）产生一定影响。归一化需在数值稳定性与情绪线索保留之间加以权衡^[7,14-15]。

(2) 输入长度处理：填充、截断与分段

在语音情绪识别中，语音信号的时长并非固定不变，不同样本的发话长度存在一定的差异。大多数深度学习模型采用 mini-batch 方式进行训练，要求同一批次内的输入维度保持一致^[14-15]。如何将可变长度的序列转换为固定格式，是需要关注的问题。填充、截断与分段是处理该问题的三种常用方法^[1,7-8]。这三种方法均旨在调整输入长度，但在信息保留方式及对模型输入结构的影响上存在差异。

填充是较为常用的方法之一，即在较短的序列末尾或特定位置填充零值或常数，使其达到目标长度^[1,7-8]。设长度为 T 的特征序列 $\mathbf{x}_t \in \mathbb{R}^d$ 需填充至目标长度 $T_{\max}$ ，则填充后的序列 $\tilde{\mathbf{x}}_t$ 可定义如下：

$$\tilde{\mathbf{x}}_t = \begin{cases} \mathbf{x}_t, & 0 \leq t < T \\ \mathbf{0}, & T \leq t < T_{\max} \end{cases} \quad (2-39)$$

其中 $\mathbf{x}_t$ 为原始时刻 t 的特征向量， $\tilde{\mathbf{x}}_t$ 为填充后的特征向量， d 为特征维度， $\mathbf{0}$ 为零向量。填充的优势在于实现较为简单，且便于适配批量训练。然而，若填充的无信息区间过长，输入中可能包含一定比例的无意义零值，造成计算资源消耗与特征分布的不确定性增加^[7,14-15]。尤其是在发话长度差异较大的数据集中，较短的样本可能大部分由填充构成^[1,7]。

截断是将过长的序列截断至目标长度，仅保留前 $T_{\max}$ 个时间步。其表达式为：

$$\hat{\mathbf{x}}_t = \mathbf{x}_t, \quad 0 \leq t < T_{\max} \quad (2-40)$$

其中 $\hat{\mathbf{x}}_t$ 为截断后保留的序列， $T_{\max}$ 为保留长度。截断有助于控制计算量，并简化批次构建。但截断可能丢弃后段中蕴含的情绪线索^[7,14-15]。由于情绪信息可能分布于发话的各个阶段，或在后半段更为集中，无差别的截断可能导致信息损失^[1,7,14]。

分段是将长序列划分为多个短分段进行处理的方式^[1,7-8]。设原始序列长度为 T ，每个分段长度为 C ，相邻分段起始间隔为 S ，则第 i 个分段可表示为：

$$\mathbf{c}_i = [\mathbf{x}_{iS}, \mathbf{x}_{iS+1}, \dots, \mathbf{x}_{iS+C-1}] \quad (2-41)$$

其中 $\mathbf{c}_i$ 为第 i 个分段， C 为分段长度， S 为步长。若 $S < C$ ，则相邻分段之间存在重叠，有助于减少关键信息落在分段边界上的风险。分段的优势在于，在控制计算量的同时，相较于截断可保留更多的时序信息。此外，可先对各分段进行独立预测，再通过平均、最大值或注意力池化等方式聚合为发话级别的结果^[1,8]。

输入长度处理方式的选择，与语音情绪识别实验设计存在一定关联。填充实现较为简单，但在长度差异较大时效率较低；截断有助于降低计算量，但存在信息损失风险；分段则在信息保留与计算效率之间提供一种折中方式，但需额外设计分段级结果的聚合机制。输入长度处理不仅是实现层面的问题，更涉及情绪线索保留、模型效率与结果稳定性之间的综合权衡^[1,7,14]。

从语音情绪识别的视角来看，输入长度处理方式在数据量较小或发话长度差异较大的数据集中具有一定影响。过度的填充可能引入一定比例的无效信息，对模型学习效率产生一定影响；过度的截断则可能丢失情绪表达的关键分段。相比之下，分段可将长序列拆分为多个分析单元，实现更细粒度的处理，在近年来的序列建模研究中受到一定关注^[7-8,10]。

2.3 面临难点

在语音情绪识别中，信号处理技术的必要性主要源于原始语音信号难以以规整、清晰的形式提供情绪信息^[7,17]。语音情绪识别中的信号处理，可视为在噪声干扰环境下表征有效特征的重要环节^[7,14,18]。现有研究亦指出，语音情绪识别在数据集构成、特征提取、噪声环境、泛化能力等方面仍面临一定挑战^[7-8,14-16]。上述挑战主要体现在语音信号的非平稳性、发话长度可变性、外部环境干扰、情绪线索的多层性、用户与数据集的分布差异以及数据规模限制等方面。

2.3.1 语音信号的非平稳性与时间非均匀性

语音信号的非平稳性与情绪线索的时间非均匀性，是语音情绪识别中较为根本的难点之一。语音在发话全程中并不保持统一的统计结构，音节边界、清浊音交替、语调升降、局部能量变化持续发生^[1,7]。情绪表达集中于发话中的特定区间，而非均

匀分布于整个发话过程^[1,7-8]。例如，愤怒可能在特定单词的强调区间或重读音节中表现为较为明显的能量上升与基频变化^[1,8]；悲伤即便整体呈现低能量与慢语速，也可能在发话后半段表现出一定程度的语调下降或拖音^[1,7]。情绪信息在时间轴上的局部分布特性，使得将整个波形视为单一静态向量的处理方式难以充分保留信息^[1,7-8]。在语音情绪识别中，相较于“提取哪些特征”的问题，“采用何种时间单位进行分析才能避免遗漏情绪信息”是需要关注的问题^[1,7]。现有语音情绪识别综述亦指出，语音属于非平稳信号，情绪信息在不同时间区间呈现不同分布。基于短时分析的声学特征提取仍被视为核心环节。分帧、加窗、短时傅里叶变换、谱图、对数梅尔谱等短时频分析技术，可视为应对上述问题的重要方法^[1,7-8]。

2.3.2 发话长度的可变性

发话长度的可变性对语音情绪识别的实验设计与模型输入构成形成一定约束^[1,7]。语音情绪识别数据集中，不同发话的长度存在差异，即便在同一情绪类别内部，短时发话与较长发话也可能同时存在。这一差异不仅影响后续特征提取，也对模型学习结构产生一定影响。若直接使用长度不一的发话进行训练，批处理过程可能面临困难；在输入维度固定的模型中，未加处理的变长序列可能难以直接使用或效率较低。采用零填充统一长度时，若填充比例过高，输入中无意义零值区间的比重可能增大；采用截断时，发话后段蕴含的情绪线索可能被丢弃。将长时发话划分为多个分段或采用分段处理，有助于捕捉局部情绪信息，但需进一步设计分段结果的整合方式^[1,7-8]。近期面向分段级语音情绪识别的相关研究亦指出，将长时发话压缩为单一固定长度向量的处理方式存在一定局限^[1,7]。发话长度的可变性问题，可视为在情绪信息保留与模型输入一致性之间寻求平衡的重要方面。

2.3.3 外部环境因素的干扰

噪声、多输入、信道差异等外部环境因素，在语音情绪识别中构成较为明显的干扰因素。实验室环境下录制的语音通常具有较为清晰的声学特征，而实际应用场景中，噪声环境、人声或物体移动产生的杂音、室内多输入、麦克风质量差异、录音距离变化、压缩过程带来的信息损失等因素可能同时存在^[1,7,15]。上述因素可能在语音信号中引入与情绪表达无直接关联的波动，改变能量分布与频谱结构，进而影响特征提取的稳定性^[7,14-15]。相较于语音识别任务，情绪识别更依赖细微的声学差异，因此即便噪声水平相近，情绪识别性能也可能受到更为明显的影响^[1,7,15]。例如，语调

的微小上升、特定频带的能量增强、带有气息感的发声质感等，均可能成为判断情绪的重要线索，而这些线索可能受噪声与多输入干扰。近期面向噪声环境下的语音情绪识别研究及相关综述亦指出，噪声条件下情绪识别性能可能出现明显下降，实际应用中需结合去噪处理、鲁棒特征设计及数据增强等策略加以应对^[1,7-8,15]。语音情绪识别中的信号处理，不应该仅以理想化、无干扰的输入为前提，而应纳入对实际环境中可能出现的声学失真的考虑。

2.3.4 情绪线索的多层性与特征表示的复杂性

情绪线索的多层性与特征表示的复杂性，是语音情绪识别中较为突出的难点之一^[1,8,44]。情绪变化不仅表现为基频升高或能量增强等单一声学维度的波动，更体现为多种声学维度的协同变化^[1,44]。某些情绪可能在语调与语速变化中体现得更为明显，另一些情绪则可能更多反映在频谱包络、共振峰结构、倒谱特性、嗓音质量、气息感、粗糙度等较为精细的声学特征之中^[1,8,44]。上述韵律、频谱、倒谱、嗓音质量等多类信息在情绪表达中相互叠加与交互，使得依赖单一特征表示可能难以充分区分不同情绪类别。例如，梅尔频率倒谱系数能够较好地概括频谱包络，但难以直接反映基频轮廓与时长模式的变化^[1,8,44]；而基频、能量等韵律特征虽易于解释，却难以涵盖频谱差异或发声质感等维度^[1,44]。现有研究中反复探讨多特征组合、特征选择与特征融合等问题，反映了这一复杂性^[1,8,44]。语音情绪识别中的核心挑战，重点不在于寻找单一“最优”特征，而在于设计能够尽可能保留情绪多层结构的输入表示方式。上述问题为后续讨论对数梅尔谱、梅尔频率倒谱系数、韵律特征及特征集（如 OpenSMILE）等技术提供了问题背景^[1,8,44]。

2.3.5 用户、语言及数据集的分布差异

用户差异、语言差异及数据集间的分布差异，与情绪本身的差异相互交织，构成语音情绪识别中的复杂问题之一^[1,7-8]。即便表达同一情绪，不同用户的基频范围、语速、重音模式、能量水平、发音习惯等方面可能存在差异^[1,7]。语言背景不同时，语调结构、音节节奏、长短音体系、重音实现方式等也会随之变化^[1,8]。不同数据集在录音环境、用户构成、情绪标签体系、表演型或自然型语音的选取等方面存在差异。在某一数据集上表现良好的输入表示或特征组合，在另一数据集上未必能保持相同性能^[1,7-8,15]。情绪变化与用户、语言、领域等因素引起的声学变化相互叠加，这两类变化在信号处理阶段较难完全分离。例如，直接使用基频或能量的绝对值，可能更

多反映用户差异而非情绪差异^[1,7]。许多研究同时关注按发话单元归一化、按语料库归一化、用户独立性及跨语料库鲁棒性等问题。相关综述亦指出，在用户独立与跨语料库设定下，情绪识别性能可能出现较为明显的下降^[1,7-8,15]。语音情绪识别中的信号处理，不仅涉及特征提取的准确性，还需关注如何在一定程度上减少用户与领域带来的无关波动^[1,7,14]。

2.3.6 情绪数据的规模限制与类别不平衡

情绪数据的规模限制与类别不平衡问题，在信号处理阶段形成一定约束^[1,7-8]。相较于通用语音识别数据，带有情绪标签的语音数据收集成本较高，标注一致性也较难保障。实际研究中使用的数据集在用户数量与发话数量上往往较为有限，部分情绪类别的样本数量可能较少，类别分布也可能存在一定程度的不平衡^[1,7-8]。在此类条件下，若输入特征维度过高，或引入与数据规模不相适应的复杂处理流程，可能增加过拟合风险；反之，若特征过度简化，则可能丢失与情绪相关的重要信息^[1,7-8]。近期研究亦指出，样本不足、特征维度过高、无关特征过多等因素可能影响语音情绪识别能力，为此常通过特征选择、数据增强及鲁棒表示设计等方式加以应对^[6-8]。信号处理阶段不应该仅追求理论上的信息丰富性，而应综合考虑实际数据条件与学习稳定性，选择适当的处理复杂度^[7,14,45]。

2.4 现有技术

语音情绪识别领域的信号处理技术，可根据输入语音转换为何种特征表示，划分为若干改进方向^[1,7-8]。第一种改进方向采用人工设计的固定变换特征。该类方法从语音信号中提取梅尔频率倒谱系数、对数梅尔谱、谱图、基频、能量、共振峰等特征^[1,7-8]。第二种改进方向利用大规模无标注语音数据中学习的特征表示。该类方法使用 Wav2Vec2、HuBERT、WavLM 等自监督学习模型，从原始语音中提取高维特征向量^[12-13]。第三种改进方向聚焦于信号的鲁棒性。该类方法采用噪声添加、多输入添加、数据增强、去噪处理、特征增强等技术^[1,7,15]。

第一种改进方向采用人工设计的固定变换特征。该类方法从语音信号中提取多种声学特征，主要可分为时频域特征、韵律特征和发声质量特征三类^[1,7-8]。时频域特征包括通过短时傅里叶变换获得的谱图、对数梅尔谱图、梅尔频率倒谱系数等^[1,8]。韵律特征包括基频、能量、语速、过零率等。发声质量特征包括共振峰、微扰、shimmer、

谐波比等。上述人工设计的声学特征，其优势在于能够将语音的时间、频率及发声属性整理为相对可解释的形式^[1,8,44]。例如，基频与能量可反映语调与发话强度的变化，梅尔频率倒谱系数及频谱类特征则可较好地概括音色与频谱包络的变化。这些声学特征可与支持向量机、隐马尔可夫模型、高斯混合模型等分类器结合使用^[1,7-8]。其中，基于 OpenSMILE 提取的 eGeMAPS、ComParE、IS09 等特征集，在情绪识别研究中作为代表性基准特征集使用。该类固定变换特征方法在特征设计上对研究者的先验判断存在一定依赖，不同特征之间可能存在一定重叠，且难以通过单一固定特征集完整捕捉情绪的复杂表达^[1,8,44]。该方法通常作为基础技术路线之一，在需要更高表达能力的场景下常与其他类型方法结合使用^[1,7-8]。

第二种改进方向利用大规模无标注语音数据中学习的特征表示。该类方法使用 Wav2Vec2、HuBERT、WavLM 等自监督学习模型，从原始语音中提取高维特征向量^[29-31]。这些自监督学习模型在大规模无标注语音数据（数千小时以上）上进行预训练，学习涵盖语音信号多个层次（音素、韵律、发声特性等）的通用特征表示^[29-31,46]。例如，在 LibriSpeech 数据集（960 小时）上预训练的 Wav2Vec2 和 HuBERT 模型，可从原始语音中提取 768 维以上的特征向量^[29-30]。在 Libri-Light 数据集（6 万小时）上训练的大规模模型则具有更为丰富的表示能力^[29]。这种特征表示与传统人工设计特征（MFCC、log-Mel 等）不同，其特点在于通过可学习的变换自动捕捉语音信号的复杂结构^[29-31]。此外，围绕语音情绪识别的下游研究已表明，自监督学习特征在冻结特征、全量微调和说话人归一化等设定下都具有较强潜力，并在噪声环境下能够提供相对稳定的表示^[12,26-28,32]。然而，该类方法也存在一定局限。首先，预训练的语音表示未必针对情绪信息进行优化，情绪识别所需的线索与预训练目标之间可能存在差异^[13,28]。其次，模型规模较大，计算资源与内存消耗较高^[13,33-34]。此外，预训练数据与目标情绪数据之间的领域差异（语言、录音环境、用户特性等）可能影响特征表示的有效性^[12-13,47]。该类方法作为信号处理技术之一，需根据数据规模与计算条件加以选择^[12-13,33]。

第三种改进方向关注信号的鲁棒性。在实际应用环境中，噪声环境、室内多输入、麦克风质量差异、录音距离变化等多种失真因素可能影响特征提取的稳定性^[1,7,15,24]。在信号处理阶段，可采用以下技术^[1,7,15,24]。第一，在训练阶段应用噪声添加、多输入添加、速度扰动、基频扰动等数据增强技术，以提高模型在不同环境条件下的适应性^[7,12,15,24]。第二，在前处理阶段应用去噪算法，改善输入信号的质量^[1,15,25]。第三，

在特征提取阶段应用选择性特征增强或鲁棒特征提取技术，获得对失真相对不敏感的特征表示^[1,7,15,25]。这些信号处理技术与特征表示本身的设计不同，其作用在于辅助现有特征提取方式在实际环境中更稳定地运行^[1,7,15,24]。

2.5 本文采用的信号处理流程

2.6 本章小结

第3章 模型结构

本章介绍语音情绪识别系统中使用的主要模型结构。经过信号处理阶段获得的 log-Mel 谱图、梅尔频率倒谱系数、韵律特征等输入表示，能够将情绪相关的声学线索整理为固定格式，但要从这些表示中判别实际情绪类别，需要合适的模型结构^[1,7]。在语音情绪识别中，模型设计涉及分类器选择的问题，同时也涉及如何学习输入特征的结构特性与时间依赖关系。

早期主要采用将人为设计的特征向量输入全连接神经网络模型或简单分类器的方式，随后引入了能够直接学习时频表示的卷积神经网络模型^[6,8]。为了反映发话中的时间依赖性与序列上下文，循环神经网络模型及其变体被广泛使用。近年来，能够选择性强调发话内部关键区间的注意力机制，以及能够高效学习全局上下文的 Transformer 模型，得到了较多关注^[9-10]。语音情绪识别技术已从简单的静态向量分类问题，逐步扩展为能够处理复杂时间序列结构与长期依赖关系的任务。

本章首先介绍语音情绪识别的基础神经网络模型结构，随后依次介绍注意力机制与 Transformer 模型。3.1 节说明全连接神经网络模型、卷积神经网络模型、循环神经网络模型及其典型变体，总结这些结构在语音情绪识别中的作用与局限。3.2 节阐述注意力机制，3.3 节介绍 Transformer 模型及其核心原理。上述介绍可为理解本研究所用模型结构提供基础。

3.1 现有基础模型结构

3.1.1 全连接神经网络模型

全连接神经网络（Fully Connected Neural Network），也称为多层感知机（Multi-Layer Perceptron, MLP），可视为一种基本的人工神经网络模型。在该结构中，每一层的每个神经元与下一层的所有神经元相互连接，输入向量经过线性变换与非线性激活函数后，逐步转换为较高层次的抽象表示。在语音情绪识别早期研究中，研究者们通常将人为设计的特征（如梅尔频率倒谱系数、基频、能量、过零率、共振峰等）组织为发话级的固定长度向量，并将其输入全连接神经网络模型，用于情绪分类^[1]。全连接神经网络模型中某一层的输出可表示为：

$$\mathbf{h}^{(l)} = \phi(\mathbf{W}^{(l)}\mathbf{h}^{(l-1)} + \mathbf{b}^{(l)}) \quad (3-1)$$

其中 $\mathbf{h}^{(l-1)}$ 为上一层的输入向量， $\mathbf{W}^{(l)}$ 为第 l 层的权重矩阵， $\mathbf{b}^{(l)}$ 为偏置向量， $\phi(\cdot)$ 为非线性激活函数， $\mathbf{h}^{(l)}$ 为当前层的输出向量。

当输入为原始特征向量 $\mathbf{x}$ ，最终输出为情绪类别的概率向量 $\hat{\mathbf{y}}$ 时，输出层通常采用 softmax 函数：

$$\hat{y}_i = \frac{\exp(z_i)}{\sum_{j=1}^C \exp(z_j)} \quad (3-2)$$

其中， z_i 为第 i 个类别的 logit， C 为情绪类别总数， $\hat{y}_i$ 为第 i 个类别的预测概率。

模型训练过程中，常采用交叉熵损失函数：

$$\mathcal{L}_{\text{CE}} = - \sum_{i=1}^C y_i \log \hat{y}_i \quad (3-3)$$

其中 y_i 为真实标签的 one-hot 编码值。

全连接神经网络模型具有结构简单、实现相对简单的特点，在输入特征维度较低时能够提供较为稳定的基线性能。通过各层的线性变换与激活函数，模型可形成非线性分类边界，从而能够处理比线性分类器更为复杂的情绪分布。

全连接神经网络模型难以保留语音信号中的时间结构与空间结构。例如，log-Mel 谱图或梅尔频率倒谱系数图中包含时间轴与频率轴上的局部模式，若将其展平为一维向量输入全连接网络，结构上的相邻关系可能被破坏。同时，参数数量随输入维度增长，可能增加过拟合风险。全连接神经网络较为适合处理发话级汇总特征，而在学习时频结构方面相对受限。

从语音情绪识别的角度来看，全连接神经网络模型仍可作为基线模型，尤其在数据规模不大且以人为设计特征为主的实验中具有解释相对简单、实现较为方便的优点。若要直接地学习情绪表示中的时间变化与局部模式，可结合后续介绍的卷积神经网络模型与循环神经网络模型^[5-6,8]。

3.1.2 卷积神经网络模型

卷积神经网络模型是一种专门用于学习输入数据局部模式的神经网络结构。在图像处理领域，卷积神经网络模型被广泛应用。在语音情绪识别中，卷积神经网络

模型同样适用于分析语音的时频表示^[8]。在语音情绪识别中，log-Mel 谱图、梅尔频率倒谱系数图、谱图等二维输入表示较为常用。卷积神经网络模型可提取 log-Mel 谱图、梅尔频率倒谱系数图、谱图等二维输入表示中的局部时频模式。例如，卷积神经网络模型可自动学习特定频带的能量集中、短时内的强度变化以及局部频谱纹理差异^[5]。

卷积神经网络模型的核心运算是卷积。对于二维输入特征图 $\mathbf{X}$ 与卷积核 $\mathbf{K}$ ，输出特征图中一个位置的计算方式为：

$$y_{i,j}^{(k)} = \sum_{m=0}^{M-1} \sum_{n=0}^{N-1} w_{m,n}^{(k)} x_{i+m,j+n} + b^{(k)} \quad (3-4)$$

其中 $x_{i+m,j+n}$ 为输入特征图的值， $w_{m,n}^{(k)}$ 为第 k 个卷积核的权重， $b^{(k)}$ 为偏置， $y_{i,j}^{(k)}$ 为输出特征图在位置 (i,j) 的值， M, N 为卷积核尺寸。

卷积后通常使用非线性激活函数，如 ReLU：

$$\text{ReLU}(x) = \max(0, x) \quad (3-5)$$

为降低维度和增强平移不变性，常使用池化操作。例如最大池化：

$$p_{i,j}^{(k)} = \max_{(m,n) \in \Omega_{i,j}} y_{m,n}^{(k)} \quad (3-6)$$

其中 $\Omega_{i,j}$ 为池化窗口区域。卷积神经网络模型的特性包括参数共享和局部连接。同一卷积核在输入的不同位置重复使用，有助于使卷积神经网络模型的参数数量少于全连接神经网络模型，并可用于学习局部模式^[8]。

在语音情绪识别中，卷积神经网络模型具有以下优势。第一，能够捕捉谱图或对数梅尔谱图中的局部能量结构与纹理。第二，参数共享机制使得在有限数据条件下可获得一定的泛化能力。第三，通过堆叠多个卷积层，可逐步从低级特征学习到高级语义特征^[5,8]。

卷积神经网络模型存在一定局限性。卷积操作主要在局部感受野内学习模式，难以建模发话过程中的长期依赖关系或全局上下文^[6]。此外，反复使用池化操作可能降低时间分辨率。若情绪线索分布在发话中相距较远的多个片段之间，仅依靠卷积神经网络模型可能不足以充分表示。一些语音情绪识别研究将卷积神经网络模型与循环神经网络、注意力机制或 Transformer 模型结合，以补充长期上下文信息^[6,10]。

3.1.3 循环神经网络模型及其变体

循环神经网络模型可视为一种为建模时间序列数据的顺序结构而设计的神经网络模型。全连接神经网络模型和卷积神经网络模型能够处理输入的静态结构或局部模式，循环神经网络模型则相对有利于反映时间点之间的依赖关系和顺序信息^[1]。在语音情绪识别中，情绪可能通过发话过程中的基频轮廓变化、能量轮廓的上升与下降、停顿与发音模式的累积效应等表现出来。时间序列建模具有一定作用^[7]。

基本循环神经网络模型的隐藏状态更新可表示为：

$$\mathbf{h}_t = \phi(\mathbf{W}_{xh}\mathbf{x}_t + \mathbf{W}_{hh}\mathbf{h}_{t-1} + \mathbf{b}_h) \quad (3-7)$$

其中 $\mathbf{x}_t$ 为 t 时刻的输入向量， $\mathbf{h}_{t-1}$ 为上一时刻的隐藏状态， $\mathbf{W}_{xh}$ 为输入-隐藏权重矩阵， $\mathbf{W}_{hh}$ 为隐藏-隐藏权重矩阵， $\mathbf{b}_h$ 为偏置向量， $\phi(\cdot)$ 为激活函数， $\mathbf{h}_t$ 为当前时刻的隐藏状态。

输出通常定义为：

$$\mathbf{y}_t = \psi(\mathbf{W}_{hy}\mathbf{h}_t + \mathbf{b}_y) \quad (3-8)$$

其中 $\mathbf{W}_{hy}$ 为隐藏-输出权重矩阵， $\mathbf{b}_y$ 为输出偏置， $\psi(\cdot)$ 为输出函数。

循环神经网络模型能够处理时间序列结构。在处理长序列时，该模型可能出现梯度消失或梯度爆炸问题。为缓解梯度消失或梯度爆炸问题，长短期记忆网络模型和门控循环单元模型被提出^[7]。长短期记忆网络模型通过输入门、遗忘门、输出门映射信息流动。典型公式如下：

$$\mathbf{f}_t = \sigma(\mathbf{W}_f[\mathbf{h}_{t-1}, \mathbf{x}_t] + \mathbf{b}_f) \quad (3-9)$$

$$\mathbf{i}_t = \sigma(\mathbf{W}_i[\mathbf{h}_{t-1}, \mathbf{x}_t] + \mathbf{b}_i) \quad (3-10)$$

$$\tilde{\mathbf{c}}_t = \tanh(\mathbf{W}_c[\mathbf{h}_{t-1}, \mathbf{x}_t] + \mathbf{b}_c) \quad (3-11)$$

$$\mathbf{c}_t = \mathbf{f}_t \odot \mathbf{c}_{t-1} + \mathbf{i}_t \odot \tilde{\mathbf{c}}_t \quad (3-12)$$

$$\mathbf{o}_t = \sigma(\mathbf{W}_o[\mathbf{h}_{t-1}, \mathbf{x}_t] + \mathbf{b}_o) \quad (3-13)$$

$$\mathbf{h}_t = \mathbf{o}_t \odot \tanh(\mathbf{c}_t) \quad (3-14)$$

其中 $\mathbf{f}_t$ 为遗忘门， $\mathbf{i}_t$ 为输入门， $\tilde{\mathbf{c}}_t$ 为候选细胞状态， $\mathbf{c}_t$ 为细胞状态， $\mathbf{o}_t$ 为输出门， $\sigma(\cdot)$ 为 sigmoid 函数， $\odot$ 为逐元素乘法。

门控循环单元模型具有相对更简单的门控结构：

$$\mathbf{z}_t = \sigma(\mathbf{W}_z[\mathbf{h}_{t-1}, \mathbf{x}_t] + \mathbf{b}_z) \quad (3-15)$$

$$\mathbf{r}_t = \sigma(\mathbf{W}_r[\mathbf{h}_{t-1}, \mathbf{x}_t] + \mathbf{b}_r) \quad (3-16)$$

$$\tilde{\mathbf{h}}_t = \tanh(\mathbf{W}_h[\mathbf{r}_t \odot \mathbf{h}_{t-1}, \mathbf{x}_t] + \mathbf{b}_h) \quad (3-17)$$

$$\mathbf{h}_t = (1 - \mathbf{z}_t) \odot \mathbf{h}_{t-1} + \mathbf{z}_t \odot \tilde{\mathbf{h}}_t \quad (3-18)$$

其中 $\mathbf{z}_t$ 为更新门， $\mathbf{r}_t$ 为重置门， $\tilde{\mathbf{h}}_t$ 为候选隐藏状态。

双向循环神经网络模型包括双向长短期记忆网络模型和双向门控循环单元模型。双向循环神经网络模型同时学习正向和反向序列，可使当前时刻的表示反映过去和未来的上下文。双向隐藏表示可通过拼接得到：

$$\mathbf{h}_t = [\vec{\mathbf{h}}_t; \overleftarrow{\mathbf{h}}_t] \quad (3-16)$$

其中 $\vec{\mathbf{h}}_t$ 为正向隐藏状态， $\overleftarrow{\mathbf{h}}_t$ 为反向隐藏状态， $[\cdot; \cdot]$ 表示向量拼接。

在语音情绪识别中，循环神经网络模型可反映时间连续性与长期上下文。例如，某些情绪可能通过整个发话的速度变化、语调的累积走向、句尾的情绪处理等得到充分的体现。循环神经网络模型、长短期记忆网络模型、门控循环单元模型可处理这类顺序信息。双向长短期记忆网络模型或双向门控循环单元模型能够利用发话前后的上下文，在语音情绪识别中被一些研究采用^[5,7]。

循环神经网络模型存在一定局限。第一，顺序计算结构可能导致并行效率相对较低，在处理较长序列时计算成本可能增加。第二，长短期记忆网络模型和门控循环单元模型缓解了基本循环神经网络模型的长期依赖问题。在极长序列中，循环神经网络模型难以充分覆盖部分关键区间。第三，对于发话中哪些区间对情绪判断更为关键，循环神经网络模型缺乏选择性强调的机制。

3.2 注意力机制

在语音情绪识别中，有研究指出情绪信息可能以不均匀的方式分布于整个发话，相对集中于特定的时间区间、特定的频率范围或特定的声学模式之中^[9,21,48-49]。卷积神经网络模型和循环神经网络模型可用于学习语音表示，然而在采用统一权重处理输入各部分时，可能难以充分区分与情绪判断相关性相对较高的区间^[5-6,8]。在此背景下，注意力机制作为一种计算输入内部相关性并据此调整信息组合权重的结构方法，被引入语音情绪识别中^[9,49]。注意力机制是一种通过相关性计算与加权聚合来重新分

配信息重要性的广义机制,这一机制既包括基于查询、键、值计算输入元素之间关系的注意力结构,也包括根据查询与键-值来源不同区分的自注意力和交叉注意力;根据注意力分数的计算方式,可使用缩放点积注意力或加性注意力;根据结构的并行化或作用范围,可使用多头注意力或局部注意力等扩展形式^[9-11,21]。

本节首先介绍注意力机制的基本概念与核心要素,说明查询、键、值的含义以及自注意力与交叉注意力的区别。随后介绍两种典型的注意力分数计算方法:缩放点积注意力和加性注意力。然后讨论多头注意力和局部注意力等结构扩展方式。最后总结注意力机制在语音情绪识别中的作用,并讨论其在数据规模、计算复杂度和可解释性等方面的局限。

3.2.1 注意力机制的基本概念与核心要素

注意力机制可理解为一种计算输入序列或特征图中各元素之间相关性,并根据计算结果调整信息组合权重的通用方法^[9,49]。在语音情绪识别中,情绪线索并非均匀分布于整个发话,而是相对集中于特定时间区间、特定频率范围或特定声学模式^[9,21,48]。基于这一特性,注意力机制通过计算输入内部元素之间的关联程度,并据此重新分配信息重要性,从而更有选择性地反映与情绪判断相关性较高的区间^[9,49]。

在注意力计算过程中,首先需要定义用于量化各输入元素之间相关性的注意力分数。设输入序列中第 i 个元素与第 j 个元素的相关性得分为 e_{ij} ,注意力机制通常对这些得分进行归一化后计算加权和。该过程的一般形式可表示为:

$$e_{ij} = a(q_i, k_j) \quad (3-19)$$

$$\alpha_{ij} = \frac{\exp(e_{ij})}{\sum_{j'=1}^T \exp(e_{ij'})} \quad (3-20)$$

$$z_i = \sum_{j=1}^T \alpha_{ij} v_j \quad (3-21)$$

其中 $a(\cdot, \cdot)$ 为相关性计算函数, q_i 为第 i 个查询, k_j 为第 j 个键, v_j 为第 j 个值。 e_{ij} 为归一化之前的注意力分数, α_{ij} 为通过 softmax 归一化得到的注意力权重, z_i 为最终的注意力输出。注意力分数可视为决定各元素在输出中比重的中间变量。后续小

节介绍的缩放点积注意力和加性注意力，区别在于如何定义 $a(\cdot, \cdot)$ 函数^[10-11,21]。

在注意力计算中，查询、键、值是常用的基本元素。设输入表示为矩阵 X ，注意力机制通常从 X 或不同输入表示构造查询矩阵 Q 、键矩阵 K 、值矩阵 V ，并计算它们之间的相关性。基础的线性变换形式可表示为：

$$Q = X_Q W_Q, \quad K = X_K W_K, \quad V = X_V W_V \quad (3-22)$$

其中 X_Q 、 X_K 、 X_V 分别为用于生成查询、键、值的输入表示， W_Q 、 W_K 、 W_V 为可学习的权重矩阵。当三个输入表示相同时，这一结构用于计算单一输入内部的元素关系。当三个输入表示不同时，则用于计算不同表示之间的元素关系。从这一角度看，查询表示当前关注的对象，键表示被比较的参考信息，值表示最终被聚合的内容^[10-11,21]。

根据查询、键、值的来源，注意力可分为自注意力和交叉注意力。自注意力是指查询、键、值均来自同一输入表示的结构。其一般形式可写为：

$$Q = X W_Q, \quad K = X W_K, \quad V = X W_V \quad (3-23)$$

$$\text{SelfAttention}(X) = \text{Attention}(Q, K, V) \quad (3-24)$$

其中 X 为一个输入序列或时频特征表示。自注意力用于计算同一输入内部各位置之间的相关性，可反映输入序列的全局关系。在语音情绪识别中，自注意力可建模特定时间帧与其他帧之间的情绪关联，从而选择性地强调对情绪判断较重要的区间^[9-10,49]。

交叉注意力则是指查询与键-值对来自不同输入表示的结构。其一般形式可写为：

$$Q = X W_Q, \quad K = Y W_K, \quad V = Y W_V \quad (3-25)$$

$$\text{CrossAttention}(X, Y) = \text{Attention}(Q, K, V) \quad (3-26)$$

其中 X 和 Y 为不同的输入表示。交叉注意力用于建模一个表示与另一个表示之间的交互，可反映不同特征空间或不同声学表示之间的相关性。在语音情绪识别中，当同时使用梅尔频率倒谱系数、对数梅尔谱图或 wav2vec 系列表示时，交叉注意力可用于学习多种异质表示之间的关联^[21,49]。

3.2.2 代表性的注意力分数计算方式

注意力可视为将输入元素之间的相关性量化为注意力分数，并通过归一化形成加权求和的机制。注意力分数的计算方式是决定注意力行为特性的关键因素。当前较为常用的注意力分数计算方法主要包括缩放点积注意力和加性注意力。两种方法均通过查询与键之间的相关性计算分数，但在分数计算函数的结构与特性上存在差异^[9-11,50]。

缩放点积注意力基于查询与键的点积计算注意力分数。设输入序列中第 i 个查询为 q_i ，第 j 个键为 k_j ，则注意力分数可表示为：

$$e_{ij} = \frac{q_i k_j^\top}{\sqrt{d_k}} \quad (3-27)$$

其中 $q_i k_j^\top$ 为查询与键的点积， d_k 为键向量的维度。除以 $\sqrt{d_k}$ 的原因在于：随着维度增加，点积值的方差可能增大，从而导致 softmax 输出趋于极端分布。因此，缩放点积注意力中的缩放因子可视为提高学习稳定性的修正项^[10-11,50]。

计算得到的分数在后续步骤中仍通过 softmax 归一化形成注意力权重，并与值向量加权聚合，其过程与式 (3-20) 和式 (3-21) 所示的一般形式一致。缩放点积注意力的矩阵形式可表示为：

$$\text{Attention}(Q, K, V) = \text{softmax} \left(\frac{QK^\top}{\sqrt{d_k}} \right) V \quad (3-28)$$

其中 $QK^\top$ 表示查询矩阵与键矩阵之间的点积结果， $\sqrt{d_k}$ 为缩放因子。该形式将注意力分数计算、归一化与加权聚合统一表示为一个矩阵运算过程^[10-11,50]。

缩放点积注意力的特点在于分数计算基于矩阵乘法。这种计算方式相对有利于并行计算，在实际实现中可能在计算效率和内存使用方面具有一定优势^[10-11,50]。在语音情绪识别中，缩放点积注意力可用于反映特定时间帧或局部区域与其他位置之间的情绪相关性，从而相对突出地强调发话中的关键区间^[10-11,21]。

加性注意力通过非线性变换计算分数，不使用查询与键的点积。其一般形式可表示为：

$$e_{ij} = v_a^\top \tanh(W_q q_i + W_k k_j + b_a) \quad (3-29)$$

其中 W_q 和 W_k 分别为查询与键的权重矩阵， b_a 为偏置向量， v_a 为用于计算最终分数的可学习向量。该公式可理解为：先对查询与键分别进行线性变换，再通过非线性

函数 $\tanh(\cdot)$ 得到分数^[9]。

加性注意力在分数计算后的归一化与加权聚合过程，与式 (3-20) 和式 (3-21) 所示的一般注意力形式一致。与缩放点积注意力相比，加性注意力的差异主要不在于后续的权重归一化与输出形成过程，而在于通过显式的线性变换与非线性函数构造注意力分数^[9]。

在语音情绪识别中，加性注意力可进一步应用于循环神经网络模型的输出或局部隐藏状态集合，从而突出与情绪判断相关性较高的时刻。例如，在 IEMOCAP 等数据集上，加性注意力与局部注意力结合使用的案例表明，可通过设计注意力分数函数相对更有针对性地强调发话中的特定区间^[9]。

3.2.3 注意力的结构类型与扩展方式

在实际应用中，注意力机制的结构设计需考虑单次注意力运算的并行化方式，以及计算范围是全局还是局部。多头注意力和局部注意力保持原有的注意力分数计算方式，是对已计算注意力的扩展，分别将注意力应用于不同的表示空间或不同的计算范围^[9-11,50]。

仅使用单头注意力时，输入内部的各种关系需要在同一个权重结构中得到反映，此时可能难以充分分离不同类型的信息。为缓解上述问题，研究者们提出了多头注意力^[10-11,50]。多头注意力将单次注意力运算并行化为多个头部，使模型能够在不同的表示子空间中同时学习多种类型的关系。

设头部数量为 h ，第 i 个头部可表示为：

$$\text{head}_i = \text{Attention}(QW_i^Q, KW_i^K, VW_i^V) \quad (3-30)$$

其中 W_i^Q 、 W_i^K 、 W_i^V 分别为第 i 个头部对应的查询、键、值变换矩阵。各头部使用不同的权重矩阵，因此即使输入表示相同，也能从不同角度学习相关性。所有头部的输出经拼接后，再通过一次线性变换得到最终结果：

$$\text{MultiHead}(Q, K, V) = \text{Concat}(\text{head}_1, \text{head}_2, \dots, \text{head}_h)W^O \quad (3-31)$$

其中 W^O 为输出变换矩阵。该结构使模型能够并行反映比单头注意力更多类型的关系^[10-11,50]。

在语音情绪识别中，情绪线索可能出现在语调变化、能量分布、频率结构、长期

上下文等多个层面，也可能存在于单一维度。基于情绪线索的多维特性，部分头部可能对语调变化或能量分布较为敏感，另一些头部则可能更关注频率结构或长期上下文关系。因此，多头注意力可用于同时反映语音信号中的多层次情绪线索^[4,10-11,21]。

多头注意力在能够处理更多关系的同时，头部数量的增加也可能导致参数数量和计算量相应上升。在数据规模有限的条件下，增加头部数量不一定带来性能提升，模型复杂度的增加可能对泛化能力造成一定负担^[7,10-11,18,23]。在语音情绪识别中，需结合输入长度、数据规模、计算资源等因素设定头部数量与模型复杂度。

当序列较长时，计算各位置对之间的注意力权重可能导致计算开销增加。有研究指出，在语音情绪识别中情绪线索往往集中在局部区间，而不是均匀分布。在整个输入范围上计算注意力不一定是合适的结构^[9-10]。局部注意力仅在某个中心位置周围的有限窗口内计算注意力权重。

局部注意力将注意力的作用范围限制在窗口 w 内。例如，当 $|i - j| > w$ 时，将对对应位置的得分设为 $-\infty$ ，从而在后续 softmax 中忽略这些位置。其表达式为：

$$e_{ij} = \begin{cases} a(q_i, k_j), & |i - j| \leq w \\ -\infty, & |i - j| > w \end{cases} \quad (3-32)$$

其中 $a(q_i, k_j)$ 对应式 (3-27) 或式 (3-29) 所示的注意力分数函数。应用 softmax 后，在窗口内部形成注意力权重。局部注意力保持分数计算方式不变，仅对注意力的作用范围进行结构性限制。

局部注意力的优势在于通过限制计算范围来降低整体计算量。全局注意力需要计算所有位置对之间的交互，计算量与序列长度的平方成正比。局部注意力仅考虑窗口内的交互，可相对减少计算负担^[10]。在语音情绪识别中，局部注意力有助于反映发话中的局部信息，如短时语调变化、能量突变区间或特定时刻的声学模式^[9-10]。

在实际研究中，局部注意力曾被应用于循环神经网络模型的隐藏状态集合，以突出发话中的关键时刻。在基于 Transformer 的模型中，也有动态窗口或移位窗口等变体，用于结构性调整注意力的作用范围^[9-11]。窗口过小可能难以反映长距离关系，窗口过大则可能削弱局部注意力的计算效率优势。局部注意力宜结合应用范围、输入长度以及情绪线索的分布特性进行适当设置。

3.2.4 注意力机制在语音情绪识别中的作用与局限

在语音情绪识别中，注意力机制可用于更有选择性地反映发话内部的情绪线索。有研究指出，语音中的情绪信息通常不均匀分布，相对集中于特定时间区间的语调变化、特定频带的能量增强、能量的明显增减或局部声学模式^[9,21,48-49]。基于情绪信息分布的不均匀性，注意力机制可对与情绪判断相关性较高的区间或特征赋予较大权重，不以相同权重处理所有输入。因此，注意力机制可视为反映情绪线索非均匀分布的一种结构手段。

注意力机制的第一个作用是突出发话内部的关键区间。在同一发话中，对情绪判断影响较大的区间可能只占整体的一部分。注意力机制可通过赋予特定时间帧、局部区域或隐藏状态较大的权重，使模型相对重视这些关键区间^[9-11,49]。在顺序或卷积特征提取过程中，一些情绪相关区间可能被弱化，注意力机制有助于重新突出这些区间，在发话较长或情绪线索较为集中的条件下具有一定作用。

注意力机制的第二个作用是连接不同时间范围或不同层次的表示信息。在语音情绪识别中，语调、节奏、能量、频率结构等多种声学信息相互作用，共同影响情绪判断。注意力机制可通过反映序列内部的长距离关系，或使一种表示选择性地参考另一种表示，从而整合单一特征或单一时刻难以覆盖的上下文信息^[10-11,21,51]。注意力机制可用于突出局部区间，也可用于灵活反映发话内部的关系结构。

注意力机制在可解释性方面也可提供辅助信息。通常情况下，注意力权重可部分显示模型相对关注哪些时间区间、局部区域或特征表示。研究者可据此辅助观察情绪线索在发话中的分布，或模型相对依赖哪些信息^[48-49]。注意力权重不等同于可解释性。注意力权重仅反映模型内部计算的一部分，最终预测还受到后续线性变换、非线性激活、分类器结构等因素的影响。注意力权重可作为可解释性的辅助参考，但不宜视为解释依据。

注意力机制在语音情绪识别中存在一些局限。第一，在数据规模有限的条件下，注意力结构可能增加过拟合风险。语音情绪数据集通常规模较小，情绪类别之间的界限也可能较为模糊。在这种情况下，引入注意力机制的复杂模型可能同时学习到情绪相关模式以及数据集的特定偏差或偶然波动^[7,18,23]。在采用注意力结构时可能综合考虑数据规模、模型复杂度、正则化策略与评估方式。

第二，注意力机制在计算复杂度方面可能存在一定负担。设输入长度为 T ，计算

所有位置对之间交互的注意力结构通常会产生如下大小的注意力矩阵：

$$A \in \mathbb{R}^{T \times T} \quad (3-33)$$

其时间与内存复杂度一般满足：

$$\text{Cost} \propto O(T^2) \quad (3-34)$$

随着发话长度或帧数增加，注意力计算量和内存占用可能迅速上升。在长发话、高分辨率谱图或多表示结合的场景中，上述计算开销可能相对较大。局部注意力、窗口化注意力、降采样或分块等方法可用于限制计算范围^[10-11]。

第三，注意力机制不一定带来性能提升。注意力机制用于重新分配输入内部的权重，但当情绪线索较弱或输入表示本身不够具有区分力时，注意力可能难以突出关键信息。若注意力权重过于分散或过度集中于少数位置，信息整合效果可能受到影响。注意力机制不应视为独立的解决方案，而应理解为与输入表示的适用性、基础模型结构、数据质量及学习条件相互配合的辅助结构^[10-11,18,23]。

3.3 Transformer 结构

注意力机制可理解为计算输入内部相关性并根据计算结果对信息进行加权组合的结构。注意力是一种计算机制，如何将其组织到实际的时间序列模型中，是独立的设计问题。Transformer 模型以注意力机制为核心，结合编码器-解码器结构、位置信息补充、残差连接、层归一化以及位置级前馈网络，作为一种模型结构被提出^[50]。

传统的循环神经网络按时间顺序更新隐藏状态，以此处理时间序列信息。卷积神经网络则基于局部感受野逐步提取相邻区间的模式。Transformer 模型通过基于注意力的交互来构建输入序列内部的全局关系，不依赖于循环结构或卷积运算^[50]。在语音情绪识别中，基于这些结构特性，Transformer 类模型逐渐得到应用，同时出现了调整输入表示单元和计算范围的多种变体结构^[10-11,23]。本节首先介绍 Transformer 模型的整体结构以及编码器与解码器的基本信息流动。随后说明位置信息如何补充到输入表示中，接着阐述 Transformer 层内部核心组件的作用。

3.3.1 Transformer 的整体架构

Transformer 模型基于编码器与解码器构成的堆叠结构。各编码器层与解码器层采用相同的内部结构重复堆叠，输入表示经过这些重复结构逐步转换为融合上下文

信息的高维表示^[50]。最初的 Transformer 模型针对序列到序列的转换任务提出，同时使用编码器和解码器。编码器从输入序列中提取上下文表示，解码器则参考编码器的输出逐步生成目标序列^[50]。

设输入表示为 $X \in \mathbb{R}^{T \times d}$ ，编码器依次通过多个编码器层，逐步反映输入序列的内部关系。这一过程可按层表示如下：

$$H^{(0)} = X \quad (3-35)$$

$$H^{(l)} = \text{EncoderLayer}^{(l)}(H^{(l-1)}), \quad l = 1, 2, \dots, L_e \quad (3-36)$$

其中 $H^{(0)}$ 为编码器的初始输入表示， $H^{(l)}$ 为第 l 个编码器层的输出， L_e 为编码器层数。通过这种重复结构，输入序列中各个位置的表示逐渐融入更广的上下文信息^[50]。

解码器接收目标序列或对应的中间表示作为输入，同时参考编码器的输出表示，逐步生成下一阶段输出。解码器的信息流动可一般地表示为：

$$S^{(0)} = Y \quad (3-37)$$

$$S^{(l)} = \text{DecoderLayer}^{(l)}(S^{(l-1)}, H^{(L_e)}), \quad l = 1, 2, \dots, L_d \quad (3-38)$$

其中 Y 为解码器侧的输入表示， $S^{(l)}$ 为第 l 个解码器层的输出， L_d 为解码器层数。解码器在反映目标序列内部信息的同时，通过参考编码器的最终输出 $H^{(L_e)}$ ，形成输入序列与输出序列之间的对应关系^[50]。

Transformer 结构的一个特点是，它不像循环神经网络模型那样按时间步顺序更新状态。循环神经网络模型依赖上一时刻的隐藏状态计算当前时刻的表示，整个序列处理本质上是顺序的。Transformer 可以在同一层内同时计算序列中多个位置之间的相关性，因此有利于并行计算^[50]。

在处理长距离依赖关系的方式上，Transformer 与传统模型结构存在差异。循环神经网络模型中，相距较远的两个时间点之间的信息需要经过多个时间步的状态传递，序列越长信息传递路径越长。卷积神经网络模型同样通过逐步扩大局部感受野来融入更广的上下文，若要反映较大范围的关系，可能需要增加层数或引入额外结构。Transformer 通过注意力运算可以计算远距离位置之间的相关性，从而相对地建模输入内部的全局关系^[10-11,50]。

语音情绪识别通常是对整个发话进行分类的任务，原始 Transformer 的编码器-解码器结构常被简化为以编码器为中心的形式或进行适当变形^[10-11,23]。在此情况下，可在编码器的最终输出上结合池化或分类头，进行发话级别的预测。该过程可概念性地表示为：

$$\hat{y} = \text{Classifier}(\text{Pool}(H^{(L_e)})) \quad (3-39)$$

其中 $\text{Pool}(\cdot)$ 表示形成发话级表示的操作，如平均池化、注意力池化或基于分类标记的聚合等， $\hat{y}$ 为最终的预测情绪类别。近年来，在语音情绪识别研究中，人们提出在以编码器为中心的结构之上，结合基于窗口的注意力、分层补丁表示或与卷积神经网络混合的结构，以调整计算范围和表示单元^[6,10-11,23]。

3.3.2 位置编码机制

Transformer 的注意力运算适合计算输入向量之间的相关性，但注意力运算本身不反映序列的顺序。当给定一组相同的输入向量时，若未提供位置信息，模型难以从结构上区分位置 1 与位置 10 的差异。在原始 Transformer 模型中，通过在输入嵌入中加入位置编码来缓解位置信息的缺失^[50]。

较为常见的固定型位置编码使用正弦函数和余弦函数为每个位置构造对应的向量。设位置索引为 pos ，维度索引为 i ，总维度为 d ，固定型位置编码通常可定义为^[50]：

$$PE(pos, 2i) = \sin\left(\frac{pos}{10000^{2i/d}}\right) \quad (3-40)$$

$$PE(pos, 2i + 1) = \cos\left(\frac{pos}{10000^{2i/d}}\right) \quad (3-41)$$

其中偶数维度使用正弦函数，奇数维度使用余弦函数。这种构造方式利用不同周期的周期函数，以连续形式表示各个位置。当位置距离发生变化时，各维度的变化模式也随之不同，因此模型可同时利用绝对位置信息以及位置之间的相对差异信息^[50]。

设输入表示为 $X \in \mathbb{R}^{T \times d}$ ，位置编码矩阵为 $PE \in \mathbb{R}^{T \times d}$ ，融合位置信息后的最终输入可表示为：

$$X' = X + PE \quad (3-42)$$

其中 X' 为补充位置信息后的输入表示。通过这种加法结构，原始输入特征与位置信息在同一维度空间中共同传递。因此，后续的注意力运算除了比较各位置的特征值，

还计算包含位置信息的表示之间的相关性^[50]。

与固定型位置编码经常被一起提及的是可学习型位置嵌入。可学习型位置嵌入将位置向量作为模型参数，在训练过程中直接更新。这种方式不使用预先通过固定函数计算每个位置向量的方法。用矩阵形式可表示为：

$$P \in \mathbb{R}^{T \times d} \quad (3-43)$$

$$X' = X + P \quad (3-44)$$

其中 P 为可学习的位置嵌入矩阵。可学习型方法的优势在于能根据数据和任务特性调整位置表示本身。由于位置向量可能适应训练数据的长度分布，当推广到训练中未出现的长序列时，其行为可能与固定型方法有所不同^[50]。

在语音情绪识别中，位置编码的含义与自然语言处理存在差异。自然语言处理中通常反映单词或子词标记的顺序，语音情绪识别中的输入单元往往是对数梅尔谱图的帧序列、梅尔频率倒谱系数序列或基于补丁的频谱表示^[10-11,23]。在此情况下，位置编码用于表示每个帧或每个补丁在发话中的时间位置。即使相同的频率结构出现，该频率结构出现在发话早期、中期还是后期，其情绪含义可能不同。补充位置信息可视为反映时间序列结构的一个因素^[10-11]。

3.3.3 Transformer 层中的关键组成结构

Transformer 的编码器和解码器由注意力子层堆叠而成。Transformer 的一层由注意力运算和用于表示重组、层间信息传递稳定的补充结构共同构成。在原始 Transformer 中，每个注意力子层之后依次应用残差连接与层归一化，随后放置位置级前馈网络，之后再次应用残差连接与层归一化^[50]。

以一个编码器层为例，输入表示 $H^{(l-1)}$ 首先经过多头自注意力子层，该子层的输出通过残差连接与层归一化更新为中间表示 $\tilde{H}^{(l)}$ 。这个中间表示随后通过位置级前馈网络，再次经过残差连接与层归一化，形成最终输出 $H^{(l)}$ 。该过程可表示为：

$$\tilde{H}^{(l)} = \text{LayerNorm}(H^{(l-1)} + \text{MHA}(H^{(l-1)})) \quad (3-45)$$

$$H^{(l)} = \text{LayerNorm}(\tilde{H}^{(l)} + \text{FFN}(\tilde{H}^{(l)})) \quad (3-46)$$

其中 $\text{MHA}(\cdot)$ 表示该编码器层的多头自注意力子层， $\text{FFN}(\cdot)$ 表示位置级前馈网络。在

编码器层内部，首先通过自注意力反映同一输入序列内部的相关性，随后各位置的表示独立经过非线性变换，形成最终输出^[50]。

解码器层的内部结构与之类似，但多了一个注意力子层。在解码器中，首先通过掩码多头自注意力反映目标序列内部的自相关性，然后通过一个注意力子层反映解码器表示与编码器最终输出之间的对应关系，之后应用位置级前馈网络。该过程可整理为：

$$\bar{S}^{(l)} = \text{LayerNorm}(S^{(l-1)} + \text{MaskedMHA}(S^{(l-1)})) \quad (3-47)$$

$$\tilde{S}^{(l)} = \text{LayerNorm}(\bar{S}^{(l)} + \text{MHA}(\bar{S}^{(l)}, H^{(L_e)})) \quad (3-48)$$

$$S^{(l)} = \text{LayerNorm}(\tilde{S}^{(l)} + \text{FFN}(\tilde{S}^{(l)})) \quad (3-49)$$

其中 $\text{MaskedMHA}(\cdot)$ 表示限制未来时刻信息直接参与的掩码自注意力子层, $\text{MHA}(\bar{S}^{(l)}, H^{(L_e)})$ 表示解码器表示参考编码器最终输出的注意力子层。在解码器层内部，目标序列内部的自相关性与输入序列的对应关系被依次反映，随后通过前馈网络更新各位置表示^[50]。

位置级前馈网络的作用是将注意力形成的上下文信息在各位置表示层面进行再变换。这种网络对已通过注意力融入上下文信息的每个位置向量施加相同的非线性变换。该网络不直接计算序列中不同位置之间的关系。其一般形式为：

$$\text{FFN}(x) = W_2 \sigma(W_1 x + b_1) + b_2 \quad (3-50)$$

其中 x 为某一位置的输入向量， W_1 、 W_2 为权重矩阵， b_1 、 b_2 为偏置向量， $\sigma(\cdot)$ 为非线性激活函数。该步骤可视为在注意力聚合的上下文信息基础上对每个位置表示进行进一步重组^[50]。

残差连接将子层的输入表示直接加到变换结果上。其一般形式为：

$$y = x + \mathcal{F}(x) \quad (3-51)$$

其中 x 为子层输入， $\mathcal{F}(x)$ 为经过注意力或前馈网络后的变换结果。残差连接在保留原始输入信息的同时加入变换结果，有助于缓解深层网络中信息过度衰减的问题^[50]。

层归一化对每个位置表示向量内部的各维度计算均值和方差，并据此对表示进

行尺度归一化。其一般形式为：

$$\mu = \frac{1}{d} \sum_{i=1}^d x_i \quad (3-52)$$

$$\sigma^2 = \frac{1}{d} \sum_{i=1}^d (x_i - \mu)^2 \quad (3-53)$$

$$\text{LayerNorm}(x) = \gamma \odot \frac{x - \mu}{\sqrt{\sigma^2 + \epsilon}} + \beta \quad (3-54)$$

其中 $x \in \mathbb{R}^d$ 为某位置的输入向量， μ 和 σ^2 分别为该向量的均值和方差， ϵ 为防数值不稳定的小常数。 γ 和 β 为可学习的缩放与平移参数， $\odot$ 表示逐元素乘法。层归一化在每个位置的表示向量内部进行归一化，因此对序列长度和批次大小的变化相对不敏感^[50]。

3.3.4 Transformer 的主要特点及其适用边界

Transformer 的第一个特点在于它相对有利于并行计算。循环神经网络模型中，当前时刻的计算依赖于前一时刻的状态，整个处理过程通常是顺序的。Transformer 通过自注意力机制可以同时计算多个位置之间的相关性，因此在输入长度相同时，Transformer 的计算结构可以相对并行化地组织^[50]。当发话长度增加到一定程度，或采用帧级、补丁级输入时，这一并行计算特性可能在一定程度上简化计算流程^[10-11]。

Transformer 的第二个特点在于它能够直接建模输入内部的全局关系。循环神经网络中，相距较远的位置之间的信息需要经过多个时间步的状态传递。卷积神经网络则需要通过逐步扩大局部感受野来拓宽上下文范围。Transformer 通过自注意力机制可以计算远距离位置之间的相关性，从而将分布在整个发话中的情绪线索整合到一个结构中^[50]。在语音情绪识别中，情绪信息可能分布在发话的多个时刻及多个时间尺度上。这种全局建模特性与发话级分类任务具有一定的相关性^[10-11]。

然而，Transformer 的优势表现与具体条件有关。随着输入长度增加，注意力计算范围扩大，计算量和内存占用可能相应增加^[50]。在语音情绪识别中，帧级序列可能较长，若采用高分辨率频谱表示或多特征融合，输入标记数量会进一步增多。在此情况下，应用原始 Transformer 结构不一定总是高效的选择，实际研究中已提出基于窗口的注意力、移位窗口、分层补丁表示等结构调整方法^[10-11]。

Transformer 的结构表达能力较强，Transformer 的稳定性受数据规模和任务条件影响。语音情绪识别数据通常规模不大，情绪类别之间的界限也可能不够清晰。在此类条件下，结构复杂的模型可能同时学习到情绪相关模式以及数据集本身的偏差。近年来，研究者提出调整输入范围、使用分层表示或结合多任务学习等方式，在跨语料库条件下提高泛化能力，不单纯扩大 Transformer 结构本身^[10-11,23]。

3.4 本章小结

第 4 章 实验设计与实验分析

本章围绕对数梅尔频谱输入条件下的语音情绪识别实验展开，比较对象包括卷积神经网络基线模型、纯 Transformer 模型以及 CNN-Conformer 模型。前文已经分别介绍了语音信号处理方法、注意力机制与 Transformer 相关结构，本章不再重复相关理论，主要说明实验对象、结构实现、训练设置以及结果分析。

本章的实验内容可以分为两个层面。第一个层面是在统一输入表示、训练框架与评价指标下比较卷积神经网络基线模型、纯 Transformer 模型以及 CNN-Conformer 模型的综合表现。第二个层面是围绕 CNN-Conformer 模型继续展开结构调整、过拟合缓解、噪声条件评价和跨语料库评价。按照这一安排，本章先给出实验参数、输入组织方式、模型结构与实现环境，再报告综合实验结果，随后补充受扰输入条件与异源语料条件下的观察，最后对本章结果进行归纳。

4.1 实验参数与设置

4.1.1 数据集与任务设置

本章实验继续采用 RAVDESS 语音情绪数据集。RAVDESS 语音情绪数据集包含多个情绪类别，并覆盖不同用户的语音样本，能够为用户无关条件下的语音情绪识别实验提供较为统一的测试环境。考虑到前文已经对数据集来源、类别构成以及语料特点进行了说明，本节仅保留与实验实现直接相关的设置内容。

在任务设定方面，本文将各模型置于相同的数据划分原则下比较，以尽量降低由数据切分方式带来的额外差异。实验过程中采用用户级划分思路，使训练集与验证集、测试集之间保持用户层面的分离，从而考察模型在未见用户语音上的泛化表现。用户级划分设定与本文关注的实际应用情境较为一致，因为真实场景下的系统通常需要面对未参与训练的用户输入。结合实验记录，当前实验所使用的语音子集共包含 1440 条语音样本、24 名用户，每名用户包含 60 条语音。8 个情绪类别中，类别 01 对应 96 条样本，其余 7 个类别各包含 192 条样本。

4.1.2 输入表示与预处理流程

各比较模型均以对数梅尔频谱作为输入表示。采用对数梅尔频谱的主要原因在于，对数梅尔频谱能够在保持频谱结构信息的同时，对语音中的能量分布与频带差异提供

表 4-1 数据集构成与用户无关划分方式

项目	说明	数值/类别数	备注
数据集	RAVDESS Speech	1440 条语音	仅使用语音部分
用户数量	用户 01–24	24 名用户	每名用户 60 条样本
情绪类别	8 类	01–08	01 类 96 条，其余各 192 条
划分方式	用户无关划分	5 折交叉验证	Optuna 阶段通常运行 1 折筛选

较为稳定的刻画。与直接使用原始波形相比，对数梅尔频谱在当前数据规模下有利于统一输入维度，也便于不同模型结构之间的对照实验。根据公开数据说明，RAVDESS 原始音频为 16bit、48kHz 单声道语音，但本项目训练时统一重采样到 16kHz，以便与当前深度学习实验配置保持一致。

实现流程中，本文首先对原始语音进行重采样与幅值归一化处理，随后按照固定帧长与帧移提取时频表示，并映射到梅尔滤波器组上，获得对数梅尔频谱特征。对于输入长度不一致的问题，本文采用分块处理方式，将较长语音切分为多个局部片段并在推理阶段进行聚合，以减少由时长差异带来的训练不稳定现象。预处理流程既保留了语音局部变化信息，也控制了模型训练时的显存开销。

在数据增强方面，实验中保留了有限度的时频遮挡设置，并对增强强度进行了约束。前期实验结果展现出一个现象：过强的数据增强未稳定改善验证结果，部分设置会削弱情绪相关细节的保留。本章在综合实验中主要采用较为克制的增强策略，以降低增强幅度对模型比较结果的额外影响。

表 4-2 输入表示与预处理参数设置

参数类别	参数名称	当前设置	说明
音频处理	采样率	16000Hz	各实验统一
特征提取	n_fft / hop_length	1024 / 160	主实验固定设置
特征维度	梅尔频带数	80	CNN-Conformer 主线统一
分块设置	chunk 长度/步长	48 / 12	综合实验主线常用设置
数据增强	时频遮挡	关闭或弱增强	代表方案主要依赖混合增强

4.1.3 比较模型的结构设计

4.1.3.1 卷积神经网络基线模型

卷积神经网络基线模型作为本文的基础比较对象，卷积神经网络基线模型的主要思路是在二维时频平面上逐层提取局部模式，再通过池化与分类头完成情绪类别判别。卷积神经网络基线模型具有明确的局部感受野与参数共享机制，能够较为直接地学习能量突变、频带形状以及局部时频纹理等模式。在对数梅尔频谱输入条件下，卷积结构通常能够形成较为稳定的训练过程，适合作为后续 Transformer 系列模型的基线对象^[5,8]。

本文采用的卷积神经网络基线模型保持了相对简洁的主干结构，不额外叠加过深的残差层或复杂注意力模块。基线模型设计用于形成实现稳定、易于复现的卷积神经网络基线模型，从而观察 Transformer 系列模型在相同输入条件下是否能够取得有意义的指标变化。需要说明的是，卷积神经网络基线模型没有按照单一先行研究逐层复现，模型结构结合语音情绪识别中常见二维卷积结构后形成项目内部基线实现^[5,8]。从实现流程看，卷积神经网络基线模型通常由若干卷积块、非线性激活层、池化层以及分类头构成。输入的对数梅尔频谱首先进入卷积块以提取局部时频模式，再通过逐层池化压缩特征图尺寸，随后将高层局部特征送入全连接分类器完成情绪类别判别。卷积神经网络技术在语音情绪识别任务中常与注意力或循环结构结合使用，相关研究说明了局部时频特征抽取在该任务中的基础价值^[5,8]。

本章采用的卷积神经网络基线模型代表配置来自当前较高验证结果对应的设置。代表配置包含 4 个卷积块，每个卷积块均由 3×3 卷积、BatchNorm、ReLU 以及 2×2 最大池化组成。通道数依次为 [32, 64, 256, 512]，卷积主干之后使用自适应平均池化（AdaptiveAvgPool2d）将特征图压缩为 4×4 ，随后经展平操作（Flatten）、丢弃层和线性分类器输出 8 类情绪结果。




图 4-1 卷积神经网络基线模型结构

图4-1对应卷积神经网络基线模型从谱图输入到情绪分类输出的处理路径。前两层卷

积块侧重整理低层能量变化与局部时频纹理，后两层卷积块在较高通道维度上压缩局部模式。自适应平均池化将不同长度输入经过卷积和池化后的高层特征整理为固定大小表示，线性分类器在固定大小表示上输出 8 类情绪结果。卷积神经网络基线模型为后续纯 Transformer 模型与 CNN-Conformer 模型提供了局部卷积归纳偏置层面的对照^[5,8]。

4.1.3.2 纯 Transformer 模型

纯 Transformer 模型不在前端引入卷积特征提取模块，模型将输入时频表示映射为一系列序列化特征后，主要依赖自注意力机制建模全局上下文关系。纯 Transformer 结构的优势在于能够较为直接地刻画远距离位置之间的相关性，并在统一的注意力框架下完成特征聚合。对于语音情绪识别任务而言，纯全局建模方式有助于观察自注意力结构在中小规模情绪语音数据上的表现边界^[10-11,50]。

与卷积神经网络基线模型相比，纯 Transformer 模型减少了显式局部归纳偏置，对输入表示和训练稳定性的要求相对较高。将纯 Transformer 模型纳入本章比较的目的，主要在于验证当模型主要依赖全局关系建模时，是否能够充分利用语音中的情绪线索，以及纯 Transformer 结构在当前数据规模下是否容易受到过拟合或局部细节捕获不足的影响。本文所称纯 Transformer 模型没有采用原始机器翻译任务中的完整编码器-解码器结构，模型依据原始 Transformer 编码器思想改写得到面向语音情绪分类的仅编码器结构^[10-11,50]。

在实现上，纯 Transformer 模型通常先将输入特征映射为一系列时序标记，再叠加位置编码信息，以保留不同时间位置的相对关系。随后，模型通过多头自注意力模块与前馈网络交替堆叠，对序列内部的相关性进行建模，并通过池化或分类标记完成整体判别^[10-11,50]。对于缺少卷积前端的结构而言，输入标记的组织方式、位置表示以及编码层深度都会直接影响模型对情绪细节的保持能力^[10-11]。

结合当前代表配置，纯 Transformer 模型在本项目中的设置为：嵌入维度 256，注意力头数 4，编码层数 5，前馈维度 1024，二维分块尺寸为 32×32 ，二维分块步长为 8×8 ，池化方式为均值池化，丢弃层比例约为 0.2707。纯 Transformer 模型将谱图划分为二维分块，再通过卷积形式的分块嵌入映射为标记序列。分块嵌入承担将二维时频表示转化为 Transformer 序列输入的作用，位置编码则用于保留不同分块之间的顺序关系。分块嵌入与位置编码路径对应原始 Transformer 编码器中标记表示、位置

编码和自注意力编码的基本思想^[50]。




图 4-2 纯 Transformer 模型结构

图4-2对应了纯 Transformer 模型从谱图到句级表示的完整路径。与原始 Transformer 论文中的编码器-解码器框架不同，本文实现不引入解码器分支，保留分块嵌入、位置编码、编码器堆叠、序列池化与线性分类器五个部分，用于直接完成 8 类情绪判别。仅编码器处理方式使纯 Transformer 模型能够作为依赖全局注意力建模的代表结构，与卷积结构和卷积-注意力混合结构形成对照^[50]。

4.1.3.3 CNN-Conformer 模型

CNN-Conformer 模型来源于卷积模块与 Conformer 编码器相结合的设计思路。在原始 Conformer 及后续语音任务变体中，常见做法是先通过前端卷积模块完成局部变换或下采样，再将中间表示映射到统一嵌入空间，随后利用 Conformer 编码器联合建模局部卷积信息与全局上下文信息，末端通过池化与分类头输出类别结果^[8,49,52]。本文将 CNN-Conformer 结构家族作为重点比较对象，目的在于检验卷积归纳偏置与注意力上下文建模在语音情绪识别任务中能否形成互补关系。

本文重点分析 CNN-Conformer 模型，主要有两个原因。第一，该结构在理论上兼顾卷积结构对局部时频细节的建模能力，以及注意力结构对较长上下文关系的表示能力，与本文的模型比较主线具有较强关联。第二，已有实验记录表明，该模型虽然在

部分设置下能够达到较高验证准确率，但也持续暴露出过拟合倾向。围绕该模型开展较细致的结构调整与训练策略分析，可以从结构组合角度回应本文关于卷积结构与 Transformer 结构组合方式的研究问题。

需要说明的是，本文综合实验所采用的代表配置已不再保留原始自动语音识别场景中常见的两级卷积压缩前端，模型前端改为面向语音情绪识别场景的无卷积前端时间分块输入组织方式。无卷积前端时间分块输入与原始 Conformer 前端设计存在明确差异^[8,49,52]。

在本文采用的代表实现中，CNN-Conformer 模型的前端不再承担强压缩作用，先利用无卷积前端时间分块方式直接构造序列标记。中间部分由若干 Conformer 编码块构成，每个编码块内部包含前馈网络、多头自注意力模块、卷积模块以及残差连接。末端部分通过注意力池化形成句级表示，并交由分类头输出情绪类别。当前实现将建模重点放在时间分块标记构造、Conformer 序列编码和句级聚合三个部分，避免继续沿用传统自动语音识别式卷积下采样前端。

当前章节在综合实验中采用的 CNN-Conformer 代表配置，采用后续实验中取得较高指标的无卷积前端时间分块输入变体。代表配置中，时间块长度为 4，归一化方式为 LayerNorm，嵌入维度为 192，编码层数为 4，注意力头数为 8，前馈维度为 768，卷积模块卷积核大小为 31，层间融合方式为末层输出，池化方式为注意力池化。训练阶段同时结合频谱级混合增强， $\alpha = 0.4$ 。在代码实现上，Conformer 块内部的执行顺序为前馈网络 → 相对位置多头自注意力 → 卷积模块 → 前馈网络 → LayerNorm，并在两个前馈分支处使用 0.5 倍率的半步残差连接。

分类器设计方面，CNN-Conformer 模型首先通过注意力池化获得句级嵌入，再经过丢弃层与线性层完成 8 类情绪分类。对于本章所采用的代表配置而言，分类器之前的句级表示维度为 192，分类头结构相对简洁，目的是将指标差异主要保留在前端标记构造方式与 Conformer 编码路径本身，减少额外复杂后端分类器带来的影响。

无卷积前端时间分块输入是一种面向情绪细粒度时间线索保留而设计的输入组织方式。无卷积前端时间分块输入不再使用标准两级卷积前端先压缩时频图，直接使用覆盖完整频带、高度等于梅尔频带数、宽度等于固定时间帧数的卷积核，将整幅谱图沿时间轴切分为若干连续时间块。每个时间块在进入序列编码之前已经包含完整频带信息，再经过层归一化和线性投影得到统一维度的序列标记。图4-4给出了无卷积前端时间分块输入的形成过程。无卷积前端时间分块输入与多层声学信息融合和多

尺度声学建模研究所关注的局部声学线索与上下文信息并用思路具有一定关联，可用于检验 Conformer 在较弱前端压缩条件下的实际收益^[8,49]。

CNN-Conformer 模型中的层间特征融合、注意力池化和混合增强分别承担不同作用。层间特征融合用于比较末层上下文表示与多层表示组合之间的差异，相关研究曾从多层声学信息角度讨论语音情绪识别中的层级特征利用^[49]。注意力池化用于在时间维度上为不同序列位置分配不同权重，语音情绪识别中的局部注意力和多尺度注意力研究均说明了聚合方式的任务相关性^[8-9]。混合增强用于在训练阶段构造较平滑的样本间过渡，以降低模型对少量训练样本的过度拟合风险。自注意力语音情绪识别中已有按照标签信息调整 mixup 训练过程的研究，该研究为本文采用混合增强提供了相关依据^[53]。




图 4-3 CNN-Conformer 模型结构




图 4-4 无卷积前端时间分块输入的形成过程

图4-3、图4-4与图4-5分别对应 CNN-Conformer 模型的整体实现路径、无卷积前端时间分块输入的形成方式以及单个 Conformer 编码块的内部结构。本文采用的代表配置没有照搬原始 Conformer 在自动语音识别任务中的前端设计，模型在保留 Conformer 编码块主干顺序的基础上调整输入组织方式。编码阶段仍采用前馈网络、相对位置




图 4-5 Conformer 编码块结构

多头自注意力、卷积模块、前馈网络与 LayerNorm 构成的结构顺序，后端使用注意力池化、丢弃层与线性分类器完成 8 类情绪判别。代表配置安排使结构差异集中在前端标记构造与序列编码部分，与 Conformer 和语音情绪识别多层声学信息建模研究具有对应关系^[8,49,52]。

经过模型结构设计，三类模型分别对应三种建模侧重：卷积神经网络基线模型强调局部时频纹理提取，纯 Transformer 模型强调基于自注意力的全局关系建模，CNN-Conformer 模型则尝试在局部卷积建模与上下文建模之间建立衔接。表4-3对三类结构的前端处理方式、注意力使用情况与结构特点进行并列整理。

表 4-3 各比较模型的结构差异与设计特点

模型	前端卷积	全局注意力	结构特点
卷积神经网络基线模型	有	无	4 层卷积块后直接分类
纯 Transformer 模型	无	有	二维分块标记与编码器堆叠
CNN-Conformer 模型	可选	有	Conformer 序列编码与注意力池化

4.1.4 训练参数与评价指标

为保证不同模型之间的可比性，本文尽量在统一训练框架下完成各类实验。训练过程中采用相同的数据读取流程、相近的优化策略以及一致的早停规则，并以验证集结果作为模型选择依据。在参数优化方面，部分实验通过 **Optuna** 搜索学习率、批大小、分块长度以及模型内部关键参数，正文仅保留与代表结果解释相关的设置内容。评价指标主要采用准确率与宏平均 F1 值，同时结合 **UAR** 进行补充观察。准确率可以直接反映整体分类正确比例，宏平均 F1 值适合在类别分布存在差异时观察模型在各类别上的平均表现，**UAR** 则用于观察不同类别召回率的整体平衡情况。考虑到语音情绪识别任务中不同情绪类别的可分性存在差异，仅使用准确率往往不足以完整反映模型质量，本章在结果讨论中将同时采用 **Accuracy**、**Macro-F1** 和 **UAR** 三个指标。

在 **CNN-Conformer** 模型的后续实验中，还引入了损失函数、采样策略、层间特征融合方式以及前端压缩方式等设置变化。保留损失函数、采样策略、层间特征融合方式和前端压缩方式的原因不在于扩大搜索规模，而在于观察模型是否可以通过贴近任务特性的结构调整缓解验证集指标波动。相关实验结果将在综合实验部分结合代表性配置进行分析。

表 4-4 训练参数与评价指标设置

类别	项目	当前设置	说明
优化设置	优化器	AdamW 系配置	各模型统一搜索主框架
优化设置	学习率	10^{-4} 量级为主	Optuna 搜索后择优
训练设置	批大小	12 或 16	由显存与模型规模决定
训练设置	训练轮数	30 轮，早停 10 轮	以较高验证指标点截断
评价设置	指标	Accuracy / Macro-F1 / UAR	与结果表一致
评价设置	模型选择依据	验证集 Macro-F1	以宏平均 F1 作为固定优化目标

4.1.5 实验环境与实现平台

实验设置除数据集、评价指标和模型超参数外，还需要交代支撑训练与评价的实现平台。本文的模型训练、参数搜索、噪声评价与跨语料库评价均依托同一套代码框架完成，主要实现基于 **PyTorch** 生态，配置管理、参数搜索和实验记录分别由 **Hydra**、

表 4-5 CNN-Conformer 关键搜索维度与候选设置

搜索维度	候选设置	设计目的
时间下采样	标准压缩 / 优先保留时间分辨率等	调整时间分辨率保留程度
层间特征融合	末层输出 / 可学习加权融合	结合浅层与深层表示
损失函数	交叉熵 / 焦点损失等	观察类别学习稳定性
采样策略	随机采样 / 加权采样	缓解类别分布差异影响
正则化设置	混合增强 / 丢弃层 / 归一化变体	控制过拟合风险

Optuna 与 MLflow 辅助完成。该部分不展开系统维护细节，只保留与复现边界直接相关的运行环境和实验组织信息。

表4-6汇总了本章实验所使用的实现平台与复现设置。与后文模型参数表不同，该表不用于说明单个模型的结构差异，而是用于限定实验执行所依赖的软件框架、硬件资源、随机种子和结果记录方式。这样的安排可以避免在正文中反复描述环境细节，也便于读者理解批大小、训练轮数、搜索规模和单卡显存约束之间的关系。

表 4-6 实验环境与实现平台

类别	当前设置	说明
操作系统	Windows 10	主要代码运行与结果整理平台
编程语言	Python 3.13 系列	训练、评价与结果分析脚本运行环境
深度学习框架	PyTorch / torchaudio	模型训练、波形读取和时频特征处理
配置管理	Hydra / OmegaConf	管理数据、模型、训练和实验覆盖参数
参数搜索与记录	Optuna / MLflow	保存搜索结果、指标、配置和模型权重
训练设备	NVIDIA GeForce RTX 2060 单卡	受显存限制，部分搜索阶段采用 fold 1 筛选

4.2 综合实验

4.2.1 各比较模型的综合实验结果

在统一的输入表示、训练流程与评价指标下，三类模型的综合实验结果构成了本章分析的基础。卷积神经网络基线模型提供了较为稳定的参照结果，纯 Transformer 模

型用于观察全局注意力建模在当前数据规模下的实际表现，CNN-Conformer 模型则用于验证卷积结构与注意力结构结合后是否能够形成有区分度的特征表示。为保证比较具有可读性，本节使用各模型在现有实验记录中的代表性较高结果作为综合对比对象。

表4-7列出了三类比较模型在综合实验中采用的代表配置。表中只保留论文分析所需的模型结构、输入设置与聚合方式，使读者能够直接看到不同模型之间的结构差异。除固定的模型结构说明外，实验过程中还针对不同模型设置了相应的参数探索范围。考虑到本文重点在于比较不同结构在语音情绪识别任务中的表现，表4-8仅概括各模型主要探索维度及代表设置，不逐次记录单次训练过程。参数探索范围用于说明代表结果来自有限候选范围内的筛选配置。

表 4-7 各比较模型的代表配置

模型	输入与前端	主干结构	聚合与分类
卷积神经网络基线模型	96×512 对数梅尔频谱	4 个卷积块，通道数 [32, 64, 256, 512]	自适应平均池化，丢弃层 0.33238，线性分类
纯 Transformer 模型	二维分块 32×32 ，步长 8×8	5 层编码器，256 维嵌入，4 头注意力	均值池化，丢弃层 0.2707，线性分类
CNN-Conformer 模型	无卷积前端时间分块，时间块长度 4	4 层编码器，192 维嵌入，8 头注意力，卷积核 31	注意力池化，混合增强 $\alpha = 0.4$ ，线性分类

表 4-8 各模型参数探索范围与代表设置

模型	主要探索维度	代表设置
卷积神经网络基线模型	通道数、丢弃层、输入尺寸、梅尔频带数、学习率	通道数 [32, 64, 256, 512]，丢弃层 0.33238， 96×512 输入，80 维梅尔频带
纯 Transformer 模型	分块尺寸、嵌入维度、层数、注意力头、池化方式	32×32 分块，步长 8×8 ，256 维嵌入，5 层 4 头，均值池化
CNN-Conformer 模型	前端组织、时间块长度、融合方式、采样策略、池化方式	无卷积前端时间分块，时间块长度 4，末层输出，随机采样，注意力池化

从表4-9可以看到，卷积神经网络基线模型在当前任务设定下仍然表现出较强的稳定

表 4-9 各比较模型的综合实验结果

模型	Accuracy	Macro-F1	UAR	参数量	说明
卷积神经网络基线模型	0.61667	0.62196	0.61563	1.41M	4 层卷积基线
纯 Transformer 模型	0.52000	0.51163	0.51250	4.21M	全局注意力建模
CNN-Conformer 模型	0.70000	0.70563	0.70938	3.55M	当前 Transformer 主线较高结果

性，代表结果达到 Accuracy 0.61667、Macro-F1 0.62196 和 UAR 0.61563。纯 Transformer 模型能够学习跨时间位置的关系，但验证集结果未持续展现出优于卷积神经网络基线模型的优势，当前代表结果为 Accuracy 0.52000、Macro-F1 0.51163 和 UAR 0.51250。CNN-Conformer 模型在当前三类模型中取得了较高的综合指标，代表结果达到 Accuracy 0.70000、Macro-F1 0.70563 和 UAR 0.70938。

表4-9中的结果说明，在当前数据规模与输入表示条件下，模型结构的复杂化不会自然带来指标提升。卷积结构在局部时频模式提取方面仍然具有较强适配性，而纯 Transformer 结构若缺少足够明确的局部归纳偏置，则可能难以稳定捕捉情绪相关细节。CNN-Conformer 模型在 Conformer 块内部卷积建模与注意力上下文建模之间建立衔接，并在引入无卷积前端时间分块输入和适度正则化后，在本实验条件下形成较高的 Macro-F1 和 UAR。

4.2.2 CNN-Conformer 模型的结构优化路径

由于 CNN-Conformer 模型同时包含输入组织、序列编码与分类模块，CNN-Conformer 模型的指标受多个结构因素共同影响。结合前期实验记录，本文围绕 CNN-Conformer 模型主要考察了以下几个方向：时间下采样方式、层间特征融合方式、损失函数与采样策略、前端主干结构重设计以及过拟合缓解策略。相关调整围绕同一个问题展开，即如何在保持局部情绪线索的同时降低训练后期的验证指标劣化。

在时间下采样方面，实验关注的是前端压缩对局部时间分辨率的影响。较强的时间压缩有助于降低序列长度与计算成本，但也可能压缩情绪识别所依赖的短时动态变化。基于时间分辨率保留需求，后续实验逐步引入了较为温和的压缩方式，用以观察保留较多时间分辨率后模型是否能够获得较稳定的验证结果。

在层间特征融合方面，实验尝试利用不同编码层的输出构造较丰富的表示。层间特征融合的基本思路是，将浅层较偏局部的表示与深层较偏上下文的表示进行组合，从

而减轻仅使用末层输出所带来的信息单一问题。除融合方式本身外，编码层数、池化方式以及参数规模也会影响层间特征融合的实际效果，需要放在同一实验框架中考察。

在训练策略方面，本文进一步考察了损失函数与采样策略的组合方式。相关调整主要服务于两个目标。第一个目标是减轻类别分布差异对训练过程的影响，第二个目标是在验证集波动较大的情况下提高模型训练的稳定性。除此之外，针对 CNN-Conformer 模型在后期训练中容易出现训练准确率持续上升而验证结果停滞甚至回落的现象，实验还引入了主干结构重设计以及较克制的正则化调节，以观察模型容量与过拟合风险之间的关系。

4.2.3 CNN-Conformer 模型的代表配置与结果观察

在综合比较层面，CNN-Conformer 模型的代表配置由多个候选方向逐步筛选形成，单一参数不能充分解释代表结果。现有实验结果表明，较温和的时间下采样方式、有限度的层间特征融合、适度的损失函数调整以及较为克制的正则化设置，通常有助于得到相对稳定的验证结果。相较于一味增加模型容量，以保留信息和控制过拟合为目标的调整符合当前数据规模下的训练需求。当前较高结果对应的代表配置采用无卷积前端时间分块输入、时间块长度为 4、LayerNorm 归一化、4 层 Conformer 编码器、8 头注意力、卷积核大小 31 以及注意力池化，并在训练时加入 $\alpha = 0.4$ 的混合增强。

需要注意的是，CNN-Conformer 模型虽然在部分配置上能够达到约 0.7 左右的准确率水平，但训练曲线仍然多次呈现出训练集指标持续提升而验证集指标提前停止改善的情况。训练曲线说明，模型已经具备较强的训练集拟合能力，但对未见用户语音的泛化能力仍然有限。CNN-Conformer 模型的后续优化重点不应仅停留在扩大结构复杂度上，还需要关注特征压缩方式、模型容量控制以及训练策略之间的平衡。

从比较结果来看，CNN-Conformer 模型的价值主要体现在两个方面。一方面，卷积结构与注意力结构的结合具有一定实验意义，在适当设置下能够获得相较纯 Transformer 模型具有竞争力的结果。另一方面，卷积与注意力结合结构在中小规模语音情绪数据上面临的共同问题也较为明显，即较强的表示能力往往伴随着较高的过拟合风险。后续分析不宜仅以结构复杂化作为优化方向，而应进一步检视模型中哪些部分对泛化能力产生了稳定贡献。

表4-10中的随机采样指训练阶段打乱训练样本后构造批次，不按类别权重重复采样。注意力池化指在时间维度学习权重，再将分块序列表示加权汇聚为句级表示。

表 4-10 CNN-Conformer 模型的代表配置

配置维度	代表设置	备注
前端形式	无卷积前端时间分块输入，时间块长度为 4	不使用标准两级卷积前端
层间特征融合	末层输出	不使用多层加权融合
损失函数	交叉熵	标签平滑设为 0
采样策略	随机采样	不额外使用加权采样
池化方式	注意力池化	学习时间权重后汇聚
正则化设置	混合增强 $\alpha = 0.4 +$ 丢弃层	LayerNorm，未采用缩窄策略

表 4-11 CNN-Conformer 模型阶段性结果汇总

优化阶段	核心设置	Accuracy	Macro-F1	结论
初始结构	两级卷积前端，相对位置 Conformer	0.63000	0.63168	早期基线
时间下采样	保留较多时间分辨率	0.62017	0.62017	未超过基线
层间融合	末层输出与加权融合比较	0.55348	0.55348	收益有限
训练策略	损失函数、采样策略、混合增强	0.70000	0.70563	代表高值
主干正则	无卷积前端时间分块，归一化筛选	0.70333	0.70042	接近高值

4.2.4 综合讨论

从整体比较结果可以看到，在当前实验条件下，卷积神经网络基线模型仍然构成一个难以忽略的参照基线。综合实验结果不意味着卷积结构在各类条件下都优于 Transformer 结构，实验现象可能说明在数据规模有限、输入表示相对固定的语音情绪识别任务中，明确的局部归纳偏置仍然具有较高实用价值。纯 Transformer 模型虽然具备较强的全局关系建模能力，但若缺少与任务相匹配的局部约束，纯 Transformer 模型的优势未必能够充分转化为验证集上的稳定收益。

CNN-Conformer 模型尝试弥补纯 Transformer 模型缺少局部归纳偏置的问题。CNN-Conformer 模型在卷积特征提取与注意力编码之间建立衔接，使局部声学线索与较长上下文关系能够在同一编码框架中共同参与分类。从已有结果看，CNN-Conformer 方

法展现出一定合理性，但也受到训练稳定性与参数规模的影响。CNN-Conformer 模型的指标上限具有一定吸引力，但结构与训练策略之间的耦合程度较高，需要审慎控制模型容量与特征压缩方式。

本阶段的综合实验提供了两个较为明确的认识。第一，若仅从当前实验结果出发，卷积结构在语音情绪识别中仍然具有较强基线意义。第二，Transformer 系列模型具有一定潜力，但在中小规模语音情绪数据上容易暴露出过拟合、训练波动和局部细节保持不足等问题。后续若继续围绕 CNN-Conformer 模型展开分析，较合适的方向是围绕输入压缩、特征融合、容量控制与泛化能力开展较细致的检验，避免继续无约束地扩大结构。

4.3 噪声条件实验

实际语音输入通常会受到背景声、环境回响以及录制设备差异的影响。为补充观察代表模型在受扰输入条件下的表现，本文在完成 clean 条件下的模型比较之后，对 CNN-Conformer 代表模型开展噪声条件实验。噪声条件实验固定模型参数与 checkpoint，不重新训练模型，只在评价阶段改变输入波形的受扰条件。当前安排用于刻画代表模型在受扰输入下的指标变化轨迹，也为后续讨论输入稳定性与泛化能力提供补充依据[6,12,15,24-25]。

噪声条件实验采用固定模型、改变测试输入的方式。实验流程为：先读取 clean 条件下选定的 CNN-Conformer 代表模型，再向评价集原始波形加入指定类型与强度的噪声，之后沿用与主实验一致的重采样、对数梅尔频谱提取、分块评价与 logit 聚合流程完成预测。噪声加入位置设在波形阶段，不在频谱图阶段直接扰动。采用波形阶段加噪的原因在于，语音录制过程中的背景干扰通常先作用于声学信号，再进入时频特征提取流程。当前处理方式更接近录制端混入干扰后的输入形式[15,24-25]。

本节围绕两个问题展开。一个问题是，clean 条件下结果较高的代表结构，在输入端逐步受扰时是否还能保持相近的判别稳定性。另一个问题是，不同频谱形态和不同时间结构的噪声，是否会引出相同或不同的退化路径。按照这一问题设置，噪声条件实验不再承担重新筛选主干结构的任务，而是固定代表模型，把观察重点集中在受扰输入对句级判别结果的影响上。这样的控制变量设置可以让噪声类型和噪声强度成为主要变化因素，避免训练策略变化干扰结果解释。

噪声条件实验在整章中的角色也需要明确。综合实验已经完成卷积神经网络基线模

型、纯 Transformer 模型与 CNN-Conformer 模型之间的主线比较，当前节更接近对代表结构边界条件的补充刻画。若在这一节同时改变模型结构、损失函数或训练策略，噪声带来的影响将与结构变化混合在一起，结果解释会变得复杂。固定 checkpoint 并只改变输入端受扰条件，可以让指标波动与噪声类型、噪声强度之间建立更直接的对应关系。

4.3.1 实验目的与评价流程

本实验的核心目标是观察已选定代表模型在输入质量变化时的稳定性，不再重新比较卷积神经网络基线模型、纯 Transformer 模型与 CNN-Conformer 模型三者之间的结构优劣。主实验中，三类模型的比较已经在统一训练设置下完成。噪声条件实验继续沿用同一套前处理与评价指标，仅额外引入受扰波形条件。这样可以把观察重点集中在输入受扰带来的变化上，减少模型结构和训练策略再次变化对结果解释造成的干扰。

信噪比采用分贝形式表示，如式4-1所示。

$$\text{SNR} = 10 \log_{10} \left(\frac{P_{\text{signal}}}{P_{\text{noise}}} \right) \quad (4-1)$$

式4-1中， P_{signal} 表示语音功率， P_{noise} 表示噪声功率。SNR 数值越高，语音相对噪声越清晰。SNR 数值越低，噪声覆盖程度越强。0dB 表示语音功率与噪声功率处于同一数量级，-5dB 表示噪声功率已经高于语音功率。在功率比意义下，-5dB 对应 $P_{\text{noise}} \approx 3.16 \times P_{\text{signal}}$ ，属于干扰较强的受扰条件。本文将 SNR 设置为 clean、20dB、10dB、5dB、0dB 和 -5dB，覆盖从轻度干扰到较强干扰的连续区间，设置方式与噪声鲁棒语音情绪识别研究中常见的分级评价思路保持一致^[12,24-25]。

4.3.2 噪声条件设计

噪声类型设置为 white、pink、babble 和 synthetic-mixed 四类。四类噪声共同覆盖了平坦频谱干扰、低频偏置干扰、语音样背景干扰以及连续背景与瞬态成分混合干扰四种情形。此处采用合成噪声而非外部噪声语料，主要考虑实验可复现性与工程实现一致性：噪声生成过程全部由当前项目代码控制，评价条件可以直接重建，不依赖额外下载的外部噪声库。当前设计更适合作为受控条件下的稳定性分析，文中对结果的解释也据此限定在合成受扰条件范围内。除此之外，噪声生成阶段还固定使

用随机种子 42，并在不同样本上按照样本索引偏移随机种子，以保持同一实验配置下的可重复性。

white 噪声由高斯随机序列直接生成，频谱能量在各频带上分布较为均匀，适合观察模型对宽带随机干扰的敏感性。**pink** 噪声在频域上施加 $1/f$ 型衰减，低频成分权重较高，更接近日常环境中持续性的低频背景干扰。**babble** 噪声通过对原始波形进行多次时间平移、幅值缩放和叠加，再混入少量有色噪声得到，当前实现中混合 4 个语音样分量，用于近似多用户同时说话时的语音样干扰。**synthetic-mixed** 噪声不是实际场景录音，而是由粉红噪声与棕色噪声按固定比例混合，并叠加 6 个短时瞬态脉冲构成的合成混合瞬态噪声，用于观察连续背景成分和零散瞬态扰动同时存在时的输入受扰影响。四类噪声的安排与噪声鲁棒语音情绪识别研究中按噪声类型和 SNR 分开报告结果的做法相一致，也便于观察不同频谱形态和时间结构对模型的影响^[12,15,25]。

表 4-12 四类合成噪声的构造方式与观察目的

噪声类型	构造方式	观察目的
white	高斯随机序列，频带能量较平坦	宽带随机干扰敏感性
pink	$1/f$ 频域衰减，低频权重较高	低频持续背景覆盖影响
babble	语音波形平移、缩放、叠加后混入有色噪声	语音样背景干扰影响
synthetic-mixed	粉红噪声、棕色噪声与瞬态脉冲混合	合成混合瞬态干扰影响

表 4-13 噪声条件实验设置

项目	设置	说明
评价模型	CNN-Conformer 代表模型	固定 clean 模型，不重新训练
加噪位置	波形阶段	加噪后再提取对数梅尔频谱
噪声类型	white / pink / babble / synthetic-mixed	四类可控合成噪声
SNR 设置	20 / 10 / 5 / 0 / -5dB	clean 作为参照
评价指标	Accuracy / Macro-F1 / UAR	同时记录相对 clean 差值

表4-13给出了噪声条件实验的统一设置。评价模型固定为 clean 条件下表现较高的 CNN-Conformer 代表配置，训练参数与分类头不作改动。所有受扰条件均以同一 fold

上的评价样本为对象，保证不同噪声条件之间仅在输入波形的受扰方式和受扰强度上存在差异。评价指标继续使用 Accuracy、Macro-F1 和 UAR，并同时记录相对 clean 条件的 Accuracy 变化值，用于衡量输入受扰后整体判别能力的变化幅度。

表4-12进一步整理了四类合成噪声的构造方式与观察目的。当前实验不追求完整覆盖真实环境中的全部噪声来源，而是以可控的合成方式构造具有代表性的受扰条件，使不同 SNR 区间和不同频谱形态下的指标变化能够在同一评价框架中进行比较。

从实验复现角度看，本节还有三项约束条件。四类噪声全部作用于同一份评价样本集合，样本顺序、分块位置和聚合方式保持一致，保证不同噪声条件之间的比较建立在同一批语音上。噪声只在波形阶段加入一次，后续的重采样、对数梅尔频谱提取、chunk 切分和 logit 聚合流程全部沿用主实验既有设置，使受扰条件成为唯一主动变化因素。结果同时报告 Accuracy、Macro-F1 和 UAR，不只观察总体正确率，还观察类别均衡性与召回率稳定性是否同步下降。这样的组织方式先固定样本、参数和评价口径，再解释单一变量变化所带来的现象，能够降低结果解读的歧义。

SNR 区间的排列同样服务于这一目的。20dB 对应轻度受扰条件，语音主体通常仍较清晰。10dB 和 5dB 位于中度受扰区间，部分局部时频纹理会与背景成分重叠。0dB 表示语音功率与噪声功率处于同一数量级。 -5dB 则属于较强覆盖情形，噪声功率已经超过语音功率。把这些等级依次展开后，可以观察模型指标是否近似连续下降，也可以判断不同噪声类型是否会在某一强度附近出现更清楚的拐点。这种噪声类型与 SNR 等级构成的双轴设计与噪声鲁棒 SER 文献中的常见报告方式保持一致^[12,15,24-25]。

4.3.3 结果与现象分析

表4-14和图4-6共同给出了 CNN-Conformer 模型在不同噪声类型与不同 SNR 条件下的变化轨迹。clean 条件下，代表模型的 Accuracy 为 0.70333，Macro-F1 为 0.70042，UAR 为 0.70000。进入 20dB 条件后，四类噪声均带来一定程度的指标回落，其中 synthetic-mixed 噪声下降幅度相对较小，Accuracy 下降 0.06667。white、pink 和 babble 在 20dB 条件下均出现约 0.09 到 0.11 的 Accuracy 回落。即便在语音仍保持较高可辨性的轻度受扰条件下，输入质量变化也会影响模型的情绪判别稳定性。

随着 SNR 继续下降，不同噪声类型之间的差异逐渐扩大。pink 噪声在 10dB 以下造成的退化较快，10dB 条件下 Accuracy 已经降至 0.36667，-5dB 条件下进一步降至 0.15000，Macro-F1 降至 0.06243。white 噪声同样随着 SNR 下降持续带来指标回

表 4-14 不同噪声条件下 CNN-Conformer 模型的实验结果

噪声类型	SNR	Accuracy	Macro-F1	UAR	Accuracy 变化
clean	clean	0.70333	0.70042	0.70000	0.00000
white	20	0.61000	0.56389	0.57812	-0.09333
white	10	0.49000	0.44717	0.46562	-0.21333
white	5	0.40667	0.32933	0.38125	-0.29667
white	0	0.34000	0.24169	0.31875	-0.36333
white	-5	0.29333	0.17877	0.27500	-0.41000
pink	20	0.60000	0.58425	0.58125	-0.10333
pink	10	0.36667	0.32255	0.34688	-0.33667
pink	5	0.27000	0.19737	0.25312	-0.43333
pink	0	0.21000	0.13333	0.19688	-0.49333
pink	-5	0.15000	0.06243	0.14062	-0.55333
babble	20	0.59667	0.57407	0.57500	-0.10667
babble	10	0.54667	0.52658	0.52500	-0.15667
babble	5	0.51667	0.49893	0.49687	-0.18667
babble	0	0.45333	0.43736	0.43438	-0.25000
babble	-5	0.44333	0.42124	0.42188	-0.26000
synthetic-mixed	20	0.63667	0.63597	0.62500	-0.06667
synthetic-mixed	10	0.58667	0.58083	0.57188	-0.11667
synthetic-mixed	5	0.55667	0.55418	0.54688	-0.14667
synthetic-mixed	0	0.45333	0.44479	0.43750	-0.25000
synthetic-mixed	-5	0.34000	0.30379	0.32500	-0.36333




图 4-6 不同噪声强度下 CNN-Conformer 模型的 Accuracy 变化

落，但下降速度略缓于 pink 噪声。babble 噪声在 20dB 时已带来较明显变化，进入低 SNR 区间后下降幅度相对平缓，-5dB 条件下仍保持 0.44333 的 Accuracy 和 0.42124 的 Macro-F1。synthetic-mixed 噪声在 20dB、10dB 和 5dB 条件下维持了相对连续的缓慢回落，进入 0dB 及以下区间后下降速度加快。当前结果反映出，频谱能量分布偏向低频且持续覆盖语音结构的噪声，对代表模型的影响更为直接。具有语音样结构或合成混合瞬态结构的干扰，在当前实现条件下呈现另一类退化轨迹。

从指标之间的对应关系看，Accuracy、Macro-F1 和 UAR 在多数噪声条件下同步回落，说明变化不仅体现在整体正确率上，也体现在类别平衡性与召回率稳定性上。pink 噪声和 white 噪声在强干扰区间内造成的 UAR 下降幅度较大，表明受扰条件会同时压缩多个情绪类别的可分性。babble 噪声在低 SNR 区间仍保留了一定的 Macro-F1 和 UAR，说明当前代表模型对语音样干扰保留了部分判别能力。考虑到当前 babble 噪声由波形平移叠加方式近似得到，这一观察更适合解释为对当前合成语音样干扰的响应特征，不直接外推到所有真实多人背景场景。

若把结果按轻度、中度、强度受扰三个区间重新整理，趋势会更加清楚。轻度受扰区间主要对应 20dB，此时四类噪声都造成了指标回落，但 Accuracy 仍维持在 0.59 以上，说明语音主体仍较清晰时，代表结构保留了相对稳定的句级判别能力。中度受扰区间可以对应 10dB 和 5dB，此时 pink 噪声和 white 噪声的退化速度开始快于 babble 和 synthetic-mixed，表明持续覆盖型频谱扰动更容易破坏当前模型依赖的局部边界。强度受扰区间对应 0dB 和 -5dB，此时四类噪声全部造成较大下降，只是下降路径并不一致。pink 噪声下降幅度较大，white 噪声次之，babble 和 synthetic-mixed 则保留了较长的缓降区间。

这一差异可以结合 CNN-Conformer 的编码方式理解。当前代表结构先通过无卷积前端时间分块方式构造覆盖完整频带的序列标记，再由 Conformer 编码层中的自注意力模块与卷积模块共同聚合局部变化和较长时间范围的上下文线索。若噪声在频谱上呈现连续低频覆盖，时间分块标记中的能量轮廓会被压缩，后续序列编码阶段能够利用的情绪线索也会相应减少。pink 噪声在低频成分上权重更高，退化速度快于 white 噪声与 babble 噪声，与这一结构特点具有一定一致性。相对地，babble 噪声虽然包含语音样扰动，但当前实现中通过时间平移和幅值叠加近似构造，仍保留了一部分与原始语音相近的局部起伏。对于依赖局部模式和上下文联合建模的结构而言，剩余线索仍可能支持部分判别，低 SNR 区间的下降相对缓和。

本节按照结果表格、趋势图、结构原因解释的顺序展开：先给出数值，再指出变化分界，随后回到模型结构与任务特征讨论原因。这样的组织方式使噪声条件实验不只是附加结果记录，而是能够与前文对 CNN-Conformer 时间分块、序列编码和注意力池化的结构描述形成呼应。这样处理后，读者即使不查看代码，也能从正文理解为何不同噪声类型会引出不同的退化轨迹。




图 4-7 pink 噪声-5dB 条件下 CNN-Conformer 模型的混淆矩阵

图4-7给出了退化幅度较大的 pink 噪声-5dB 条件下的混淆情况。混淆矩阵可以看到，强干扰条件下的错误不再局限于少数相邻情绪类别，多类别之间也出现了更分散的偏移。结合 SNR 曲线与结果表，可以将这一现象理解为：当低频持续噪声长时间覆盖语音能量轮廓和局部时频纹理后，模型在分块编码与注意力池化阶段获得的句级表示中，情绪相关线索所占比例被进一步压缩，类别之间的边界也随之变得模糊。本节实验可以视为代表模型在受扰输入条件下的补充观察。当前结果刻画了 CNN-Conformer 模型在不同噪声类型和不同 SNR 区间中的退化方式，也进一步说明主实验中取得较高 clean 指标的结构，在受扰条件下仍会受到噪声频谱形态和强度变化的

影响。基于这一组实验，后续若继续扩展相关工作，可围绕噪声增强训练、真实噪声语料评价或语音增强预处理展开。当前章节则将噪声条件实验保持在固定代表模型、观察输入受扰影响的范围内，以便与主实验中的模型比较主线保持一致。

若将本节结果回接到整章主线，可以得到两个较为明确的观察。**clean** 条件下取得较高指标，并不意味着模型在受扰输入下自动具备同等稳定性。噪声频谱形态和强度等级都会改变情绪线索的可见程度。当前 CNN-Conformer 结构在面对语音背景干扰与混合环境干扰时保留了部分韧性，但在持续低频覆盖条件下退化更快。这样的现象为后续工作提供了较清晰的延伸方向：若继续围绕同一结构展开，可以优先考虑面向低频持续噪声的增强策略、面向波形级干扰的鲁棒训练，或者面向频带选择的特征增强模块。当前论文范围内，本节更重要的价值在于把代表结构在受扰输入下的退化方式记录清楚，并将这种退化与噪声类型、SNR 区间以及模型结构特征建立对应关系。

4.4 跨语料库实验

跨语料库实验用于补充观察 CNN-Conformer 模型在语料分布发生变化时的稳定性。前文的综合比较、结构调整与噪声条件实验，均建立在训练语料与评价语料保持同源的前提下。这一安排适合刻画同语料条件下的模型判别能力，但不足以说明模型在录制环境、表演强度、用户构成和语句集合发生变化时是否仍能保持稳定。跨语料库实验继续采用综合实验中选定的 CNN-Conformer 代表配置，并在不引入目标语料监督信息的条件下，考察同一结构从源语料迁移到异源语料后的指标变化。这一设计与跨语料库语音情绪识别研究中常见的 **source-only** 基线设置保持一致，可作为后续比较域不变建模、迁移学习或对抗式适配方法的起点^[14,16-18,23,54]。

本节关注的重点是一个更基础的问题：在不改变跨语料库运行主干结构、仅将类别空间对齐到公共情绪集合的条件下，CNN-Conformer 模型迁移到另一套英语语音情绪语料后会出现多大幅度的指标波动。按照这一目标，本文将跨语料库实验限定为固定 **source-only** 训练协议、重新完成源语料训练、在目标语料直接评价的观察型实验，目标语料阶段不再追加调参，也不引入额外域对齐模块。这样的安排便于把结果解释集中在语料差异本身，减少新增训练策略对现象判断的干扰。

本节的问题设置还可以再细化一步。需要观察模型在 **source** 域内部是否已经形成可用的六类情绪边界，也需要观察同一组边界迁移到 **target** 域后会保留多少有效性。若

source 端和 target 端同时偏低，问题会更多指向六类任务本身。若 source 端仍保有中等水平而 target 端急剧下降，问题则更接近语料分布偏移。将问题拆成可验证的子问题后，再依次给出协议与结果，可以让后续的数值解读更有针对性。

4.4.1 实验协议与评价流程

跨语料库实验选择 RAVDESS 作为源语料，选择 CREMA-D 作为目标语料。两套语料均为英语表演式语音情绪数据，适合在语言保持一致的条件下观察录制条件、演员数量、句子内容与情绪表达分布变化带来的影响。选择 CREMA-D 作为目标语料的原因在于，CREMA-D 同样属于英语表演式语音情绪语料，但用户数量和样本规模更大，句子集合与表演分布也不同，能够在语言类型基本一致时形成清晰的语料分布变化。由于 RAVDESS 原始标注包含 8 类情绪，而 CREMA-D 仅提供 6 类离散情绪，当前实验仅保留两套语料共同具备的六类：neutral、happy、sad、angry、fearful 和 disgust。这样处理的目的是避免类别集合不一致对结果解释造成额外干扰，也与跨语料库研究中按公共类别重建标签空间的常见做法一致^[14,18,23,54]。

从数据规模看，源语料 RAVDESS 六类子集共包含 1056 条语音，24 名用户各提供 44 条样本。目标语料 CREMA-D 六类子集共包含 7442 条语音，覆盖 91 名用户。训练阶段仅使用 RAVDESS 六类子集，并按照用户划分执行 GroupKFold，本次记录运行第 1 个 fold。模型结构沿用综合实验中选定的 CNN-Conformer 代表配置，主要结构与超参数保持不变，包括无卷积前端时间分块输入、80 维对数梅尔频谱、帧移 160、分块长度 48、分块步长 12、嵌入维度 192、4 层 Conformer 编码器、8 个注意力头、前馈维度 768、卷积模块核大小 31、注意力池化以及频谱级混合增强 $\alpha = 0.4$ 。由于跨语料库评价只保留两套语料共有的六类情绪，分类头输出维度由 8 类调整为 6 类，其余主干设置继续保持代表配置。评价阶段先依据源语料验证集的 Macro-F1 选择代表 epoch，再将同一 checkpoint 直接用于 CREMA-D 六类全体样本的推理，不在目标语料上追加微调、阈值校准或早停选择。

这一协议背后包含三项设计考虑。源语料和目标语料都选用英语表演式语音库，可以在语言保持一致的前提下，尽量把差异集中到录制环境、用户规模、句子集合与情绪表达强度上。类别空间收缩到六类公共情绪后，输出层定义在两套语料上保持一致，结果解释可以聚焦在语料分布差异，而不需要额外讨论缺失类别对决策边界的影响。训练阶段仍采用用户级分组而不是随机抽样，这样 source validation 与主实验

中的未见用户设定保持一致，便于把跨语料库结果放回整章统一的泛化框架中理解。

表 4-15 跨语料库实验协议设置

项目	设置值	说明
源语料	RAVDESS 六类子集	1056 条语音，24 名用户
目标语料	CREMA-D 六类子集	7442 条语音，91 名用户
类别空间	六类公共情绪	neutral、happy、sad、angry、fearful、disgust
训练方式	source-only	仅用源语料训练，目标语料不参与选择
数据划分	GroupKFold, fold 1	按用户划分源训练集与源验证集
模型结构	CNN-Conformer 代表配置	保持主干结构和主要超参数
分类头	6 类输出	仅重构公共类别输出层
评价指标	Accuracy / Macro-F1 / UAR / ECE	源验证集选 epoch，目标语料直接推理

上述流程需要补充说明一点：跨语料库实验并不直接保留 8 类分类头，而是在保持 CNN-Conformer 代表结构和主要超参数的基础上，将输出层重构为公共六类情绪分类头。采用这一处理的原因在于，8 类标签集合与 6 类公共标签集合并不一致。若直接使用 8 类输出层，类别空间转换会额外引入输出层不匹配和标签压缩问题，语料差异与类别变换造成的影响也难以分开讨论。当前协议更适合作为跨语料库基线，也更接近相关研究中先统一公共类别、再报告 source-only 结果的通行做法^[14,16,23]。

从复现角度看，本节流程还固定了另外两项约束。目标语料不参与模型选择，代表 epoch 完全由源验证集 Macro-F1 决定，目标域标签不会反向影响 checkpoint 选择过程。目标语料评价沿用主实验中的对数梅尔频谱提取、batch 推理和统一指标统计口径，不在跨语料库阶段额外引入新的前处理变体。通过这两项约束，跨语料库实验与主实验之间保留了较好的可比性，数值差异更容易解释为语料分布变化带来的影响，而不是流程变化带来的影响。

若将本节协议写成更细的实验流程，可以概括为：先从 RAVDESS 原始 8 类样本中筛出与 CREMA-D 重合的六类情绪，再按用户执行 source train/source validation 划分。随后保持 CNN-Conformer 代表结构和主要超参数，仅将分类头重构为 6 类输出，并在 RAVDESS 六类子集上执行 source-only 训练。每个 epoch 结束后记录源验证集 Accuracy、Macro-F1、UAR 与 ECE。接着选出源验证集 Macro-F1 较高的 epoch 作为

代表 checkpoint。再将这一 checkpoint 直接应用到 CREMA-D 六类全集，统计目标语料上的四项指标与混淆情况。显式列出关键流程后，读者仅凭正文即可复原本次实验的执行逻辑。

4.4.2 实验结果与现象分析

本次跨语料库实验的代表模型出现在第 20 个 epoch。源语料验证集上，Accuracy 达到 0.58182，Macro-F1 达到 0.56897，UAR 达到 0.58333。同一 checkpoint 迁移到 CREMA-D 后，Accuracy 降为 0.19377，Macro-F1 降为 0.09243，UAR 降为 0.18936。除分类指标外，置信度校准误差也出现较大扩大，源验证集 ECE 为 0.22191，而目标语料 ECE 升至 0.56109。表4-16给出了本次运行的主要数值。

表 4-16 跨语料库实验结果

评价集合	代表 Epoch	Accuracy	Macro-F1	UAR	ECE
RAVDESS 源验证集	20	0.58182	0.56897	0.58333	0.22191
CREMA-D 目标语料	20	0.19377	0.09243	0.18936	0.56109




图 4-8 跨语料库实验中源验证集与目标语料的指标差距

图4-8显示，当前模型在源语料内部已经能够学习到一定程度的六类情绪边界，但这种

边界并未稳定迁移到目标语料。当前结果首先反映出同语料指标与跨语料库指标并不等价。即使模型在 RAVDESS 内部取得了中等水平的验证指标，迁移到 CREMA-D 后仍可能出现大幅退化。结合前文主实验结果，可以将这一现象理解为：CNN-Conformer 在同语料条件下对局部时频模式与长程上下文的联合建模具有一定有效性，但这种表示仍包含较强的语料特征，尚未形成足够稳定的跨语料共享表示。

从训练过程看，源语料训练 F1 在后期继续上升，而源验证集 Macro-F1 在 0.56 附近进入平台区，说明当前结构在源语料内部已经出现一定程度的过拟合倾向。过拟合本身并不足以完全解释目标语料上接近随机水平的 Macro-F1，但会放大源域特征对模型参数的牵引，使得模型更倾向于保留与 RAVDESS 录制条件、表演方式和能量分布有关的判别模式。当测试对象切换到 CREMA-D 时，句子集合、情绪强度、用户数量与录制差异共同改变了输入分布，源域中形成的判别边界难以直接保持有效^[14,17-18]。若把源域和目标域结果并排理解，可以看到两个更细的现象。源验证集仍能形成一定程度的六类情绪边界，说明 CNN-Conformer 代表配置在公共六类标签空间内具有可用的源域判别能力。目标端的指标下降幅度大于源端的波动幅度，说明问题的主体并不只是六类任务更难，而是模型在 RAVDESS 内部形成的判别模式难以直接跨越到 CREMA-D。也就是说，跨语料库落差来自标签空间重建后的源语料训练难度，也来自两套语料之间更根本的域分布差异。

这种域分布差异可以从数据构成上进一步理解。RAVDESS 的用户数量较少，录制条件相对统一，类别样本数也更接近均衡。CREMA-D 覆盖更多用户和更大的样本量，情绪表达强度、说话节奏和句子集合都更丰富。对于采用无卷积前端时间分块输入的 CNN-Conformer 代表配置而言，若训练阶段主要接触到 RAVDESS 中的稳定表演模式，时间分块标记、Conformer 编码层与注意力池化得到的表示就可能带有较明显的源域偏向。这种偏向在同语料验证集上未必会立即暴露，但当测试条件切换到用户数量更大、语句组合更复杂的 CREMA-D 时，分类边界就会快速松动。

图4-9进一步展示了目标语料上的类别混淆情况。与同语料条件下仍能保持一定结构化混淆不同，跨语料库条件下多类样本的判别边界出现收缩，若干类别之间出现更广泛的相互偏移。这一现象与目标语料 ECE 升高相互对应，表明问题并不局限于个别类别召回率下降，也体现在模型输出置信度与真实分布之间的失配上。也就是说，当前 source-only CNN-Conformer 基线在 CREMA-D 上不仅分类不稳，模型输出分数对目标语料也缺乏稳定校准。




图 4-9 CREMA-D 目标语料上的混淆矩阵

本节结果更适合被解释为跨语料库基线观察，而不宜直接推广为 CNN-Conformer 结构无效的结论。当前记录仅运行 1 个 fold，尚未形成完整 5-fold 平均结果。实验采用的是公共六类标签空间下的 source-only 训练协议，没有引入任何域不变约束、跨语料库特征标准化或目标域适配策略。相关研究表明，跨语料库语音情绪识别通常需要通过迁移子空间学习、域不变特征学习、对抗式域泛化或多任务建模来减弱语料间偏移，单纯依赖源语料监督往往难以获得稳定结果^[14,16-18,23,54]。基于上述限制，本文将本节结果定位为 CNN-Conformer 代表配置的异源语料初步泛化观察，主要价值在于量化源域与目标域之间的指标落差，并为后续是否引入专门的跨语料库建模策略提供依据。

当前数值可以支持这样一个判断：source-only CNN-Conformer 代表配置在 RAVDESS 到 CREMA-D 的迁移条件下，跨语料库一般化能力偏弱。当前数值还不足以支持另外两个更强的判断：CNN-Conformer 在所有跨语料库场景下都不适合，或者仅靠重新调学习率、batch size 与 dropout 就能填平当前落差。原因在于，本节没有引入域对齐、域不变正则或目标域适配模块，也没有给出完整 5-fold 平均结果。本节更适合作

为暴露 source-only 指标鸿沟的证据，而不是已经完成跨语料库改进的证据。

把这一节放回整章主线，可以得到与噪声实验相互呼应的另一条结论。噪声实验说明同一模型面对输入受扰时会沿不同路径退化。跨语料库实验则说明同一模型离开原始语料分布后，会出现更明显的整体失配。前者更接近输入端稳定性问题，后者更接近表示层域偏移问题。两节共同补足了主实验之外的观察维度，也让 CNN-Conformer 代表结构的优点与边界都能在论文中得到更完整的呈现。

4.5 本章小结

本章首先说明了语音情绪识别实验所采用的数据集、输入表示、比较模型结构以及训练参数设置，并在统一条件下对卷积神经网络基线模型、纯 Transformer 模型和 CNN-Conformer 模型进行了综合比较。综合实验结果表明，卷积结构在当前任务设定下仍然具有较强的参照意义，而 Transformer 系列模型虽然展现出一定建模潜力，但指标变化仍受到训练稳定性与过拟合现象的一定影响。

围绕 CNN-Conformer 模型所开展的进一步分析表明，模型指标不主要取决于结构规模的持续增加，而与时间下采样、层间特征融合、损失函数与采样策略以及模型容量控制之间的协调有关。噪声条件实验和类别层面分析补充展现了代表模型在输入信号质量变化、训练稳定性和类别混淆方面的结果，也为后续开展噪声增强训练与跨语料库验证提供了实验依据。

跨语料库实验进一步表明，在保持 CNN-Conformer 代表结构和主要超参数、仅将分类头重构为六类输出的条件下，RAVDESS 源验证集与 CREMA-D 目标语料之间仍存在明显指标落差。这一结果说明同语料条件下的较高指标不能直接等同于异源语料稳定性，也为后续研究引入域不变建模或目标域适配策略提供了依据。

结 论

结论作为毕业设计（论文）正文的最后部分单独排写，但不加章号。结论是对整个论文主要结果的总结。在结论中应明确指出本研究的创新点，对其应用前景和社会、经济价值等加以预测和评价，并指出今后进一步在本研究方向进行研究工作的展望与设想。结论部分的撰写应简明扼要，突出创新性。阅后删除此段。

结论正文样式与文章正文相同：宋体、小四；行距：22 磅；间距段前段后均为 0 行。阅后删除此段。

参考文献

- [1] Ma H, Yarosh S. A Review of Affective Computing Research Based on Function-Component-Representation Framework[J]. IEEE Transactions on Affective Computing, 2023, 14(2): 1655-1674.
- [2] Raamkumar A S, Yang Y. Empathetic Conversational Systems: A Review of Current Advances, Gaps, and Opportunities[J]. IEEE Transactions on Affective Computing, 2023, 14(4): 2722-2739.
- [3] Shou Y, Meng T, Ai W, et al. A Comprehensive Survey on Multi-modal Conversational Emotion Recognition with Deep Learning[J]. ACM Transactions on Information Systems, 2026, 44(2): 47:1-47:48.
- [4] Hou M, Zhang Z, Cao Q, et al. Multi-View Speech Emotion Recognition Via Collective Relation Construction[J]. IEEE/ACM Transactions on Audio, Speech, and Language Processing, 2022, 30: 218-229.
- [5] Zhang L, Wang Y, Du J, et al. CNN-BiGRU Speech Emotion Recognition Based on Attention Mechanism[C]//2023 2nd International Conference on Artificial Intelligence and Intelligent Information Processing (AIIP). IEEE, 2023: 85-89.
- [6] Liu Z, Kang X, Ren F. Dual-TBNet: Improving the Robustness of Speech Features via Dual-Transformer-BiLSTM for Speech Emotion Recognition[J]. IEEE/ACM Transactions on Audio, Speech, and Language Processing, 2023, 31: 2193-2203.
- [7] Lin W C, Busso C. Chunk-Level Speech Emotion Recognition: A General Framework of Sequence-to-One Dynamic Temporal Modeling[J]. IEEE Transactions on Affective Computing, 2023, 14(2): 1215-1227.
- [8] Peng Z, Lu Y, Pan S, et al. Efficient Speech Emotion Recognition Using Multi-Scale CNN and Attention[C]//ICASSP 2021 - 2021 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP). IEEE, 2021: 3020-3024.
- [9] Mirsamadi S, Barsoum E, Zhang C. Automatic Speech Emotion Recognition Using Recurrent Neural Networks with Local Attention[C]//2017 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP). IEEE, 2017.
- [10] Chen S, Xing X, Zhang W, et al. DWFormer: Dynamic Window Transformer for Speech Emotion Recognition[C]//ICASSP 2023 - 2023 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP). IEEE, 2023: 1-5.
- [11] Wang Y, Lu C, Lian H, et al. Speech Swin-Transformer: Exploring a Hierarchical Transformer with Shifted Windows for Speech Emotion Recognition[C]//ICASSP 2024 - 2024 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP). IEEE, 2024: 11646-11650.
- [12] Thanh P V, Huyen N T T, Quan P N, et al. A Robust Pitch-Fusion Model for Speech Emotion Recognition in Tonal Languages[C]//ICASSP 2024 - 2024 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP). IEEE, 2024: 12386-12390.
- [13] Sampath A, Tavernor J, Mower Provost E. Efficient Finetuning for Dimensional Speech Emotion Recognition in the Age of Transformers[C]//ICASSP 2025 - 2025 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP). IEEE, 2025.
- [14] Zhang W, Song P. Transfer Sparse Discriminant Subspace Learning for Cross-Corpus Speech Emotion Recognition[J]. IEEE/ACM Transactions on Audio, Speech, and Language Processing, 2020,

- 28: 307-318.
- [15] Leem S G, Fulford D, Onnela J P, et al. Selective Acoustic Feature Enhancement for Speech Emotion Recognition With Noisy Speech[J]. *IEEE/ACM Transactions on Audio, Speech, and Language Processing*, 2024, 32: 917-929.
 - [16] Su B H, Lee C C. Unsupervised Cross-Corpus Speech Emotion Recognition Using a Multi-Source Cycle-GAN[J]. *IEEE Transactions on Affective Computing*, 2023, 14(3): 1991-2004.
 - [17] Lu C, Zong Y, Zheng W, et al. Domain Invariant Feature Learning for Speaker-Independent Speech Emotion Recognition[J]. *IEEE/ACM Transactions on Audio, Speech, and Language Processing*, 2022, 30: 2217-2230.
 - [18] Gao Y, Wang L, Liu J, et al. Adversarial Domain Generalized Transformer for Cross-Corpus Speech Emotion Recognition[J]. *IEEE Transactions on Affective Computing*, 2024, 15(2): 697-708.
 - [19] Mao S, Ching P C, Lee T. Enhancing Segment-Based Speech Emotion Recognition by Iterative Self-Learning[J]. *IEEE/ACM Transactions on Audio, Speech, and Language Processing*, 2022, 30: 123-134.
 - [20] Hao Y. Channel Attention Scale Feature Fusion with SwiGLU for Speech Emotion Recognition [C]//2024 5th International Conference on Electronic Communication and Artificial Intelligence (ICECAI). IEEE, 2024.
 - [21] He Y, Minematsu N, Saito D. Multiple Acoustic Features Speech Emotion Recognition Using Cross-Attention Transformer[C]//ICASSP 2023 - 2023 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP). IEEE, 2023.
 - [22] Prabhu N R, Lehmann-Willenbrock N, Gerkmann T. End-to-End Label Uncertainty Modeling in Speech Emotion Recognition Using Bayesian Neural Networks and Label Distribution Learning[J]. *IEEE Transactions on Affective Computing*, 2024, 15(2): 579-592.
 - [23] Ahn C S, Rana R, Busso C, et al. Multitask Transformer for Cross-Corpus Speech Emotion Recognition[J]. *IEEE Transactions on Affective Computing*, 2025, 16(3): 1581-1591.
 - [24] Zhou H, Du J, Tu Y H, et al. Using Speech Enhancement Preprocessing for Speech Emotion Recognition in Realistic Noisy Conditions[C]//Proc. Interspeech 2020. 2020: 4701-4705.
 - [25] Tzeng J T, Leem S G, Salman A N, et al. Noise-Robust Speech Emotion Recognition Using Shared Self-Supervised Representations with Integrated Speech Enhancement[C]//ICASSP 2025 - 2025 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP). IEEE, 2025: 1-5.
 - [26] Pepino L, Riera P, Ferrer L. Emotion Recognition from Speech Using wav2vec 2.0 Embeddings[C]//Interspeech 2021. 2021: 3400-3404.
 - [27] Morais E d S, Hoory R, Zhu W, et al. Speech Emotion Recognition Using Self-Supervised Features [C]//ICASSP 2022 - 2022 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP). IEEE, 2022: 6922-6926.
 - [28] Fang Y, Xing X, Xu X, et al. Exploring Downstream Transfer of Self-Supervised Features for Speech Emotion Recognition[C]//Interspeech 2023. 2023.
 - [29] Baevski A, Zhou H, Mohamed A, et al. wav2vec 2.0: A Framework for Self-Supervised Learning of Speech Representations[C]//Advances in Neural Information Processing Systems: vol. 33. 2020: 12449-12460.
 - [30] Hsu W N, Bolte B, Tsai Y H H, et al. HuBERT: Self-Supervised Speech Representation Learning by Masked Prediction of Hidden Units[J]. *CoRR*, 2021, abs/2106.07447.

- [31] Chen S, Wang C, Chen Z, et al. WavLM: Large-Scale Self-Supervised Pre-Training for Full Stack Speech Processing[J]. IEEE Journal of Selected Topics in Signal Processing, 2022, 16(6): 1503-1514.
- [32] Gat I, Aronowitz H, Zhu W, et al. Speaker Normalization for Self-Supervised Speech Emotion Recognition[C]//ICASSP 2022 - 2022 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP). IEEE, 2022: 7342-7346.
- [33] Feng T, Narayanan S. PEFT-SER: On the Use of Parameter Efficient Transfer Learning Approaches For Speech Emotion Recognition Using Pre-trained Speech Models[C]//2023 11th International Conference on Affective Computing and Intelligent Interaction (ACII). IEEE, 2023: 1-8.
- [34] Lashkarashvili N, Wu W, Sun G, et al. Parameter Efficient Finetuning for Speech Emotion Recognition and Domain Adaptation[C]//ICASSP 2024 - 2024 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP). IEEE, 2024: 10986-10990.
- [35] Chandola D, Altarawneh E, Jenkin M, et al. SERC-GCN: Speech Emotion Recognition in Conversation Using Graph Convolutional Networks[C]//ICASSP 2024 - 2024 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP). IEEE, 2024: 76-80.
- [36] Lee Y, Yoon S, Jung K. Multimodal Speech Emotion Recognition Using Cross Attention with Aligned Audio and Text[C]//Interspeech 2020. 2020: 2717-2721.
- [37] Hu D, Chen C, Zhang P, et al. A Two-Stage Attention Based Modality Fusion Framework for Multimodal Speech Emotion Recognition[J]. IEICE Transactions on Information and Systems, 2021, 104-D(8): 1391-1394.
- [38] Santoso J, Yamada T, Ishizuka K, et al. Speech Emotion Recognition Based on Self-Attention Weight Correction for Acoustic and Text Features[J]. IEEE Access, 2022, 10: 115732-115743.
- [39] Kim K, Cho N. Focus-attention-enhanced Crossmodal Transformer with Metric Learning for Multimodal Speech Emotion Recognition[C]//Interspeech 2023. 2023: 2673-2677.
- [40] Sun D, He Y, Han J. Using Auxiliary Tasks In Multimodal Fusion of Wav2vec 2.0 And BERT for Multimodal Emotion Recognition[C]//ICASSP 2023 - 2023 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP). IEEE, 2023: 1-5.
- [41] Li Y. Enhancing Speech Emotion Recognition for Real-World Applications via ASR Integration[C]//ACIIW 2023. 2023: 1-5.
- [42] Zaidi S A M, Latif S, Qadir J. Cross-Language Speech Emotion Recognition Using Multimodal Dual Attention Transformers[J]. CoRR, 2023, abs/2306.13804.
- [43] Luna-Jiménez C, Kleinlein R, Griol D, et al. A Proposal for Multimodal Emotion Recognition Using Aural Transformers and Action Units on RAVDESS Dataset[J]. Applied Sciences, 2022, 12(1): 327.
- [44] Pappagari R K, Prasanna S M L. Music Theory-Inspired Acoustic Representation for Speech Emotion Recognition[J]. IEEE/ACM Transactions on Audio, Speech, and Language Processing, 2023, 31: 2534-2547.
- [45] Fan W, Xu X, Cai B, et al. ISNet: Individual Standardization Network for Speech Emotion Recognition[J]. IEEE/ACM Transactions on Audio, Speech, and Language Processing, 2022, 30: 1803-1814.
- [46] Yang S w, Chi P H, Chuang Y S, et al. SUPERB: Speech Processing Universal PERFORMANCE Benchmark[C]//Interspeech 2021. 2021: 1194-1198.
- [47] Park S, Mark M, Park B, et al. Using Speaker-Specific Emotion Representations in Wav2vec 2.0-Based Modules for Speech Emotion Recognition[J]. Computers, Materials and Continua, 2023,

- 77(1): 1009-1030.
- [48] Liu Y, Sun H, Guan W, et al. A Discriminative Feature Representation Method Based on Cascaded Attention Network With Adversarial Strategy for Speech Emotion Recognition[J]. IEEE/ACM Transactions on Audio, Speech, and Language Processing, 2023, 31: 1063-1074.
 - [49] Zou H, Si Y, Chen C, et al. Speech Emotion Recognition with Co-Attention Based Multi-Level Acoustic Information[C]//ICASSP 2022 - 2022 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP). IEEE, 2022.
 - [50] Vaswani A, Shazeer N, Parmar N, et al. Attention Is All You Need[C]//Advances in Neural Information Processing Systems: vol. 30. Curran Associates, Inc., 2017: 5998-6008.
 - [51] Hou M, Zhang Z, Cao Q, et al. Multi-View Speech Emotion Recognition Via Collective Relation Construction[J]. IEEE/ACM Transactions on Audio, Speech, and Language Processing, 2022, 30: 218-229.
 - [52] Gulati A, Qin J, Chiu C, et al. Conformer: Convolution-augmented Transformer for Speech Recognition[C]//Proc. Interspeech 2020. 2020: 5036-5040.
 - [53] Kang L, Zhang L, Jiang D. Learning Robust Self-Attention Features for Speech Emotion Recognition with Label-Adaptive Mixup[C]//ICASSP 2023 - 2023 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP). IEEE, 2023: 1-5.
 - [54] Luo H, Han J. Nonnegative Matrix Factorization Based Transfer Subspace Learning for Cross-Corpus Speech Emotion Recognition[J]. IEEE/ACM Transactions on Audio, Speech, and Language Processing, 2020, 28: 2047-2060.

致 谢

值此论文完成之际，首先向我的导师……

致谢正文样式与文章正文相同：宋体、小四；行距：22 磅；间距段前段后均为 0 行。阅后删除此段。