

北京理工大学

本科生毕业设计（论文）

基于注意力机制的声学信号情绪识别系统

Emotion Recognition System for Acoustic Signals Based on an
Attention Mechanism

学 院： 计算机学院

专 业： 软件工程

班 级： 07822201

学生姓名： 姜现日

学 号： 1820191086

指导教师： 李凡

2026 年 5 月 14 日

原创性声明

本人郑重声明：所呈交的毕业设计（论文），是本人在指导老师的指导下独立进行研究所取得的成果。除文中已经注明引用的内容外，本文不包含任何其他个人或集体已经发表或撰写过的研究成果。对本文的研究做出重要贡献的个人和集体，均已在文中以明确方式标明。

特此申明。

本人签名：

日期：

年

月

日

关于使用授权的声明

本人完全了解北京理工大学有关保管、使用毕业设计（论文）的规定，其中包括：①学校有权保管、并向有关部门送交本毕业设计（论文）的原件与复印件；②学校可以采用影印、缩印或其它复制手段复制并保存本毕业设计（论文）；③学校可允许本毕业设计（论文）被查阅或借阅；④学校可以学术交流为目的，复制赠送和交换本毕业设计（论文）；⑤学校可以公布本毕业设计（论文）的全部或部分内容。

本人签名：

日期：

年

月

日

指导老师签名：

日期：

年

月

日

摘 要

语音情绪识别技术旨在从语音信号中识别用户表达的情绪状态，在人机交互、心理健康辅导和用户画像归纳等场景中具有重要的应用价值。由于语音情绪特征分布在能量、频谱、韵律和时间上下文等多个层面，且用户差异、噪声干扰和数据规模限制会影响模型训练，因此本文关注的问题是如何在有限数据条件下构建稳定的输入表示和分类模型。

本文围绕对数梅尔频谱输入下的语音情绪识别方法开展研究。首先，对语音情绪识别数据集、信号预处理、时频变换、特征归一化和长度处理方法进行整理，确定以重采样、幅值归一化、对数梅尔频谱提取和分块组织为基础的信号处理流程。随后，本文从卷积神经网络、注意力机制和 Transformer 结构出发，构建卷积神经网络基线模型、纯 Transformer 模型和 CNN-Conformer 模型，并在 RAVDESS 语音情绪数据集上进行用户无关条件下的对比实验。针对 CNN-Conformer 模型，本文进一步比较前端标记化方式、模型容量、层间输出策略、池化方式和混合增强等因素对结果的影响。

实验结果显示，卷积神经网络基线模型取得 0.62196 的 Macro-F1，纯 Transformer 模型取得 0.51163 的 Macro-F1，采用无卷积前端时间分块输入、4 层 Conformer 编码器、注意力池化和频谱级混合增强的 CNN-Conformer 模型取得 0.70563 的 Macro-F1、0.70000 的 Accuracy 和 0.70938 的 UAR。补充的噪声条件实验与跨语料库实验表明，clean 条件下的较高指标不能直接等同于受扰输入或异源语料条件下的稳定表现。本文工作说明，在当前数据规模下，局部时频建模、时间上下文建模与适度正则化之间的组合方式，对语音情绪识别模型的泛化表现具有较大改进。

关键词：语音情绪识别；对数梅尔频谱；卷积神经网络；Transformer；CNN-Conformer

Abstract

Speech emotion recognition aims to infer the emotional state expressed in speech and has practical value in human-computer interaction, mental health support and service feedback systems. Since emotional features in speech are distributed across energy, spectral structure, prosody and temporal context, speech emotion recognition is affected by user differences, noise interference, and limited data scale. This paper focuses on how to construct universal input representations and general models.

This paper concentrates on speech emotion recognition methods based on log-Mel spectrogram. Firstly, this paper reviews datasets, signal preprocessing, time-frequency transformation, feature normalization, and sequence length handling methods. Consequently, this study adopts a processing pipeline based on resampling, amplitude normalization, log-Mel spectrogram extraction, and chunk organization. Moreover, convolutional neural networks, attention mechanisms, and Transformer structures are discussed. At last, convolutional neural network baseline, a pure Transformer model, and a CNN-Conformer model are implemented on the RAVDESS speech emotion dataset under a user-independent setting. Their performances are then compared to evaluate the effectiveness of each architecture. For the CNN-Conformer model, this paper conducts experiments in aspects of frontend tokenization, model capacity, layer output strategy, pooling method, and mixup regularization.

The experimental results show that the convolutional neural network baseline obtains a Macro-F1 of 0.62196, while the pure Transformer model obtains a Macro-F1 of 0.51163. The CNN-Conformer model with no-stem temporal patch input, it contains Conformer encoder layers, attention pooling, spectrogram-level mixup and it achieves a Macro-F1 of 0.70563, an Accuracy of 0.70000, and a UAR of 0.70938. Additional experiments indicate that higher performance under clean in-corpus conditions does not directly imply stable behavior under corrupted inputs or external corpora. The paper highlights the coordination among local time-frequency modeling, temporal context modeling, and moderate regularization. This combination has a clear influence on the generalization behavior of speech emotion recognition models under the current data scale.

Key Words: Speech Emotion Recognition; Log-Mel Spectrogram; Convolutional Neural Network; Transformer; CNN-Conformer

目 录

摘 要	I
Abstract	II
第 1 章 绪论	1
1.1 研究背景	1
1.2 研究意义	2
1.3 研究现状及发展趋势	3
1.3.1 语音情绪识别研究的发展历程	3
1.3.2 语音情绪识别数据集的研究现状	4
1.3.3 声学特征与信号处理方法的研究现状	5
1.3.4 基于深度学习的语音情绪识别模型研究现状	7
1.3.5 注意力机制与 Transformer 研究现状	7
1.3.6 低资源、噪声环境及跨语料库泛化研究现状	8
1.4 现有研究的总结与不足	9
1.4.1 评估方法论现状与局限	9
1.4.2 模型复杂度与数据规模	10
1.4.3 声学特征与语言特征的融合	11
1.5 研究内容	12
1.6 本文组织结构	13
第 2 章 音频情绪数据集与信号处理方法	15
2.1 音频情绪数据集的类型与选择	15
2.2 信号处理技术	17
2.2.1 信号预处理	17
2.2.2 时频变换与频谱分析	19
2.2.3 感知特征提取	25
2.2.4 特征后处理与序列长度处理	29
2.3 现有技术	31
2.4 本文采用的信号处理流程	33
2.5 本章小结	34
第 3 章 模型结构	36
3.1 现有基础模型结构	36
3.1.1 全连接神经网络模型	36

3.1.2	卷积神经网络模型	38
3.1.3	循环神经网络模型及其变体	39
3.2	注意力机制	41
3.2.1	注意力机制的基本概念与关键要素	42
3.2.2	代表性的注意力分数计算方式	44
3.2.3	注意力的结构类型与扩展方式	45
3.3	Transformer 结构	47
3.3.1	Transformer 的整体架构	47
3.3.2	位置编码机制	50
3.3.3	Transformer 层中的关键组成结构	51
3.3.4	Transformer 的主要特点及其适用边界	53
3.4	本章小结	54
第 4 章	实验设计与实验分析	55
4.1	实验参数与设置	55
4.1.1	数据集与任务设置	55
4.1.2	输入表示与预处理流程	56
4.1.3	比较模型的结构设计	56
4.1.4	训练参数与评价指标	70
4.1.5	实验环境与实现平台	71
4.2	综合实验	71
4.2.1	各比较模型的综合实验结果	71
4.2.2	CNN-Conformer 模型的结构优化路径	73
4.2.3	CNN-Conformer 模型的代表配置与结果观察	73
4.2.4	综合讨论	73
4.3	噪声条件实验	74
4.3.1	实验目的与评价流程	74
4.3.2	噪声条件设计	75
4.3.3	结果与现象分析	75
4.4	跨语料库实验	77
4.4.1	实验协议与评价流程	77
4.4.2	实验结果与现象分析	77
4.5	本章小结	79

北京理工大学本科生毕业设计（论文）

结 论	80
参考文献	82
致 谢	86

第1章 绪论

1.1 研究背景

情绪可通过多种媒介进行表示，其中语音因同时承载文字语义与非文字语义，成为人机交互中情绪感知的重要媒介^[1-2]。语音采集成本较低，无需复杂外部设备即可获得。更重要的是，语音中的语调、语速、重音、节奏、能量及音色等非文字语义要素，为识别用户情绪状态提供了信息依据。即便是相同的句子，语速、音高、发音力度及呼吸方式的变化，也会形成不同的情绪表现。语音情绪识别由此需要处理文字语义之外的声学线索，并把这些线索与后续交互决策联系起来。

随着近年来人工智能技术的快速发展，人机交互系统从显式执行用户指令，转向对用户状态与意图进行隐式感知^[3-4]。用户情绪状态的感知是这种人机交互范式转型中的关键环节之一。系统解析用户“说了什么”这一显式信息，同时识别用户“在何种情绪状态下说话”的隐式线索。在人类决策过程中，情绪会映射个体的行为方式，也会影响人机交互实际表现。具备情绪理解能力的人机交互系统，能够基于用户语音中的隐式情绪线索，动态调整交互策略，从而提升交互的自然度与用户体验。情绪识别技术已应用于教育、心理咨询、医疗辅助、客户服务及数字内容交互等领域，并有潜力提升系统交互性能。快速识别用户情绪有望成为下一代人机交互系统提升人机协作效率的关键能力之一。

当前语音情绪识别仍面临一系列挑战。情绪本身具有模糊性与主观性，人类情绪并不总是以边界分明的类别存在；同一种情绪在跨用户身上，也可能表现出差异较大的语音特征。例如，愤怒与兴奋、快乐与惊讶等相邻情绪类别，往往共享相似声学特性，分类边界随之变得模糊。语音情绪识别的性能还受数据集分布、样本质量、用户构成、录音环境及语言背景影响。当数据集分布差异较大时，在一个数据集上训练的模型可能在其他数据集或跨用户条件下出现性能下降。噪声环境、多输入、信道差异及设备特征差异也会干扰情绪线索提取。带有情绪标注的语音数据规模远小于普通语音数据，收集成本又较高；在这种条件下，复杂模型未必带来更高收益。本研究据此把重点放在数据受限及多变环境下的情绪表示学习问题上。

1.2 研究意义

情绪识别技术作为识别人类状态与意图的关键技术之一，在心理健康辅助诊断、客户服务系统、教育类智能导学及基于情绪的内容生成等多个领域，持续展现出应用潜力。语音作为承载情绪特征的主要媒介，具备易获得即可采集的固有优势，能以较低成本对接实际交互场景。基于上述分析，本研究侧重于人机交互系统层面的设计与验证，旨在为相关技术从实验环境向实际应用场景的转化提供方案。

本研究致力于构建一套系统化、分层次的语音情绪识别技术方案，进一步拓展语音在人机交互领域的研究实践。首先，本研究将围绕标准化数据输入与预处理环节，设计面向语音情绪识别的数据处理流程。本研究拟设计包含重采样、长度对齐、声学特征提取与归一化处理的预处理流水线，以减少输入差异对特征分布的干扰，并为后续模型提供相对稳定的非文字语义特征。在受限数据规模下，上述预处理流程有助于提高模型训练的一致性，并为语音情绪特征提取与结果复现能提供较为稳定的输入条件。

第二，基于卷积神经网络模型与 Transformer 模型的对比架构，本研究分别构建卷积神经网络基线模型与 Transformer 模型，以比较两类模型在语音情绪识别中的表现差异。在语音情绪识别中，情绪信息往往集中于特定时间区间或声学模式之内，对关键区间赋予更高权重的注意力机制是语音情绪识别领域的研究方向^[5-7]。Transformer 模型凭借自注意力机制，可用于捕捉语音信号中的长程依赖关系，在建模全局上下文方面具有一定潜力。本研究通过对比实验，分析卷积神经网络模型与 Transformer 模型在数据受限条件下的识别能力、稳定性及计算效率，为人机交互系统中模型结构的选择提供依据。

第三，拟构建适用于受限数据规模下的稳定评估框架。针对语音情绪识别中数据规模受限、情绪类别边界模糊及模型性能易受数据划分影响等问题，本研究拟引入差异化实验、交叉验证及混淆矩阵深度分析等策略。通过上述多维度评估策略，构建相应的评估方法。上述稳定评估框架旨在突破单一准确率指标的局限，为模型的科学评价与结果解释提供更为可靠的依据。

最后，本研究将基于上述评估框架，进一步考察模型在实际应用场景下的泛化能力。为此，本研究将引入噪声环境、多输入等环境干扰，以及跨用户、跨语料库等数据分布变化，从而验证模型在非理想条件下的稳定性与可靠性。上述探索旨在评

估模型从实验环境向实际应用场景迁移的可行性，为语音情绪识别技术的工程化落地提供实证依据。

随着大模型与注意力机制在文本等时序信息处理中的发展，Transformer 在情绪识别任务中展现出一定潜力。语音情绪识别中，情绪信息在整个语音片段中的分布往往不均匀，常集中于特定时间段或声学模式。对关键信息赋予更高权重的注意力机制，已成为语音情绪识别领域的重要研究方向之一^[5-7]。Transformer 凭借自注意力机制处理长期依赖关系并整合全局上下文，可在一定程度上补充传统卷积神经网络模型与循环神经网络模型的不足^[8]。利用大规模无标注数据的自监督预训练同样是应对标签稀缺问题的重要方向^[9-10]。本研究没有采用大规模预训练路线，而是从模型架构维度考察注意力机制与 Transformer 对关键情绪信息捕获的作用。

1.3 研究现状及发展趋势

1.3.1 语音情绪识别研究的发展历程

本文将语音情绪识别的发展演进大致划分为以下四个阶段：传统的基于特征工程阶段、基于机器学习阶段、基于深度学习阶段，以及利用注意力机制、Transformer 与预训练模型的新兴阶段。在早期研究中，主流方法主要依赖于人为设计的声学特征，并以此为依据进行情绪分类。该阶段的研究重点在于探究如何从语音信号中提取特征以更好地反映情绪差异，其中梅尔频率倒谱系数、音高、能量、共振峰及韵律等特征被广泛研究^[3]。上述人为设计的特征与分类器方法具有较强的可解释性，且能在数据规模较小的条件下进行实验。受限于固定特征集合，该类方法难以充分刻画情绪的复合性及其时序动态变化^[8,11]。




图 1-1 语音情绪识别方法从人工特征、机器学习、卷积建模、循环建模到 Transformer 范式的演进关系

基于机器学习的方法在特征工程之外，进一步关注分类算法的性能。支持向量机

(Support Vector Machine, SVM)、隐马尔可夫模型 (Hidden Markov Model, HMM)、高斯混合模型 (Gaussian Mixture Model, GMM)、K 近邻算法 (K-Nearest Neighbors, KNN) 及随机森林 (Random Forest, RF) 等多种机器学习分类器陆续被引入, 研究者们围绕人为设计特征与各类分类器组合开展情绪分类性能比较研究^[3]。特征选择、数据归一化及降维等辅助技术也得到关注, 语音情绪识别逐渐被系统化为典型的模式分类问题。该路线仍较大程度上受限于研究人员的先验判断, 难以充分捕捉情绪表达中固有的非线性特征与长期依赖关系^[8,11]。

深度学习技术的引入成为语音情绪识别研究的关键转折点。卷积神经网络模型被广泛用于从语谱图或对数梅尔谱等时频表示中自动学习局部模式^[8,12]。循环神经网络模型、长短期记忆网络模型等则被用于对语音信号内部的时间连续性及其上下文依赖关系进行建模^[5,11]。在此基础上, 结合卷积神经网络模型与循环神经网络模型的混合架构被提出, 进一步促进了同时学习局部特征与时序信息的研究趋势^[13]。最终, 语音情绪识别研究逐渐从人为设计的特征转向表示学习的范式。

随着大模型与注意力机制在文本等时序信息处理中的发展, Transformer 在情绪识别任务中展现出一定潜力。语音情绪识别中, 情绪信息在整个语音片段中的分布往往不均匀, 常集中于特定时间段或声学模式。对关键信息赋予更高权重的注意力机制成为语音情绪识别领域的重要研究方向之一^[5-7]。Transformer 凭借自注意力机制处理长期依赖关系并整合全局上下文, 可在一定程度上补充传统卷积神经网络模型与循环神经网络模型的不足^[8]。利用大规模无标注数据的自监督预训练也成为应对标签稀缺问题的重要方向^[9-10]。本研究没有采用大规模预训练路线, 而是从模型架构维度考察注意力机制与 Transformer 对关键情绪信息捕获的作用。

1.3.2 语音情绪识别数据集的研究现状

数据集一直是语音情绪识别研究的出发点, 同时也是评估模型性能的基准要素。目前语音情绪识别研究中常用的数据集包括 RAVDESS、IEMOCAP、EMO-DB、SAVEE、TESS、CREMA-D、MSP-Podcast、MSP-IMPROV 及 CASIA 等^[3,14]。这些数据集在语种、用户规模、情绪类别划分、录音环境、发音模式及标注范式等维度上均存在一定差异。此类差异体现在样本数量上, 也与模型所能习得的情绪特征及泛化能力密切相关。

当前主流的语音情绪识别数据集主要可分为表演型数据集与自发型或自然型数

据集^[14]。诸如 RAVDESS、EMO-DB、CASIA 等表演型数据集，多收录在受控环境下由演员演绎的情绪语音；这类数据集的主要优势在于情绪标注相对明确，实验具有较高的可重复性。IEMOCAP、MSP-IMPROV 等数据集融入对话、即兴或自然发音等元素，能够更真实地反映实际交互场景中的情绪表达^[3]。自然型数据集同时面临情绪边界模糊、标注一致性不足及预处理难度较大等挑战。数据集的选择不宜只看规模或被引频次，还需要结合研究目标判断：是关注界限清晰的基准测试验证，还是更重视实际应用场景下的泛化能力。

对于情绪标注方式而言，数据集可划分为离散标签（如愤怒、快乐）与连续维度（如效价、唤醒度）两类。前者主要适用于离散类别分类任务，后者能更细腻地刻画情绪。离散标签数据集往往难以充分反映情绪的复合性与渐变性，连续维度标注在实验设计与评价体系构建方面也面临一定的技术困难^[3,14]。

1.3.3 声学特征与信号处理方法的研究现状

在语音情绪识别中，输入信号质量及信号处理具有重要作用。早期研究主要基于先验知识手工提取具有情绪区分度的声学特征，例如梅尔频率倒谱系数、音高、能量、过零率等。这些特征既可单独使用，也可组成综合特征集。基于 OpenSMILE 工具提取的 eGeMAPS、ComParE 等特征集，长期作为情绪识别领域的重要基准之一，为后续研究提供了稳定的基线^[3,14]。

随着深度学习的发展，输入表示从定长特征向量转向以语谱图、对数梅尔谱图等时频表示为主。这些时频表示能有效保留语音内在的时序动态与频谱特征，与卷积神经网络模型及 Transformer 等深度学习架构具有良好的协同性^[6,8,12]。近期研究比较同一音频的多种表示，并探讨表示融合技术，表明输入特征已成为影响模型感知情绪的关键设计维度之一。

信号处理方法也朝着精细化方向发展。在信号处理方面，针对变长序列的填充(padding)、滑动窗口分割、序列分割等技术受到研究者的关注。此外，噪声消除、数据增强等方法也逐渐成为研究热点^[11,15]。近年来，诸多研究指出仅凭实验室环境难以验证模型的泛化能力，需要考察包含噪声或多输入等干扰情景下的识别性能^[16-18]。声学特征提取与信号处理技术是语音情绪识别的主要基础。这些信号处理技术在输入特征与模型的深度融合中起到重要作用，成为连接数据预处理与模型构建的主要环节之一，为系统识别能力提供了支撑^[3,14]。




图 1-2 语音情绪识别中常见声学特征的变换关系与信息侧重点比较

表 1-1 常见声学信号与特征表示的处理方式比较

表示对象	处理方式	反映信息	特点与适用性
原始波形	按采样率记录时域振幅	发音强弱、停顿	信息完整，频率结构不直观
能量轮廓	按短时帧计算功率统计	强度、重音	解释性较强，频带信息不足
基频与音高	估计声带振动频率	语调、韵律	对韵律变化敏感，易受噪声影响
对数梅尔谱图	短时傅里叶变换、梅尔滤波与对数压缩	时频能量、听觉频带	保留局部时频纹理，适合深度学习模型输入
梅尔频率倒谱系数	梅尔能量取对数后并行离散余弦变换	谱包络、音色	表示紧凑，二维纹理信息较弱

1.3.4 基于深度学习的语音情绪识别模型研究现状

基于深度学习的语音情绪识别技术，最初是为了解决传统人为设计特征方法的局限性而提出，现已成为人机交互领域的重要研究方向之一。早期的深度学习研究主要围绕卷积神经网络模型与循环神经网络模型展开。卷积神经网络模型能够从时频特征中有效提取局部模式，而循环神经网络模型、长短期记忆网络模型等则适用于对语音信号中的时间连续性与序列上下文进行建模^[8,11,13]。在此基础上，结合卷积神经网络模型与循环神经网络模型优势的混合架构被广泛探索，以同时学习局部特征与时序信息^[12]。

相较于传统机器学习分类器，这些深度学习架构具有较强的非线性映射能力，也能够自动学习无需人为设计的深层特征。卷积神经网络模型可以有效提取特定频段上的能量集中区域与语谱图中的局部结构差异；长短期记忆网络模型则能够对整段语音中的音高变化及能量变化轨迹进行建模^[8,11-12]。随着近期各类一维、二维卷积神经网络模型变体以及其与循环神经网络模型的融合机制被相继提出，语音情绪识别被视为一项复杂的序列学习任务^[2,13]。

深度学习架构也存在一定局限性。卷积神经网络模型受限于局部感受野，难以建模长程时序的全局依赖关系^[5-6,8,11-12]。循环神经网络模型的顺序计算机制往往导致并行效率较低，且在处理超长序列时可能面临较高的计算开销。带有情绪标注的训练数据通常规模较小，单纯增加模型参数容易导致过拟合问题。过拟合使得模型仅能记忆特定训练集的特征，难以学习到情绪的通用特征，从而影响模型的泛化能力^[15,19]。当前研究不再局限于增加网络深度，而是在保证性能的前提下，探索引入注意力机制等优化架构来强化全局特征捕捉。这些探索旨在控制模型复杂度的同时提升识别性能^[7]。

1.3.5 注意力机制与 Transformer 研究现状

语音情绪识别中，情绪信息并非均匀分布于整个语音片段，这成为注意力机制被引入语音情绪识别的重要背景之一。现有的卷积神经网络模型与循环神经网络模型在处理输入时通常对输入特征赋予相近的权重，实际情绪线索却往往更集中地体现于特定时间段、特定词汇或特定频段^[8,12,19]。为充分反映情绪信息在语音片段中的非均匀分布特性，近年来研究者们广泛探索注意力机制，使模型对关键情绪信息赋予更高权重^[5-7]。加性注意力 (Additive Attention)、多头注意力机制 (Multi-Head Attention)、

局部注意力机制 (Local Attention)、交叉注意力机制 (Cross-Attention) 及通道注意力机制 (Channel Attention) 等多种衍生结构相继被提出^[20-21]。

Transformer 以自注意力机制为主要结构，能够直接对序列内部的全局关系进行建模，在语音情绪识别研究中逐步成为常见方法之一^[6-8]。与传统循环神经网络模型的串行处理机制相比，Transformer 支持并行计算，也能直接建模长距离依赖关系，在解析复杂语音结构时展现出一定优势。研究者们相继提出多种基于 Transformer 的情绪识别模型，包括纯 Transformer 架构、卷积神经网络模型与 Transformer 的混合架构、将窗口 Transformer(Swin Transformer) 应用于语谱图分析的模型，以及结合移位窗口或动态窗口的改进架构。Transformer 在全局上下文建模与长时依赖处理方面具有一定优势，结合注意力机制可更精准地捕捉关键情绪特征。

基于注意力机制与 Transformer 的方法并不适用于每一种场景。此类结构通常伴随较大的参数规模与计算开销，并对训练数据量提出较高要求。在数据受限条件下，模型容易因过度参数化而难以获得相应的泛化能力^[15,22-23]。当前研究不再局限于扩大 Transformer 规模，转而深入探索在卷积神经网络模型中嵌入轻量级注意力模块，或引入较为简洁的辅助注意力架构^[6-7,20]。上述研究趋势表明，注意力机制与 Transformer 是重要技术手段，其使用仍需根据实际数据规模与计算资源进行权衡。

1.3.6 低资源、噪声环境及跨语料库泛化研究现状

在当前的语音情绪识别研究中，相比于单一数据集上的准确率，模型在实际应用场景中的鲁棒性与泛化能力正逐渐成为更重要的衡量标准之一。这一发展趋势主要源于以下两项客观因素：其一，带有情绪标注的音频数据收集成本相对较高，相关数据集规模通常较小，使得许多研究仍面临低资源条件的限制^[10,12,15]。其二，在实际应用场景中，环境噪声、多输入干扰、信道差异、跨用户的发音习惯以及预训练数据集与目标任务之间的数据分布差异等因素相互交织，容易导致同一模型在不同测试环境下出现稳定性下降^[16-18]。

在针对噪声环境的相关研究中，噪声添加、多输入模拟、端到端语音增强以及数据增强等技术逐渐成为研究重点^[11,15,24-25]。相关研究指出，仅凭实验室环境难以有效评估模型的实际应用性能，多种噪声条件下的鲁棒性评估由此变得重要^[16,18]。针对跨用户及跨语料库问题，研究者们正积极探索降低模型对特定源领域或用户样本较强依赖的去相关方法^[17,23]。领域自适应、迁移学习、域泛化策略、多条件混合训练

及特征归一化等方法，已成为应对该问题的重要技术途径^[14]。

利用自监督预训练语音模型的低资源情绪识别研究也呈较快增长趋势^[9-10,26-28]。以 Wav2Vec2、HuBERT、WavLM 及 DistilHuBERT 等为代表的自监督预训练模型，能够从无标注数据中学习通用声学特征^[29-31]。这些模型可为标注数据不足的情绪分析提供深层特征，相关研究已在 IEMOCAP 等数据集上验证了冻结特征、全量微调、说话人归一化及下游迁移等策略的有效性^[32]。此类大规模模型的运行成本仍较高，微调稳定性也有待提高；围绕参数高效微调的研究正尝试缓解部署与迁移成本^[33-34]。预训练领域与目标情绪数据集之间的数据分布差异仍存在一定挑战^[18]。低资源条件、噪声环境及跨语料库问题相互交织，后续研究需要同时检视输入特征、模型结构、学习策略与评估框架。

1.4 现有研究的总结与不足

尽管语音情绪识别技术在模型架构与特征表示等方面取得了进展，现有研究在评估方法、模型设计及多模态融合等层面仍存在若干有待研究的方向。

1.4.1 评估方法论现状与局限

近年来，语音情绪识别研究在模型架构与特征表示等方面取得了一定进展，评估体系构建与泛化能力考量仍存在一定局限^[8,16,19]。当前多数研究主要依赖于单一数据集上的准确率作为主要评价指标。不同研究在数据预处理、特征提取及实验设置等环节存在差异，这些差异导致不同模型之间的性能结果难以有效比较^[3,11]。特定数据集上取得的优异表现往往难以充分反映模型在实际应用场景中的泛化能力。这种评估体系的不完善已成为制约语音情绪识别领域进一步发展的关键因素。

在泛化能力的评估方面，现有研究往往面临跨用户、跨语料库及跨场景下的能力下降问题。相关研究指出，在特定数据集上表现良好的模型，在面对跨用户、不同语言背景或噪声环境时，识别准确率往往出现一定程度的下降。这种性能下降现象与由跨用户差异引起的领域偏移密切相关^[15-17,22]。除了准确率与泛化能力，模型的置信度校准也是评估体系的重要维度。置信度校准旨在使模型的预测置信度与实际准确性相匹配，避免模型出现过于自信或信心不足的情况。部分模型往往倾向于表现出较高自信度，但其置信度与预测准确性之间的一致性仍有待提高^[8,19]。已有研究尝试将置信度校准方法引入语音情绪识别技术，这些方法在实际应用中的效果仍可

能存在局限，在跨用户、跨语料库等复杂场景下也可能对模型性能产生影响^[11]。

针对评估体系不完善、泛化能力不足及置信度校准等问题，未来的研究可从方法论层面进行系统性探索与设计。首先，已有研究指出，多样化评估指标体系对提升评估可靠性具有一定作用^[3,8,19]。该体系可在准确率之外纳入对模型置信度、稳定性及跨场景泛化能力的综合考量。其次，相关研究也强调推动评估协议标准化的重要性，明确数据预处理、特征提取及实验设置的规范，有助于提高不同研究之间结果的可比性。此外，相关研究进一步强调在多种噪声条件、跨用户及跨语料库等复杂场景下进行模型性能评估的重要性，通过构建更具挑战性的测试基准，更真实地反映模型在实际应用中的鲁棒性与可靠性。构建系统化的评估框架，有助于为语音情绪识别技术的工程化落地提供更为可靠的实证依据。

1.4.2 模型复杂度与数据规模

近年来，语音情绪识别研究在模型架构方面取得了一定进展，其中以 Transformer 为代表的预训练模型在语音情绪识别技术中表现出一定性能提升^[6-8]。以 Transformer 为代表的预训练模型参数量通常较大，训练与推理过程对计算资源与数据规模提出了较高要求。相关研究指出，在语音情绪识别技术中，标注数据的获取成本较高，使得现有数据集规模相对较小，一定程度上制约了复杂模型的泛化能力^[10,12,22]。在数据受限条件下，模型参数过度增加往往导致过拟合问题，使得模型倾向于记忆特定训练集的特征，而难以学习到具有泛化能力的情绪表征^[11,19]。

在模型设计层面，当前研究对计算效率与资源消耗的考量仍有待进一步探索^[15,23]。标准的自注意力机制具有随输入序列长度呈二次增长的计算复杂度，而语音信号往往持续时间较长且存在一定程度的时序冗余，这种计算特性使得 Transformer 在语音情绪识别技术中的部署面临一定挑战^[6-8]。为缓解这一问题，近年来出现了多种高效注意力机制变体，例如窗口注意力机制、动态窗口注意力机制及通道注意力机制等，这些机制旨在降低计算开销的同时保持模型性能^[12,20-21]。相关研究指出，这些高效注意力机制在语音情绪识别领域的系统性评估仍较为有限，这些方法在实际部署中的表现仍有待进一步验证。

针对预训练模型在计算资源受限条件下的部署问题，相关研究已通过模型压缩技术探索效率与性能的平衡^[15-16,22]。编码器层剪枝、知识蒸馏及量化等方法，可使压缩后的模型在保持一定识别准确率的同时，有效降低参数量与推理时延。压缩过程

往往伴随一定程度的信息损失，如何在模型表达能力与计算效率之间实现有效平衡，仍是当前研究面临的主要挑战^[23]。

1.4.3 声学特征与语言特征的融合

传统的语音情绪识别研究主要关注声学特征，例如梅尔频率倒谱系数、音高、能量等。这些特征能够捕捉语音中的韵律、音质等非文字语义信息，在一定程度上反映用户的情绪状态。语音信号中除声学信息外，还包含文字语义信息这一重要维度，但现有研究对此关注相对较少。语言内容承载的语义信息，可为情绪表达提供重要线索，例如特定的情绪词汇、句式及表达方式^[1,4]。相关研究指出，声学特征与语言特征具有互补性，这两种特征的有效融合有望提升情绪识别的准确性与鲁棒性^[35-37]。

声学特征主要反映语音表达方式（即“怎么说”），如语调、语速、音高等。语言特征则主要反映表达内容（即“说什么”），如词汇、句法、语义等。人类在表达情绪时，通常会同时通过声学特征与语言特征传递信息。例如，同样一句话“真是太好了”，用不同的语调可表达真诚的高兴，也可能传递讽刺意味。仅依靠声学或语言特征往往难以全面捕捉复杂情绪。近年来，研究者们逐步探索声学特征与语言特征的融合方法，以期综合利用这两种特征的优势，有望提升情绪识别的性能^[1,35,38-39]。

声学特征提取通常采用人为设计的特征（如梅尔频率倒谱系数、韵律特征）或基于深度学习的自动特征学习方法（如语谱图、预训练声学模型 Wav2Vec 2.0 等）^[6,26-27,29]。语言特征提取则多基于词嵌入（word embeddings）或预训练语言模型（如 BERT、RoBERTa）得到文本的高维语义表示^[1,35,39]。在语音情绪识别技术中，通常需要对语音进行语音识别（ASR）获得文本转录，这一过程可能带来语音识别错误的风险，从而影响融合效果^[40]。

声学特征与语言特征融合方法主要分为三类：早期融合（特征级融合）、中期融合（隐藏层融合）和晚期融合（决策级融合）。早期融合将声学特征与语言特征拼接后输入分类器；中期融合在多模态模型的中间层交互；晚期融合则分别训练两个单模态模型后融合输出^[1,36-37]。随着注意力机制的发展，基于跨模态注意力（cross-modal attention）的融合方法逐渐成为主流，能够动态加权交互不同模态的信息，更有效地捕捉模态间的关联^[35,38-39,41]。此外，一些研究提出基于 Transformer 架构的多模态模型，在 IEMOCAP 等数据集上表现出一定潜力。

尽管声学特征与语言特征融合方法表现出一定潜力，但仍面临一定挑战。首先，

语音识别（ASR）的错误可能影响语言特征的质量，特别是在噪声环境或非正式口语场景中，ASR 性能下降可能使融合效果受到一定影响^[39-40]。其次，声学特征与语言特征之间的对齐问题仍需解决：词与文本的时序粒度差异，使得如何有效融合仍有待探索^[1,35,38]。此外，现有融合模型往往依赖大量标注数据，在低资源场景下泛化能力可能受到一定限制^[4]。最后，一些融合方法在特定数据集上表现良好，但这些方法在不同语言、文化和情境下的鲁棒性仍有待验证^[41-42]。

针对声学特征与语言特征融合方法面临的挑战，未来研究可从以下几个方向进行探索：一是探索具有更强鲁棒性的语音识别技术，以降低语音识别错误对融合效果的影响；二是发展无监督或自监督的多模态预训练方法，以减少对标注数据的依赖；三是研究更精细的跨模态对齐机制，以期实现声学特征与语言特征的深度融合；四是在更多实际应用场景和不同语言环境中进一步考察模型的泛化能力。上述四个方向的探索，有望推动声学特征与语言特征融合在语音情绪识别中的发展^[1,4,39,41]。

1.5 研究内容

本研究聚焦于构建一个基于语音情绪识别系统。本文聚焦于以下四个主要维度展开研究：数据筛选与输入处理流程的构建、基于卷积神经网络模型的基线模型设计、轻量级注意力机制的引入，以及面向受限数据规模的鲁棒性评估框架的搭建。

第一，设计面向语音情绪识别技术的数据集筛选与输入处理流程。本研究以公开且结构相对清晰的语音情绪数据集为主，梳理这些数据集的基础属性，包括标签构成、用户分布、情绪类别、录音时长及噪声情况等，旨在为后续模型的输入表示提供稳定的基础。在梳理数据基础属性的基础上，设计整合重采样、长度对齐、特征提取、归一化处理及数据质量控制的输入处理流水线，以为后续模型提供稳定的输入表示。此项工作的主要意义包括对数据本身的梳理，也包括对可能影响结果的输入变量进行预先控制，从而为提升后续模型训练的稳定性与结果的复现性提供可靠基础。

第二，面向语音情绪识别技术，设计基于卷积神经网络模型的基线模型。本研究选取对数梅尔谱图或梅尔频率倒谱系数等时频表示作为输入特征，以帮助卷积神经网络模型学习语音信号中的局部时空模式^[8,12]。设计该基线模型的主要目的在于，为后续融合注意力机制的扩展模型提供清晰的性能基准。

第三，基于卷积神经网络模型与 Transformer 模型的对比架构，本研究构建卷积

神经网络基线模型与 Transformer 模型，以比较两类模型在语音情绪识别中的表现差异。在语音情绪识别中，情绪信息可能集中于特定时间区间或声学模式之内。基于上述观察，对关键时间区间赋予更高权重的注意力机制，被视为语音情绪识别领域的研究方向。Transformer 模型凭借自注意力机制，可用于捕捉语音信号中的长程依赖关系，在建模全局上下文方面具有一定潜力。本研究通过对比实验，分析卷积神经网络模型与 Transformer 模型在数据受限条件下的识别能力、稳定性及计算效率，为人机交互系统中模型结构的选择提供基础。

第四，拟构建兼顾受限数据规模与结果可解释性的鲁棒性评估框架。鉴于多数语音情绪数据集规模受限、情绪类别边界模糊，且模型能力容易受数据划分影响，本研究将避免仅依赖单一实验准确率的简单评价方式。在可行范围内，研究将引入差异化实验、交叉验证、混淆矩阵分析及相似情绪类别间的细粒度错误分析等方法，以构建更为多维的验证体系。在此过程中，还将同步考察噪声环境、跨用户及验证集划分变化对评估结果的影响，以提升实验结果的泛化能力与科学可解释性。

上述研究过程包括从数据提取到模型构建的主要阶段，各模块及执行顺序如图 1-3 所示。




图 1-3 研究流程图：涵盖数据预处理、卷积神经网络模型与 Transformer 并行对比及结果分析

1.6 本文组织结构

本文共分为四章，各章的具体内容安排如下：

第一章介绍本文的绪论。首先阐述语音情绪识别研究的背景与现实需求，并总结本研究的理论价值与实际意义。其次，梳理语音情绪识别领域的研究现状与主要趋势，并阐述本文拟开展的主要研究内容。

第二章主要介绍语音数据集的选择与语音信号的处理方法。首先，对比分析当前语音情绪识别领域常用公开数据集的类型与特点，并说明本研究在数据集选择上的标准与考量。其次，梳理语音信号处理中的主要问题及现有技术对策，并说明本研究所采用的输入处理流程与特征表示方法。为后续模型训练与实验验证提供可靠的数据基础与特征表示方法。

第三章介绍面向语音情绪识别的模型架构设计。首先，对全连接神经网络、卷积神经网络模型及循环神经网络模型等传统网络结构的功能特征与局限性进行梳理。其次，介绍注意力机制，阐明该机制在使模型聚焦于语音信号中关键情绪信息方面的优势，并分析 Transformer 架构的基本原理与架构特点。

第四章介绍本研究的实验设计与结果分析。首先，说明实验软硬件配置、数据集规模、训练集与验证集的划分、损失函数及优化手段选择等主要实验参数设定。其次，呈现包含基线模型与融合注意力的增强模型在内的综合评估结果，并对比能力及分析其机理。最后，通过开展噪声环境实验、跨语料库验证、细粒度错误分析及基于用户维度的针对性评估等扩展验证，全面且客观地审视本文所提模型架构的实际效用界限与局限性。

第2章 音频情绪数据集与信号处理方法

2.1 音频情绪数据集的类型与选择

本节梳理当前语音情绪识别研究中常用的代表性公开数据集，比较与分析其基础属性。将以各数据集的语言、采集方式、情绪表达特点、用户构成、情绪标签结构、数据规模、公开访问性及可用性为中心进行比较，并在此基础上尝试归纳适合本研究的数据集选择标准。详细对比见表 2-1。

表 2-1 语音情绪识别常用公开数据集比较

类别	数据集	语言	规模	标签构成	对话上下文	多模态
表演型	RAVDESS	英语	7,356 条	离散类 (8)	低	是
表演型	EMO-DB	德语	约 535 条	离散类 (7)	低	否
表演型	SAVEE	英语	480 条	离散类 (7)	低	是
表演型	TESS	英语	2,800 条	离散类 (7)	低	否
表演型	CREMA-D	英语	7,442 条	离散类 (6)	低	是
表演型	CASIA	汉语	约 1,200 条	离散类 (6)	低	否
对话型	IEMOCAP	英语	约 12 小时	离散 + 连续类	高	是
诱导型	MSP-IMPROV	英语	约 9 小时	离散类	高	是
自然型	MSP-Podcast	英语	409 小时	离散 + 连续类	中-高	否
对话型	MELD	英语	1.3 万条	离散类	高	是
自然型	FAU Aibo	德语	约 9 小时	离散类	中等	否
交互型	RECOLA	法语	多模态	连续类	高	是
诱导型	eNTERFACE	英语	音视频	离散类	低	是
半自然	ShEMO	波斯语	3,000 条	离散类	低	否
现实自然	EMOVOME	西班牙语	999 条	离散 + 连续类	中等	否
自然型	CNSCED	汉语	14 小时	多维度离散类 (6)	中等	否

从表 2-1 可见，代表性语音情绪数据集首先根据情绪采集方式与情绪表达性质

被较为明确地区分。RAVDESS、EMO-DB、SAVEE、TESS、CREMA-D、CASIA 等数据集属于在受控环境下由演员表达情绪的表演型基准数据集，这些数据集的共同特点是情绪标签相对明确、实验条件较为稳定。IEMOCAP 与 MSP-IMPROV 包含对话与即兴互动，比表演型基准数据集具有相对更为复杂的情绪表达；MSP-Podcast、FAU Aibo、EMOVOME、CNSCED 等数据集则包含自然语音或实际环境因素，具有更接近实际应用场景的特性。这类自然型数据集也同时面临情绪边界模糊、标签一致性以及数据整理难度较高等问题。

语音情绪数据集还可以根据标签构成方式与问题定义方式进行区分。RAVDESS、EMO-DB、SAVEE、TESS、CREMA-D、CASIA 等数据集提供愤怒、快乐、悲伤、恐惧、中性等离散标签，较为便利地应用于多分类实验。RECOLA、MSP-Podcast、EMOVOME 等数据集同时提供效价、唤醒度、支配度等连续维度，更适用于将情绪作为回归问题或维度情绪模型处理的研究。对于 IEMOCAP、MELD 这类对话上下文重要的数据集，除了发话的声学特征外，还可以进一步考虑用户交替、上下文流程、对话结构等附加因素。上述分析表明，数据集之间的差异体现在规模上，也与研究如何定义情绪以及设定何种任务存在一定关联^[3,43]。

语言、用户构成、公开访问性也是用于比较数据集时的主要标准。英语数据集包括 RAVDESS、TESS、CREMA-D、SAVEE 等表演型基准数据集，也包括 IEMOCAP、MSP-IMPROV、MSP-Podcast、MELD 等对话型、自然型数据集。德语方面有 EMO-DB 与 FAU Aibo，汉语方面有 CASIA 与 CNSCED，波斯语方面有 ShEMO，西班牙语方面有 EMOVOME，均为代表性示例。用户数与人口统计信息在不同数据集之间也存在一定差异。例如，TESS 仅包含两名女性用户，SAVEE 仅包含男性用户，而 CREMA-D 则包含 91 名具有不同年龄和人口统计信息的用户。MSP-Podcast 在用户数与发话多样性方面属于较为大规模的自然语音数据集，因而在一定程度上区别于其他基准数据集。此外，部分数据集相对易于公开访问，部分则需要许可证注册或单独审批程序，部分数据集仅选择性使用原始多模态资料中的音频子集。数据集在语言、人口统计信息与公开访问性上的差异，既体现在附加信息层面，也与研究的可重复性与泛化能力密切相关。

本研究在数据集选择时重点考虑以下几项标准。其一，数据集应具备公开访问性或在研究过程中可稳定获取，且具备支持后续实验可重复性的形式。其二，标签构成方式应相对明确，能够直接应用于分类实验。其三，用户数与性别分布不宜过

度偏斜，应具备基本的平衡性与代表性。其四，数据规模应能够支撑基础实验，同时预处理与模型验证不宜过于复杂。其五，数据集应具备基准数据集性质，即在已有研究中较为常用，以便后续进行结果比较与实验分析。

基于上述标准，本研究首先选择 RAVDESS 作为基础实验数据集。RAVDESS 可公开访问，性别分布较为均衡，情绪类别构成清晰，较为适合进行基础分类实验。此外，RAVDESS 在语音情绪识别相关现有研究中较为常用，属于代表性基准数据集之一，便于后续实验结果的分析与比较。RAVDESS 属于在受控环境下由专业演员演绎情绪的表演型基准数据集，与实际应用场景中的自然语音存在差异。综合考量数据访问性、标签稳定性、实验可重复性、输入处理流程的清晰度等因素，该数据集适合在本研究的初期实验阶段使用。

2.2 信号处理技术

2.2.1 信号预处理

(1) 输入格式统一：重采样与通道统一

不同语音数据集或录音设备采集的音频文件可能具有不同的采样频率和通道配置。部分文件以 8 kHz、16 kHz、22.05 kHz、44.1 kHz 或 48 kHz 等不同采样频率存储，且单声道与立体声格式也可能混用。这些差异会影响可分析的频率范围、时间分辨率以及后续特征的统计分布。为稳定应用相同的特征提取流程，特征提取前通常需要完成重采样与通道统一。

重采样（resampling）是将原始采样频率下的离散信号重新表达为目标采样频率的过程。在概念上可理解为先从原离散信号恢复连续时间信号，再按目标采样频率重新采样，理想化情况下可表示为：

$$x_r[m] = x_c\left(\frac{m}{F'_s}\right) \quad (2-1)$$

其中 $x_r[m]$ 为重采样后的离散信号， $x_c(t)$ 为恢复的连续时间信号， F'_s 为目标采样频率， m 为新采样索引。

实际实现中并不直接计算连续时间信号，而是通过插值与抗混叠滤波相结合的数字化处理完成。尤其在下采样时，超出奈奎斯特频率的成分可能引发混叠，通常需要通过低通滤波器抑制高频成分后再进行重采样。对于立体声或多声道输入信号，为

保持特征提取的一致性，常将其转换为单声道。一种常见的方法是取左右声道平均值，可表示为：

$$x_{\text{mono}}[n] = \frac{x_L[n] + x_R[n]}{2} \quad (2-2)$$

其中 $x_L[n]$ 和 $x_R[n]$ 分别为左右声道信号， $x_{\text{mono}}[n]$ 为转换后的单声道信号。该方法实现简单，较为适用于多数语音情绪识别实验，当某些声学信息仅集中于特定声道时，可能因平均化导致信息损失^[11,15]。

重采样与通道统一虽不直接产生情绪线索，但对于保证后续特征提取输入条件的一致性较为重要。若采样频率与通道格式未统一，即便采用相同的短时傅里叶变换（Short-Time Fourier Transform, STFT）或梅尔滤波器组（Mel filterbank）参数，也可能得到分布不同的特征，从而增加模型误将设备差异或存储格式差异作为情绪信息学习的风险。统一输入格式有助于保障后续处理可重复性与实验可比性的基础环节。

(2) 振幅归一化

不同语音文件在用户的发声音量、麦克风灵敏度、录音距离、设备增益、存储格式等方面可能存在一定差异。这种差异可能源于情绪表达本身的差别，也可能反映录音条件的不同。若保留这种振幅差异直接提取特征，模型可能过度学习与情绪无关的振幅变化，从而影响识别性能^[11,44]。振幅归一化（amplitude normalization）用于统一输入信号的振幅范围。

峰值归一化（peak normalization）是一种简单且常用的方法之一。该方法以整个信号中绝对值最大的样本为基准进行缩放，可表示为：

$$x_{\text{peak}}[n] = \frac{x[n]}{\max_{0 \leq n < N} |x[n]| + \varepsilon} \quad (2-3)$$

其中 $x[n]$ 为原始信号， $x_{\text{peak}}[n]$ 为峰值归一化后的信号， N 为总样本数， ε 为防止分母为零的极小常数。经此归一化的信号，其最大绝对振幅通常较为接近 1。峰值归一化的优点在于计算简单、直观，可较为快速地将信号动态范围调整到统一水平。峰值归一化的缺点在于，若信号中存在较大的瞬时峰值，其余部分的相对强度可能被过度压缩^[11]。

均方根归一化（RMS normalization）也是一种常用的方法之一。均方根（RMS）反映信号的平均强度水平，定义为：

$$\text{RMS}(x) = \sqrt{\frac{1}{N} \sum_{n=0}^{N-1} x[n]^2} \quad (2-4)$$

据此，RMS 归一化可表示为：

$$x_{\text{rms}}[n] = \frac{x[n]}{\text{RMS}(x) + \varepsilon} \quad (2-5)$$

其中 $\text{RMS}(x)$ 为原始信号的均方根值， $x_{\text{rms}}[n]$ 为归一化后的信号。若需要指定目标 RMS 值 r_t ，可表示为：

$$x_{\text{target-rms}}[n] = \frac{r_t}{\text{RMS}(x) + \varepsilon} x[n] \quad (2-6)$$

其中 r_t 为目标 RMS 值。RMS 归一化以信号的均方根值为基准，相较于峰值归一化，通常可提供较为稳定的幅度调节效果^[11,14-15]。

在语音情绪识别中，振幅归一化有助于减少因录音条件差异带来的无关振幅变化。情绪表达本身也包含发声强度、响度等重要线索，过度归一化可能削弱这些与情绪相关的强度信息。例如，愤怒、喜悦常伴随较高发声强度，而悲伤、疲惫则可能呈现较低且平缓的强度分布。应用振幅归一化时，需要在减少录音条件差异与保留情绪相关强度信息之间取得平衡^[11,14,44]。

此外，振幅归一化并非适用于所有情况。将整个信号缩放至统一振幅范围时，噪声环境也会被同步放大或缩小。振幅归一化可视为信号振幅统一的基础步骤，噪声消除与鲁棒性增强应该结合后续的数据增强或鲁棒性策略共同实现。

2.2.2 时频变换与频谱分析

(1) 分帧与帧重叠：时间分辨率与频率分辨率的权衡

设离散语音信号长度为 N ，记作 $x[n]$ ，帧长为 L ，帧移（hop size）为 H ，则第 m 帧可表示为：

$$x_m[n] = x[mH + n], \quad 0 \leq n < L \quad (2-7)$$

其中 $x[n]$ 为原始离散语音信号， $x_m[n]$ 为第 m 帧， L 为帧长（样本数）， H 为帧移，

m 为帧索引。总帧数 M 通常按下式计算：

$$M = \left\lfloor \frac{N - L}{H} \right\rfloor + 1 \quad (2-8)$$

其中 $\lfloor \cdot \rfloor$ 为向下取整函数。上述公式表示从长度为 N 的信号中以帧移 H 滑动提取长度为 L 的帧所能得到的帧数。

例如，当采样频率 $F_s = 16 \text{ kHz}$ 时，25 ms 帧对应约 400 个样本，10 ms 帧移对应约 160 个样本。帧重叠是指相邻帧之间存在公共区间，即 $H < L$ 的情形。重叠率可表示为：

$$r = 1 - \frac{H}{L} \quad (2-9)$$

例如 $L = 400$ 、 $H = 160$ 时，重叠率为 60%。采用帧重叠的目的是避免相邻帧之间信息断裂，使时间轴上的变化更为平滑稳定。重叠率过小可能导致帧间连续性不足，过大则会增加计算量并引入过多冗余信息。

帧长与帧移共同决定了时间分辨率与频率分辨率之间的权衡。通常，帧移越小，时间轴上的分析越密集，时间分辨率越高，上述关系可近似表示为：

$$\Delta t \approx \frac{H}{F_s} \quad (2-10)$$

其中 Δt 为相邻分析点的时间间隔。频率分辨率则与快速傅里叶变换（Fast Fourier Transform, FFT）长度相关：

$$\Delta f \approx \frac{F_s}{N_{\text{FFT}}} \quad (2-11)$$

其中 Δf 为频率 bin 间隔， N_{FFT} 为快速傅里叶变换长度。帧长过短虽能提升时间分辨率，但会降低频率分辨率，难以刻画精细的频谱结构；帧长过长虽能提高频率分辨率，但可能破坏帧内信号的准平稳性。

从语音情绪识别的视角来看，分帧与重叠涉及计算层面的处理，也直接关系到情绪信息的保留。情绪表达通常并非均匀分布于整段语音，而往往集中于特定的时间区间（如抑扬变化、能量突增、停顿等）^[5,11-12]。合理设定帧参数有助于保留这些时间相关的情绪线索，并为后续的时频变换提供稳定的基础。

（2）傅里叶变换：从时域到频域的基础

分析语音信号的频率结构，常用的方法之一是傅里叶变换。时域波形包含发声

强度、周期性、共振特性、频带能量分布等信息，但仅从时域难以直观解读这些内容。在语音情绪识别中，基频、共振峰、频谱斜率、频带能量分布等频域线索具有一定作用。将时域信号转换为频域表示，是需要关注的基础步骤之一。傅里叶变换为后续的短时傅里叶变换、谱图以及梅尔系列特征提取提供了理论基础。

对于长度为 N 的离散信号 $x[n]$ ，其离散傅里叶变换（Discrete Fourier Transform, DFT）定义为：

$$X[k] = \sum_{n=0}^{N-1} x[n] e^{-j2\pi kn/N}, \quad 0 \leq k < N \quad (2-12)$$

其中 $x[n]$ 为时域离散信号， $X[k]$ 为第 k 个频率 bin 的复数谱值， N 为变换长度， j 为虚数单位， k 为频率 bin 索引。

复数谱包含幅度与相位信息。幅度谱可由下式计算：

$$|X[k]| = \sqrt{\Re(X[k])^2 + \Im(X[k])^2} \quad (2-13)$$

其中 $\Re(X[k])$ 、 $\Im(X[k])$ 分别为 $X[k]$ 的实部与虚部。

功率谱通常定义为：

$$P[k] = |X[k]|^2 \quad (2-14)$$

频率 bin k 对应的实际频率近似为：

$$f_k = \frac{kF_s}{N} \quad (2-15)$$

其中 F_s 为采样频率。上述公式表明离散傅里叶变换将时域信号分解为频率轴上的离散分量。

在语音情绪识别中，离散傅里叶变换与快速傅里叶变换是获取频域信息的基础方法之一。但离散傅里叶变换对整个信号进行一次变换，难以直接反映频率结构随时间的变化。例如，同一段语音中，起始与结尾的基频、能量分布可能不同，而单次离散傅里叶变换会将这些差异平均化。与对整段语音进行一次傅里叶变换相比，采用短时傅里叶变换进行逐帧分析相对更为重要。傅里叶变换是解析语音频率结构的基本工具，快速傅里叶变换则是其实用化计算的关键算法。

(3) 窗函数：频谱泄漏抑制与频率分辨率权衡

在处理语音数据的时候，傅里叶变换可以将语音信号从时间幅度函数变换为时




图 2-1 傅里叶变换将时域波形转换为频域幅度谱的直观过程

间频率的函数，但是傅里叶变换会在帧的起始与结束位置产生不连续性。这种不连续性是由于实际信号被截断为有限长度所致。这种边界不连续会导致频谱泄漏，使得频谱展宽并引起相邻频率成分的相互干扰。为减轻这一影响，需要对每一帧乘以窗函数，这一过程称为加窗。

将窗函数 $w[n]$ 作用于第 m 帧 $x_m[n]$ ，得到加窗后的信号：

$$x_m^{(w)}[n] = x_m[n] \cdot w[n], \quad 0 \leq n < L \quad (2-16)$$

其中 $x_m[n]$ 为原第 m 帧， $w[n]$ 为长度为 L 的窗函数， $x_m^{(w)}[n]$ 为加窗后的帧。

在时域乘以窗函数等价于在频域进行卷积，即：

$$X_m^{(w)}(\omega) = X_m(\omega) * W(\omega) \quad (2-17)$$

其中 $X_m(\omega)$ 为原帧的频谱， $W(\omega)$ 为窗函数的频谱， $*$ 为卷积运算。窗函数的形状决定了其主瓣宽度与旁瓣衰减特性，从而影响泄漏抑制程度与频率分辨率。

汉明窗定义为：

$$w_{\text{Ham}}[n] = 0.54 - 0.46 \cos\left(\frac{2\pi n}{L-1}\right), \quad 0 \leq n < L \quad (2-18)$$

汉宁窗定义为：

$$w_{\text{Hann}}[n] = 0.5 \left(1 - \cos\left(\frac{2\pi n}{L-1}\right)\right), \quad 0 \leq n < L \quad (2-19)$$

其中 L 为窗长， n 为窗内样本索引。这两类窗函数能平滑帧两端，有效抑制频谱泄漏，较矩形窗在频谱泄漏抑制方面更为有效。汉明窗在泄漏抑制与频率分辨率之间取得较好平衡，在语音特征提取中较为常见。汉宁窗同样具有平滑特性，且窗端衰

减更平缓。

对于语音情绪识别，整体声学模式的稳定性通常比精确跟踪单一频谱峰值更受关注，汉明窗在相关任务中较为常见。

(4) 短时傅里叶变换：时频分析的桥梁

离散傅里叶变换能够揭示信号的频率构成，但难以直接反映频率结构随时间的变化。语音信号具有时变特性，情绪表达体现在特定时间区间的语调变化、能量转移、共振结构演变等方面。在语音情绪识别中，频率信息需要和时间变化趋势共同分析。短时傅里叶变换为此目的而引入，通过对短时区间逐段进行傅里叶变换，同时呈现信号的时间与频率分布。

短时傅里叶变换可理解为对信号施加滑动窗，并对每个窗内分段进行傅里叶变换。该变换的一般形式可表示为：

$$X(m, k) = \sum_{n=-\infty}^{\infty} x[n] \cdot w[n - mH] \cdot e^{-j2\pi kn/N} \quad (2-20)$$

其中 $x[n]$ 为原始离散信号， $w[n - mH]$ 为移动至第 m 个时间位置的窗函数， H 为帧移， N 为快速傅里叶变换长度， m 为时间帧索引， k 为频率 bin 索引。

结合前述分帧处理，短时傅里叶变换也可按帧表示为：

$$X(m, k) = \sum_{n=0}^{L-1} x_m[n] \cdot w[n] \cdot e^{-j2\pi kn/N} \quad (2-21)$$

其中 $x_m[n]$ 为第 m 帧信号， L 为帧长， $w[n]$ 为窗函数， N 为快速傅里叶变换长度。该表达式说明，短时傅里叶变换可视为“分帧—加窗—逐帧快速傅里叶变换”的连续过程。

短时傅里叶变换能够同时提供时间与频率信息，但该变换的时间分辨率与频率分辨率之间往往存在权衡。采用较短的窗函数可获得较好的时间分辨率，但频率分辨率可能相应降低；采用较长的窗函数则可获得更精细的频率结构，但对时间变化的响应能力相对较弱。上述时间分辨率与频率分辨率之间的权衡关系与帧移、快速傅里叶变换长度及采样频率等因素密切相关。

在语音情绪识别中，短时傅里叶变换可同时保留随时间演变的声学模式。例如，愤怒或喜悦可能伴随特定区间的能量聚集与快速的语调变化，而悲伤则可能表现为相对平缓的频谱演变。短时傅里叶变换可同时保留这些时变模式，从而为后续的谱

图、对数梅尔谱（log-Mel spectrogram）及梅尔频率倒谱系数等特征提取提供基础。短时傅里叶变换是连接语音时域与频域分析的重要中间表示之一，能够在一定程度上反映情绪表达中的时变特性。




图 2-2 傅里叶变换与短时傅里叶变换在时间信息保留方式上的差异

(5) 频谱图：时频表示的三种形式

短时傅里叶变换的输出为复数矩阵，该矩阵的维度分别为时间索引 m 与频率索引 k 。该复数表达在数学上是完整的，但在实际语音分析或模型输入中，通常将其转换为幅度或能量形式。谱图（spectrogram）即为此类时间-频率表示，同时呈现时间轴、频率轴以及各时频位置的强度，可较为清晰地展示语音信号的结构变化。

一种基本形式是幅度谱图，使用短时傅里叶变换结果的绝对值：

$$S_{\text{mag}}(m, k) = |X(m, k)| \quad (2-22)$$

其中 $X(m, k)$ 为短时傅里叶变换结果， $S_{\text{mag}}(m, k)$ 为幅度谱图值。幅度谱图反映各时频位置的振幅大小，可较为清晰地观察不同频带的相对强度差异。

功率谱图（power spectrogram）则使用幅度的平方，从能量角度进行表示：

$$S_{\text{pow}}(m, k) = |X(m, k)|^2 \quad (2-23)$$

功率谱图与信号的能量分布较为密切地相关，在许多声学特征提取中作为基础输入使用。在语音处理中，功率形式往往比幅度形式较为常见，后续的梅尔滤波器组（Mel filterbank）运算也通常基于功率谱图进行。

对数谱图（log spectrogram）通过对功率谱图取对数，压缩动态范围，使其更接近人耳听觉感知特性。最简单的对数表达形式为：

$$S_{\log}(m, k) = \log(S_{\text{pow}}(m, k) + \varepsilon) \quad (2-24)$$

其中 ε 为极小常数，用于避免对零取对数引起的数值不稳定。实际实现中有时采用 dB 刻度，即：

$$S_{\text{dB}}(m, k) = 10 \log_{10}(S_{\text{pow}}(m, k) + \varepsilon) \quad (2-25)$$

或以幅度谱图为基础的 dB 表示为：

$$S_{\text{dB-mag}}(m, k) = 20 \log_{10}(S_{\text{mag}}(m, k) + \varepsilon) \quad (2-26)$$

对数刻度能够压缩大动态范围，使得微弱频率成分相对更易被观测。

谱图是语音情绪识别中较为常用的输入表示之一^[5-6,12]。不同情绪状态下，特定频带的能量分布、谱包络、共振结构及发声强度的时变模式可能有所不同，谱图能够较为清晰地呈现这些差异。在卷积神经网络类模型中，常将谱图视作二维图像，自动学习具有情绪判别性的时频模式^[7,13]。此外，对数谱图是后续梅尔滤波器组、对数梅尔谱及梅尔频率倒谱系数等特征构建的基础。

谱图本身并不总是适合直接作为最终输入。线性频率轴难以直接反映人耳的非线性感知特性，高频区域分布了较多频率 bin^[6]。同时，谱图的分辨率与分布受短时傅里叶变换参数、窗长、帧移及变换长度等因素影响^[12]。谱图是重要的中间表示，在实际应用中还可进一步转换为梅尔尺度或倒谱系数等更具感知适应性的特征^[43]。

2.2.3 感知特征提取

(1) Mel 尺度与梅尔滤波器组

为弥补线性频率轴无法直接反映人耳听觉特性的不足，常采用梅尔尺度（Mel scale）。这是一种模拟人耳听觉感知的非线性频率刻度。线性频率 f （单位 Hz）与梅




图 2-3 幅度谱图、功率谱图与对数谱图在同一时频结构上的显示差异

尔频率 m 之间的典型转换关系为：

$$m = 2595 \log_{10} \left(1 + \frac{f}{700} \right) \quad (2-27)$$

该转换在低频区域保持相对较高的分辨率，在高频区域逐渐压缩，从而构建出更贴近听觉感知的频率轴。在语音情绪识别中，梅尔尺度有助于以类人耳的方式重构语调、共振、频带能量分布等情绪相关线索^[12,43]。

梅尔滤波器组是将梅尔尺度应用于特征提取的具体方法。通常在线性频率轴上按梅尔间隔布置多个三角形滤波器，每个滤波器对相应频带的能量进行汇总。设第 p 个梅尔滤波器为 $H_p[k]$ ，则第 m 帧第 p 个梅尔频带的能量为：

$$E_p(m) = \sum_{k=0}^{N-1} |X(m, k)|^2 H_p[k] \quad (2-28)$$

其中 $|X(m, k)|^2$ 为第 m 帧第 k 个频率 bin 的功率谱值， N 为频率 bin 总数。

梅尔滤波器组的作用在于将相邻频率区间按听觉感知特性进行整合，从而将原始精细的线性频谱压缩为相对稳定、具有感知意义的频带能量表示^[6,12]。该过程具有多个优点：一是提供更贴近人耳感知的频域表达；二是通过频带能量聚合，能在一

定程度上降低噪声敏感性；三是作为对数梅尔谱和梅尔频率倒谱系数等特征的基础，可较为便捷地与后续处理结合。

梅尔滤波器组会丢失部分精细的频率结构，对于需要精确分析窄带成分的任务可能存在局限。在语音情绪识别中，整体能量分布与听觉相似性往往更受关注，梅尔特征仍较为常见^[12,20,43]。

(2) 对数梅尔谱图：听觉感知与时频表示的融合

对梅尔滤波器组输出的各帧频带能量取对数，即得到对数梅尔谱图。可理解为将基于短时傅里叶变换的功率谱映射至梅尔刻度后，再通过取对数运算压缩动态范围。对数梅尔谱图既模拟了人耳的非线性听觉特性，又通过对数变换使能量分布更为平稳。

设梅尔滤波器组输出能量为 $E_p(m)$ ，其定义如下：

$$E_p(m) = \sum_{k=0}^{N-1} |X(m, k)|^2 H_p[k] \quad (2-29)$$

对该能量取对数，得到第 m 帧第 p 个梅尔频带的对数能量：

$$M_p(m) = \log(E_p(m) + \varepsilon) \quad (2-30)$$

其中 $M_p(m)$ 为对数梅尔谱值， ε 为极小常数，用于避免对零取对数。

实际应用中，也可采用 dB 刻度，即：

$$M_p^{(\text{dB})}(m) = 10 \log_{10}(E_p(m) + \varepsilon) \quad (2-31)$$

语音信号的能量动态范围较广。原始功率谱或梅尔滤波器组输出中，某些频带能量可能远大于其他频带，若未经处理直接使用，模型可能过度关注大值区域。对数变换可压缩动态范围，使小能量差异也能被有效保留，同时与人耳的对数响度感知特性有一定关联。对数梅尔谱是数值处理结果，也是连接物理信号与听觉感知的常用表示之一^[7,12,21]。

例如，愤怒或喜悦常伴随能量聚集与快速语调变化，而悲伤则可能表现为相对平缓的频谱演变。对数梅尔谱图能够以较为清晰的二维形式呈现这些差异，适合卷积神经网络或注意力机制学习局部模式与关键区域^[7,12-13]。尽管近年来也出现未经处理直接使用原始波形的端到端方法，但对数梅尔谱图仍是目前较为稳定、较为常用的基线特征之一^[43]。




图 2-4 梅尔谱图与对数梅尔谱图的生成关系及动态范围差异




图 2-5 对数梅尔频谱的时间-频带结构与情绪线索表达

对数梅尔谱图也存在一定的局限。梅尔刻度的信息压缩会损失部分线性频率轴的细节，滤波器数量、快速傅里叶变换长度、帧移、窗长等参数的选择也会影响最终特征的分辨率与分布^[6,12]。实际应用中需根据具体数据集与模型结构设置参数。

(3) 梅尔频率倒谱系数：从谱包络到紧凑特征

前文所述的对数梅尔谱图能反映人耳听觉特性，但仍保留了各梅尔频带的能量值。在传统语音处理中，将整体谱包络压缩为低维表示往往比直接使用频带能量更便于建模。梅尔频率倒谱系数是较为常用的倒谱特征，通过对梅尔滤波器组输出的对数能量进行离散余弦变换（Discrete Cosine Transform, DCT）得到。梅尔频率倒谱系数可视为将对数梅尔谱进一步压缩为紧凑系数向量的结果。

设第 m 帧第 p 个梅尔频带的对数能量为 $M_p(m)$ ，则第 q 个梅尔频率倒谱系数通常计算如下：

$$c_q(m) = \sum_{p=1}^P M_p(m) \cos \left[\frac{\pi q}{P} \left(p - \frac{1}{2} \right) \right], \quad 0 \leq q < Q \quad (2-32)$$

其中 $c_q(m)$ 为第 m 帧第 q 个梅尔频率倒谱系数， P 为梅尔滤波器总数， Q 为保留的系数个数。

在语音处理实践中，常保留前若干阶系数。低阶系数主要反映谱包络的整体形状，而高阶系数对细节变化和噪声相对更为敏感^[3,12,43]。

在语音情绪识别中，梅尔频率倒谱系数是较为常用的特征之一：不同情绪状态下的共振结构、谱斜率、能量分布等特征可能不同，该特征可将这些变化归纳为相对稳定的低维表示，从而在小规模数据条件下也能提供较为可靠的基线。近年来，梅尔频率倒谱系数仍较为常见地用于基准对比或作为卷积神经网络的二维输入之一^[3,12,43]。

梅尔频率倒谱系数也存在局限。作为一种谱包络的压缩表示，该特征往往难以保留对数梅尔谱图中保留的部分精细时频结构。此外，该特征的最终表现受滤波器个数、系数阶数、帧长、帧移等参数影响，高阶系数的取舍需根据具体任务合理设置。梅尔频率倒谱系数在一定条件下可作为有效特征，但其适用性取决于数据规模、模型结构及任务特点^[6,12]。

2.2.4 特征后处理与序列长度处理

(1) 特征归一化：方法、统计量范围与权衡

在语音情绪识别中，特征归一化被视为缩小不同维度特征之间尺度差异、提高学习过程中数值稳定性与收敛性的重要步骤^[3,11,15]。不同类别的语音特征在数值范围与分布上可能存在较大差异。例如，对数梅尔能量、梅尔频率倒谱系数、基频、能量、时长等特征的量纲与分布特性各不相同^[12,43]。若未经归一化处理，某些维度的数值差异可能对模型训练产生较大影响^[14]。归一化可视为在数值调整的基础上，将不同特征维度重新映射至可比且可学习范围的过程。

本文使用的 Z-score 归一化（Z-score normalization）是语音情绪识别中较为常用的归一化方法之一^[14-15]。该方法将各特征值线性变换为均值为 0、标准差为 1 的分布，定义如下：

$$z = \frac{x - \mu}{\sigma + \varepsilon} \quad (2-33)$$

其中 x 为原始特征值， μ 为均值， σ 为标准差， z 为归一化后的值， ε 为防止分母为零的极小常数。

该变换将输入特征进行中心化与尺度统一。在使用基于梯度的学习模型时，若输入分布存在一定偏斜或各维度尺度差异较大，训练过程可能出现不稳定的情况。在此类场景下，Z-score 归一化被视为语音处理中较为常用的预处理方式之一^[11,14-15]。

(2) 输入长度处理：填充、截断与分段

在语音情绪识别中，语音信号的时长并非固定不变，不同样本的发话长度存在一定的差异。大多数深度学习模型采用 mini-batch 方式进行训练，要求同一批次内的输入维度保持一致^[14-15]。如何将可变长度的序列转换为固定格式，是需要关注的问题。填充、截断与分段是处理该问题的三种常用方法^[3,11-12]。这三种方法均旨在调整

输入长度，但在信息保留方式及对模型输入结构的影响上存在差异。

填充是较为常用的方法之一，即在较短的序列末尾或特定位置填充零值或常数，使其达到目标长度^[3,11-12]。设长度为 T 的特征序列 $\mathbf{x}_t \in \mathbb{R}^d$ 需填充至目标长度 $T_{\max}$ ，则填充后的序列 $\tilde{\mathbf{x}}_t$ 可定义如下：

$$\tilde{\mathbf{x}}_t = \begin{cases} \mathbf{x}_t, & 0 \leq t < T \\ \mathbf{0}, & T \leq t < T_{\max} \end{cases} \quad (2-34)$$

其中 $\mathbf{x}_t$ 为原始时刻 t 的特征向量， $\tilde{\mathbf{x}}_t$ 为填充后的特征向量， d 为特征维度， $\mathbf{0}$ 为零向量。填充的优势在于实现较为简单，且便于适配批量训练。若填充的无信息区间过长，输入中可能包含一定比例的无意义零值，造成计算资源消耗与特征分布的不确定性增加^[11,14-15]。在发话长度差异较大的数据集中，较短样本可能大部分由填充构成^[3]。

截断是将过长的序列截断至目标长度，仅保留前 $T_{\max}$ 个时间步。其表达式为：

$$\hat{\mathbf{x}}_t = \mathbf{x}_t, \quad 0 \leq t < T_{\max} \quad (2-35)$$

其中 $\hat{\mathbf{x}}_t$ 为截断后保留的序列， $T_{\max}$ 为保留长度。截断有助于控制计算量，并简化批次构建。但截断可能丢弃后段中蕴含的情绪线索^[11,14-15]。由于情绪信息可能分布于发话的各个阶段，或在后半段更为集中，无差别的截断可能导致信息损失^[3]。

分段是将长序列划分为多个短分段进行处理的方式^[3,11-12]。设原始序列长度为 T ，每个分段长度为 C ，相邻分段起始间隔为 S ，则第 i 个分段可表示为：

$$\mathbf{c}_i = [\mathbf{x}_{iS}, \mathbf{x}_{iS+1}, \dots, \mathbf{x}_{iS+C-1}] \quad (2-36)$$

其中 $\mathbf{c}_i$ 为第 i 个分段， C 为分段长度， S 为步长。若 $S < C$ ，则相邻分段之间存在重叠，有助于减少关键信息落在分段边界上的风险。分段可在控制计算量的同时保留较多时序信息。实践中可先对各分段独立预测，再通过平均、最大值或注意力池化等方式聚合为发话级别的结果^[3,12]。

输入长度处理方式的选择，与语音情绪识别实验设计存在一定关联。填充实现较为简单，但在长度差异较大时效率较低；截断有助于降低计算量，但存在信息损失

风险；分段在信息保留与计算效率之间提供一种折中方式，同时需要额外设计分段级结果的聚合机制。输入长度处理属于实现层面的问题，也涉及情绪线索保留、模型效率与结果稳定性之间的综合权衡^[3,11,14]。




图 2-6 变长语音特征的长度处理与输入组织方式

从语音情绪识别的视角来看，输入长度处理方式在数据量较小或发话长度差异较大的数据集中具有一定影响。过度的填充可能引入一定比例的无效信息，对模型学习效率产生一定影响；过度的截断则可能丢失情绪表达的关键分段。相比之下，分段可将长序列拆分为多个分析单元，实现更细粒度的处理，在近年来的序列建模研究中受到一定关注^[6,11-12]。

2.3 现有技术

语音情绪识别领域的信号处理技术，可根据输入语音转换为何种特征表示，划分为若干改进方向^[3,11-12]。第一种改进方向采用人工设计的固定变换特征。该类方法从语音信号中提取梅尔频率倒谱系数、对数梅尔谱、谱图、基频、能量、共振峰等特征。第二种改进方向利用大规模无标注语音数据中学习的特征表示。该类方法使用 Wav2Vec2、HuBERT、WavLM 等自监督学习模型，从原始语音中提取高维特征向量^[9-10]。第三种改进方向聚焦于信号的鲁棒性。该类方法采用噪声添加、多输入添加、数据增强、去噪处理、特征增强等技术^[15]。

第一种改进方向采用人工设计的固定变换特征。该类方法从语音信号中提取多种声学特征，主要可分为时频域特征、韵律特征和发声质量特征三类^[3,11-12]。时频域特征包括通过短时傅里叶变换获得的谱图、对数梅尔谱图、梅尔频率倒谱系数等。韵律特征包括基频、能量、语速、过零率等。发声质量特征包括共振峰、微扰、shimmer、谐波比等。上述人工设计的声学特征，其优势在于能够将语音的时间、频率及发声

属性整理为相对可解释的形式^[43]。例如，基频与能量可反映语调与发话强度的变化，梅尔频率倒谱系数及频谱类特征则可较好地概括音色与频谱包络的变化。这些声学特征可与支持向量机、隐马尔可夫模型、高斯混合模型等分类器结合使用。其中，基于 OpenSMILE 提取的 eGeMAPS、ComParE、IS09 等特征集，在情绪识别研究中作为代表性基准特征集使用。该类固定变换特征方法在特征设计上对研究者的先验判断存在一定依赖，不同特征之间可能存在一定重叠，且难以通过单一固定特征集完整捕捉情绪的复杂表达。该方法通常作为基础技术路线之一，在需要更高表达能力的场景下常与其他类型方法结合使用。

第二种改进方向利用大规模无标注语音数据中学习的特征表示。该类方法使用 Wav2Vec2、HuBERT、WavLM 等自监督学习模型，从原始语音中提取高维特征向量^[29-31]。这些自监督学习模型在大规模无标注语音数据（数千小时以上）上进行预训练，学习涵盖语音信号多个层次（音素、韵律、发声特性等）的通用特征表示^[45]。例如，在 LibriSpeech 数据集（960 小时）上预训练的 Wav2Vec2 和 HuBERT 模型，可从原始语音中提取 768 维以上的特征向量。在 Libri-Light 数据集（6 万小时）上训练的大规模模型则具有更为丰富的表示能力。这种特征表示与传统人工设计特征（MFCC、log-Mel 等）不同，其特点在于通过可学习的变换自动捕捉语音信号的复杂结构。围绕语音情绪识别的下游研究已表明，自监督学习特征在冻结特征、全量微调和说话人归一化等设定下都具有较强潜力，并在噪声环境下能够提供相对稳定的表示^[9,26-28,32]。该类方法也存在一定局限。首先，预训练的语音表示未必针对情绪信息进行优化，情绪识别所需的线索与预训练目标之间可能存在差异^[10]。其次，模型规模较大，计算资源与内存消耗较高^[33-34]。此外，预训练数据与目标情绪数据之间的领域差异（语言、录音环境、用户特性等）可能影响特征表示的有效性^[46]。该类方法作为信号处理技术之一，需根据数据规模与计算条件加以选择。

第三种改进方向关注信号的鲁棒性。在实际应用环境中，噪声环境、室内多输入、麦克风质量差异、录音距离变化等多种失真因素可能影响特征提取的稳定性^[3,11,15,24]。在信号处理阶段，可采用以下技术。第一，在训练阶段应用噪声添加、多输入添加、速度扰动、基频扰动等数据增强技术，以提高模型在不同环境条件下的适应性^[9]。第二，在前处理阶段应用去噪算法，改善输入信号的质量^[25]。第三，在特征提取阶段应用选择性特征增强或鲁棒特征提取技术，获得对失真相对不敏感的特征表示。这些信号处理技术与特征表示本身的设计不同，其作用在于辅助现有特征提取方式在

实际环境中更稳定地运行。

2.4 本文采用的信号处理流程

结合前文对数据集、信号处理技术和任务难点的分析，本文实验采用以对数梅尔频谱为中心的信号处理流程。该流程不直接使用原始波形作为分类器输入，也不引入大规模自监督语音模型提取高维表示。实验先将语音整理为具有明确时频含义的二维表示，再根据不同模型的输入接口完成尺寸整理或分块组织。这样的安排有助于在计算成本、特征可解释性和模型比较一致性之间取得相对平衡^[3,11-12]。




图 2-7 本文采用的信号处理流程

(1) 输入格式统一与幅值归一化。

本文首先对原始语音进行格式统一处理。RAVDESS 语音样本原始采样率较高，实验流程中将语音统一重采样到 16kHz，并保持单声道输入形式。采样率统一后，不同语音样本在后续短时分析中具有一致的时间刻度。幅值归一化用于降低录音音量差异对特征提取的影响，使后续频谱能量分布更多反映发话本身的声学变化，而不是文件级音量尺度差异^[3,11]。

(2) 对数梅尔频谱提取。

完成基础预处理后，本文采用短时傅里叶变换和梅尔滤波器组提取对数梅尔频谱。主实验中采用 80 维梅尔频带，快速傅里叶变换长度设为 1024，帧移设为 160，在 16kHz 采样率下约对应 10ms 的时间步长。频率范围主要覆盖 0Hz 至 6000Hz 区间。对数梅尔频谱既保留语音在时间轴上的局部变化，又将频率轴整理为接近听觉感知的频带表示，适合作为卷积神经网络、Transformer 和 CNN-Conformer 模型的共同输入基础^[3,12]。

(3) 特征标准化与输入长度组织。

对数梅尔频谱提取后，本文对特征进行标准化处理，以降低不同样本之间整体

能量尺度差异带来的影响。由于语音样本长度不完全一致，输入长度处理根据模型结构有所区分。卷积神经网络基线模型采用固定尺寸谱图输入，便于与二维卷积分类器相适配；CNN-Conformer 代表配置则采用分块组织方式，将发话按固定帧数整理为局部时间块，再在推理阶段聚合得到发话级结果。上述处理方式使模型能够在控制显存开销的同时保留较多局部时间信息^[11-12]。

(4) 训练阶段的有限增强处理。

在训练阶段，本文保留较为克制的数据增强策略。对 CNN-Conformer 代表配置，实验采用频谱级混合增强，在训练样本及其标签之间进行线性插值，降低模型对少量训练样本或特定用户声学模式的依赖。该处理属于训练阶段的正则化技术，不改变推理阶段的输入流程。噪声条件实验在模型选择完成后作为补充评价进行，噪声只在评价波形阶段加入，用于观察已选代表模型在受扰输入下的变化情况^[15,24,47]。

通过上述处理，本文形成了从原始语音到模型输入的统一流程：语音格式统一、幅值归一化、对数梅尔频谱提取、特征标准化、长度组织与模型输入构造。该流程为第四章中的三类模型比较提供相同的声学输入基础，也为后续噪声条件和跨语料库评价保留了可复现的前处理口径。

2.5 本章小结

本章围绕语音情绪识别中的数据集选择与信号处理技术展开说明。首先，本章比较了常见语音情绪数据集的来源、规模、标签体系和适用条件，并结合用户数量、类别覆盖和实验可复现性，确定 RAVDESS 语音情绪数据集作为本文主要实验对象。数据集选择为后续用户无关划分、模型比较和类别层面分析提供了实验基础。

随后，本章从信号预处理、时频变换、感知特征提取、特征后处理与序列长度处理等方面整理了语音情绪识别中常用的信号处理技术。语音信号具有非平稳性和长度可变性，情绪线索又分布在能量、频谱、韵律和发声质量等多个层面。短时傅里叶变换、对数梅尔频谱、梅尔频率倒谱系数、归一化和分段处理等技术，可将原始波形转化为较适合模型学习的输入表示。

在此基础上，本章归纳了语音情绪识别面临的主要难点，包括外部环境干扰、用户与数据集分布差异、数据规模限制和类别不平衡等问题。现有技术通常从人工设计声学特征、自监督语音表示和鲁棒性增强三个方向展开。结合本文的实验条件，后续章节采用以对数梅尔频谱为中心的信号处理流程，并在相同输入基础上比较卷积

神经网络基线模型、纯 Transformer 模型和 CNN-Conformer 模型的表现。

第3章 模型结构

本章介绍语音情绪识别系统中使用的主要模型结构。经过信号处理阶段获得的 log-Mel 谱图、梅尔频率倒谱系数、韵律特征等输入表示，能够将情绪相关的声学线索整理为固定格式，但要从这些表示中判别实际情绪类别，需要合适的模型结构^[3,11]。在语音情绪识别中，模型设计涉及分类器选择的问题，同时也涉及如何学习输入特征的结构特性与时间依赖关系。

本章首先介绍语音情绪识别的基础神经网络模型结构，随后依次介绍注意力机制与 Transformer 模型。3.1 节说明全连接神经网络模型、卷积神经网络模型、循环神经网络模型及其典型变体，总结这些结构在语音情绪识别中的作用与局限。3.2 节阐述注意力机制，3.3 节介绍 Transformer 模型及其主要原理。上述介绍可为理解本研究所用模型结构提供基础。

3.1 现有基础模型结构

3.1.1 全连接神经网络模型

全连接神经网络（Fully Connected Neural Network），也称为多层感知机（Multi-Layer Perceptron, MLP），可视为一种基本的人工神经网络模型。在该结构中，每一层的每个神经元与下一层的所有神经元相互连接，输入向量经过线性变换与非线性激活函数后，逐步转换为较高层次的抽象表示。在语音情绪识别早期研究中，研究者们通常将人为设计的特征（如梅尔频率倒谱系数、基频、能量、过零率、共振峰等）组织为发话级的固定长度向量，并将其输入全连接神经网络模型，用于情绪分类^[3]。全连接神经网络模型中某一层的输出可表示为：

$$\mathbf{h}^{(l)} = \phi(\mathbf{W}^{(l)}\mathbf{h}^{(l-1)} + \mathbf{b}^{(l)}) \quad (3-1)$$

其中 $\mathbf{h}^{(l-1)}$ 为上一层的输入向量， $\mathbf{W}^{(l)}$ 为第 l 层的权重矩阵， $\mathbf{b}^{(l)}$ 为偏置向量， $\phi(\cdot)$ 为非线性激活函数， $\mathbf{h}^{(l)}$ 为当前层的输出向量。

当输入为原始特征向量 $\mathbf{x}$ ，最终输出为情绪类别的概率向量 $\hat{\mathbf{y}}$ 时，输出层通常采




图 3-1 多层感知机中固定长度声学特征向量、全连接层、偏置项和激活函数的基本关系

用 softmax 函数：

$$\hat{y}_i = \frac{\exp(z_i)}{\sum_{j=1}^C \exp(z_j)} \quad (3-2)$$

其中， z_i 为第 i 个类别的 logit， C 为情绪类别总数， $\hat{y}_i$ 为第 i 个类别的预测概率。

模型训练过程中，常采用交叉熵损失函数：

$$\mathcal{L}_{\text{CE}} = - \sum_{i=1}^C y_i \log \hat{y}_i \quad (3-3)$$

其中 y_i 为真实标签的 one-hot 编码值。

全连接神经网络模型具有结构简单、实现相对简单的特点，在输入特征维度较低时能够提供较为稳定的基线性能。通过各层的线性变换与激活函数，模型可形成非线性分类边界，从而能够处理比线性分类器更为复杂的情绪分布。

全连接神经网络模型难以保留语音信号中的时间结构与空间结构。例如，log-Mel 谱图或梅尔频率倒谱系数图中包含时间轴与频率轴上的局部模式，若将其展平为一维向量输入全连接网络，结构上的相邻关系可能被破坏。同时，参数数量随输入维度增长，可能增加过拟合风险。全连接神经网络较为适合处理发话级汇总特征，而在学习时频结构方面相对受限。

从语音情绪识别的角度来看，全连接神经网络模型仍可作为基线模型，尤其在数据规模不大且以人为设计特征为主的实验中具有解释相对简单、实现较为方便的优点。若要直接地学习情绪表示中的时间变化与局部模式，可结合后续介绍的卷积神经网络模型与循环神经网络模型^[8,12-13]。

3.1.2 卷积神经网络模型

卷积神经网络模型是一种专门用于学习输入数据局部模式的神经网络结构。在图像处理领域，卷积神经网络模型被广泛应用。在语音情绪识别中，卷积神经网络模型同样适用于分析语音的时频表示^[12]。在语音情绪识别中，log-Mel 谱图、梅尔频率倒谱系数图、谱图等二维输入表示较为常用。卷积神经网络模型可提取 log-Mel 谱图、梅尔频率倒谱系数图、谱图等二维输入表示中的局部时频模式。例如，卷积神经网络模型可自动学习特定频带的能量集中、短时内的强度变化以及局部频谱纹理差异^[13]。




图 3-2 卷积神经网络在对数梅尔谱图上通过卷积核、特征图和池化提取局部时频模式

卷积神经网络模型的主要运算是卷积。对于二维输入特征图 $\mathbf{X}$ 与卷积核 $\mathbf{K}$ ，输出特征图中一个位置的计算方式为：

$$y_{i,j}^{(k)} = \sum_{m=0}^{M-1} \sum_{n=0}^{N-1} w_{m,n}^{(k)} x_{i+m,j+n} + b^{(k)} \quad (3-4)$$

其中 $x_{i+m,j+n}$ 为输入特征图的值， $w_{m,n}^{(k)}$ 为第 k 个卷积核的权重， $b^{(k)}$ 为偏置， $y_{i,j}^{(k)}$ 为输出特征图在位置 (i,j) 的值， M, N 为卷积核尺寸。

卷积后通常使用非线性激活函数，如 ReLU：

$$\text{ReLU}(x) = \max(0, x) \quad (3-5)$$

为降低维度和增强平移不变性，常使用池化操作。例如最大池化：

$$p_{i,j}^{(k)} = \max_{(m,n) \in \Omega_{i,j}} y_{m,n}^{(k)} \quad (3-6)$$

其中 $\Omega_{i,j}$ 为池化窗口区域。卷积神经网络模型的特性包括参数共享和局部连接。同一卷积核在输入的不同位置重复使用，有助于使卷积神经网络模型的参数数量少于全连接神经网络模型，并可用于学习局部模式^[12]。

在语音情绪识别中，卷积神经网络模型具有以下优势。第一，能够捕捉谱图或对数梅尔谱图中的局部能量结构与纹理。第二，参数共享机制使得在有限数据条件下可获得一定的泛化能力。第三，通过堆叠多个卷积层，可逐步从低级特征学习到高级语义特征^[12-13]。

卷积神经网络模型存在一定局限性。卷积操作主要在局部感受野内学习模式，难以建模发话过程中的长期依赖关系或全局上下文^[8]。此外，反复使用池化操作可能降低时间分辨率。若情绪线索分布在发话中相距较远的多个片段之间，仅依靠卷积神经网络模型可能不足以充分表示。一些语音情绪识别研究将卷积神经网络模型与循环神经网络、注意力机制或 Transformer 模型结合，以补充长期上下文信息^[6]。

3.1.3 循环神经网络模型及其变体

循环神经网络模型可视为一种为建模时间序列数据的顺序结构而设计的神经网络模型。全连接神经网络模型和卷积神经网络模型能够处理输入的静态结构或局部模式，循环神经网络模型则相对有利于反映时间点之间的依赖关系和顺序信息^[3]。在语音情绪识别中，情绪可能通过发话过程中的基频轮廓变化、能量轮廓的上升与下降、停顿与发音模式的累积效应等表现出来。时间序列建模具有一定作用^[11]。

基本循环神经网络模型的隐藏状态更新可表示为：

$$\mathbf{h}_t = \phi(\mathbf{W}_{xh}\mathbf{x}_t + \mathbf{W}_{hh}\mathbf{h}_{t-1} + \mathbf{b}_h) \quad (3-7)$$

其中 $\mathbf{x}_t$ 为 t 时刻的输入向量， $\mathbf{h}_{t-1}$ 为上一时刻的隐藏状态， $\mathbf{W}_{xh}$ 为输入-隐藏权重矩阵， $\mathbf{W}_{hh}$ 为隐藏-隐藏权重矩阵， $\mathbf{b}_h$ 为偏置向量， $\phi(\cdot)$ 为激活函数， $\mathbf{h}_t$ 为当前时刻的隐藏状态。

输出通常定义为：

$$\mathbf{y}_t = \psi(\mathbf{W}_{hy}\mathbf{h}_t + \mathbf{b}_y) \quad (3-8)$$




图 3-3 循环神经网络沿时间帧递推隐藏状态并形成发话级上下文表示

其中 $\mathbf{W}_{hy}$ 为隐藏-输出权重矩阵， $\mathbf{b}_y$ 为输出偏置， $\psi(\cdot)$ 为输出函数。

循环神经网络模型能够处理时间序列结构。在处理长序列时，该模型可能出现梯度消失或梯度爆炸问题。为缓解梯度消失或梯度爆炸问题，长短期记忆网络模型和门控循环单元模型被提出^[11]。长短期记忆网络模型通过输入门、遗忘门、输出门映射信息流动。典型公式如下：

$$\mathbf{f}_t = \sigma(\mathbf{W}_f[\mathbf{h}_{t-1}, \mathbf{x}_t] + \mathbf{b}_f) \quad (3-9)$$

$$\mathbf{i}_t = \sigma(\mathbf{W}_i[\mathbf{h}_{t-1}, \mathbf{x}_t] + \mathbf{b}_i) \quad (3-10)$$

$$\tilde{\mathbf{c}}_t = \tanh(\mathbf{W}_c[\mathbf{h}_{t-1}, \mathbf{x}_t] + \mathbf{b}_c) \quad (3-11)$$

$$\mathbf{c}_t = \mathbf{f}_t \odot \mathbf{c}_{t-1} + \mathbf{i}_t \odot \tilde{\mathbf{c}}_t \quad (3-12)$$

$$\mathbf{o}_t = \sigma(\mathbf{W}_o[\mathbf{h}_{t-1}, \mathbf{x}_t] + \mathbf{b}_o) \quad (3-13)$$

$$\mathbf{h}_t = \mathbf{o}_t \odot \tanh(\mathbf{c}_t) \quad (3-14)$$

其中 $\mathbf{f}_t$ 为遗忘门， $\mathbf{i}_t$ 为输入门， $\tilde{\mathbf{c}}_t$ 为候选细胞状态， $\mathbf{c}_t$ 为细胞状态， $\mathbf{o}_t$ 为输出门， $\sigma(\cdot)$ 为 sigmoid 函数， $\odot$ 为逐元素乘法。

门控循环单元模型具有相对更简单的门控结构：

$$\mathbf{z}_t = \sigma(\mathbf{W}_z[\mathbf{h}_{t-1}, \mathbf{x}_t] + \mathbf{b}_z) \quad (3-15)$$

$$\mathbf{r}_t = \sigma(\mathbf{W}_r[\mathbf{h}_{t-1}, \mathbf{x}_t] + \mathbf{b}_r) \quad (3-16)$$

$$\tilde{\mathbf{h}}_t = \tanh(\mathbf{W}_h[\mathbf{r}_t \odot \mathbf{h}_{t-1}, \mathbf{x}_t] + \mathbf{b}_h) \quad (3-17)$$

$$\mathbf{h}_t = (1 - \mathbf{z}_t) \odot \mathbf{h}_{t-1} + \mathbf{z}_t \odot \tilde{\mathbf{h}}_t \quad (3-18)$$

其中 $\mathbf{z}_t$ 为更新门， $\mathbf{r}_t$ 为重置门， $\tilde{\mathbf{h}}_t$ 为候选隐藏状态。

双向循环神经网络模型包括双向长短期记忆网络模型和双向门控循环单元模型。双向循环神经网络模型同时学习正向和反向序列，可使当前时刻的表示反映过去和

未来的上下文。双向隐藏表示可通过拼接得到：

$$\mathbf{h}_t = [\vec{\mathbf{h}}_t; \overleftarrow{\mathbf{h}}_t] \quad (3-16)$$

其中 $\vec{\mathbf{h}}_t$ 为正向隐藏状态， $\overleftarrow{\mathbf{h}}_t$ 为反向隐藏状态， $[\cdot; \cdot]$ 表示向量拼接。

在语音情绪识别中，循环神经网络模型可反映时间连续性与长期上下文。例如，某些情绪可能通过整个发话的速度变化、语调的累积走向、句尾的情绪处理等得到充分的体现。循环神经网络模型、长短期记忆网络模型、门控循环单元模型可处理这类顺序信息。双向长短期记忆网络模型或双向门控循环单元模型能够利用发话前后的上下文，在语音情绪识别中被一些研究采用^[11,13]。

循环神经网络模型存在一定局限。第一，顺序计算结构可能导致并行效率相对较低，在处理较长序列时计算成本可能增加。第二，长短期记忆网络模型和门控循环单元模型缓解了基本循环神经网络模型的长期依赖问题。在极长序列中，循环神经网络模型难以充分覆盖部分关键区间。第三，对于发话中哪些区间对情绪判断更为关键，循环神经网络模型缺乏选择性强调的机制。

3.2 注意力机制

在语音情绪识别中，有研究指出情绪信息可能以不均匀的方式分布于整个发话，相对集中于特定的时间区间、特定的频率范围或特定的声学模式之中^[5,21,48-49]。卷积神经网络模型和循环神经网络模型可用于学习语音表示；在采用统一权重处理输入各部分时，模型可能难以充分区分与情绪判断相关性相对较高的区间^[8,12-13]。注意力机制作为一种计算输入内部相关性并据此调整信息组合权重的结构方法，被引入语音情绪识别中。注意力机制通过相关性计算与加权聚合来重新分配信息重要性，既包括基于查询、键、值计算输入元素之间关系的注意力结构，也包括根据查询与键-值来源不同区分的自注意力和交叉注意力；根据注意力分数的计算方式，可使用缩放点积注意力或加性注意力；根据结构的并行化或作用范围，可使用多头注意力或局部注意力等扩展形式^[6-7]。

本节首先介绍注意力机制的基本概念与关键要素，说明查询、键、值的含义以及自注意力与交叉注意力的区别。随后介绍两种典型的注意力分数计算方法：缩放点积注意力和加性注意力。然后讨论多头注意力和局部注意力等结构扩展方式。最后总结注意力机制在语音情绪识别中的作用，并讨论其在数据规模、计算复杂度和

可解释性等方面的局限。




图 3-4 注意力机制通过查询、键和值计算相关性权重并突出关键语音片段

3.2.1 注意力机制的基本概念与关键要素

注意力机制可理解作为一种计算输入序列或特征图中各元素之间相关性，并根据计算结果调整信息组合权重的通用方法^[5,49]。在语音情绪识别中，情绪线索并非均匀分布于整个发话，通常相对集中于特定时间区间、特定频率范围或特定声学模式^[21,48]。基于这一特性，注意力机制通过计算输入内部元素之间的关联程度，并据此重新分配信息重要性，从而更有选择性地反映与情绪判断相关性较高的区间。

在注意力计算过程中，首先需要定义用于量化各输入元素之间相关性的注意力分数。设输入序列中第 i 个元素与第 j 个元素的相关性得分为 e_{ij} ，注意力机制通常对这些得分进行归一化后计算加权和。该过程的一般形式可表示为：

$$e_{ij} = a(q_i, k_j) \quad (3-19)$$

$$\alpha_{ij} = \frac{\exp(e_{ij})}{\sum_{j'=1}^T \exp(e_{ij'})} \quad (3-20)$$

$$z_i = \sum_{j=1}^T \alpha_{ij} v_j \quad (3-21)$$

其中 $a(\cdot, \cdot)$ 为相关性计算函数， q_i 为第 i 个查询， k_j 为第 j 个键， v_j 为第 j 个值。 e_{ij}

为归一化之前的注意力分数， α_{ij} 为通过 **softmax** 归一化得到的注意力权重， z_i 为最终的注意力输出。注意力分数可视为决定各元素在输出中比重的中间变量。后续小节介绍的缩放点积注意力和加性注意力，区别在于如何定义 $a(\cdot, \cdot)$ 函数^[6-7,21]。

在注意力计算中，查询、键、值是常用的基本元素。设输入表示为矩阵 X ，注意力机制通常从 X 或不同输入表示构造查询矩阵 Q 、键矩阵 K 、值矩阵 V ，并计算它们之间的相关性。基础的线性变换形式可表示为：

$$Q = X_Q W_Q, \quad K = X_K W_K, \quad V = X_V W_V \quad (3-22)$$

其中 X_Q 、 X_K 、 X_V 分别为用于生成查询、键、值的输入表示， W_Q 、 W_K 、 W_V 为可学习的权重矩阵。当三个输入表示相同时，这一结构用于计算单一输入内部的元素关系。当三个输入表示不同时，则用于计算不同表示之间的元素关系。从这一角度看，查询表示当前关注的对象，键表示被比较的参考信息，值表示最终被聚合的内容^[6-7,21]。

根据查询、键、值的来源，注意力可分为自注意力和交叉注意力。自注意力是指查询、键、值均来自同一输入表示的结构。其一般形式可写为：

$$Q = X W_Q, \quad K = X W_K, \quad V = X W_V \quad (3-23)$$

$$\text{SelfAttention}(X) = \text{Attention}(Q, K, V) \quad (3-24)$$

其中 X 为一个输入序列或时频特征表示。自注意力用于计算同一输入内部各位置之间的相关性，可反映输入序列的全局关系。在语音情绪识别中，自注意力可建模特定时间帧与其他帧之间的情绪关联，从而选择性地强调对情绪判断较重要的区间^[5-6,49]。

交叉注意力则是指查询与键-值对来自不同输入表示的结构。其一般形式可写为：

$$Q = X W_Q, \quad K = Y W_K, \quad V = Y W_V \quad (3-25)$$

$$\text{CrossAttention}(X, Y) = \text{Attention}(Q, K, V) \quad (3-26)$$

其中 X 和 Y 为不同的输入表示。交叉注意力用于建模一个表示与另一个表示之间的交互，可反映不同特征空间或不同声学表示之间的相关性。在语音情绪识别中，当同时使用梅尔频率倒谱系数、对数梅尔谱图或 wav2vec 系列表示时，交叉注意力可

用于学习多种异质表示之间的关联^[21,49]。

3.2.2 代表性的注意力分数计算方式

注意力可视为将输入元素之间的相关性量化为注意力分数，并通过归一化形成加权和的机制。注意力分数的计算方式是决定注意力行为特性的关键因素。当前较为常用的注意力分数计算方法主要包括缩放点积注意力和加性注意力。两种方法均通过查询与键之间的相关性计算分数，但在分数计算函数的结构与特性上存在差异^[5-7,50]。

缩放点积注意力基于查询与键的点积计算注意力分数。设输入序列中第 i 个查询为 q_i ，第 j 个键为 k_j ，则注意力分数可表示为：

$$e_{ij} = \frac{q_i k_j^\top}{\sqrt{d_k}} \quad (3-27)$$

其中 $q_i k_j^\top$ 为查询与键的点积， d_k 为键向量的维度。除以 $\sqrt{d_k}$ 的原因在于：随着维度增加，点积值的方差可能增大，从而导致 softmax 输出趋于极端分布。缩放点积注意力中的缩放因子可视为提高学习稳定性的修正项^[6-7,50]。

计算得到的分数在后续步骤中仍通过 softmax 归一化形成注意力权重，并与值向量加权聚合，其过程与式 (3-20) 和式 (3-21) 所示的一般形式一致。缩放点积注意力的矩阵形式可表示为：

$$\text{Attention}(Q, K, V) = \text{softmax} \left(\frac{QK^\top}{\sqrt{d_k}} \right) V \quad (3-28)$$

其中 $QK^\top$ 表示查询矩阵与键矩阵之间的点积结果， $\sqrt{d_k}$ 为缩放因子。该形式将注意力分数计算、归一化与加权聚合统一表示为一个矩阵运算过程^[6-7,50]。




图 3-5 缩放点积注意力中的查询、键、值计算流程

缩放点积注意力的特点在于分数计算基于矩阵乘法。这种计算方式相对有利于并行计算，在实际实现中可能在计算效率和内存使用方面具有一定优势^[6-7,50]。在语音情绪识别中，缩放点积注意力可用于反映特定时间帧或局部区域与其他位置之间的情绪相关性，从而相对突出地强调发话中的关键区间^[21]。

加性注意力通过非线性变换计算分数，不使用查询与键的点积。其一般形式可表示为：

$$e_{ij} = v_a^\top \tanh(W_q q_i + W_k k_j + b_a) \quad (3-29)$$

其中 W_q 和 W_k 分别为查询与键的权重矩阵， b_a 为偏置向量， v_a 为用于计算最终分数的可学习向量。该公式可理解为：先对查询与键分别进行线性变换，再通过非线性函数 $\tanh(\cdot)$ 得到分数^[5]。

加性注意力在分数计算后的归一化与加权聚合过程，与式 (3-20) 和式 (3-21) 所示的一般注意力形式一致。与缩放点积注意力相比，加性注意力的主要差异体现在注意力分数构造阶段：该方法使用显式线性变换与非线性函数计算分数^[5]。

在语音情绪识别中，加性注意力可进一步应用于循环神经网络模型的输出或局部隐藏状态集合，从而突出与情绪判断相关性较高的时刻。例如，在 IEMOCAP 等数据集上，加性注意力与局部注意力结合使用的案例表明，可通过设计注意力分数函数相对更有针对性地强调发话中的特定区间^[5]。

3.2.3 注意力的结构类型与扩展方式

在实际应用中，注意力机制的结构设计需考虑单次注意力运算的并行化方式，以及计算范围是全局还是局部。多头注意力和局部注意力保持原有的注意力分数计算方式，是对已计算注意力的扩展，分别将注意力应用于不同的表示空间或不同的计算范围^[5-7,50]。

仅使用单头注意力时，输入内部的各种关系需要在同一个权重结构中得到反映，此时可能难以充分分离不同类型的信息。为缓解上述问题，研究者们提出了多头注意力^[6-7,50]。多头注意力将单次注意力运算并行化为多个头部，使模型能够在不同的表示子空间中同时学习多种类型的关系。

设头部数量为 h ，第 i 个头部可表示为：

$$\text{head}_i = \text{Attention}(QW_i^Q, KW_i^K, VW_i^V) \quad (3-30)$$

其中 W_i^Q 、 W_i^K 、 W_i^V 分别为第 i 个头部的查询、键、值变换矩阵。各头部使用不同的权重矩阵，即使输入表示相同，也能从不同角度学习相关性。所有头部的输出经拼接后，再通过一次线性变换得到最终结果：

$$\text{MultiHead}(Q, K, V) = \text{Concat}(\text{head}_1, \text{head}_2, \dots, \text{head}_h)W^O \quad (3-31)$$

其中 W^O 为输出变换矩阵。该结构使模型能够并行反映比单头注意力更多类型的关系^[6-7,50]。

在语音情绪识别中，情绪线索可能出现在语调变化、能量分布、频率结构、长期上下文等多个层面，也可能存在于单一维度。基于情绪线索的多维特性，部分头部可能对语调变化或能量分布较为敏感，另一些头部则可能更关注频率结构或长期上下文关系。多头注意力可用于同时反映语音信号中的多层次情绪线索^[2,6-7,21]。

多头注意力在能够处理更多关系的同时，头部数量的增加也可能导致参数数量和计算量相应上升。在数据规模有限的条件下，增加头部数量不一定带来性能提升，模型复杂度的增加可能对泛化能力造成一定负担^[6-7,11,18,23]。在语音情绪识别中，需要结合输入长度、数据规模、计算资源等因素设定头部数量与模型复杂度。

当序列较长时，计算各位置对之间的注意力权重可能导致计算开销增加。有研究指出，在语音情绪识别中情绪线索往往集中在局部区间，而不是均匀分布。在整个输入范围上计算注意力不一定是合适的结构^[5-6]。局部注意力仅在某个中心位置周围的有限窗口内计算注意力权重。

局部注意力将注意力的作用范围限制在窗口 w 内。例如，当 $|i - j| > w$ 时，可将对应位置的得分设为 $-\infty$ ，从而在后续 softmax 中忽略这些位置。其表达式为：

$$e_{ij} = \begin{cases} a(q_i, k_j), & |i - j| \leq w \\ -\infty, & |i - j| > w \end{cases} \quad (3-32)$$

其中 $a(q_i, k_j)$ 对应式 (3-27) 或式 (3-29) 所示的注意力分数函数。应用 softmax 后，在窗口内部形成注意力权重。局部注意力保持分数计算方式不变，仅对注意力的作用范围进行结构性限制。

局部注意力的优势在于通过限制计算范围来降低整体计算量。全局注意力需要计算所有位置对之间的交互，计算量与序列长度的平方成正比。局部注意力仅考虑窗口内的交互，可相对减少计算负担^[6]。在语音情绪识别中，局部注意力有助于反映发话中的局部信息，如短时语调变化、能量突变区间或特定时刻的声学模式^[5]。

在实际研究中，局部注意力曾被应用于循环神经网络模型的隐藏状态集合，以突出发话中的关键时刻。在基于 Transformer 的模型中，也有动态窗口或移位窗口等变体，用于结构性调整注意力的作用范围^[5-7]。窗口过小可能难以反映长距离关系，窗口过大则可能削弱局部注意力的计算效率优势。局部注意力宜结合应用范围、输入长度以及情绪线索的分布特性进行适当设置。

3.3 Transformer 结构

注意力机制可理解为计算输入内部相关性并根据计算结果对信息进行加权组合的结构。注意力是一种计算机制，如何将其组织到实际的时间序列模型中，是独立的设计问题。Transformer 模型以注意力机制为主要结构，结合编码器-解码器结构、位置信息补充、残差连接、层归一化以及位置级前馈网络，作为一种模型结构被提出^[50]。

传统的循环神经网络按时间顺序更新隐藏状态，以此处理时间序列信息。卷积神经网络则基于局部感受野逐步提取相邻区间的模式。Transformer 模型通过基于注意力的交互来构建输入序列内部的全局关系，不依赖于循环结构或卷积运算^[50]。在语音情绪识别中，基于这些结构特性，Transformer 类模型逐渐得到应用，同时出现了调整输入表示单元和计算范围的多种变体结构^[6-7,23]。本节首先介绍 Transformer 模型的整体结构以及编码器与解码器的基本信息流动。随后说明位置信息如何补充到输入表示中，接着阐述 Transformer 层内部关键组件的作用。

3.3.1 Transformer 的整体架构

Transformer 模型基于编码器与解码器构成的堆叠结构。各编码器层与解码器层采用相同的内部结构重复堆叠，输入表示经过这些重复结构逐步转换为融合上下文信息的高维表示^[50]。最初的 Transformer 模型针对序列到序列的转换任务提出，同时使用编码器和解码器。编码器从输入序列中提取上下文表示，解码器则参考编码器的输出逐步生成目标序列。

设输入表示为 $X \in \mathbb{R}^{T \times d}$ ，编码器依次通过多个编码器层，逐步反映输入序列的内部关系。这一过程可按层表示如下：

$$H^{(0)} = X \quad (3-33)$$




图 3-6 参考原始 Transformer 结构重绘的编码器、解码器及语音情绪识别中编码器分类路径

$$H^{(l)} = \text{EncoderLayer}^{(l)}(H^{(l-1)}), \quad l = 1, 2, \dots, L_e \quad (3-34)$$

其中 $H^{(0)}$ 为编码器的初始输入表示， $H^{(l)}$ 为第 l 个编码器层的输出， L_e 为编码器层数。通过这种重复结构，输入序列中各个位置的表示逐渐融入更广的上下文信息^[50]。

解码器接收目标序列或对应的中间表示作为输入，同时参考编码器的输出表示，逐步生成下一阶段输出。解码器的信息流动可一般地表示为：

$$S^{(0)} = Y \quad (3-35)$$

$$S^{(l)} = \text{DecoderLayer}^{(l)}(S^{(l-1)}, H^{(L_e)}), \quad l = 1, 2, \dots, L_d \quad (3-36)$$

其中 Y 为解码器侧的输入表示， $S^{(l)}$ 为第 l 个解码器层的输出， L_d 为解码器层数。解码器在反映目标序列内部信息的同时，通过参考编码器的最终输出 $H^{(L_e)}$ ，形成输入序列与输出序列之间的对应关系^[50]。

Transformer 结构的一个特点是，它不像循环神经网络模型那样按时间步顺序更新状态。循环神经网络模型依赖上一时刻的隐藏状态计算当前时刻的表示，整个序列处理本质上是顺序的。Transformer 可以在同一层内同时计算序列中多个位置之间的相关性，有利于并行计算^[50]。

在处理长距离依赖关系的方式上，Transformer 与传统模型结构存在差异。循环神经网络模型中，相距较远的两个时间点之间的信息需要经过多个时间步的状态传递，序列越长信息传递路径越长。卷积神经网络模型同样通过逐步扩大局部感受野来融入更广的上下文，若要反映较大范围的关系，可能需要增加层数或引入额外结构。Transformer 通过注意力运算可以计算远距离位置之间的相关性，从而相对地建模输入内部的全局关系^[6-7,50]。

语音情绪识别通常是对整个发话进行分类的任务，原始 Transformer 的编码器-解码器结构常被简化为以编码器为中心的形式或进行适当变形^[6-7,23]。在此情况下，可在编码器的最终输出上结合池化或分类头，进行发话级别的预测。该过程可概念性地表示为：

$$\hat{y} = \text{Classifier}(\text{Pool}(H^{(L_e)})) \quad (3-37)$$

其中 $\text{Pool}(\cdot)$ 表示形成发话级表示的操作，如平均池化、注意力池化或基于分类标记的聚合等， $\hat{y}$ 为最终的预测情绪类别。近年来，在语音情绪识别研究中，人们提出在

以编码器为中心的结构之上，结合基于窗口的注意力、分层补丁表示或与卷积神经网络混合的结构，以调整计算范围和表示单元^[6-8,23]。

3.3.2 位置编码机制

Transformer 的注意力运算适合计算输入向量之间的相关性，但注意力运算本身不反映序列的顺序。当给定一组相同的输入向量时，若未提供位置信息，模型难以从结构上区分位置 1 与位置 10 的差异。在原始 Transformer 模型中，通过在输入嵌入中加入位置编码来缓解位置信息的缺失^[50]。

较为常见的固定型位置编码使用正弦函数和余弦函数为每个位置构造对应的向量。设位置索引为 pos ，维度索引为 i ，总维度为 d ，固定型位置编码通常可定义为^[50]：

$$PE(pos, 2i) = \sin\left(\frac{pos}{10000^{2i/d}}\right) \quad (3-38)$$

$$PE(pos, 2i + 1) = \cos\left(\frac{pos}{10000^{2i/d}}\right) \quad (3-39)$$

其中偶数维度使用正弦函数，奇数维度使用余弦函数。这种构造方式利用不同周期的周期函数，以连续形式表示各个位置。当位置距离发生变化时，各维度的变化模式也随之不同，模型可同时利用绝对位置信息以及位置之间的相对差异信息^[50]。

设输入表示为 $X \in \mathbb{R}^{T \times d}$ ，位置编码矩阵为 $PE \in \mathbb{R}^{T \times d}$ ，融合位置信息后的最终输入可表示为：

$$X' = X + PE \quad (3-40)$$

其中 X' 为补充位置信息后的输入表示。通过这种加法结构，原始输入特征与位置信息在同一维度空间中共同传递。后续注意力运算除了比较各位置的特征值，还计算包含位置信息的表示之间的相关性^[50]。

与固定型位置编码经常被一起提及的是可学习型位置嵌入。可学习型位置嵌入将位置向量作为模型参数，在训练过程中直接更新。这种方式不使用预先通过固定函数计算每个位置向量的方法。用矩阵形式可表示为：

$$P \in \mathbb{R}^{T \times d} \quad (3-41)$$

$$X' = X + P \quad (3-42)$$

其中 P 为可学习的位置嵌入矩阵。可学习型方法的优势在于能根据数据和任务特性调整位置表示本身。由于位置向量可能适应训练数据的长度分布，当推广到训练中未出现的长序列时，其行为可能与固定型方法有所不同^[50]。

在语音情绪识别中，位置编码的含义与自然语言处理存在差异。自然语言处理中通常反映单词或子词标记的顺序，语音情绪识别中的输入单元往往是对数梅尔谱图的帧序列、梅尔频率倒谱系数序列或基于补丁的频谱表示^[6-7,23]。在此情况下，位置编码用于表示每个帧或每个补丁在发话中的时间位置。即使相同的频率结构出现，该频率结构出现在发话早期、中期还是后期，其情绪含义可能不同。补充位置信息可视为反映时间序列结构的一个因素。

3.3.3 Transformer 层中的关键组成结构

Transformer 的编码器和解码器由注意力子层堆叠而成。Transformer 的一层由注意力运算和用于表示重组、层间信息传递稳定的补充结构共同构成。在原始 Transformer 中，每个注意力子层之后依次应用残差连接与层归一化，随后放置位置级前馈网络，之后再次应用残差连接与层归一化^[50]。

以一个编码器层为例，输入表示 $H^{(l-1)}$ 首先经过多头自注意力子层，该子层的输出通过残差连接与层归一化更新为中间表示 $\tilde{H}^{(l)}$ 。这个中间表示随后通过位置级前馈网络，再次经过残差连接与层归一化，形成最终输出 $H^{(l)}$ 。该过程可表示为：

$$\tilde{H}^{(l)} = \text{LayerNorm}(H^{(l-1)} + \text{MHA}(H^{(l-1)})) \quad (3-43)$$

$$H^{(l)} = \text{LayerNorm}(\tilde{H}^{(l)} + \text{FFN}(\tilde{H}^{(l)})) \quad (3-44)$$

其中 $\text{MHA}(\cdot)$ 表示该编码器层的多头自注意力子层， $\text{FFN}(\cdot)$ 表示位置级前馈网络。在编码器层内部，首先通过自注意力反映同一输入序列内部的相关性，随后各位置的表示独立经过非线性变换，形成最终输出^[50]。

解码器层的内部结构与之类似，但多了一个注意力子层。在解码器中，首先通过掩码多头自注意力反映目标序列内部的自相关性，然后通过一个注意力子层反映解码器表示与编码器最终输出之间的对应关系，之后应用位置级前馈网络。该过程可整理为：

$$\bar{S}^{(l)} = \text{LayerNorm}(S^{(l-1)} + \text{MaskedMHA}(S^{(l-1)})) \quad (3-45)$$




图 3-7 Transformer 编码器层的基本信息流动

$$\tilde{S}^{(l)} = \text{LayerNorm}(\bar{S}^{(l)} + \text{MHA}(\bar{S}^{(l)}, H^{(L_e)})) \quad (3-46)$$

$$S^{(l)} = \text{LayerNorm}(\tilde{S}^{(l)} + \text{FFN}(\tilde{S}^{(l)})) \quad (3-47)$$

其中 $\text{MaskedMHA}(\cdot)$ 表示限制未来时刻信息直接参与的掩码自注意力子层, $\text{MHA}(\bar{S}^{(l)}, H^{(L_e)})$ 表示解码器表示参考编码器最终输出的注意力子层。在解码器层内部, 目标序列内部的自相关性与输入序列的对应关系被依次反映, 随后通过前馈网络更新各位置表示^[50]。

位置级前馈网络的作用是将注意力形成的上下文信息在各位置表示层面进行再变换。这种网络对已通过注意力融入上下文信息的每个位置向量施加相同的非线性变换。该网络不直接计算序列中不同位置之间的关系。其一般形式为:

$$\text{FFN}(x) = W_2 \sigma(W_1 x + b_1) + b_2 \quad (3-48)$$

其中 x 为某一位置的输入向量, W_1 、 W_2 为权重矩阵, b_1 、 b_2 为偏置向量, $\sigma(\cdot)$ 为非线性激活函数。该步骤可视为在注意力聚合的上下文信息基础上对每个位置表示进行进一步重组^[50]。

残差连接将子层的输入表示直接加到变换结果上。其一般形式为:

$$y = x + \mathcal{F}(x) \quad (3-49)$$

其中 x 为子层输入, $\mathcal{F}(x)$ 为经过注意力或前馈网络后的变换结果。残差连接在保留原始输入信息的同时加入变换结果, 有助于缓解深层网络中信息过度衰减的问题^[50]。

层归一化对每个位置表示向量内部的各维度计算均值和方差, 并据此对表示进行尺度归一化。其一般形式为:

$$\mu = \frac{1}{d} \sum_{i=1}^d x_i \quad (3-50)$$

$$\sigma^2 = \frac{1}{d} \sum_{i=1}^d (x_i - \mu)^2 \quad (3-51)$$

$$\text{LayerNorm}(x) = \gamma \odot \frac{x - \mu}{\sqrt{\sigma^2 + \epsilon}} + \beta \quad (3-52)$$

其中 $x \in \mathbb{R}^d$ 为某位置的输入向量， μ 和 σ^2 分别为该向量的均值和方差， ϵ 为防数值不稳定的小常数。 γ 和 β 为可学习的缩放与平移参数， $\odot$ 表示逐元素乘法。层归一化在每个位置的表示向量内部进行归一化，对序列长度和批次大小的变化相对不敏感^[50]。

3.3.4 Transformer 的主要特点及其适用边界

Transformer 的第一个特点在于它相对有利于并行计算。循环神经网络模型中，当前时刻的计算依赖于前一时刻的状态，整个处理过程通常是顺序的。Transformer 通过自注意力机制可以同时计算多个位置之间的相关性，在输入长度相同时，其计算结构可以相对并行化地组织^[50]。当发话长度增加到一定程度，或采用帧级、补丁级输入时，这一并行计算特性可能在一定程度上简化计算流程^[6-7]。

Transformer 的第二个特点在于它能够直接建模输入内部的全局关系。循环神经网络中，相距较远的位置之间的信息需要经过多个时间步的状态传递。卷积神经网络则需要通过逐步扩大局部感受野来拓宽上下文范围。Transformer 通过自注意力机制可以计算远距离位置之间的相关性，从而将分布在整个发话中的情绪线索整合到一个结构中^[50]。在语音情绪识别中，情绪信息可能分布在发话的多个时刻及多个时间尺度上。这种全局建模特性与发话级分类任务具有一定的相关性^[6-7]。

Transformer 的优势表现与具体条件有关。随着输入长度增加，注意力计算范围扩大，计算量和内存占用可能相应增加^[50]。在语音情绪识别中，帧级序列可能较长；若采用高分辨率频谱表示或多特征融合，输入标记数量会进一步增多。在此情况下，应用原始 Transformer 结构不一定总是高效的选择，实际研究中已提出基于窗口的注意力、移位窗口、分层补丁表示等结构调整方法^[6-7]。

Transformer 的结构表达能力较强，Transformer 的稳定性受数据规模和任务条件影响。语音情绪识别数据通常规模不大，情绪类别之间的界限也可能不够清晰。在此类条件下，结构复杂的模型可能同时学习到情绪相关模式以及数据集本身的偏差。近年来，研究者提出调整输入范围、使用分层表示或结合多任务学习等方式，在跨

语料库条件下提高泛化能力，不单纯扩大 Transformer 结构本身^[6-7,23]。




图 3-8 Transformer 在语音情绪识别中的适用边界

3.4 本章小结

本章围绕语音情绪识别模型结构展开说明，依次介绍了基础神经网络模型、注意力机制和 Transformer 结构。前馈神经网络能够处理固定维度特征表示，但对语音序列中的局部时频模式和长时依赖关系刻画较为有限。卷积神经网络通过局部感受野和参数共享机制提取二维谱图中的局部模式，在对数梅尔频谱输入条件下具有较好的结构适配性。循环神经网络、长短时记忆网络和门控循环单元则从时间递推角度处理序列信息，为语音情绪识别中的时序建模提供了基础方案。

在注意力机制部分，本章说明了注意力得分、权重归一化和加权求和的基本过程，并进一步讨论了自注意力、多头注意力以及注意力池化等结构。注意力机制的作用在于根据输入内部不同位置之间的相关性重新分配信息权重，使模型能够从发话中筛选与情绪判断关系较大的片段。对于语音情绪识别任务，注意力机制既可作为序列编码器内部的关系建模方式，也可作为发话级表示聚合方法。

在 Transformer 结构部分，本章介绍了编码器结构、位置编码、残差连接、层归一化和位置级前馈网络等组成部分。Transformer 通过自注意力机制计算序列内部不同位置之间的关系，适合刻画较长范围的上下文信息；但在语音情绪识别这类数据规模相对有限的任务中，纯注意力结构也可能面临局部声学线索不足和训练稳定性不足的问题。基于上述分析，第四章将卷积神经网络基线模型、纯 Transformer 模型和 CNN-Conformer 模型作为主要比较对象，用实验结果检验局部时频建模、全局上下文建模以及二者组合后的表现差异。

第 4 章 实验设计与实验分析

本章围绕对数梅尔频谱输入条件下的语音情绪识别实验展开，比较对象包括卷积神经网络基线模型、纯 Transformer 模型以及 CNN-Conformer 模型。前文已经分别介绍了语音信号处理方法、注意力机制与 Transformer 相关结构，本章不再重复相关理论，主要说明实验对象、结构实现、训练设置以及结果分析。

本章的实验内容可以分为两个层面。第一个层面是在统一输入表示、训练框架与评价指标下比较卷积神经网络基线模型、纯 Transformer 模型以及 CNN-Conformer 模型的综合表现。第二个层面是围绕 CNN-Conformer 模型继续展开结构调整、过拟合缓解、噪声条件评价和跨语料库评价。按照这一安排，本章先给出实验参数、输入组织方式、模型结构与实现环境，再报告综合实验结果，随后补充受扰输入条件与异源语料条件下的观察，最后对本章结果进行归纳。

4.1 实验参数与设置

4.1.1 数据集与任务设置

本章实验继续采用 RAVDESS 语音情绪数据集。RAVDESS 语音情绪数据集包含 neutral、calm、happy、sad、angry、fearful、disgust 和 surprised 共 8 个情绪类别，并覆盖不同用户的语音样本，能够为用户无关条件下的语音情绪识别实验提供较为统一的测试环境。考虑到前文已经对数据集来源、类别构成以及语料特点进行了说明，本节仅保留与实验实现直接相关的设置内容。

在任务设定方面，本文将各模型置于相同的数据划分原则下比较，以尽量降低由数据切分方式带来的额外差异。实验过程中采用用户级划分思路，使训练集与验证集、测试集之间保持用户层面的分离，从而考察模型在未见用户语音上的泛化表现。用户级划分设定与本文关注的实际应用情境较为一致，因为真实场景下的系统通常需要面对未参与训练的用户输入。结合实验记录，当前实验所使用的语音子集共包含 1440 条语音样本、24 名用户，每名用户包含 60 条语音。在 8 个情绪类别中，neutral 类别包含 96 条样本，其余 7 个情绪类别各包含 192 条样本。

表 4-1 数据集构成与用户无关划分方式

项目	说明	数值/类别数	备注
数据集	RAVDESS Speech	1440 条语音	仅使用语音部分
用户数量	用户 01–24	24 名用户	每名用户 60 条样本
情绪类别	8 类	neutral、calm、happy、sad、angry、fearful、disgust、surprised	neutral 为 96 条，其余 7 类各 192 条
划分方式	用户无关划分	5 折交叉验证	Optuna 阶段通常运行 1 折筛选

4.1.2 输入表示与预处理流程

各比较模型均以对数梅尔频谱作为输入表示。采用对数梅尔频谱的主要原因在于，对数梅尔频谱能够在保持频谱结构信息的同时，对语音中的能量分布与频带差异提供较为稳定的刻画。与直接使用原始波形相比，对数梅尔频谱在当前数据规模下有利于统一输入维度，也便于不同模型结构之间的对照实验。根据公开数据说明，RAVDESS 原始音频为 16bit、48kHz 单声道语音，但本项目训练时统一重采样到 16kHz，以便与当前深度学习实验配置保持一致。

实现流程中，本文首先对原始语音进行重采样与幅值归一化处理，随后按照固定帧长与帧移提取时频表示，并映射到梅尔滤波器组上，获得对数梅尔频谱特征。各比较模型使用 96×512 的对数梅尔频谱输入，纯 Transformer 模型在此基础上形成二维分块标记，CNN-Conformer 代表配置则进一步采用时间分块输入组织方式。预处理流程既保留了语音局部变化信息，也控制了模型训练时的显存开销。

在数据增强方面，实验中保留了有限度的时频遮挡设置，并对增强强度进行了约束。前期实验结果展现出一个现象：过强的数据增强未稳定改善验证结果，部分设置会削弱情绪相关细节的保留。本章在综合实验中主要采用较为克制的增强策略，以降低增强幅度对模型比较结果的额外影响。

4.1.3 比较模型的结构设计

4.1.3.1 卷积神经网络基线模型

卷积神经网络基线模型作为本文的基础比较对象，卷积神经网络基线模型的主要思路是在二维时频平面上逐层提取局部模式，再通过池化与分类头完成情绪类别判别。卷积神经网络基线模型具有明确的局部感受野与参数共享机制，能够较为直

表 4-2 输入表示与预处理参数设置

参数类别	参数名称	当前设置	说明
音频处理	采样率	16000Hz	各实验统一
特征类型	输入表示	对数梅尔频谱	各比较模型共同采用
输入尺寸	谱图尺寸	96×512	各比较模型统一
纯 Transformer 模型	输入组织	二维分块标记	由谱图分块形成序列输入
CNN-Conformer 模型	输入组织	时间分块输入	代表配置采用时间块长度 4
数据增强	时频遮挡	关闭或弱增强	代表方案主要依赖混合增强




图 4-1 卷积神经网络基线模型结构

接地学习能量突变、频带形状以及局部时频纹理等模式。在对数梅尔频谱输入条件下，卷积结构通常能够形成较为稳定的训练过程，适合作为后续 Transformer 系列模型的基线对象^[12-13]。

本文采用的卷积神经网络基线模型保持了相对简洁的主干结构，不额外叠加过深的残差层或复杂注意力模块。基线模型设计用于形成实现稳定、易于复现的卷积神经网络基线模型，从而观察 Transformer 系列模型在相同输入条件下是否能够取得有意义的指标变化。需要说明的是，卷积神经网络基线模型没有按照单一先行研究逐层复现，模型结构结合语音情绪识别中常见二维卷积结构后形成项目内部基线实现^[12-13]。

从实现流程看，卷积神经网络基线模型通常由若干卷积块、非线性激活层、池化层以及分类头构成。输入的对数梅尔频谱首先进入卷积块以提取局部时频模式，再通过逐层池化压缩特征图尺寸，随后将高层局部特征送入全连接分类器完成情绪类别判别。卷积神经网络技术在语音情绪识别任务中常与注意力或循环结构结合使用，相关研究说明了局部时频特征抽取在该任务中的基础价值^[12-13]。

本章采用的卷积神经网络基线模型代表配置来自当前较高验证结果对应的设置。代表配置包含 4 个卷积块，每个卷积块均由 3×3 卷积、BatchNorm、ReLU 以及 2×2 最大池化组成。通道数依次为 [32, 64, 256, 512]，卷积主干之后使用自适应平均池化（AdaptiveAvgPool2d）将特征图压缩为 4×4 ，随后经展平操作（Flatten）、丢弃层和线性分类器输出 8 类情绪结果。

图4-1对应卷积神经网络基线模型从谱图输入到情绪分类输出的处理路径。前两层卷积块侧重整理低层能量变化与局部时频纹理，后两层卷积块在较高通道维度上压缩局部模式。自适应平均池化将不同长度输入经过卷积和池化后的高层特征整理为固定大小表示，线性分类器在固定大小表示上输出 8 类情绪结果。卷积神经网络基线模型为后续纯 Transformer 模型与 CNN-Conformer 模型提供了局部卷积归纳偏置层面的对照^[12-13]。

4.1.3.2 纯 Transformer 模型

纯 Transformer 模型不在前端引入卷积特征提取模块，模型将输入时频表示映射为一系列序列化特征后，主要依赖自注意力机制建模全局上下文关系。纯 Transformer 结构的优势在于能够较为直接地刻画远距离位置之间的相关性，并在统一的注意力框架下完成特征聚合。对于语音情绪识别任务而言，纯全局建模方式有助于观察自注意力结构在中小规模情绪语音数据上的表现边界^[6-7,50]。

与卷积神经网络基线模型相比，纯 Transformer 模型减少了显式局部归纳偏置，对输入表示和训练稳定性的要求相对较高。将纯 Transformer 模型纳入本章比较的目的，主要在于验证当模型主要依赖全局关系建模时，是否能够充分利用语音中的情绪线索，以及纯 Transformer 结构在当前数据规模下是否容易受到过拟合或局部细节捕获不足的影响。本文所称纯 Transformer 模型没有采用原始机器翻译任务中的完整编码器-解码器结构，模型依据原始 Transformer 编码器思想改写得到面向语音情绪分类的仅编码器结构^[6-7,50]。

在实现上，纯 Transformer 模型通常先将输入特征映射为一系列时序标记，再叠加位置编码信息，以保留不同时间位置的相对关系。随后，模型通过多头自注意力模块与前馈网络交替堆叠，对序列内部的相关性建模，并通过池化或分类标记完成整体判别^[6-7,50]。对于缺少卷积前端的结构而言，输入标记的组织方式、位置表示以及编码层深度都会直接影响模型对情绪细节的保持能力。

结合当前代表配置，纯 Transformer 模型在本项目中的设置为：嵌入维度 256，注意力头数 4，编码层数 5，前馈维度 1024，二维分块尺寸为 32×32 ，二维分块步长为 8×8 ，池化方式为均值池化，丢弃层比例约为 0.2707。纯 Transformer 模型将谱图划分为二维分块，再通过卷积形式的分块嵌入映射为标记序列。分块嵌入承担将二维时频表示转化为 Transformer 序列输入的作用，位置编码则用于保留不同分块之间

的顺序关系。分块嵌入与位置编码路径对应原始 Transformer 编码器中标记表示、位置编码和自注意力编码的基本思想^[50]。




图 4-2 纯 Transformer 模型结构

图4-2对应了纯 Transformer 模型从谱图到句级表示的完整路径。与原始 Transformer 论文中的编码器-解码器框架不同，本文实现不引入解码器分支，保留分块嵌入、位置编码、编码器堆叠、序列池化与线性分类器五个部分，用于直接完成 8 类情绪判别。仅编码器处理方式使纯 Transformer 模型能够作为依赖全局注意力建模的代表结构，与卷积结构和卷积-注意力混合结构形成对照^[50]。




图 4-3 纯 Transformer 结构限制的主要来源

图4-3概括了纯 Transformer 模型在当前语音情绪识别设置中的三类限制来源。第一类限制来自输入组织层面，二维时频邻接关系在分块展平后需要在序列表示中重新学习。第二类限制来自局部线索层面，短时能量变化与语调转折可能在分块嵌入中被压缩。第三类限制来自句级聚合层面，均值池化会使不同片段对发话级表示的贡献趋于平均。图中三类限制对应后文对输入组织、局部连续约束和句级聚合方式的分析。

相关研究可以为上述分析提供外部依据。DWFormer 研究指出，语音情绪相关时间区域会分散在发话的不同局部位置，且有效信息的时间尺度会在片段内部和片段之间发生变化，单一 Transformer 结构可能难以精确定位不同尺度上的情绪相关区域^[6]。Speech Swin-Transformer 研究进一步把局部窗口、移位窗口和层级聚合引入语音情绪识别任务，用于刻画帧级、片段级和更高层级的情绪线索^[7]。上述研究保留了自注意力结构的价值，同时提示语音情绪识别任务通常需要把全局关系建模与局部时间结构、层级声学线索结合起来。基于这一背景，本文对纯 Transformer 模型的分析既来自单次实验数值，也与相关 Transformer 语音情绪识别研究中的结构改进方向相互对应。

从声学信号结构看，纯 Transformer 模型在本任务中的不足首先来自输入标记组织方式。对数梅尔频谱同时包含时间轴和频带轴。时间轴反映发话过程中的能量起伏、语速变化和局部停顿，频带轴反映音色、共振峰分布和能量重心。语音情绪识别技术所依赖的非文字语义线索往往同时分布在这两个维度上。纯 Transformer 模型将二维谱图切分为若干二维分块后，再展平为一维标记序列。展平操作便于送入编码器，但二维邻接关系会被转换为序列位置关系。相邻频带之间的连续性、相邻时间片段之间的短时动态，以及同一时间片段内不同频带共同形成的声学形态，都需要由后续注意力层重新学习。

纯 Transformer 模型的分块方式还会影响短时声学线索的保留。本章代表配置采用 32×32 二维分块和 8×8 分块步长。在当前帧移设置下，单个分块会覆盖相对较长的时间范围。语音情绪线索中的重音、短促能量变化、局部频带突变和语调转折，可能只出现在较短区间内。若这些变化在分块嵌入阶段被合并到同一个标记中，后续自注意力层虽然可以比较不同标记之间的相关性，但较细的局部变化已经被压缩到标记向量内部。分块压缩过程会降低模型直接利用短时声学动态的便利性。

自注意力机制擅长比较序列中不同位置之间的相关性，这一能力对发话级情绪

判别具有一定价值。发话中的情绪状态可能跨越多个时间片段，模型需要把较早出现的语调走势与后续的能量变化共同纳入判断。纯 Transformer 模型可以在同一层内建立远距离标记之间的联系。问题在于，自注意力本身缺少类似卷积核的局部连续约束。对于中小规模语音情绪数据，模型需要从有限样本中同时学习局部声学模式、位置关系和全局聚合方式。训练样本不足时，模型可能先学习到与训练划分相关的偶然关联，局部情绪细节的稳定利用就会受到影响。

纯 Transformer 模型的另一处限制来自句级聚合方式。当前代表配置使用均值池化将各个标记表示汇聚为发话级表示。均值池化具有实现简洁和参数较少的优点，适合形成清晰的对照结构。语音情绪识别任务中的有效线索往往呈非均匀时间分布。部分发话可能在少数片段中出现较强的情绪提示，其他片段只提供背景性语音内容。均值池化会为各个标记分配相同权重，情绪相关片段在最终表示中的比例可能被无关片段稀释。均值池化设置与后续 CNN-Conformer 模型采用注意力池化形成对照。

结合实验结果可以看到，纯 Transformer 模型的局限不宜简单归结为参数规模不足。表4-8中，纯 Transformer 模型参数量约为 4.21M，高于卷积神经网络基线模型的 1.41M，也高于 CNN-Conformer 模型的 3.55M。纯 Transformer 模型的 Accuracy 为 0.52000，Macro-F1 为 0.51163，UAR 为 0.51250，低于卷积神经网络基线模型和 CNN-Conformer 模型。实验数值说明，在当前数据规模、输入表示和训练协议下，参数量增加没有自然转化为更稳定的验证指标。模型结构是否提供与声学情绪线索相匹配的归纳偏置，可能比单纯扩大表示容量更能影响结果。




图 4-4 纯 Transformer 模型的训练曲线

图4-4进一步给出了纯 Transformer 代表配置在第 1 个 fold 上的训练过程。训练损失随 epoch 推进持续下降，训练 Accuracy 逐步上升到较高水平。验证损失在中后

期出现较大波动，验证 Accuracy 整体低于训练 Accuracy，并且没有与训练 Accuracy 保持同步上升。结合表4-8中的验证指标，这一现象说明纯 Transformer 模型已经具备较强的训练集拟合能力，但在当前用户划分验证条件下，训练过程中的表示容量没有稳定转化为验证集收益。这一观察与前文关于中小规模语音情绪数据中局部约束和聚合方式影响泛化结果的分析具有对应关系。




图 4-5 纯 Transformer 模型的校准曲线与混淆矩阵

图4-5（a）从输出置信度角度补充了模型稳定性观察。纯 Transformer 代表配置的 ECE 为 0.29362，可靠性曲线在多个置信度区间内偏离理想校准线，较高置信度区间的实际正确比例也没有与预测置信度保持一致。校准结果说明模型输出分数与验证集真实正确率之间存在一定失配。对于语音情绪识别任务而言，类别间声学差异较细，若模型在局部线索和句级聚合层面形成的表示不够稳定，输出置信度也可能受到影响。这一结果与训练曲线和混淆矩阵共同构成纯 Transformer 代表配置的实验侧证据。

从类别判别角度看，纯 Transformer 模型的混淆情况也可以与结构特点联系起来理解。若模型主要依赖全局注意力关系和均值池化，局部能量突变、短时频带纹理以及少量关键片段的贡献可能不够突出。情绪类别之间本身存在声学相似性，例如若干类别都可能表现为较高能量或较快语速。局部线索被压缩后，模型更容易把这

些类别映射到接近的表示区域。全局关系能够提供较长范围上下文，但缺少局部建模路径时，全局关系不一定能弥补短时细节的不足。

图4-5（b）给出了纯 Transformer 代表配置在验证集上的类别混淆情况。混淆矩阵中，angry、disgust 和 calm 类别保留了相对较高的对角线比例，说明模型能够识别一部分能量或语调边界较清楚的样本。neutral、sad、happy 和 fearful 类别的对角线比例相对较低，且出现更分散的偏移。sad 样本被预测为 disgust 的比例达到 0.28，fearful 样本被预测为 happy 的比例达到 0.33，disgust 样本被预测为 angry 的比例达到 0.23，neutral 样本也会向 sad 和 disgust 等类别分散。上述混淆关系说明纯 Transformer 代表配置仍能形成部分发话级判别表示，但对若干声学相近类别的边界组织仍然不够稳定。类别混淆结果与前文结构分析相互对应，说明全局注意力和均值池化可以形成发话级判别表示，但局部时频线索和少量高信息片段的贡献仍可能不够突出。

上述分析不宜理解为否定 Transformer 结构在语音情绪识别中的价值。更合适的理解是，纯 Transformer 模型在本章中承担了一个结构边界测试角色。纯 Transformer 模型用于检验仅依赖全局注意力和二维分块标记时，声学情绪线索能否被充分组织成稳定的发话级表示。实验结果支持后续结构调整方向，即在保留注意力建模长程上下文能力的同时，引入更贴近声学信号局部连续性的建模路径，并使用更符合情绪片段非均匀分布特点的句级聚合方式。

4.1.3.3 CNN-Conformer 模型

CNN-Conformer 模型来源于卷积模块与 Conformer 编码器相结合的设计思路。原始 Conformer 模型面向语音识别任务提出，设计动机在于把自注意力的较长范围上下文建模能力和卷积结构的局部动态建模能力放入同一个编码块中^[51]。语音信号具有连续时间结构，发音过程中的短时变化会影响局部声学形态，跨越较长时间范围的语调趋势也会影响发话级判断。单独使用自注意力结构时，模型可以直接比较远距离位置，但局部连续性需要从数据中学习。单独使用卷积结构时，局部模式提取较为直接，但长距离关系通常需要通过层数堆叠或额外结构逐步扩大感受野。Conformer 编码块把两类结构组合在同一层级上，可视为面向语音序列的一种混合编码方案。

原始 Conformer 研究的实验对象是自动语音识别任务，评价指标为词错误率。该研究在 LibriSpeech 基准上报告了 test 和 test-other 集合的结果，在不使用外部语言模型时取得 2.1% 和 4.3% 的词错误率，在使用外部语言模型时取得 1.9% 和 3.9% 的词




图 4-6 CNN-Conformer 模型结构

错误率。小规模 10M 参数设置也报告了 2.7% 和 6.3% 的词错误率^[51]。上述结果说明 Conformer 结构在语音序列建模中具有较强的局部与全局依赖联合建模能力。需要限定的是，原始结果来自大规模自动语音识别基准，本文任务是中小规模语音情绪识别分类任务，标签空间、数据规模、评价指标和错误类型均与自动语音识别不同。本文引用原始 Conformer 研究的目的是，说明结构设计依据，并不把词错误率结果直接外推到本文的情绪分类结果。

典型 Conformer 编码块由两个前馈网络模块、多头自注意力模块、卷积模块、残差连接和归一化操作构成^[51]。前馈网络模块负责在每个时间位置内部进行非线性表示变换，相当于对每个标记的通道维度进行重新组织。多头自注意力模块负责建立不同时间位置之间的相关性，使模型能够在同一层内整合较长时间范围内的信息。卷积模块通过局部连接处理相邻标记之间的动态关系，使短时变化、局部平滑性和局部频谱纹理能够以更直接的方式参与编码。残差连接用于保留输入表示并缓解深层堆叠带来的信息衰减，归一化操作用于稳定不同子模块之间的表示尺度。

Conformer 编码块采用类似 macaron 的前馈结构。输入表示先经过一个前馈网络分支，并以半步残差的形式加入原表示。随后表示进入多头自注意力模块，用于吸收较长范围上下文。接着，卷积模块补充局部序列建模。最后，第二个前馈网络分支再次更新每个时间位置的通道表示，并通过归一化得到编码块输出。半步残差的意义在于降低单个前馈分支对表示更新的幅度，使自注意力路径、卷积路径和前馈路径在同一编码块中保持较平衡的贡献。Conformer 编码块结构与仅由自注意力和前馈网络组成的 Transformer 编码器存在差异。




图 4-7 Conformer 编码块结构

$$\begin{aligned}
 \tilde{x}_1 &= x + \frac{1}{2}\text{FFN}(x), \\
 \tilde{x}_2 &= \tilde{x}_1 + \text{MHSA}(\tilde{x}_1), \\
 \tilde{x}_3 &= \tilde{x}_2 + \text{Conv}(\tilde{x}_2), \\
 y &= \text{LayerNorm}\left(\tilde{x}_3 + \frac{1}{2}\text{FFN}(\tilde{x}_3)\right).
 \end{aligned} \tag{4-1}$$

式4-1给出了本文实现所遵循的 Conformer 编码块计算流程。输入标记 x 先经过半步前馈更新，再进入相对位置多头自注意力模块。自注意力模块在序列范围内整合跨片段上下文。卷积模块随后在相邻时间标记之间补充局部动态约束。第二个前馈网络再次调整每个标记的通道表示，末端 LayerNorm 统一输出尺度。这一流程使每个编码块内部同时包含通道变换、全局关系、局部连续性和尺度稳定化四类操作。

卷积模块是 Conformer 区别于普通 Transformer 编码器的关键组成。卷积模块通常包含逐点卷积、门控线性单元、深度可分离卷积、归一化和非线性激活。逐点卷积用于扩展通道并生成门控分支，门控线性单元根据输入内容调节信息通过比例。深度可分离卷积在时间维度上进行局部计算，卷积核大小决定相邻时间范围内可被直接整合的区域。对于语音情绪识别任务，卷积模块可以用于刻画短时能量变化、局部频带形态和语调转折附近的动态模式。该路径补充了自注意力对全局关系的建模方式。

多头自注意力模块在 Conformer 编码块中承担较长范围信息交互。语音情绪通

常由多个时间片段共同体现，发话中的语调走势、停顿位置和能量分布可能在多个时间片段之间形成关联。自注意力模块可以让一个时间标记关联其他时间标记的表示，从而把分散在发话中的线索放入同一上下文中。本文实现采用相对位置多头自注意力，目的在于让注意力计算同时感知标记内容和标记间相对距离。与仅叠加固定位置编码的处理相比，相对位置表示更适合描述语音序列中相邻片段、间隔片段和较远片段之间的关系^[51]。

本文使用 CNN-Conformer 这一名称描述当前结构家族，但代表配置没有沿用原始自动语音识别场景中常见的两级卷积压缩前端。原始 Conformer 往往在编码器之前使用卷积下采样，以降低序列长度并扩大局部接收范围^[51]。本文的代表配置面向语音情绪识别任务，对前端组织方式进行了调整。模型前端采用无卷积前端时间分块输入，将对数梅尔频谱沿时间轴划分为覆盖完整梅尔频带的时间片段，再把每个时间片段投影为序列标记。前端设计减少对早期卷积压缩的依赖，把较多频带结构保留到 Conformer 编码阶段。




图 4-8 无卷积前端时间分块输入的形成过程

从任务设置看，原始 Conformer 需要把较长语音序列映射为文字序列，模型更关注连续声学单元到文字单元的对齐与识别。本文的 CNN-Conformer 模型输出 8 类情绪标签，模型更关注整段发话中的非文字语义线索是否能够形成稳定的类别边界。原始 Conformer 实验使用自动语音识别常见的词错误率评价，本文使用 Accuracy、Macro-F1 和 UAR 评价分类结果，并按照用户划分验证集以观察未见用户条件下的判别能力。原始 Conformer 的前端压缩有助于降低自动语音识别中的长序列计算负担，本文的无卷积前端时间分块输入则更强调在进入编码器之前保留完整频带结构。上述差别决定了本文不能简单复现原始自动语音识别结构，而需要在 Conformer 编码思想基础上进行面向语音情绪识别任务的输入组织调整。

无卷积前端时间分块输入与纯 Transformer 模型的二维分块方式存在直接差别。纯 Transformer 模型把谱图切分为二维补丁，再将二维补丁展平为一维序列。本文 CNN-Conformer 代表配置中的时间分块输入覆盖完整频带，每个标记保留同一时间

片段内的整体频带结构。时间分块处理方式使单个标记更接近一个短时间声学片段，而不是局部时频小块。对于语音情绪识别任务，时间分块标记组织方式有助于保留音色、频带能量分布和短时动态之间的共同关系，也减少早期二维补丁切分对频带结构的割裂。

Conformer 编码阶段在时间分块输入组织方式上进一步发挥作用。时间分块标记进入编码器后，相对位置多头自注意力负责比较不同时间片段之间的关系，卷积模块负责在相邻时间片段之间建立局部动态约束。两个路径分别处理较长范围上下文和局部连续变化。语音情绪线索既可能表现为整段发话的总体语调趋势，也可能表现为少数位置上的能量变化或频带纹理变化。Conformer 编码块的组合结构能够让这两类线索在同一序列表示中共同更新。

当前代表配置中，Conformer 编码器包含 4 个编码块，嵌入维度为 192，注意力头数为 8，前馈维度为 768，卷积模块卷积核大小为 31。卷积核大小 31 使局部卷积路径能够覆盖一定范围内的相邻时间标记。这里的卷积覆盖范围作用在时间分块后的标记序列上，区别于原始波形中的单个采样点邻域。卷积模块处理的是已经包含完整频带信息的短时间片段序列。卷积核设置使局部路径与前端时间分块方式形成对应关系。

当前实现中的执行顺序为前馈网络、相对位置多头自注意力、卷积模块、前馈网络和 LayerNorm。两个前馈分支均使用 0.5 倍率的半步残差连接。执行顺序保留了 Conformer 编码块的基本思想。前馈网络用于调整每个标记的通道表示，自注意力用于吸收跨片段上下文，卷积模块用于补充相邻片段动态，末端归一化用于稳定输出尺度。结构安排比纯 Transformer 编码器多出一条显式局部建模路径，也比单纯卷积结构保留了更直接的长程关系建模能力。

注意力池化是本文 CNN-Conformer 代表配置的另一项关键设计。纯 Transformer 代表配置使用均值池化，各时间标记在句级表示中具有相同权重。CNN-Conformer 代表配置使用注意力池化，在时间维度上学习每个标记对发话级情绪判别的贡献。对于情绪线索分布不均匀的发话，注意力池化可以让情绪相关片段在句级表示中获得更高权重。池化设计与语音情绪识别中关注局部高信息片段的研究思路具有对应关系^[5,12]。

训练阶段的混合增强用于缓解中小规模数据条件下的过拟合风险。CNN-Conformer 代表配置具有较强表示能力，训练过程中容易出现训练集指标持续提高而验证集指

标提前停滞的现象。混合增强通过在样本和标签层面构造较平滑的过渡样本，使模型在训练阶段接触到更连续的判别边界。混合增强不改变 Conformer 编码块的结构，但会影响模型对少量训练样本的依赖程度。相关自注意力语音情绪识别研究为在语音情绪识别任务中使用混合增强提供了依据^[47]。

将上述结构放回本章模型演进脉络，可以看到 CNN-Conformer 代表配置不是单纯扩大模型规模的结果。纯 Transformer 模型的参数量高于 CNN-Conformer 代表配置，但验证指标低于后者。CNN-Conformer 代表配置的改进来自多个环节的组合，包括完整频带时间分块输入、Conformer 编码块中的相对位置自注意力和卷积模块、注意力池化以及训练阶段的混合增强。结构组合从输入组织、序列编码和句级聚合三个层面回应了纯 Transformer 模型在局部细节、时间片段权重和中小规模训练稳定性方面暴露出的不足。

本文重点分析 CNN-Conformer 模型，主要有两个原因。第一，CNN-Conformer 结构在理论上同时利用局部建模和上下文建模，与本文围绕声学情绪线索组织方式展开的比较主线具有较强关联。第二，已有实验记录表明，CNN-Conformer 模型在部分设置下能够达到较高验证指标，也持续暴露出训练后期过拟合倾向。围绕 CNN-Conformer 模型开展较细致的结构调整与训练策略分析，可以从结构组合角度回应卷积结构与 Transformer 结构如何协同的问题。

需要说明的是，本文综合实验所采用的代表配置已不再保留原始自动语音识别场景中常见的两级卷积压缩前端。模型前端改为面向语音情绪识别场景的无卷积前端时间分块输入组织方式。无卷积前端时间分块输入与原始 Conformer 前端设计存在明确差异^[12,49,51]。

在本文采用的代表实现中，CNN-Conformer 模型的前端不承担强压缩作用，先利用无卷积前端时间分块方式直接构造序列标记。中间部分由若干 Conformer 编码块构成，每个编码块内部包含前馈网络、相对位置多头自注意力模块、卷积模块以及残差连接。末端部分通过注意力池化形成句级表示，并交由分类头输出情绪类别。当前实现将建模重点放在时间分块标记构造、Conformer 序列编码和句级聚合三个部分，减少传统自动语音识别式卷积下采样前端造成的早期压缩。

当前章节在综合实验中采用的 CNN-Conformer 代表配置，采用后续实验中取得较高指标的无卷积前端时间分块输入变体。代表配置中，时间块长度为 4，归一化方式为 LayerNorm，嵌入维度为 192，编码层数为 4，注意力头数为 8，前馈维度为 768，

卷积模块卷积核大小为 31，层间融合方式为末层输出，池化方式为注意力池化。训练阶段同时结合频谱级混合增强， $\alpha = 0.4$ 。在代码实现上，Conformer 块内部的执行顺序为前馈网络 → 相对位置多头自注意力 → 卷积模块 → 前馈网络 → LayerNorm，并在两个前馈分支处使用 0.5 倍率的半步残差连接。

分类器设计方面，CNN-Conformer 模型首先通过注意力池化获得句级嵌入，再经过丢弃层与线性层完成 8 类情绪分类。对于本章所采用的代表配置而言，分类器之前的句级表示维度为 192，分类头结构相对简洁，目的是将指标差异主要保留在前端标记构造方式与 Conformer 编码路径本身，减少额外复杂后端分类器带来的影响。

无卷积前端时间分块输入是一种面向情绪细粒度时间线索保留而设计的输入组织方式。无卷积前端时间分块输入不使用标准两级卷积前端先压缩时频图，直接使用覆盖完整频率维度、宽度等于固定时间帧数的卷积核，将整幅谱图沿时间轴切分为若干连续时间块。每个时间块在进入序列编码之前已经包含完整频带信息，再经过层归一化和线性投影得到统一维度的序列标记。图4-8给出了无卷积前端时间分块输入的形成过程。无卷积前端时间分块输入与多层声学信息融合和多尺度声学建模研究所关注的局部声学线索与上下文信息并用思路具有一定关联，可用于检验 Conformer 在较弱前端压缩条件下的实际收益^[12,49]。

CNN-Conformer 模型中的层间特征融合、注意力池化和混合增强分别承担不同作用。层间特征融合用于比较末层上下文表示与多层表示组合之间的差异，相关研究曾从多层声学信息角度讨论语音情绪识别中的层级特征利用^[49]。注意力池化用于在时间维度上为不同序列位置分配不同权重，语音情绪识别中的局部注意力和多尺度注意力研究均说明了聚合方式的任务相关性^[5,12]。混合增强用于在训练阶段构造较平滑的样本间过渡，以降低模型对少量训练样本的过度拟合风险。自注意力语音情绪识别中已有按照标签信息调整 mixup 训练过程的研究，该研究为本文采用混合增强提供了相关依据^[47]。

图4-6、图4-7与图4-8分别对应 CNN-Conformer 模型的整体实现路径、单个 Conformer 编码块的内部结构以及无卷积前端时间分块输入的形成方式。本文采用的代表配置没有照搬原始 Conformer 在自动语音识别任务中的前端设计，模型在保留 Conformer 编码块主干顺序的基础上调整输入组织方式。编码阶段仍采用前馈网络、相对位置多头自注意力、卷积模块、前馈网络与 LayerNorm 构成的结构顺序，后端使用注意力池化、丢弃层与线性分类器完成 8 类情绪判别。代表配置安排使结构差异

集中在前端标记构造与序列编码部分，与 Conformer 和语音情绪识别多层声学信息建模研究具有对应关系^[12,49,51]。

经过模型结构设计，三类模型分别对应三种建模侧重：卷积神经网络基线模型强调局部时频纹理提取，纯 Transformer 模型强调基于自注意力的全局关系建模，CNN-Conformer 模型则尝试在局部卷积建模与上下文建模之间建立衔接。表4-3对三类结构的前端处理方式、注意力使用情况与结构特点进行并列整理。

表 4-3 各比较模型的结构差异与设计特点

模型	前端卷积	全局注意力	结构特点
卷积神经网络基线模型	有	无	4 层卷积块后直接分类
纯 Transformer 模型	无	有	二维分块标记与编码器堆叠
CNN-Conformer 模型	可选	有	Conformer 序列编码与注意力池化

4.1.4 训练参数与评价指标

为保证不同模型之间的可比性，本文尽量在统一训练框架下完成各类实验。训练过程中采用相同的数据读取流程、相近的优化策略以及一致的早停规则，并以验证集结果作为模型选择依据。在参数优化方面，部分实验通过 Optuna 搜索学习率、批大小、分块长度以及模型内部关键参数，正文仅保留与代表结果解释相关的设置内容。

评价指标主要采用准确率与宏平均 F1 值，同时结合 UAR 进行补充观察。准确率可以直接反映整体分类正确比例，宏平均 F1 值适合在类别分布存在差异时观察模型在各类别上的平均表现，UAR 则用于观察不同类别召回率的整体平衡情况。考虑到语音情绪识别任务中不同情绪类别的可分性存在差异，仅使用准确率往往不足以完整反映模型质量，本章在结果讨论中将同时采用 Accuracy、Macro-F1 和 UAR 三个指标。

在 CNN-Conformer 模型的后续实验中，还引入了损失函数、采样策略、层间特征融合方式以及前端压缩方式等设置变化。保留这些比较项，主要是为了观察贴近任务特性的结构调整能否缓解验证集指标波动，而不是扩大搜索规模。相关实验结果将在综合实验部分结合代表性配置进行分析。

表 4-4 训练参数与评价指标设置

类别	项目	当前设置	说明
优化设置	优化器	AdamW 系配置	各模型统一搜索主框架
优化设置	学习率	10^{-4} 量级为主	Optuna 搜索后择优
训练设置	批大小	12 或 16	由显存与模型规模决定
训练设置	训练轮数	30 轮，早停 10 轮	以较高验证指标点截断
评价设置	指标	Accuracy / Macro-F1 / UAR	与结果表一致
评价设置	模型选择依据	验证集 Macro-F1	以宏平均 F1 作为固定优化目标

表 4-5 CNN-Conformer 关键搜索维度与候选设置

搜索维度	候选设置	设计目的
时间下采样	标准压缩 / 优先保留时间分辨率等	调整时间分辨率保留程度
层间特征融合	末层输出 / 可学习加权融合	结合浅层与深层表示
损失函数	交叉熵 / 焦点损失等	观察类别学习稳定性
采样策略	随机采样 / 加权采样	缓解类别分布差异影响
正则化设置	混合增强 / 丢弃层 / 归一化变体	控制过拟合风险

4.1.5 实验环境与实现平台

实验设置除数据集、评价指标和模型超参数外，还需要交代支撑训练与评价的实现平台。本文的模型训练、参数搜索、噪声评价与跨语料库评价均依托同一套代码框架完成，主要实现基于 PyTorch 生态，配置管理、参数搜索和实验记录分别由 Hydra、Optuna 与 MLflow 辅助完成。该部分不展开系统维护细节，只保留与复现边界直接相关的运行环境和实验组织信息。

表4-6汇总了本章实验所使用的实现平台与复现设置。与后文模型参数表不同，表4-6用于限定实验执行所依赖的软件框架、硬件资源、随机种子和结果记录方式，单个模型的结构差异则由后续模型参数表说明。集中列出实验环境可以避免在正文中反复描述环境细节，也便于读者理解批大小、训练轮数、搜索规模和单卡显存约束之间的关系。

4.2 综合实验

4.2.1 各比较模型的综合实验结果

在统一的对数梅尔频谱输入、训练流程与评价指标下，本节比较卷积神经网络基线模型、纯 Transformer 模型与 CNN-Conformer 模型。综合实验仅保留具有代表性

表 4-6 实验环境与实现平台

类别	当前设置	说明
操作系统	Windows 10	主要代码运行与结果整理平台
编程语言	Python 3.13 系列	训练、评价与结果分析脚本运行环境
深度学习框架	PyTorch / torchaudio	模型训练、波形读取和时频特征处理
配置管理	Hydra / OmegaConf	管理数据、模型、训练和实验覆盖参数
参数搜索与记录	Optuna / MLflow	保存搜索结果、指标、配置和模型权重
训练设备	NVIDIA GeForce RTX 2060 单卡	受显存限制，部分搜索阶段采用 fold 1 筛选

的较高结果，用于说明三类结构在相同评价框架下的主要差异。

表4-7概括三类模型的代表配置。该表只保留结构对比所需的信息，具体中间搜索过程不再逐项展开。

表 4-7 各比较模型的代表配置

模型	输入与前端	主干结构	聚合与分类
卷积神经网络基线模型	96×512 对数梅尔频谱	4 个卷积块，通道数 [32, 64, 256, 512]	自适应平均池化，丢弃层 0.33238，线性分类
纯 Transformer 模型	二维分块 32×32 ，步长 8×8	5 层编码器，256 维嵌入，4 头注意力	均值池化，丢弃层 0.2707，线性分类
CNN-Conformer 模型	无卷积前端时间分块，时间块长度 4	4 层编码器，192 维嵌入，8 头注意力，卷积核 31	注意力池化，混合增强 $\alpha = 0.4$ ，线性分类

表 4-8 各比较模型的综合实验结果

模型	Accuracy	Macro-F1	UAR	参数量	说明
卷积神经网络基线模型	0.61667	0.62196	0.61563	1.41M	4 层卷积基线
纯 Transformer 模型	0.52000	0.51163	0.51250	4.21M	全局注意力建模
CNN-Conformer 模型	0.70000	0.70563	0.70938	3.55M	当前 Transformer 主线较高结果

从表4-8可以看到，卷积神经网络基线模型达到 Accuracy 0.61667、Macro-F1 0.62196

和 UAR 0.61563，说明局部时频模式仍具有较强参照意义。纯 Transformer 模型的三项指标分别为 0.52000、0.51163 和 0.51250，未显示出稳定优于卷积基线的优势。CNN-Conformer 模型达到 Accuracy 0.70000、Macro-F1 0.70563 和 UAR 0.70938，说明局部建模与上下文建模结合后更适合当前实验条件。

4.2.2 CNN-Conformer 模型的结构优化路径

CNN-Conformer 模型同时包含输入组织、序列编码与分类模块，指标受多个结构因素共同影响。结合前期实验记录，本文主要考察时间下采样、层间特征融合、训练策略、前端重设计与过拟合缓解等方向，核心目标是在保留局部情绪线索的同时降低验证指标劣化。




图 4-9 CNN-Conformer 模型的结构优化路径

图4-9按照实验推进顺序整理了 CNN-Conformer 模型的主要调整路径。早期结构以两级卷积前端和相对位置 Conformer 编码为基础，后续实验围绕前端重设计、无卷积前端时间分块、混合增强与归一化筛选展开。上述调整分别对应时间分辨率保留、层间表示利用和训练稳定性控制，具体数值仍以表4-10为准。

4.2.3 CNN-Conformer 模型的代表配置与结果观察

在综合比较层面，CNN-Conformer 模型的代表配置由多个候选方向逐步筛选形成，单一参数不能充分解释代表结果。当前较高结果对应无卷积前端时间分块输入、时间块长度 4、LayerNorm 归一化、4 层 Conformer 编码器、8 头注意力、卷积核大小 31、注意力池化以及 $\alpha = 0.4$ 的混合增强。表4-9中的随机采样指训练阶段打乱训练样本后构造批次，注意力池化指在时间维度学习权重并汇聚为句级表示。

4.2.4 综合讨论

从整体比较结果可以看到，卷积神经网络基线模型仍然构成重要参照。纯 Transformer 模型具备全局关系建模能力，但若缺少与任务相匹配的局部约束，其优势难以稳定转化为验证集收益。CNN-Conformer 模型在局部声学线索与较长上下文关系之间建立衔接，取得了当前较高结果；同时，阶段性结果也说明该结构仍受训练稳

表 4-9 CNN-Conformer 模型的代表配置

配置维度	代表设置	备注
前端形式	无卷积前端时间分块输入，时间块长度为 4	不使用标准两级卷积前端
层间特征融合	末层输出	不使用多层加权融合
损失函数	交叉熵	标签平滑设为 0
采样策略	随机采样	不额外使用加权采样
池化方式	注意力池化	学习时间权重后汇聚
正则化设置	混合增强 $\alpha = 0.4 + \text{丢弃层}$	LayerNorm，未采用缩窄策略

表 4-10 CNN-Conformer 模型阶段性结果汇总

优化阶段	关键设置	Accuracy	Macro-F1	结论
初始结构	两级卷积前端，相对位置 Conformer	0.63000	0.63168	早期基线
时间下采样	保留较多时间分辨率	0.62017	0.62017	未超过基线
层间融合	末层输出与加权融合比较	0.55348	0.55348	收益有限
训练策略	损失函数、采样策略、混合增强	0.70000	0.70563	代表高值
主干正则	无卷积前端时间分块，归一化筛选	0.70333	0.70042	接近高值

定性、特征压缩方式和模型容量控制的影响。

4.3 噪声条件实验

实际语音输入会受到背景声、环境回响和录制设备差异影响。为补充观察代表模型在受扰输入下的表现，本文固定 clean 条件下选定的 CNN-Conformer checkpoint，只在评价阶段向原始波形加入指定类型与强度的合成噪声，再沿用主实验的重采样、对数梅尔频谱提取、分块评价与 logit 聚合流程完成预测。该实验不重新筛选模型结构，作用是记录代表模型在受控噪声条件下的指标退化轨迹^[8-9,15,24-25]。

4.3.1 实验目的与评价流程

本实验的主要目标是观察已选定代表模型在输入质量变化时的稳定性。主实验已经完成三类模型比较，噪声条件实验只额外引入受扰波形条件，以减少模型结构和训练策略变化对结果解释的干扰。

信噪比采用分贝形式表示，如式4-2所示。

$$\text{SNR} = 10 \log_{10} \left(\frac{P_{\text{signal}}}{P_{\text{noise}}} \right) \quad (4-2)$$

式4-2中， P_{signal} 表示语音功率， P_{noise} 表示噪声功率。本文将 SNR 设置为 clean、20dB、10dB、5dB、0dB 和 -5dB，覆盖从轻度干扰到较强干扰的连续区间。该设置与噪声鲁棒语音情绪识别研究中常见的分级评价思路保持一致^[9,24-25]。

4.3.2 噪声条件设计

噪声类型设置为 white、pink、babble 和 synthetic-mixed 四类，分别对应宽带随机干扰、低频偏置干扰、语音样背景干扰和混合瞬态干扰。此处采用合成噪声，主要用于形成可重复的受控评价条件，因此本文不对真实环境噪声建模作展开讨论。四类噪声与 SNR 等级构成双轴设计，便于观察不同频谱形态和不同强度下的退化差异^[9,15,25]。

表 4-11 噪声条件实验设置

项目	设置	说明
评价模型	CNN-Conformer 代表模型	固定 clean 模型，不重新训练
加噪位置	波形阶段	加噪后再提取对数梅尔频谱
噪声类型	white / pink / babble / synthetic-mixed	四类可控合成噪声
SNR 设置	20 / 10 / 5 / 0 / -5dB	clean 作为参照
评价指标	Accuracy / Macro-F1 / UAR	同时记录相对 clean 差值

表4-11给出了统一设置。四类噪声作用于同一份评价样本，样本顺序、分块位置、聚合方式和评价指标保持一致，使不同条件之间的主要差异集中在输入波形受扰方式和受扰强度上。


4.3.3 结果与现象分析

表4-12和图4-10显示，clean 条件下代表模型的 Accuracy 为 0.70333，Macro-F1 为 0.70042，UAR 为 0.70000。进入 20dB 后，四类噪声均造成指标回落；随着 SNR 继续下降，不同噪声类型之间的差异扩大。pink 噪声在 10dB 以下退化较快，-5dB 条件下 Accuracy 降至 0.15000，Macro-F1 降至 0.06243。babble 噪声和 synthetic-mixed 噪声在低 SNR 区间下降相对缓和，但仍低于 clean 条件。


从指标对应关系看，Accuracy、Macro-F1 和 UAR 在多数噪声条件下同步下降，说明受扰输入同时影响整体正确率、类别均衡性和召回率稳定性。结合 CNN-Conformer 的时间分块与序列编码方式看，持续低频覆盖会压缩能量轮廓和局部时频纹理，使

表 4-12 不同噪声条件下 CNN-Conformer 模型的实验结果

噪声类型	SNR	Accuracy	Macro-F1	UAR	Accuracy 变化
clean	clean	0.70333	0.70042	0.70000	0.00000
white	20	0.61000	0.56389	0.57812	-0.09333
white	10	0.49000	0.44717	0.46562	-0.21333
white	5	0.40667	0.32933	0.38125	-0.29667
white	0	0.34000	0.24169	0.31875	-0.36333
white	-5	0.29333	0.17877	0.27500	-0.41000
pink	20	0.60000	0.58425	0.58125	-0.10333
pink	10	0.36667	0.32255	0.34688	-0.33667
pink	5	0.27000	0.19737	0.25312	-0.43333
pink	0	0.21000	0.13333	0.19688	-0.49333
pink	-5	0.15000	0.06243	0.14062	-0.55333
babble	20	0.59667	0.57407	0.57500	-0.10667
babble	10	0.54667	0.52658	0.52500	-0.15667
babble	5	0.51667	0.49893	0.49687	-0.18667
babble	0	0.45333	0.43736	0.43438	-0.25000
babble	-5	0.44333	0.42124	0.42188	-0.26000
synthetic-mixed	20	0.63667	0.63597	0.62500	-0.06667
synthetic-mixed	10	0.58667	0.58083	0.57188	-0.11667
synthetic-mixed	5	0.55667	0.55418	0.54688	-0.14667
synthetic-mixed	0	0.45333	0.44479	0.43750	-0.25000
synthetic-mixed	-5	0.34000	0.30379	0.32500	-0.36333



(a) 不同噪声强度下的 Accuracy 变化



(b) pink 噪声-5dB 条件下的混淆矩阵

图 4-10 噪声条件下 CNN-Conformer 模型的结果可视化

后续注意力池化获得的情绪相关线索减少。图4-10右图中的混淆矩阵也显示，强 pink 噪声条件下错误分布更加分散，类别边界明显变得模糊。

本节实验定位为代表模型在受扰输入下的补充观察。结果说明，clean 条件下取得较高指标并不意味着模型在受扰输入下具有同等稳定性；噪声频谱形态和强度等级都会改变情绪线索的可见程度。当前论文不展开噪声建模改进，只把上述结果作为代表结构边界条件的记录。

4.4 跨语料库实验

跨语料库实验用于补充观察 CNN-Conformer 模型在语料分布变化时的稳定性。前文实验均建立在训练语料与评价语料同源的前提下，难以说明模型面对录制条件、用户构成和语句集合变化时的表现。本节采用 source-only 设置，不引入目标语料监督信息，考察同一结构从源语料迁移到异源语料后的指标变化^[14,16-18,23,52]。

4.4.1 实验协议与评价流程

跨语料库实验选择 RAVDESS 作为源语料，选择 CREMA-D 作为目标语料。两套语料均为英语表演式语音情绪数据，但用户数量、样本规模、句子集合和表演分布不同。由于两套语料的标签集合不完全一致，当前实验仅保留公共六类情绪：neutral、happy、sad、angry、fearful 和 disgust。公共类别处理可以减少类别集合差异对结果解释的干扰，也符合跨语料库研究中重建公共标签空间的常见做法^[14,18,23,52]。

源语料 RAVDESS 六类子集包含 1056 条语音，目标语料 CREMA-D 六类子集包含 7442 条语音。训练阶段仅使用 RAVDESS 六类子集，并按照用户划分执行 Group-KFold，本次记录运行第 1 个 fold。模型沿用 CNN-Conformer 代表配置，仅将分类头输出维度由 8 类调整为 6 类；评价阶段依据源语料验证集 Macro-F1 选择代表 epoch，再将同一 checkpoint 直接用于 CREMA-D 全体六类样本推理。

上述协议固定两项约束：目标语料不参与模型选择，目标语料评价沿用主实验中的对数梅尔频谱提取、batch 推理和统一指标统计口径。这样可以把数值差异主要解释为语料分布变化带来的影响。

4.4.2 实验结果与现象分析

本次跨语料库实验的代表模型出现在第 20 个 epoch。源语料验证集上，Accuracy 达到 0.58182，Macro-F1 达到 0.56897，UAR 达到 0.58333。同一 checkpoint 迁移到

表 4-13 跨语料库实验协议设置

项目	设置值	说明
源语料	RAVDESS 六类子集	1056 条语音，24 名用户
目标语料	CREMA-D 六类子集	7442 条语音，91 名用户
类别空间	六类公共情绪	neutral、happy、sad、angry、fearful、disgust
训练方式	source-only	仅用源语料训练，目标语料不参与选择
数据划分	GroupKFold, fold 1	按用户划分源训练集与源验证集
模型结构	CNN-Conformer 代表配置	保持主干结构和主要超参数
分类头	6 类输出	仅重构公共类别输出层
评价指标	Accuracy / Macro-F1 / UAR / ECE	源验证集选 epoch, 目标语料直接推理

CREMA-D 后，三项分类指标均明显下降，目标语料 ECE 也升至 0.56109。表4-14给出了本次运行的主要数值。

表 4-14 跨语料库实验结果

评价集合	代表 Epoch	Accuracy	Macro-F1	UAR	ECE
RAVDESS 源验证集	20	0.58182	0.56897	0.58333	0.22191
CREMA-D 目标语料	20	0.19377	0.09243	0.18936	0.56109




图 4-11 跨语料库实验结果可视化

表4-14和图4-11显示，当前模型在源语料内部能够形成一定程度的六类情绪边界，但该边界没有稳定迁移到目标语料。源验证集 Macro-F1 为 0.56897，目标语料 Macro-F1 降至 0.09243，说明同语料指标与跨语料库指标不能等同。结合训练现象看，源语料训练 F1 后期继续上升，而源验证集 Macro-F1 进入平台区，模型可能保留了较明显的源域偏向^[14,17-18]。

图4-11右图进一步显示，目标语料上多类样本的判别边界出现收缩，不同类别之间发生更广泛的相互偏移。该现象与目标语料 ECE 升高相互对应，表明问题不仅是个别类别召回率下降，也包括模型输出置信度与目标分布之间的失配。

本节结果应解释为跨语料库基线观察。当前记录仅运行 1 个 fold，且没有引入域不变约束、跨语料库特征标准化或目标域适配策略。相关研究表明，跨语料库语音情绪识别通常需要迁移子空间学习、域不变特征学习、对抗式域泛化或多任务建模来减弱语料间偏移，单纯依赖源语料监督往往难以获得稳定结果^[14,16-18,23,52]。因此，本节主要用于量化 source-only 条件下的指标落差，并与噪声实验共同说明代表模型在输入受扰和语料迁移条件下的边界。

4.5 本章小结

本章首先说明了语音情绪识别实验所采用的数据集、输入表示、比较模型结构以及训练参数设置，并在统一条件下对卷积神经网络基线模型、纯 Transformer 模型和 CNN-Conformer 模型进行了综合比较。综合实验结果表明，卷积结构在当前任务设定下仍然具有较强的参照意义，而 Transformer 系列模型虽然展现出一定建模潜力，但指标变化仍受到训练稳定性与过拟合现象的一定影响。

围绕 CNN-Conformer 模型所开展的进一步分析表明，模型指标不主要取决于结构规模的持续增加，而与时间下采样、层间特征融合、损失函数与采样策略以及模型容量控制之间的协调有关。噪声条件实验和类别层面分析补充展现了代表模型在输入信号质量变化、训练稳定性和类别混淆方面的结果，也为后续开展噪声增强训练与跨语料库验证提供了实验依据。

跨语料库实验进一步表明，在保持 CNN-Conformer 代表结构和主要超参数、仅将分类头重构为六类输出的条件下，RAVDESS 源验证集与 CREMA-D 目标语料之间仍存在明显指标落差。这一结果说明同语料条件下的较高指标不能直接等同于异源语料稳定性，也为后续研究引入域不变建模或目标域适配策略提供了依据。

结 论

语音情绪识别技术需要从非平稳语音信号中提取与情绪状态相关的声学特征。受用户差异、噪声干扰、语料分布变化和标注数据规模限制影响，传统模型在同源 clean 条件下取得的指标，很难能够直接代表实际应用环境中的稳定性。本文围绕对数梅尔频谱输入下的语音情绪识别方法开展研究，主要完成了数据集与信号处理流程整理、基础模型结构分析、卷积神经网络基线模型与 Transformer 系列模型对比，以及 CNN-Conformer 代表结构的进一步实验分析。

在数据与信号处理方面，本文选取 RAVDESS 语音情绪数据集作为主要实验对象，采用用户无关划分方式组织训练与评价。本文将原始语音统一重采样到 16kHz，并采用幅值归一化、短时傅里叶变换、梅尔滤波器组映射、对数变换和特征标准化等处理，形成以对数梅尔频谱为中心的输入表示。针对发话长度不一致的问题，本文结合固定尺寸整理和分块组织方式，使不同模型能够在相对统一的声学输入基础上进行比较。

在模型结构方面，本文首先分析了前馈神经网络、卷积神经网络、循环神经网络、注意力机制和 Transformer 结构的基本特点。随后，本文实现并比较了三类模型：卷积神经网络基线模型、纯 Transformer 模型和 CNN-Conformer 模型。实验结果显示，卷积神经网络基线模型取得 0.62196 的 Macro-F1、0.61667 的 Accuracy 和 0.61563 的 UAR，说明局部时频模式提取在当前任务条件下仍具有较强的参照意义。纯 Transformer 模型取得 0.51163 的 Macro-F1、0.52000 的 Accuracy 和 0.51250 的 UAR，说明缺少显式局部归纳偏置时，纯注意力结构在当前数据规模下较难稳定转化为验证集收益。

CNN-Conformer 模型在本文实验中取得较高的综合指标。代表配置采用无卷积前端时间分块输入、LayerNorm、192 维嵌入、4 层 Conformer 编码器、8 个注意力头、768 维前馈网络、卷积核大小 31、末层输出、注意力池化和频谱级混合增强。该配置取得 0.70563 的 Macro-F1、0.70000 的 Accuracy 和 0.70938 的 UAR。实验过程表明，CNN-Conformer 模型的结果不主要来自结构规模的持续增加，该结果还与前端标记化方式、模型容量控制、池化策略和训练阶段正则化之间的组合有关。无卷积前端时间分块输入减少了多级卷积压缩对细粒度时间线索的影响，混合增强在一定程度上缓解了用户无关划分下的过拟合风险。

本文还围绕已选定的 CNN-Conformer 代表模型开展了噪声条件实验和跨语料库实验。噪声条件实验表明，模型在 `clean` 条件下的较高指标不能直接等同于受扰输入下的稳定表现；不同噪声类型和不同 SNR 区间会形成不同的退化轨迹，其中持续低频覆盖型噪声对当前结构影响较为明显。跨语料库实验以 RAVDESS 六类子集为源语料、CREMA-D 六类子集为目标语料，在不使用目标语料监督信息的 `source-only` 设置下进行评价。源验证集 Macro-F1 为 0.56897，而目标语料 Macro-F1 降至 0.09243，说明当前模型对语料分布变化仍较为敏感。上述补充实验为本文结果提供了边界说明，也为后续鲁棒性建模提供了依据。

本文工作仍存在若干限制。第一，主要实验基于 RAVDESS 语音子集，数据规模和语料类型较为有限。第二，跨语料库实验只采用 `source-only` 基线设置，尚未引入域适配或域不变表示学习。第三，本文主要采用对数梅尔频谱作为输入表示，尚未系统比较自监督语音特征、多模态信息或文本内容对语音情绪识别的补充作用。后续研究可围绕真实噪声条件下的增强训练、跨语料库域适配、用户差异抑制、自监督语音表示轻量化应用以及多模态情绪识别展开，从而进一步提高模型在实际环境中的适应能力。

参考文献

- [1] Shou Y, Meng T, Ai W, et al. A Comprehensive Survey on Multi-modal Conversational Emotion Recognition with Deep Learning[J]. ACM Transactions on Information Systems, 2026, 44(2): 47:1-47:48.
- [2] Hou M, Zhang Z, Cao Q, et al. Multi-View Speech Emotion Recognition Via Collective Relation Construction[J]. IEEE/ACM Transactions on Audio, Speech, and Language Processing, 2022, 30: 218-229.
- [3] Ma H, Yarosh S. A Review of Affective Computing Research Based on Function-Component-Representation Framework[J]. IEEE Transactions on Affective Computing, 2023, 14(2): 1655-1674.
- [4] Raamkumar A S, Yang Y. Empathetic Conversational Systems: A Review of Current Advances, Gaps, and Opportunities[J]. IEEE Transactions on Affective Computing, 2023, 14(4): 2722-2739.
- [5] Mirsamadi S, Barsoum E, Zhang C. Automatic Speech Emotion Recognition Using Recurrent Neural Networks with Local Attention[C]//2017 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP). IEEE, 2017.
- [6] Chen S, Xing X, Zhang W, et al. DWFormer: Dynamic Window Transformer for Speech Emotion Recognition[C]//ICASSP 2023 - 2023 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP). IEEE, 2023: 1-5.
- [7] Wang Y, Lu C, Lian H, et al. Speech Swin-Transformer: Exploring a Hierarchical Transformer with Shifted Windows for Speech Emotion Recognition[C]//ICASSP 2024 - 2024 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP). IEEE, 2024: 11646-11650.
- [8] Liu Z, Kang X, Ren F. Dual-TBNet: Improving the Robustness of Speech Features via Dual-Transformer-BiLSTM for Speech Emotion Recognition[J]. IEEE/ACM Transactions on Audio, Speech, and Language Processing, 2023, 31: 2193-2203.
- [9] Thanh P V, Huyen N T T, Quan P N, et al. A Robust Pitch-Fusion Model for Speech Emotion Recognition in Tonal Languages[C]//ICASSP 2024 - 2024 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP). IEEE, 2024: 12386-12390.
- [10] Sampath A, Tavernor J, Mower Provost E. Efficient Finetuning for Dimensional Speech Emotion Recognition in the Age of Transformers[C]//ICASSP 2025 - 2025 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP). IEEE, 2025.
- [11] Lin W C, Busso C. Chunk-Level Speech Emotion Recognition: A General Framework of Sequence-to-One Dynamic Temporal Modeling[J]. IEEE Transactions on Affective Computing, 2023, 14(2): 1215-1227.
- [12] Peng Z, Lu Y, Pan S, et al. Efficient Speech Emotion Recognition Using Multi-Scale CNN and Attention[C]//ICASSP 2021 - 2021 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP). IEEE, 2021: 3020-3024.
- [13] Zhang L, Wang Y, Du J, et al. CNN-BiGRU Speech Emotion Recognition Based on Attention Mechanism[C]//2023 2nd International Conference on Artificial Intelligence and Intelligent Information Processing (AIIP). IEEE, 2023: 85-89.
- [14] Zhang W, Song P. Transfer Sparse Discriminant Subspace Learning for Cross-Corpus Speech Emotion Recognition[J]. IEEE/ACM Transactions on Audio, Speech, and Language Processing, 2020,

- 28: 307-318.
- [15] Leem S G, Fulford D, Onnela J P, et al. Selective Acoustic Feature Enhancement for Speech Emotion Recognition With Noisy Speech[J]. *IEEE/ACM Transactions on Audio, Speech, and Language Processing*, 2024, 32: 917-929.
 - [16] Su B H, Lee C C. Unsupervised Cross-Corpus Speech Emotion Recognition Using a Multi-Source Cycle-GAN[J]. *IEEE Transactions on Affective Computing*, 2023, 14(3): 1991-2004.
 - [17] Lu C, Zong Y, Zheng W, et al. Domain Invariant Feature Learning for Speaker-Independent Speech Emotion Recognition[J]. *IEEE/ACM Transactions on Audio, Speech, and Language Processing*, 2022, 30: 2217-2230.
 - [18] Gao Y, Wang L, Liu J, et al. Adversarial Domain Generalized Transformer for Cross-Corpus Speech Emotion Recognition[J]. *IEEE Transactions on Affective Computing*, 2024, 15(2): 697-708.
 - [19] Mao S, Ching P C, Lee T. Enhancing Segment-Based Speech Emotion Recognition by Iterative Self-Learning[J]. *IEEE/ACM Transactions on Audio, Speech, and Language Processing*, 2022, 30: 123-134.
 - [20] Hao Y. Channel Attention Scale Feature Fusion with SwiGLU for Speech Emotion Recognition [C]//2024 5th International Conference on Electronic Communication and Artificial Intelligence (ICECAI). IEEE, 2024.
 - [21] He Y, Minematsu N, Saito D. Multiple Acoustic Features Speech Emotion Recognition Using Cross-Attention Transformer[C]//ICASSP 2023 - 2023 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP). IEEE, 2023.
 - [22] Prabhu N R, Lehmann-Willenbrock N, Gerkmann T. End-to-End Label Uncertainty Modeling in Speech Emotion Recognition Using Bayesian Neural Networks and Label Distribution Learning[J]. *IEEE Transactions on Affective Computing*, 2024, 15(2): 579-592.
 - [23] Ahn C S, Rana R, Busso C, et al. Multitask Transformer for Cross-Corpus Speech Emotion Recognition[J]. *IEEE Transactions on Affective Computing*, 2025, 16(3): 1581-1591.
 - [24] Zhou H, Du J, Tu Y H, et al. Using Speech Enhancement Preprocessing for Speech Emotion Recognition in Realistic Noisy Conditions[C]//Proc. Interspeech 2020. 2020: 4701-4705.
 - [25] Tzeng J T, Leem S G, Salman A N, et al. Noise-Robust Speech Emotion Recognition Using Shared Self-Supervised Representations with Integrated Speech Enhancement[C]//ICASSP 2025 - 2025 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP). IEEE, 2025: 1-5.
 - [26] Pepino L, Riera P, Ferrer L. Emotion Recognition from Speech Using wav2vec 2.0 Embeddings[C]//Interspeech 2021. 2021: 3400-3404.
 - [27] Morais E d S, Hoory R, Zhu W, et al. Speech Emotion Recognition Using Self-Supervised Features [C]//ICASSP 2022 - 2022 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP). IEEE, 2022: 6922-6926.
 - [28] Fang Y, Xing X, Xu X, et al. Exploring Downstream Transfer of Self-Supervised Features for Speech Emotion Recognition[C]//Interspeech 2023. 2023.
 - [29] Baevski A, Zhou H, Mohamed A, et al. wav2vec 2.0: A Framework for Self-Supervised Learning of Speech Representations[C]//Advances in Neural Information Processing Systems: vol. 33. 2020: 12449-12460.
 - [30] Hsu W N, Bolte B, Tsai Y H H, et al. HuBERT: Self-Supervised Speech Representation Learning by Masked Prediction of Hidden Units[J]. *CoRR*, 2021, abs/2106.07447.

- [31] Chen S, Wang C, Chen Z, et al. WavLM: Large-Scale Self-Supervised Pre-Training for Full Stack Speech Processing[J]. IEEE Journal of Selected Topics in Signal Processing, 2022, 16(6): 1503-1514.
- [32] Gat I, Aronowitz H, Zhu W, et al. Speaker Normalization for Self-Supervised Speech Emotion Recognition[C]//ICASSP 2022 - 2022 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP). IEEE, 2022: 7342-7346.
- [33] Feng T, Narayanan S. PEFT-SER: On the Use of Parameter Efficient Transfer Learning Approaches For Speech Emotion Recognition Using Pre-trained Speech Models[C]//2023 11th International Conference on Affective Computing and Intelligent Interaction (ACII). IEEE, 2023: 1-8.
- [34] Lashkarashvili N, Wu W, Sun G, et al. Parameter Efficient Finetuning for Speech Emotion Recognition and Domain Adaptation[C]//ICASSP 2024 - 2024 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP). IEEE, 2024: 10986-10990.
- [35] Lee Y, Yoon S, Jung K. Multimodal Speech Emotion Recognition Using Cross Attention with Aligned Audio and Text[C]//Interspeech 2020. 2020: 2717-2721.
- [36] Hu D, Chen C, Zhang P, et al. A Two-Stage Attention Based Modality Fusion Framework for Multimodal Speech Emotion Recognition[J]. IEICE Transactions on Information and Systems, 2021, 104-D(8): 1391-1394.
- [37] Santoso J, Yamada T, Ishizuka K, et al. Speech Emotion Recognition Based on Self-Attention Weight Correction for Acoustic and Text Features[J]. IEEE Access, 2022, 10: 115732-115743.
- [38] Kim K, Cho N. Focus-attention-enhanced Crossmodal Transformer with Metric Learning for Multimodal Speech Emotion Recognition[C]//Interspeech 2023. 2023: 2673-2677.
- [39] Sun D, He Y, Han J. Using Auxiliary Tasks In Multimodal Fusion of Wav2vec 2.0 And BERT for Multimodal Emotion Recognition[C]//ICASSP 2023 - 2023 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP). IEEE, 2023: 1-5.
- [40] Li Y. Enhancing Speech Emotion Recognition for Real-World Applications via ASR Integration[C]//ACIIW 2023. 2023: 1-5.
- [41] Zaidi S A M, Latif S, Qadir J. Cross-Language Speech Emotion Recognition Using Multimodal Dual Attention Transformers[J]. CoRR, 2023, abs/2306.13804.
- [42] Luna-Jiménez C, Kleinlein R, Griol D, et al. A Proposal for Multimodal Emotion Recognition Using Aural Transformers and Action Units on RAVDESS Dataset[J]. Applied Sciences, 2022, 12(1): 327.
- [43] Pappagari R K, Prasanna S M L. Music Theory-Inspired Acoustic Representation for Speech Emotion Recognition[J]. IEEE/ACM Transactions on Audio, Speech, and Language Processing, 2023, 31: 2534-2547.
- [44] Fan W, Xu X, Cai B, et al. ISNet: Individual Standardization Network for Speech Emotion Recognition[J]. IEEE/ACM Transactions on Audio, Speech, and Language Processing, 2022, 30: 1803-1814.
- [45] Yang S w, Chi P H, Chuang Y S, et al. SUPERB: Speech Processing Universal PERFORMANCE Benchmark[C]//Interspeech 2021. 2021: 1194-1198.
- [46] Park S, Mark M, Park B, et al. Using Speaker-Specific Emotion Representations in Wav2vec 2.0-Based Modules for Speech Emotion Recognition[J]. Computers, Materials and Continua, 2023, 77(1): 1009-1030.
- [47] Kang L, Zhang L, Jiang D. Learning Robust Self-Attention Features for Speech Emotion Recognition with Label-Adaptive Mixup[C]//ICASSP 2023 - 2023 IEEE International Conference on

- Acoustics, Speech and Signal Processing (ICASSP). IEEE, 2023: 1-5.
- [48] Liu Y, Sun H, Guan W, et al. A Discriminative Feature Representation Method Based on Cascaded Attention Network With Adversarial Strategy for Speech Emotion Recognition[J]. IEEE/ACM Transactions on Audio, Speech, and Language Processing, 2023, 31: 1063-1074.
- [49] Zou H, Si Y, Chen C, et al. Speech Emotion Recognition with Co-Attention Based Multi-Level Acoustic Information[C]//ICASSP 2022 - 2022 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP). IEEE, 2022.
- [50] Vaswani A, Shazeer N, Parmar N, et al. Attention Is All You Need[C]//Advances in Neural Information Processing Systems: vol. 30. Curran Associates, Inc., 2017: 5998-6008.
- [51] Gulati A, Qin J, Chiu C, et al. Conformer: Convolution-augmented Transformer for Speech Recognition[C]//Proc. Interspeech 2020. 2020: 5036-5040.
- [52] Luo H, Han J. Nonnegative Matrix Factorization Based Transfer Subspace Learning for Cross-Corpus Speech Emotion Recognition[J]. IEEE/ACM Transactions on Audio, Speech, and Language Processing, 2020, 28: 2047-2060.

致 谢

值此论文完成之际，谨向在毕业设计与论文写作过程中给予帮助的老师、同学和家人表示感谢。

首先，感谢导师张哈希老师在选题确定、实验设计、论文结构和写作规范等方面给予的指导。导师对研究问题的把握、对实验结果解释的要求以及对论文表述细节的修改意见，使本文能够在较为清晰的逻辑框架下完成。

其次，感谢计算机学院相关课程与实践环节提供的知识基础。数据处理、深度学习模型实现、实验记录和结果分析等工作，均受益于本科阶段课程训练与项目实践积累。

同时，感谢同学们在实验环境配置、论文排版和问题讨论过程中给予的帮助。相关交流为本文实验复现和写作修改提供了支持。

最后，感谢家人在学习和生活上的理解与支持。家人的陪伴使本人能够较为稳定地完成毕业设计工作。