北京理工大學

本科生毕业设计（论文）

北京理工大学本科生毕业设计（论文）题目

The Subject of Undergraduate Graduation Project (Thesis) of Beijing Institute of Technology

学　　院：计算机学院

专　　业：软件工程

班　　级：07822201

学生姓名：姜现日

学　　号：1820191086

指导教师：张哈希

2026 年 3 月 11 日

原创性声明

本人郑重声明：所呈交的毕业设计（论文），是本人在指导老师的指导下独立进行研究所取得的成果。除文中已经注明引用的内容外，本文不包含任何其他个人或集体已经发表或撰写过的研究成果。对本文的研究做出重要贡献的个人和集体，均已在文中以明确方式标明。

特此申明。

本人签名：　　日 期：　　年　　月　　日

关于使用授权的声明

本人完全了解北京理工大学有关保管、使用毕业设计（论文）的规定，其中包括：①学校有权保管、并向有关部门送交本毕业设计（论文）的原件与复印件；②学校可以采用影印、缩印或其它复制手段复制并保存本毕业设计（论文）；③学校可允许本毕业设计（论文）被查阅或借阅；④学校可以学术交流为目的，复制赠送和交换本毕业设计（论文）；⑤学校可以公布本毕业设计（论文）的全部或部分内容。

本人签名：　　日 期：　　年　　月　　日

指导老师签名：　　日 期：　　年　　月　　日

北京理工大学本科生毕业设计（论文）题目

摘　要

本文……。

摘要正文选用模板中的样式所定义的“正文”，每段落首行缩进 2 个字符；或者手动设置成每段落首行缩进 2 个汉字，字体：宋体，字号：小四，行距：固定值 22 磅，间距：段前、段后均为 0 行。阅后删除此段。

摘要是一篇具有独立性和完整性的短文，应概括而扼要地反映出本论文的主要内容。包括研究目的、研究方法、研究结果和结论等，特别要突出研究结果和结论。中文摘要力求语言精炼准确，本科生毕业设计（论文）摘要建议 300-500 字。摘要中不可出现参考文献、图、表、化学结构式、非公知公用的符号和术语。英文摘要与中文摘要的内容应一致。阅后删除此段。

关键词：北京理工大学；本科生；毕业设计（论文）——请在“main.tex”开头设置

The Subject of Undergraduate Graduation Project (Thesis) of Beijing Institute of Technology

Abstract

In order to study……

Abstract 正文设置成每段落首行缩进 2 字符，字体：Times New Roman，字号：小四，行距：固定值 22 磅，间距：段前、段后均为 0 行。阅后删除此段。

Key Words: BIT; Undergraduate; Graduation Project (Thesis)

目 录

摘 要 I
Abstract II
第 1 章 绪论 1
1.1 研究背景 1
1.2 研究意义 2
1.3 研究现状及发展趋势 4
1.3.1 语音情感识别研究的发展历程 4
1.3.2 语音情感识别数据集的研究现状 5
1.3.3 声学特征与信号处理方法的研究现状 6
1.3.4 基于深度学习的语音情感识别模型研究现状 7
1.3.5 注意力机制与 Transformer 研究现状 8
1.3.6 低资源、噪声环境及跨语料库泛化研究现状 8
1.3.7 现有研究的总结与不足 9
1.4 研究内容 10
1.5 本文组织结构 11
第 2 章 音频数据集与信号处理方法 13
2.1 音频情感数据集的类型与选择 13
2.2 信号处理技术 13
2.2.1 面临难点 13
2.2.2 现有技术 13
2.2.3 本文采用的信号处理流程 13
2.3 本章小结 13
第 3 章 模型结构 14
3.1 现有基础模型结构 14
3.2 注意力机制 14
3.3 Transformer 结构 14
3.4 本章小结 14
第 4 章 实验设计与实验分析 15
4.1 实验参数与设置 15
4.2 综合实验 15
4.3 噪声条件实验 15

4.4 跨语料库相关实验 15
4.5 更细粒度分析 15
4.6 本章小结 15
结 论 16
参考文献 17
致 谢 18

第 1 章 绪论

1.1 研究背景

近年来，随着人工智能技术的飞速发展，人机交互已逐渐摆脱以执行简单命令为中心的阶段，并向着更加精细化理解用户状态与意图的方向扩展。如果说过去的智能系统主要集中于解析用户“说了什么”这类显式信息，那么如今，系统同步洞察用户“在何种情绪状态下说话”的能力正变得日益重要。情绪直接影响着人类的决策过程、反应方式以及交互态度。因此，能够理解情绪信息的系统可以实现更加自然、对人类更加友好的交互体验。事实上，情感识别技术在教育、心理咨询、医疗辅助、客户服务及数字内容交互等多个应用场景中均展现出了巨大的潜力，可被视为下一代智能系统为了实现与人类更高效协作所必须具备的核心能力之一。

获取情感信息的方法多种多样，包括面部表情、生理信号、文本及行为模式等。在这些媒介当中，语音作为情感识别的重要载体一直备受关注。语音是人类最自然的交流手段之一，其优势在于能够以较低的成本、在无需复杂额外设备的条件下轻松获取。此外，语音中不仅包含简单的语言维度语义，还蕴含了语调、语速、重音、节奏、能量及音色等丰富的非语言线索，这些线索为反映说话者的情绪状态提供了详尽的信息支撑。即便是相同的句子，由于语速、音高、发音力度以及呼吸变化的不同，也能被解读出截然不同的情感。这充分表明了语音是表达情感的直接且多层次的通道。正是基于这些特性，语音情感识别已成为旨在实质性提升人机交互水平的核心研究方向。

基于语音的情感识别研究由来已久，其方法论也在不断地演进。在早期研究中，广泛采用的方法是首先提取由人工设计的声学特征（如梅尔频率倒谱系数、音高、能量及韵律等），随后利用隐马尔可夫模型、高斯混合模型以及支持向量机等传统的机器学习分类器对情感进行分类。这类方法的优点在于模型解释性较强且实现过程直观清晰，但在充分表征如情感这般边界模糊且具有强烈时间序列依赖性的信息时存在一定的局限性。此后，随着深度学习的快速发展，卷积神经网络、循环神经网络、长短期记忆网络及双向长短期记忆网络等架构被引入该领域。研究重心逐渐向模型自动学习语音的时频模式方向转移。近年来，研究者们已不再局限于堆叠更深的网络架构，而是越来越侧重于引入注意力机制与主干架构结合，从而使模型能够更具

选择性地聚焦于话语内部对情感表达至关重要的时间段和特征。这一转变表明了语音情感识别正从传统的以特征工程为中心的阶段，向能够进行精细表征学习及重要特征区间选择的以模型结构为中心的阶段迈进。

然而，目前的语音情感识别仍面临诸多难以克服的挑战。最根本的问题在于情感本身的模糊性与主观性。人类的情感并非总是以边界分明的类别存在，且即便是同一种情感，在不同的说话者身上也可能表现出截然不同的语音特征。同时，如愤怒与兴奋、快乐与惊讶等紧密相邻的情感类别，往往共享着相似的声学特性，导致分类边界易趋于模糊。此外，语音情感识别的性能极大地依赖于数据集的条件与质量、说话人构成、录音环境以及语言背景等因素。如果数据集之间存在较大的分布差异，在一个数据集上训练的模型很容易在其他数据集或陌生的说话者条件下出现性能退化。这种现象在跨说话人及跨语料库设定下尤为突出。在实际的应用环境中，背景噪声、混响、信道差异以及设备特征差异等因素都会干扰情感线索的稳定提取。此外，带有情感标注的语音数据相比于普通语音数据规模更小，且收集成本高昂，导致过于复杂的模型并不能总是保证取得更优的效果。因此，当下的语音情感识别研究不应仅仅停留在提出更复杂结构的层面上，而应当持续探索如何在数据受限以及多变的环境条件下获取稳定、可靠的情感表征。

基于上述背景，当下的语音情感识别研究呈现出两方面的发展趋势：一方面致力于寻找更具表达力的特征表征；另一方面则聚焦于设计能够在受限数据规模和实际环境约束下依然稳定运行的模型架构。特别是考虑到情感信息通常并非均匀分布在整个发音片段中，而是集中体现于特定的时间段或特定的声学模式中。在此背景下，能够针对性地突出关键部分的注意力机制架构构成了具有重要价值的研究方向。因此，本文主要针对基于语音信号的情感识别问题，在综合考量声学特征表征与模型架构之间关系的基础上，探究一种能够在受限数据条件下相对稳定地学习情感特征信息的基于注意力机制的语音情感识别系统。这一研究动机也为本文后续所涉及的数据集选取、信号处理流程制订、模型架构设计以及实验分析提供了核心出发点。

1.2 研究意义

本研究在将语音情感识别技术拓展至多种实际应用场景方面具有重要的现实意义。作为深入理解人类状态与意图的核心技术，情感识别在心理健康辅助诊断、客户服务系统、教育类智能导学以及基于情感的内容生成等多个领域，持续展现出广

阔的应用前景。尤其值得一提的是，语音信号能够在无需依托复杂设备的条件下较为自然地获取，并且由于其包含了语调、语速、能量、重音及音色等丰富的情感线索，被认为是非常容易与实际交互环境相接轨的情感信号。基于此，本研究并未将对语音情感识别技术的探讨仅停留在抽象概念层面，而是致力于在具体的系统层面上进行设计与验证，这构成了本研究的首要意义。换言之，本研究具备了将基于语音的情感识别技术推向实际应用的基础实践性质，在本科阶段通过系统实现与实验验证来探究其可行性，具有显著的理论与实践价值。

此外，本研究还将近年来在语音情感识别领域中占据重要地位的注意力机制应用于实际基于声学的情感识别问题中并进行深入探讨，这也赋予了本研究重要的方法论意义。语音情感识别研究已从早期依赖手工特征及传统分类器主导的方法阶段，发展至利用卷积神经网络、循环神经网络、长短期记忆网络等深度学习架构的阶段；而近年来，能够针对话语内部在情感上具有关键作用的时间片段或频率区域进行选择性聚焦的基于注意力机制的研究正日益活跃。然而，对于本科毕业论文而言，其核心不在于提出全新的大规模网络架构，而在于将已被验证有效性的机制恰当地部署于实际数据与具体的模型结构中，并通过实验验证其应用价值。因此，本研究并非单纯地将注意力机制作为前沿技术生搬硬套，而是旨在具体剖析其如何在语音情感识别架构中补全对情感信息的表征能力。

进一步而言，本研究在充分考量语音情感识别实际所面临的多重约束条件的背景下，探讨了模型架构与实验设计之间的关系，这同样具有深刻的意义。受制于情感边界的模糊性、跨说话人差异、数据集间的分布差异、噪声环境、受限的数据规模以及跨语料库的泛化难题，语音情感识别成为一个难以仅凭单纯的准确率对比便能全面评估的研究领域。即便是相同的模型，依据其所经历的预处理流程、选用的特征表征方式以及训练所处的数据条件的不同，其最终结果亦会产生巨大偏差。在这一语境下，本研究并不侧重于强调特定模型在特定数据集上所取得的高分，而是将重心放在探究在受限数据及现实约束条件下，何种输入表征、何种模型架构以及何种评估策略能够产出相对稳定且合理的结果。这为系统性地审视影响语音情感识别实验结果的各项因素，并更为明晰地揭示模型设计与实验设计之间的内在联系，提供了基础性的参考框架。

最后，本研究将语音信号处理、特征提取、数据预处理、深度学习模型设计、注意力机制的引入、训练与推理流程的构建，乃至实验评估与结果分析的全过程，统

合于一个单一的工程项目之中，这展现了突出的学习与工程价值。语音情感识别绝非仅靠单一算法即可完成的孤立任务，而是一个需要深刻理解数据特性与质量、合理选择输入表征方法、在模型复杂度与数据规模间取得平衡，并有机串联最终结果解释与分析全流程的综合性系统工程问题。因此，本研究并非对已有研究的简单复现，而是基于相关文献开展问题定义，在受限条件下进行系统设计，并通过实验结果验证其合理性。这一连贯的实施过程，凸显了本研究在学术训练与工程实践层面的双重意义。

综合来看，本研究的意义在于从具体系统的维度验证语音情感识别技术的实际应用可行性，通过实验探明注意力机制的应用潜力，梳理并强调了兼顾现实约束的实验设计的重要性，并由此提出了一套在本科层次上具备可重复性的综合性研究范例。也就是说，在语音情感识别领域激烈的技术角逐中，本研究的目标并非单纯追求最前沿的性能指标，而是旨在阐明一条在受限条件下依然能够进行有意义的架构设计与科学验证的研究路径，其价值正在于此。

1.3 研究现状及发展趋势

语音情感识别研究伴随着情感计算与人机交互的发展而持续拓宽。早期的研究主要围绕有限的声学特征及传统分类器展开，而随着深度学习的引入，研究领域逐渐向时频表征学习、注意力机制、Transformer 架构以及自监督表征的应用等方向扩展。与此同时，近年来的研究已不再局限于单一的准确率提升，而是开始兼顾数据集的多样性、噪声环境、跨说话人及跨语料库泛化、计算效率等实际应用层面的问题。因此，为了准确把握当前语音情感识别领域的研究动态，不仅需要梳理模型的发展脉络，更应当综合审视数据集、特征表征、架构设计、泛化难题以及效率优化等多个维度。综上所述，本节旨在系统梳理语音情感识别领域的核心研究脉络，从而为本文后续的研究定位与问题意识奠定清晰的理论基础。

1.3.1 语音情感识别研究的发展历程

语音情感识别的发展演进大体可划分为四个阶段：传统的基于特征工程阶段、基于机器学习阶段、基于深度学习阶段，以及利用注意力机制、Transformer 与预训练表征的新兴阶段。在早期研究中，主流方法高度依赖于人工设计与情感相关的声学特征，并以此作为情感分类的依据。该时期的研究核心在于探究从语音信号中提取

何种特征方能最精准地反映情感差异，其中梅尔频率倒谱系数、音高、能量、共振峰及韵律等特征被广泛采用。这类方法的优势在于其具备较强的直观解释性，且能在数据规模较小的条件下开展实验；然而，其在充分刻画情感的复合性及时序动态变化方面存在明显的局限。

随后的研究不仅关注特征设计本身，亦开始着力提升分类算法的性能。由此，支持向量机、隐马尔可夫模型、高斯混合模型、K 近邻算法及随机森林等多种机器学习分类器被相继引入，学界广泛开展了基于手工提取特征与各类分类器组合的情感分类性能比较研究。在此阶段，诸如特征选择、数据归一化以及降维等辅助技术亦被纳入讨论范畴，语音情感识别由此被进一步系统化为典型的模式分类问题。尽管如此，此类方法仍深度受制于研究人员的先验判断，难以充分捕捉情感表达中固有的非线性特征与长期依赖关系。

深度学习的引入构成了语音情感识别研究的重大转折点。卷积神经网络被广泛应用于从语谱图或对数梅尔谱等时频表征中自动学习局部模式；而循环神经网络、长短期记忆网络等则被部署用于对发音内部的时间连续性与上下文依赖关系进行建模。此后，结合卷积与循环结构的混合架构应运而生，进一步强化了同步学习局部特征与时序信息的趋势。在这一进程中，语音情感识别逐渐实现了从依赖手工特征向侧重表征学习的范式转换。

当下，学界正积极引入注意力机制与 Transformer 架构。鉴于情感信息通常并非在整个语音片段中呈均匀分布，而是更为集中地体现于特定的时间区间或声学模式之中，赋权予关键信号特征的注意力架构顺理成章地成为研究的自然延伸。同时，Transformer 凭借其自注意力机制，能够更为直接地处理长期依赖并把握全局上下文，从而被视作弥补传统卷积与循环架构固有缺陷的有力方案。此外，将自监督语音模型的预训练表征应用于语音情感识别的研究亦呈上升趋势，在情感标签稀缺的语境下，旨在通过迁移学习最大化地利用普遍意义上的语音表征。综上所述，当前的研究脉络正从传统的特征工程向深度学习过渡，并进一步演化向基于注意力与 Transformer 的高阶表征学习方向，这一转变构成了本文后续研究设计的核心背景。

1.3.2 语音情感识别数据集的研究现状

数据集始终是语音情感识别研究的出发点，同时也是解读模型性能的基准要素。目前学界广泛采用的数据集包括 RAVDESS、IEMOCAP、EMO-DB、SAVEE、TESS、

CREMA-D、MSP-Podcast、MSP-IMPROV 以及 CASIA 等。这些语料库在语种、说话人规模、情感类别划分、录音环境、发音模式以及标注范式等维度上均呈现出显著区别。此类差异不仅体现于样本数量的多寡，更直接决定了模型所能习得的情感线索的本质特征及其泛化潜力。

当前主流的语音情感识别数据集大体可分为表演型语料库与自发型或自然型语料库。诸如 RAVDESS、EMO-DB、CASIA 等表演型语料库，多收录了在受控环境下由演员演绎产生的情感语音；其优势在于情感标注相对明确，实验具备较高的可重复性。相对而言，IEMOCAP、MSP-IMPROV 等语料库则融入了对话、即兴或自然发音等元素，能够更为逼真地反映出实际交互场景中的情感流露。然而自然型数据集不可避免地伴随着情感边界模糊、标注一致性堪忧以及系统预处理难度加剧的挑战。由此可见，数据集的遴选绝非单纯依据规模或被引频次，而是与研究重点（测重界限分明的基准测试验证，还是更关注向真实环境的泛化演进）密不可分。

对于情感标注手段而言，数据集可划分为含如愤怒、快乐等独立情感的离散类别标注，与包含效价、唤起度等向量维度的连续维度标注两类。前者适用于验证主流的典型分类实验，后者则在连续空间内对情感进行更为细腻的刻画。然而离散类别数据集往往难以全盘反映情感的复合渐变特征，而维度标注的实验设计与评价体系设定将面对更多技术困难。近年来相关讨论不断深化，从数据集本身的内部构造来评价基准模型的论述正日益扩展。综上所述，数据集既是语音情感识别不可或缺的实验土壤，更在本质上充当着界定研究命题深度与泛化边界的核心要素。

1.3.3 声学特征与信号处理方法的研究现状

在语音情感识别中，输入特征表征及信号处理的价值无可替代。早期的研究中，主流思路多仰赖研究人员依据先验知识手工提取具有情感区分度的声学特征，例如梅尔频率倒谱系数、音高、能量、过零率等。这些特征既可单独发挥效用，亦可组成综合特征集。特别的是，建立在 OpenSMILE 工具之上的 eGeMAPS、ComParE 等特征组长久以来作为情感识别领域的重要标杆，发挥了参照作用。

伴随着深度学习的全面渗透，输入表征亦突破了定长特征向量，拓展至以语谱图、对数梅尔谱图等为主导的时频表征。此类表征手段能够有效地保留语音内在的动态时序波动与频谱特征，与卷积神经网络及 Transformer 等深度学习架构展现出极高的协同效率。近期的研究不仅对比同一原始音频提取的多重表征，亦致力于探讨

表征融合技术，明确输入特征已成为决定模型在何种“视角”感知情感的核心设计维度。

在信号处理方面也在朝着日益细致的角度延伸。针对时序非同一长度特征引发的需求进行预填补、滑移切开、序列切块以及强化对于背景干扰消除、扩增的数据反演等皆受到了广泛关注。近年来诸多探讨噪声环境情感识别文献强调，仅凭实验室纯净环境难以验证泛功能，应当全面检测包含干扰噪声或混响衰退情景以加强鲁棒性。由此可见，声学特征萃取与信号补正技术非但并非无足轻重，相反成为了确保数据底座和后续模型相互融合发挥战力的重要科研独立枢轴。

1.3.4 基于深度学习的语音情感识别模型研究现状

基于深度学习的语音情感识别模型，最初是为了突破传统依赖手工特征模式的方法瓶颈而提出，现已成为该领域的基础主流架构。早期的深度学习研究主要围绕卷积神经网络与循环神经网络展开。卷积神经网络能够从时频特征中高效提取局部模式，而循环神经网络、长短期记忆网络等则适用于对发音过程中的时间连续性与序列上下文进行建模。在此基础上，结合卷积网络提取局部特征与循环网络捕获长时序结构优势的混合架构被迅速推广并广泛应用。

相较于传统机器学习分类器，这些深度学习架构不仅具有强大的非线性映射能力，更能够自动学习未经人为定义的深层高维表征。卷积神经网络可有效提取特定频段的能量集中或谱面结构的局部差异，而长短期记忆网络则能够对跨越整段语音的音高变化与能量轨迹进行建模。随着近期各类一维、二维卷积变体及其与循环架构融合机制的相继提出，语音情感识别已被普遍视作一项高度复杂的序列学习任务。

然而，深度学习架构亦存在固有的局限性。卷积网络受限于局部感受野，难以直接获取全局上下文依赖；而循环网络的顺序计算机制导致并行化效率低下，且在处理超长序列时容易面临较高的计算开销。更为关键的是，由于带有情感标注的训练数据通常规模较小，盲目增加模型参数极易导致严重的过拟合问题，使得模型仅能记忆特定训练集的表征，进而偏离对情感本质的通用理解。因此，当前的研究早已超越了单纯增加网络层数的单一思路，转而在保留必要表征能力的前提下，积极探索通过引入注意力机制与相关优化架构来强化全局特征捕捉，并在性能与模型复杂度之间寻求更为合理的平衡。

1.3.5 注意力机制与 Transformer 研究现状

在语音中，情感信息并非均匀分布于整个发音过程，这构成了注意力机制被引入语音情感识别的重要背景。现有的卷积与循环架构在处理输入时通常持相对均等的态度，然而实际的情感线索往往更集中地体现于特定的时间片段、特定的词汇抑或特定的频段区域。为充分反映这一特性，近年来的研究积极采用注意力机制，促使模型为情感表达中更为关键的部分赋予更高的权重。在此过程中，不仅出现了简单的加权叠加形式注意力，多头注意力、局部注意力、交叉注意力以及通道注意力等多种衍生结构亦相继涌现。

凭借以自注意力为核心的机制，Transformer 能够直接对序列内部的全局关系进行建模，在语音情感识别研究中逐步占据了核心地位。不同于传统循环网络严重依赖串行处理构架，Transformer 不仅支持并行计算，更能直接把握长距离依赖关系，因而在解析复杂的语音结构时展现出显著优势。基于此，学界提出了纯 Transformer 架构的情感识别模型、混合卷积与 Transformer 的架构、将视窗 Transformer 机制应用于语谱图分析的模型，以及结合移位窗口或动态窗口的各类型改进架构。最新研究表明，Transformer 在全局上下文理解与长时依赖建模方面具备天然优势，若辅以注意力机制的精准导向，将能更为精细地捕捉到承载重要情感信息的底层特征。

然而，基于注意力机制与 Transformer 的方法并非在所有场景下均适用。此类结构普遍伴随着庞大的参数规模与算力开销，并对训练数据量提出了较高要求。在数据量受限的条件下，模型极易因过度参数化而无法获得与之匹配的泛化性能。因此，当前的研究早已摒弃了盲目扩大 Transformer 规模的单一方向，转而深入探索如何在卷积主干网络中内嵌轻量级注意力模块，或是引入较为简洁的辅助性注意力架构。这一趋势表明：注意力机制与 Transformer 并非仅仅作为技术堆砌，而是需要与实际可用的数据规模及计算资源相平衡，进行合理取舍的关键技术。

1.3.6 低资源、噪声环境及跨语料库泛化研究现状

在目前的语音情感识别研究中，相较于单一数据集上的准确率提升，模型在实际且真实环境下的鲁棒性与泛化能力正成为更为关键的衡量标准。这一发展趋势主要受制于两项客观条件。其一，由于带有精准情感标注的音频数据收集成本极为高昂，相关数据集的整体规模通常较小，导致诸多研究至今依然受限于低资源的数据条件。其二，在真实应用场景中，环境噪声、混响干扰、信道差异、不同说话人的发

音习惯、甚至预训练数据集与目标任务库间的数据分布偏移等变量相互交织，极易导致同一模型在不同的推理工况下产生剧烈的性能波动。

针对噪声环境的专项研究中，添加噪声模拟、混响模拟、端到端语音增强机制以及各项数据扩增技术成为了讨论的核心焦点。大量探讨含噪语音情感识别的文献明确指出，若仅基于纯净环境下的实验数据，将很难科学评估模型向实际应用延伸的可行性，因而多类混合噪声背景下的鲁棒性测试势在必行。与此同时，旨在攻克跨说话人及跨语料库配置瓶颈的研究团队，正积极探寻减弱模型对特定源领域或说话人样本过度依赖的脱敏机制。领域自适应、迁移学习、域泛化策略、多条件混合训练以及更为严密的特征归一化方案，皆成为化解此项难题的重要技术路径。

另一方面，将基于自监督学习的预训练语音模型应用于低资源情感识别的尝试正呈现快速上升趋势。包含 Wav2Vec2、HuBERT、WavLM 及 DistilHuBERT 在内的大型预训练表征，能够依托其从无标注数据中汲取的普遍声学规律，向受阻于标注壁垒的情感分析回馈深层次表征支撑。无可否认，此类大规模模型的运行成本仍然高昂，迁移微调的稳定性尚无法完全保证，更为关键的是，前期海量预训练领域分布与特定靶向情感数据集之间存在的系统性域偏移现象难以彻底消除。因此，融合了低资源限制、噪声环境及跨语料库的综合问题，本质上已演变成了迫切要求研究者对输入特征、模型结构、学习策略至评估框架进行全局重构的复合型前沿命题。

1.3.7 现有研究的总结与不足

综上所述，语音情感识别研究的演进路线，已经从传统的高维度手工特征与机器学习分类器构筑的体系，逐步拓展至基于时频表征的深度神经网络模型、以及利用注意力机制、Transformer 架构与自监督特征利用的综合研究阶段。在应用数据集的遴选层面，早期研究多依赖表演型的预设语料，而今则扩展至包含自然对话与真实环境特质的语料库。而在实验设定评价维度，研究视点也从单一语料库的准确率，转向包含噪声环境、跨说话人及跨语料库环境里的高标准泛化指标考核。此等发展进程表明，语音情感识别已从单纯的分类模型比较，演变为融合数据条件、输入表征、模型架构及泛化兼容等综合考量的深入研究领域。

不可忽视的是，现存研究依然存在几项共通不足。第一，许多研究在特定数据集条件内取得优异表现，但测试对象切换为跨来源说话人抑或跨界语料库时则发生显著性能衰退，暴露出脆弱的泛化能力。第二，尽管引入注意力机制及 Transformer

之类的高性能架构备受关注，却缺乏深入结合实际算力约束及数据局限来进行针对性的轻量化设计研究。第三，在系统性梳理诸如特征表达、预处理、输入长度处理、网络结构与后评估之间有机联系的理论剖析仍然不足，多以末端总体得分作为核心产出。因此，未来研究理应超越单纯构建复杂模型的考量，向综合评估特征与架构、数据与泛化、效能与算力相互平衡的全面框架进发。

总之，本节梳理研究现状的目的在于明晰哪些问题已得到充分探讨，哪些架构漏洞亟待完善。这为本文后续提出具体研究内容及确立技术路线提供了最直接的理论指导依据。

1.4 研究内容

本研究旨在受限的数据条件下，设计并实现一套基于语音信号的用户情感识别系统。为此，本文将围绕数据与输入处理基建的构筑、基于卷积神经网络（CNN）的基础模型设计、轻量级注意力机制的融合，以及小规模数据环境下稳定评估框架的构建等四个核心维度展开。

第一，构建面向语音情感识别系统的数据与输入处理流程。本研究优先选用公开且结构相对清晰的语音情感数据集，全面审查数据的标签构成、说话人分布、情感类别、录音时长及噪声情况等基础属性。在此基础之上，设计包含重采样、长度对齐、特征提取、归一化处理及数据质量控制在内的输入处理流水线，旨在为后续模型提供能够稳定学习的输入表征。此项工作的根本目的不仅在于整理数据本身，更在于预先控制可能影响实验结果的各项输入变量，从而为提升后续模型训练的稳定性与结果再现性奠定坚实基础。

第二，设计并构建用于语音情感识别的 CNN 基础模型。本研究采用对数梅尔谱图（log-Mel spectrogram）或梅尔频率倒谱系数（MFCC）等时频表征作为输入表征，使卷积神经网络能够有效学习语音信号内部局部的时空动态模式。优先构建 CNN 基础模型之意图，在于为后续融入注意力机制后的扩展模型提供直观的性能对比基准。易言之，本文的初期重点并非直接提出繁复冗庞的网络结构，而是优先搭建结构简洁且具备良好解释性的基线模型，并以此为参照基点，严密评估后续每项改进措施的实际效用。

第三，在 CNN 基础特征框架之上引入轻量级注意力机制，以期更高效地突出并利用发音内部的核心情感线索。在语音情感识别任务中，情感信息往往并非在整个

语音片段内呈现均匀分布，而是相对集中于特定的时间区间或声学模式之中。因此，赋予关键判断片段特异性权重的注意力架构构成了极具价值的扩展方向。相较于直接构建重型 Transformer 全架构，本研究优先考虑将相对简化、高度可调的轻量级注意力模块嵌入 CNN 特征特征图之上。借此探索在低资源数据约束下，如何在有效规避模型复杂度不受控激增的同时，最大化地利用信息聚焦效应以增强情感识别能力。

第四，建立兼顾小规模数据约束与结果强解释性的稳健评估框架。鉴于多数语音情感数据集固有的规模受限、不同情感类别间边界模糊，且模型表现极易受数据划分方式左右等系统性难题，本研究将摒弃仅依赖单一实验所得绝对准确率的粗略评价模式。在可行限度内，研究将全面引入多次重复实验、交叉验证策略、混淆矩阵深度剖析及相似情感类别间的细粒度错误分析机制，构筑更为立体的验证体系。在此过程中，视具体需要，还将同步检视噪声植入、跨说话人分布以及验证集划分形式变化对最终度量的扰动，以切实保障实验结果的泛化信度与科学解释性。

上述研究过程涵盖了从数据提取直至结构定型与后分析的完整周期，其主要研究工作模块及其执行顺序，详见图 1-1。

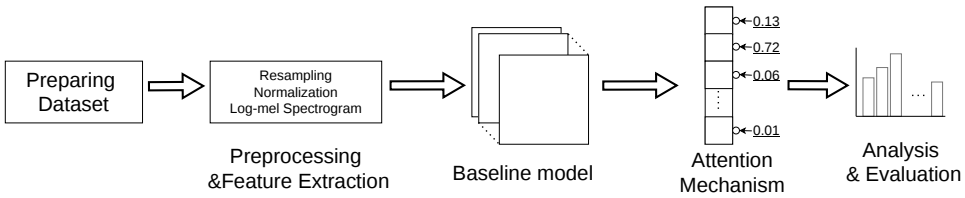

图 1-1 总体研究流程图：涵盖数据处理、基线模型、注意力机制及评估体系

综上所述，本研究聚焦于语音情感识别难题，将系统性地沿着数据输入底座搭建、CNN 基线模型架构、轻量级注意力机制植入，以及制定契合受限数据环境的严密评估策略此四大维度予以推进。申言之，本文的核心追求绝非简单堆砌单一的模型刷分产出，而是试图在数据匮乏及算力现实等局限中，系统求证何种输入流构型、网络架构配合与实验求证设计方能构建出最具效用与科学依据的语音情感识别系统。

1.5 本文组织结构

本文共分为四章，各章的具体内容安排如下：

第一章，主要涵盖本研究的绪论部分。首先，论述语音情感识别研究的基础背

景与现实需求，进而总结本研究的理论价值与实际意义。其次，全面梳理国内外在语音情感识别领域的研究现状与最新发展趋势，并在此基础上明确提出本文拟开展的核心研究内容。最后，简明概述全文的结构组织与各章节内容，以便读者预先把握本文的整体脉络。

第二章，重点探讨音频数据集的遴选及输入信号的处理方法。首先，对比分析当前语音情感识别领域内广泛采用的主要公开数据集的类型与特性，据此阐明本研究在数据集选型上的标准及考量。其次，系统梳理典型语音信号处理环节中面临的核心难点及现有技术对策，进而详细阐述本研究所采用的输入处理流程及特征表征方法。借此，为后续的模型训练与实验验证确立清晰的数据基础与科学的表征环境。

第三章，详述面向语音情感识别的模型架构设计。首先，对全连接神经网络、卷积神经网络及循环神经网络等传统基础网络结构的功能特征及局限性进行系统评述。其次，引入注意力机制，阐明其在促使模型聚焦于发音内部关键情感线索方面的优势；并进一步剖析 Transformer 架构的基本原理与全局结构特性。通过上述论述，为本研究核心模型设计的切入点与结构演化提供严谨的理论支撑与架构依据。

第四章，集中展示本研究的实验设计并进行深度的结果分析。首先，详细说明包含实验软硬件环境、数据集规模配置、训练及验证集的划分策略、损失函数及优化手段选择等核心实验参数设定。其次，系统呈现包含基线模型与融合注意力增强结构在内的综合测评结果，并进行细致的性能比对及机理解释。最后，通过开展噪声条件实验、跨语料库验证实验、细粒度错误分析机制及基于说话人维度的针对性评估等一系列扩展验证，进一步立体且客观地审视本文所提构型的实际效用界限与固有局限。

遵循上述章节布局，本论文循序渐进地构建了从提出研究背景起始，历经数据与输入处理、模型网络设计，直至最终完成定量实验验证与结果剖析的完整研究闭环。综上所述，全文在组织结构上严格遵照了从提出问题到研究方法设计，再到以实验事实作为验证的规范化学术研究流程。

第 2 章 音频数据集与信号处理方法

2.1 音频情感数据集的类型与选择

2.2 信号处理技术

2.2.1 面临难点

2.2.2 现有技术

2.2.3 本文采用的信号处理流程

2.3 本章小结

第 3 章 模型结构

3.1 现有基础模型结构

3.2 注意力机制

3.3 Transformer 结构

3.4 本章小结

第 4 章 实验设计与实验分析

4.1 实验参数与设置

4.2 综合实验

4.3 噪声条件实验

4.4 跨语料库相关实验

4.5 更细粒度分析

4.6 本章小结

结　论

本文结论……[1]。

结论作为毕业设计（论文）正文的最后部分单独排写，但不加章号。结论是对整个论文主要结果的总结。在结论中应明确指出本研究的创新点，对其应用前景和社会、经济价值等加以预测和评价，并指出今后进一步在本研究方向进行研究工作的展望与设想。结论部分的撰写应简明扼要，突出创新性。阅后删除此段。

结论正文样式与文章正文相同：宋体、小四；行距：22 磅；间距段前段后均为 0 行。阅后删除此段。

参考文献

[1] 张伯伟. 全唐五代诗格会考[M]. 南京: 江苏古籍出版社, 2002.

致　谢

值此论文完成之际，首先向我的导师……

致谢正文样式与文章正文相同：宋体、小四；行距：22 磅；间距段前段后均为 0 行。阅后删除此段。