北京理工大學

本科生毕业设计（论文）

北京理工大学本科生毕业设计（论文）题目

The Subject of Undergraduate Graduation Project (Thesis) of Beijing Institute of Technology

学　　院：计算机学院

专　　业：软件工程

班　　级：07822201

学生姓名：姜现日

学　　号：1820191086

指导教师：张哈希

2026 年 3 月 25 日

原创性声明

本人郑重声明：所呈交的毕业设计（论文），是本人在指导老师的指导下独立进行研究所取得的成果。除文中已经注明引用的内容外，本文不包含任何其他个人或集体已经发表或撰写过的研究成果。对本文的研究做出重要贡献的个人和集体，均已在文中以明确方式标明。

特此申明。

本人签名：　　日 期：　　年　　月　　日

关于使用授权的声明

本人完全了解北京理工大学有关保管、使用毕业设计（论文）的规定，其中包括：①学校有权保管、并向有关部门送交本毕业设计（论文）的原件与复印件；②学校可以采用影印、缩印或其它复制手段复制并保存本毕业设计（论文）；③学校可允许本毕业设计（论文）被查阅或借阅；④学校可以学术交流为目的，复制赠送和交换本毕业设计（论文）；⑤学校可以公布本毕业设计（论文）的全部或部分内容。

本人签名：　　日 期：　　年　　月　　日

指导老师签名：　　日 期：　　年　　月　　日

北京理工大学本科生毕业设计（论文）题目

摘　要

本文……。

摘要正文选用模板中的样式所定义的“正文”，每段落首行缩进 2 个字符；或者手动设置成每段落首行缩进 2 个汉字，字体：宋体，字号：小四，行距：固定值 22 磅，间距：段前、段后均为 0 行。阅后删除此段。

摘要是一篇具有独立性和完整性的短文，应概括而扼要地反映出本论文的主要内容。包括研究目的、研究方法、研究结果和结论等，特别要突出研究结果和结论。中文摘要力求语言精炼准确，本科生毕业设计（论文）摘要建议 300-500 字。摘要中不可出现参考文献、图、表、化学结构式、非公知公用的符号和术语。英文摘要与中文摘要的内容应一致。阅后删除此段。

关键词：北京理工大学；本科生；毕业设计（论文）——请在“main.tex”开头设置

The Subject of Undergraduate Graduation Project (Thesis) of Beijing Institute of Technology

Abstract

In order to study……

Abstract 正文设置成每段落首行缩进 2 字符，字体：Times New Roman，字号：小四，行距：固定值 22 磅，间距：段前、段后均为 0 行。阅后删除此段。

Key Words: BIT; Undergraduate; Graduation Project (Thesis)

目 录

摘 要 I
Abstract II
第 1 章 绪论 1
1.1 研究背景 1
1.2 研究意义 3
1.3 研究现状及发展趋势 4
1.3.1 语音情绪识别研究的发展历程 4
1.3.2 语音情绪识别数据集的研究现状 5
1.3.3 声学特征与信号处理方法的研究现状 6
1.3.4 基于深度学习的语音情绪识别模型研究现状 6
1.3.5 注意力机制与 Transformer 研究现状 7
1.3.6 低资源、噪声环境及跨语料库泛化研究现状 8
1.4 现有研究的总结与不足 9
1.4.1 评估方法论现状与局限 9
1.4.2 模型复杂度与数据规模 10
1.4.3 声学特征与语言特征的融合 10
1.5 研究内容 12
1.6 本文组织结构 13
第 2 章 音频情绪数据集与信号处理方法 15
2.1 音频情绪数据集的类型与选择 15
2.2 信号处理技术 18
2.2.1 信号预处理 18
2.2.2 时频变换与频谱分析 20
2.2.3 感知特征提取 20
2.2.4 特征后处理与序列长度处理 20
2.2.5 数据增强与鲁棒性提升 20
2.2.6 面临难点 20
2.2.7 现有技术 20
2.2.8 本文采用的信号处理流程 20
2.3 本章小结 20

第 3 章　模型结构 21
3.1　现有基础模型结构 21
3.2　注意力机制 21
3.3　Transformer 结构 21
3.4　本章小结 21
第 4 章　实验设计与实验分析 22
4.1　实验参数与设置 22
4.2　综合实验 22
4.3　噪声条件实验 22
4.4　跨语料库相关实验 22
4.5　更细粒度分析 22
4.6　本章小结 22
结　论 23
参考文献 24
致　谢 26

第 1 章 绪论

1.1 研究背景

随着近年来人工智能技术的快速发展，人机交互系统从显式执行用户指令，转向对用户状态与意图进行隐式感知。用户情绪状态的感知是这种人机交互范式转型中的核心环节之一。系统不仅要解析用户“说了什么”这一显式信息，更需识别用户“在何种情绪状态下说话”的隐式线索。在人类决策过程中，情绪不仅调节个体的行为方式，也影响着人机交互的实际表现。具备情绪理解能力的人机交互系统，能够基于用户语音中的隐式情绪线索，动态调整交互策略，从而提升交互的自然度与用户体验。情绪识别技术已应用于教育、心理咨询、医疗辅助、客户服务及数字内容交互等领域，并有潜力提升系统交互性能。情绪识别技术有望成为下一代人机交互系统提升人机协作效率的关键能力之一。

情绪可通过多种媒介进行表达，其中语音因同时承载文字语义与非文字语义，成为人机交互中情绪感知的核心媒介。语音凭借这种对文字语义与非文字语义的双重承载能力，在人机交互系统中承担着传递情绪信息的主要功能，从而实现用户状态与系统响应之间的有效连接。语音作为人类日常交流的媒介，在人机交互系统中具有一定的工程优势：采集成本低，且无需复杂外部设备即可高效获取。语音中不仅包含文字语义，还承载着语调、语速、重音、节奏、能量及音色等非文字语义要素。这些非文字语义要素为识别用户的情绪状态提供了主要的信息依据。即便是相同的句子，因语速、音高、发音力度及呼吸等非文字语义要素的差异，也会呈现出具有一定差异的情绪状态。这些非文字语义要素共同构成了语音传递情绪信息的多维结构。语音传递情绪信息的多维结构使语音情绪识别成为提升人机交互性能的重要研究方向之一。

基于语音的情绪识别研究有着较长的历史。语音情绪识别研究的重心正从特征工程向深度表示学习转向。早期研究主要采用手工设计的声学特征，如梅尔频率倒谱系数 (Mel-Frequency Cepstral Coefficients, MFCC)、音高、能量及韵律等。隐马尔可夫模型 (Hidden Markov Model, HMM)、高斯混合模型 (Gaussian Mixture Model, GMM) 及支持向量机 (Support Vector Machine, SVM) 等传统机器学习分类器被用于情绪分类。上述手工特征与机器学习分类器方法的主要优点在于模型解释性较强且实现直

观清晰，但在充分表征情绪这种界限模糊且具有强时间序列依赖性的信息时，仍暴露出一定的局限性。为解决上述基于手工特征的传统机器学习方法的局限性，卷积神经网络 (Convolutional Neural Network, CNN)、循环神经网络 (Recurrent Neural Network, RNN)、长短期记忆网络 (Long Short-Term Memory, LSTM) 及双向长短期记忆网络 (Bidirectional LSTM, BiLSTM) 等深度学习架构被引入语音情绪识别研究。研究重心逐渐转向模型自动学习语音时频特征的方向。近年来，研究者的关注点逐渐从堆叠更深的网络架构转向将注意力机制与骨干架构结合，从而使模型能够更具选择性地聚焦于语音中对情绪表达的关键时间段与特征。这一转变标志着语音情绪识别正从传统的以特征工程为中心的阶段，向以模型结构为中心的精细表示学习与关键特征选择阶段发展。

然而，当前语音情绪识别仍面临一系列挑战。首先，情绪本身的模糊性与主观性是其主要难题之一。人类的情绪并非总是以边界分明的类别存在，且即便是同一种情绪，在跨说话人身上也可能表现出截然不同的语音特征。例如，愤怒与兴奋、快乐与惊讶等紧密相邻的情绪类别，往往共享着相似的声学特性，导致分类边界趋于模糊。第二，语音情绪识别的性能在一定程度上受限于数据集的分布特性、样本质量、说话人构成、录音环境及语言背景等因素。当数据集分布差异较大时，在一个数据集上训练的模型可能在其他数据集或跨说话人条件下出现性能下降。这一问题在跨说话人及跨语料库设定下更为常见。第三，实际应用场景中的噪声环境、混响、信道差异及设备特征差异等因素，均可能干扰情绪线索的稳定提取。最后，带有情绪标注的语音数据规模远小于普通语音数据，且收集成本高昂，因此复杂模型并不总能取得更优效果。因此，在持续优化网络架构的基础上，本研究应侧重探索如何在数据受限及多变环境下获取稳定、可靠的情绪表示。

基于上述背景，当前语音情绪研究主要体现在两个方面：一方面注重探索更具表示能力的特征提取方法；另一方面则聚焦于设计能够在受限数据规模及实际应用场景约束下稳定运行的模型架构。特别是，情绪信息往往并非均匀分布于语音片段，而是集中于特定时间段或声学模式中。在此背景下，通过对关键情绪区间赋予更高权重以缓解非均匀分布问题的注意力机制，成为语音情绪识别的一个重要研究方向之一。因此，本文聚焦于基于语音信号的情绪识别问题，综合考量声学特征与模型架构的关系，进而探索一种能在受限数据条件下较为稳定地学习情绪特征的注意力机制情绪识别系统。上述研究出发点为本文后续的数据集选取、信号处理流程制定、

模型架构设计及实验分析提供了研究动机。

1.2 研究意义

情绪识别技术作为识别人类状态与意图的核心技术之一，在心理健康辅助诊断、客户服务系统、教育类智能导学及基于情绪的内容生成等多个领域，持续显示出应用潜力。语音作为承载情绪特征的核心媒介，具备无需外部设备即可采集的固有优势，能以较低成本对接实际交互场景。基于上述分析，本研究在审视相关机制的基础上，侧重于人机交互系统层面的设计与验证，旨在为相关技术从实验环境向实际应用场景的转化提供参考。

本研究致力于构建一套系统化、分层次的语音情绪识别方案，以通过具体实践验证其工程与学术价值。首先，本研究将围绕标准化数据输入与预处理环节，设计面向语音情绪识别的数据处理流程。本研究拟设计包含重采样、长度对齐、声学特征提取与归一化处理的预处理流水线，以减少输入差异对特征分布的干扰，并为后续模型提供相对稳定的非文字语义特征。在受限数据规模下，上述预处理流程有助于提高模型训练的一致性，并为语音情绪特征提取与结果复现能提供较为稳定的输入条件。

第二，以卷积神经网络为基线模型，融合轻量级注意力机制，以突出语音中承载情绪信息的关键时间段及局部声学模式。相较于直接采用参数规模较大的网络结构，本研究在保留必要表示能力的前提下，旨在验证注意力模块通过权重调整强化关键情绪特征、减少非关键片段干扰的具体作用。同时，分析其对情绪信息组织与表示过程的影响。上述探索不仅有助于在控制模型复杂度增长的同时提升识别性能，也可为轻量化人机交互系统的模型结构设计提供参考，并为后续模型优化提供基础。

第三，拟构建适用于受限数据规模下的稳定评估框架。针对语音情绪识别中数据规模受限、情绪类别边界模糊及模型性能易受数据划分影响等问题，本研究拟引入重复实验、交叉验证及混淆矩阵深度分析等策略。通过上述多维度评估策略，构建相应的评估方法。上述稳定评估框架旨在突破单一准确率指标的局限，为模型的科学评价与结果解释提供更为可靠的依据。

最后，本研究将基于上述评估框架，进一步考察模型在实际应用场景下的泛化能力。为此，本研究将引入噪声环境、混响等环境干扰，以及跨说话人、跨语料库等数据分布变化，从而验证模型在非理想条件下的稳定性与可靠性。上述探索旨在评

估模型从实验环境向实际应用场景迁移的可行性，为语音情绪识别技术的工程化落地提供实证依据。

随着大模型与注意力机制在文本等时序信息处理中的发展，Transformer 在情绪识别任务中展现出一定潜力。语音情绪识别中，情绪信息往往并非均匀分布于整个语音片段，而是集中于特定时间段或声学模式。因此，对关键信息赋予更高权重的注意力机制成为该领域的重要研究方向之一[1-3]。Transformer 凭借自注意力机制，能够更有效地处理长期依赖关系并把握全局上下文，从而被视为弥补传统卷积神经网络与循环神经网络固有缺陷的重要方案之一[2-4]。此外，利用大规模无标注数据的自监督预训练已成为应对标签稀缺问题的重要研究方向之一[5-6]。与上述自监督预训练方向不同，本研究则更侧重于从模型架构维度深入探究注意力机制与 Transformer 对捕获关键情绪信息的具体贡献。

1.3 研究现状及发展趋势

1.3.1 语音情绪识别研究的发展历程

本文将语音情绪识别的发展演进大致划分为以下四个阶段：传统的基于特征工程阶段、基于机器学习阶段、基于深度学习阶段，以及利用注意力机制、Transformer 与预训练模型的新兴阶段。在早期研究中，主流方法主要依赖于手工设计的声学特征，并以此为依据进行情绪分类。该时期的研究核心在于探究如何从语音信号中提取特征以更好地反映情绪差异，其中梅尔频率倒谱系数、音高、能量、共振峰及韵律等特征被广泛研究[7-9]。上述手工特征与分类器方法的优势在于具有较强的可解释性，且能在数据规模较小的条件下进行实验。然而，上述手工特征与分类器方法难以充分刻画情绪的复合性及其时序动态变化，仍存在一定局限[7-9]。

基于机器学习的方法不仅关注特征工程本身，也开始注重提升分类算法的性能。由此，支持向量机 (SVM)、隐马尔可夫模型 (HMM)、高斯混合模型 (GMM)、K 近邻算法 (K-Nearest Neighbors, KNN) 及随机森林 (Random Forest, RF) 等多种机器学习分类器陆续被引入，研究者广泛开展了基于手工特征与各类分类器组合的情绪分类性能比较研究[8,10-12]。特征选择、数据归一化及降维等辅助技术也得到研究者的关注，语音情绪识别从而被系统化为典型的模式分类问题[8,10]。尽管如此，上述基于手工特征的传统机器学习方法仍很大程度上受限于研究人员的先验判断，难以充分捕捉情绪表达中固有的非线性特征与长期依赖关系[7-8,13]。

深度学习的引入成为语音情绪识别研究的关键转折点。卷积神经网络被广泛用于从语谱图或对数梅尔谱等时频表示中自动学习局部模式[4,14]。循环神经网络、长短期记忆网络等则被用于对语音信号内部的时间连续性及上下文依赖关系进行建模[1,8,13]。在此基础上，结合卷积神经网络与循环神经网络的混合架构被提出，进一步促进了同时学习局部特征与时序信息的研究趋势[4,8,14]。最终，语音情绪识别研究逐渐从手工特征转向表示学习的范式。

随着大模型与注意力机制在文本等时序信息处理中的发展，Transformer 在情绪识别任务中展现出一定潜力。语音情绪识别中，情绪信息往往并非均匀分布于整个语音片段，而是集中于特定时间段或声学模式。因此，对关键信息赋予更高权重的注意力机制成为该领域的重要研究方向之一[1-3]。Transformer 凭借自注意力机制，能够更有效地处理长期依赖关系并把握全局上下文，从而被视为弥补传统卷积神经网络与循环神经网络固有缺陷的重要方案之一[2-4]。此外，利用大规模无标注数据的自监督预训练已成为应对标签稀缺问题的重要研究方向之一[5-6]。与上述自监督预训练方向不同，本研究则更侧重于从模型架构维度深入探究注意力机制与 Transformer 对捕获关键情绪信息的具体贡献。

1.3.2 语音情绪识别数据集的研究现状

数据集一直是语音情绪识别研究的出发点，同时也是评估模型性能的基准要素。目前语音情绪识别研究中常用的数据集包括 RAVDESS、IEMOCAP、EMO-DB、SAVEE、TESS、CREMA-D、MSP-Podcast、MSP-IMPROV 及 CASIA 等[8,10]。这些数据集在语种、说话人规模、情绪类别划分、录音环境、发音模式及标注范式等维度上均存在一定差异[8,10]。此类差异不仅体现在样本数量上，更与模型所能习得的情绪特征及泛化能力密切相关。

当前主流的语音情绪识别数据集主要可分为表演型数据集与自发型或自然型数据集[8,10]。诸如 RAVDESS、EMO-DB、CASIA 等表演型数据集，多收录了在受控环境下由演员演绎的情绪语音；这类数据集的主要优势在于情绪标注相对明确，实验具有较高的可重复性。相比之下，IEMOCAP、MSP-IMPROV 等数据集则融入了对话、即兴或自然发音等元素，能够更真实地反映实际交互场景中的情绪表达[8,10]。然而，自然型数据集也面临着情绪边界模糊、标注一致性不足及预处理难度较大等挑战[8,10]。数据集的选择并非仅取决于规模或被引频次，而是与研究目标（关注界限清

晰的基准测试验证，或更重视实际应用场景下的泛化能力）密切相关。

对于情绪标注方式而言，数据集可划分为离散标签（如愤怒、快乐）与连续维度（如效价、唤醒度）两类。前者主要适用于离散类别分类任务，后者则能更细腻地刻画情绪。然而，离散标签数据集往往难以充分反映情绪的复合性与渐变性，而连续维度标注在实验设计与评价体系构建方面也面临一定的技术困难[8,10]。

1.3.3 声学特征与信号处理方法的研究现状

在语音情绪识别中，输入特征及信号处理具有重要作用。早期研究主要基于先验知识手工提取具有情绪区分度的声学特征，例如梅尔频率倒谱系数、音高、能量、过零率等。这些特征既可单独使用，也可组成综合特征集。基于 OpenSMILE 工具提取的 eGeMAPS、ComParE 等特征集，长期作为情绪识别领域的重要基准之一，为后续研究提供了稳定的基线[8,10]。

随着深度学习的发展，输入表示从定长特征向量转向以语谱图、对数梅尔谱图等时频表示为主。这些时频表示能有效保留语音内在的时序动态与频谱特征，与卷积神经网络及 Transformer 等深度学习架构具有良好的协同性[2,4,14]。近期研究不仅比较同一音频的多种表示，并探讨表示融合技术，表明输入特征成为决定模型感知情绪的核心设计维度之一[2,4,14]。

信号处理方法也朝着精细化方向发展。在信号处理方面，针对变长序列的填充(padding)、滑动窗口分割、序列分割等技术受到研究者的关注。此外，噪声消除、数据增强等方法也逐渐成为研究热点之一[9,13]。近年来，诸多研究指出仅凭实验室环境难以验证模型的泛化能力，需要考察包含噪声或混响等干扰情景下的识别性能[9,11,15-16]。声学特征提取与信号处理技术是语音情绪识别的主要基础之一。这些信号处理技术在输入特征与模型的深度融合中起到主要作用，成为连接数据预处理与模型构建的主要环节之一，为系统识别性能提供了支撑[8,10]。

1.3.4 基于深度学习的语音情绪识别模型研究现状

基于深度学习的语音情绪识别模型，最初是为了解决传统手工特征方法的局限性而提出，现已成为该领域的重要研究方向之一。早期的深度学习研究主要围绕卷积神经网络与循环神经网络展开。卷积神经网络能够从时频特征中有效提取局部模式，而循环神经网络、长短期记忆网络等则适用于对语音信号中的时间连续性与序列上下文进行建模[4,8,13]。在此基础上，结合卷积神经网络与循环神经网络优势的混

合架构被广泛探索，以同时学习局部特征与时序信息[4,8,14]。

相较于传统机器学习分类器，这些深度学习架构不仅具有较强的非线性映射能力，更能够自动学习无需手工设计的深层特征。卷积神经网络可以有效提取特定频段上的能量集中区域与语谱图中的局部结构差异，而长短期记忆网络则能够对整段语音中的音高变化及能量变化轨迹进行建模[4,8,13-14]。随着近期各类一维、二维卷积神经网络变体以及其与循环神经网络的融合机制被相继提出，语音情绪识别被视为一项复杂的序列学习任务[4,14,17-18]。

然而，深度学习架构也存在一定局限性。卷积神经网络受限于局部感受野，难以建模长程时序的全局依赖关系[2,4,14]。而循环神经网络的顺序计算机制往往导致并行效率较低，且在处理超长序列时可能面临较高的计算开销[1,8,13]。带有情绪标注的训练数据通常规模较小，因此单纯增加模型参数容易导致过拟合问题。过拟合使得模型仅能记忆特定训练集的特征，难以学习到情绪的通用特征，从而影响模型的泛化能力[7-8,13]。因此，当前研究不局限于单纯增加网络深度，而是在保证性能的前提下，积极探索引入注意力机制等优化架构来强化全局特征捕捉。这些探索旨在控制模型复杂度的同时提升识别性能[2-4]。

1.3.5 注意力机制与 Transformer 研究现状

语音情绪识别中，情绪信息并非均匀分布于整个语音片段，这成为注意力机制被引入语音情绪识别的重要背景之一。现有的卷积神经网络与循环神经网络在处理输入时通常对所有输入特征赋予相近的权重，然而实际的情绪线索往往更集中地体现于特定时间段、特定词汇或特定频段[4,7,17]。为充分反映情绪信息在语音片段中的非均匀分布特性，近年来研究者广泛探索注意力机制，使模型对关键情绪信息赋予更高权重[1-3]。此外，加性注意力 (Additive Attention)、多头注意力机制 (Multi-Head Attention)、局部注意力机制 (Local Attention)、交叉注意力机制 (Cross-Attention) 及通道注意力机制 (Channel Attention) 等多种衍生结构相继被提出[1-2,19-20]。

Transformer 以自注意力机制为核心，能够直接对序列内部的全局关系进行建模，在语音情绪识别研究中逐步成为核心方法之一[2-4]。不同于传统循环神经网络的串行处理机制，Transformer 不仅支持并行计算，更能直接建模长距离依赖关系，从而在解析复杂语音结构时展现出一定优势[2-4]。在此背景下，研究者们相继提出了多种基于 Transformer 的情绪识别模型。其中包括纯 Transformer 架构、卷积神经网络与

Transformer 的混合架构、将窗口 Transformer(Swin Transformer) 应用于语谱图分析的模型，以及结合移位窗口或动态窗口的改进架构[2-3]。Transformer 在全局上下文建模与长时依赖处理方面具有一定优势，结合注意力机制可更精准地捕捉关键情绪特征[2-3]。

然而，基于注意力机制与 Transformer 的方法并非在所有场景下均适用。此类结构通常伴随较大的参数规模与计算开销，并对训练数据量提出较高要求。在数据受限条件下，模型容易因过度参数化而难以获得相应的泛化能力[5,9,21]。因此，当前研究不再局限于单纯扩大 Transformer 规模，转而深入探索在卷积神经网络中嵌入轻量级注意力模块，或引入较为简洁的辅助注意力架构[2-3,19]。上述研究趋势表明，注意力机制与 Transformer 不仅是重要的技术手段，更需要根据实际数据规模与计算资源进行权衡与选择。

1.3.6 低资源、噪声环境及跨语料库泛化研究现状

在当前的语音情绪识别研究中，相比于单一数据集上的准确率，模型在实际应用场景中的鲁棒性与泛化能力正逐渐成为更重要的衡量标准之一。这一发展趋势主要源于以下两项客观因素：其一，带有情绪标注的音频数据收集成本相对较高，相关数据集规模通常较小，使得许多研究仍面临低资源条件的限制[6,8-9]。其二，在实际应用场景中，环境噪声、混响干扰、信道差异、跨说话人的发音习惯以及预训练数据集与目标任务之间的数据分布差异等因素相互交织，容易导致同一模型在不同测试环境下出现稳定性下降[9,11,15-16]。

在针对噪声环境的相关研究中，噪声添加、混响模拟、端到端语音增强以及数据增强等技术逐渐成为研究重点之一[9,13]。相关研究指出，仅凭实验室环境难以有效评估模型的实际应用性能，因此在多种噪声条件下进行鲁棒性评估尤为重要[9,11,16]。针对跨说话人及跨语料库问题，研究者们正积极探索降低模型对特定源领域或说话人样本较强依赖的去相关方法[11,15-16,21]。领域自适应、迁移学习、域泛化策略、多条件混合训练及特征归一化等方法，已成为应对该问题的重要技术途径之一[10-11,15,21]。

另一方面，利用自监督预训练语音模型的低资源情绪识别研究呈较快增长趋势[5-6,22]。以 Wav2Vec2、HuBERT、WavLM 及 DistilHuBERT 等为代表的自监督预训练模型，能够从无标注数据中学习通用声学特征。这些模型可为标注数据不足的情绪分析提供深层特征[5-6,22]。此类大规模模型的运行成本仍较高，微调的稳定性仍有待提

高。此外，预训练领域与目标情绪数据集之间的数据分布差异仍存在一定挑战[5-6,22]。因此，融合低资源条件、噪声环境及跨语料库的综合问题，已成为一项综合性挑战，需要研究者从输入特征、模型结构、学习策略到评估框架进行系统的重新思考与设计。

1.4 现有研究的总结与不足

1.4.1 评估方法论现状与局限

近年来，语音情绪识别研究在模型架构与特征表示等方面取得了一定进展，然而在评估体系的构建与泛化能力的考量上，现有研究仍存在一定的局限性[4,7,11]。当前多数研究主要依赖于单一数据集上的准确率作为核心评价指标。然而，不同研究在数据预处理、特征提取及实验设置等环节存在一定的差异。这些差异导致不同模型之间的性能结果难以有效比较[4,7,13]。特定数据集上取得的优异表现往往难以充分反映模型在实际应用场景中的泛化能力。这种评估体系的不完善已成为制约该领域进一步发展的关键因素之一[4,11]。

在泛化能力的评估方面，现有研究往往面临跨说话人、跨语料库及跨场景下的性能下降问题。相关研究指出，在特定数据集上表现良好的模型，在面对跨说话人、不同语言背景或噪声环境时，这些模型的识别准确率往往出现一定程度的下降。这种性能下降现象与由跨说话人差异引起的领域偏移密切相关[5,9,11,15]。除了准确率与泛化能力，模型的置信度校准也是评估体系的重要维度之一。置信度校准旨在使模型的预测置信度与实际准确性相匹配，避免模型出现过于自信或信心不足的情况。部分模型往往倾向于表现出较高自信度，但其置信度与预测准确性之间的一致性仍有待提高[4,7-8]。已有研究尝试将置信度校准方法引入语音情绪识别任务。然而这些置信度校准方法在实际应用中的效果可能仍存在一定局限性，且在跨说话人、跨语料库及噪声环境等条件下可能对模型性能产生一定影响[4,10,13]。

针对评估体系不完善、泛化能力不足及置信度校准等问题，未来的研究可从方法论层面进行系统性探索与设计。首先，已有研究指出，建立更加多元化的评估指标体系对提升评估可靠性具有重要意义[7]。该体系可在准确率之外纳入对模型置信度、稳定性及跨场景泛化能力的综合考量。其次，相关研究也强调推动评估协议标准化的重要性，明确数据预处理、特征提取及实验设置的规范，有助于提高不同研究之间结果的可比性[7]。此外，相关研究进一步强调在多种噪声条件、跨说话人及跨语料

库等复杂场景下进行模型性能评估的重要性，通过构建更具挑战性的测试基准，更真实地反映模型在实际应用中的鲁棒性与可靠性[4,8,12]。构建系统化的评估框架，有助于为语音情绪识别技术的工程化落地提供更为可靠的实证依据。

1.4.2 模型复杂度与数据规模

近年来，语音情绪识别研究在模型架构方面取得了一定进展，其中以 Transformer 为代表的预训练模型在语音情绪识别任务中表现出一定性能提升[2-4]。然而，以 Transformer 为代表的预训练模型参数量通常较大，这些模型的训练与推理过程对计算资源与数据规模提出了较高要求[2-4]。相关研究指出，在语音情绪识别任务中，标注数据的获取成本较高，使得现有数据集规模相对较小，一定程度上制约了复杂模型的泛化能力[5-6,22]。在数据受限条件下，模型参数过度增加往往导致过拟合问题，使得模型倾向于记忆特定训练集的特征，而难以学习到具有泛化能力的情绪表征[7-8,13]。

在模型设计层面，当前研究对计算效率与资源消耗的考量仍有待进一步探索[5,9,21]。标准的自注意力机制具有随输入序列长度呈二次增长的计算复杂度，而语音信号往往持续时间较长且存在一定程度的时序冗余，这种计算特性使得 Transformer 在语音情绪识别任务中的部署面临一定挑战[2-4]。为缓解这一问题，近年来出现了多种高效注意力机制变体，例如窗口注意力机制、动态窗口注意力机制及通道注意力机制等，这些机制旨在降低计算开销的同时保持模型性能[2-3,14,19-20]。然而，相关研究指出，这些高效注意力机制在语音情绪识别领域的系统性评估仍较为有限，这些方法在实际部署中的表现仍有待进一步验证[4,14]。

针对预训练模型在计算资源受限条件下的部署问题，相关研究已通过模型压缩技术探索效率与性能的平衡[5,9,11]。编码器层剪枝、知识蒸馏及量化等方法，可使压缩后的模型在保持一定识别准确率的同时，有效降低参数量与推理时延[9,11]。然而，压缩过程中往往伴随一定程度的信息损失，如何在模型表达能力与计算效率之间实现有效平衡，仍是当前研究面临的主要挑战之一[5,9,11]。

1.4.3 声学特征与语言特征的融合

传统的语音情绪识别研究主要关注声学特征，例如梅尔频率倒谱系数、音高、能量等。这些特征能够捕捉语音中的韵律、音质等非文字语义信息，在一定程度上往往反映说话人的情绪状态。然而，语音信号中除声学信息外，还包含文字语义信息这一重要维度，但现有研究对此关注相对较少。语言内容承载的语义信息，可为情绪

表达提供重要线索，例如特定的情绪词汇、句式及表达方式[8,23]。相关研究指出，声学特征与语言特征具有互补性，这两种特征的有效融合有望提升情绪识别的准确性与鲁棒性[8,23]。

声学特征主要反映语音表达方式（即“怎么说”），如语调、语速、音高等。语言特征则主要反映表达内容（即“说什么”），如词汇、句法、语义等。人类在表达情绪时，通常会同时通过声学特征与语言特征传递信息。例如，同样一句话“真是太好了”，用不同的语调可表达真诚的高兴，也可能传递讽刺意味。因此，仅依靠声学或语言特征往往难以全面捕捉复杂情绪。近年来，研究者逐步探索声学特征与语言特征的融合方法，以期综合利用这两种特征的优势，有望提升情绪识别的性能[8,24]

声学特征提取通常采用手工设计的特征（如梅尔频率倒谱系数、韵律特征）或基于深度学习的自动特征学习方法（如语谱图、预训练声学模型 wav2vec 2.0 等）[8,14,23]。语言特征提取则多基于词嵌入（word embeddings）或预训练语言模型（如 BERT、RoBERTa）得到文本的高维语义表示[8,23-24]。在语音情绪识别任务中，通常需要对语音进行语音识别（ASR）获得文本转录，这一过程可能带来语音识别错误的风险，从而影响融合效果[1,23]。

声学特征与语言特征融合方法主要分为三类：早期融合（特征级融合）、中期融合（隐藏层融合）和晚期融合（决策级融合）。早期融合将声学特征与语言特征拼接后输入分类器；中期融合在多模态模型的中间层交互；晚期融合则分别训练两个单模态模型后融合输出。随着注意力机制的发展，基于跨模态注意力（cross-modal attention）的融合方法逐渐成为主流，能够动态加权交互不同模态的信息，更有效地捕捉模态间的关联[20,24]。此外，一些研究提出基于 Transformer 架构的多模态模型，在 IEMOCAP 等数据集上表现出一定潜力[2,4]。

尽管声学特征与语言特征融合方法表现出一定潜力，但仍面临一定挑战。首先，语音识别（ASR）的错误可能影响语言特征的质量，特别是在噪声环境或非正式口语场景中，ASR 性能下降可能使融合效果受到一定影响。其次，声学特征与语言特征之间的对齐问题仍需解决：语音与文本的时序粒度差异，使得如何有效融合仍有待探索[8,24]。此外，现有融合模型往往依赖大量标注数据，在低资源场景下泛化能力可能受到一定限制[8,24]。最后，一些融合方法在特定数据集上表现良好，但这些方法在不同语言、文化和情境下的鲁棒性仍有待验证。

针对声学特征与语言特征融合方法面临的挑战，未来研究可从以下几个方向进

行探索：一是探索具有更强鲁棒性的语音识别技术，以降低语音识别错误对融合效果的影响；二是发展无监督或自监督的多模态预训练方法，以减少对标注数据的依赖；三是研究更精细的跨模态对齐机制，以期实现声学特征与语言特征的深度融合；四是在更多实际应用场景和不同语言环境中进一步考察模型的泛化能力。上述四个方向的进一步探索，有望推动声学特征与语言特征融合在语音情绪识别中的应用[1,20,23-24]。

1.5 研究内容

本研究聚焦于构建一个基于语音的情绪识别系统。本文聚焦于以下四个主要维度展开研究：数据筛选与输入处理流程的构建、基于卷积神经网络的基线模型设计、轻量级注意力机制的引入，以及面向受限数据规模的鲁棒性评估框架的搭建。

第一，设计面向语音情绪识别任务的数据集筛选与输入处理流程。本研究以公开且结构相对清晰的语音情绪数据集为主，梳理这些数据集的基础属性，包括标签构成、说话人分布、情绪类别、录音时长及噪声情况等，旨在为后续模型的输入表示提供稳定的基础。在梳理数据基础属性的基础上，设计整合重采样、长度对齐、特征提取、归一化处理及数据质量控制的输入处理流水线，以为后续模型提供稳定的输入表示。此项工作的主要意义，不仅在于对数据本身的梳理，更在于对可能影响结果的输入变量进行预先控制，从而为提升后续模型训练的稳定性与结果的复现性提供可靠基础。

第二，面向语音情绪识别任务，设计基于卷积神经网络的基线模型。本研究选取对数梅尔谱图或梅尔频率倒谱系数等时频表示作为输入特征，以帮助卷积神经网络学习语音信号中的局部时空模式[4,14]。设计该基线模型的主要目的在于，为后续融合注意力机制的扩展模型提供清晰的性能基准。

第三，基于卷积神经网络的特征框架，拟引入轻量级注意力机制，以突出语音中的主要情绪线索。在语音情绪识别任务中，情绪信息倾向于集中于特定的时间区间或声学模式之内。基于上述观察，对关键时间区间赋予更高权重的注意力机制，被视为该领域的重要研究方向之一。相较于直接构建大规模 Transformer 架构，本研究拟将相对简化、灵活性较高的轻量级注意力模块嵌入卷积神经网络特征图中。借此探索在数据受限条件下，如何在有效控制模型复杂度的前提下，更有效地利用注意力聚焦效应以提升情绪识别能力。

第四，拟构建兼顾受限数据规模与结果可解释性的鲁棒性评估框架。鉴于多数

语音情绪数据集规模受限、情绪类别边界模糊，且模型性能容易受数据划分影响，本研究将避免仅依赖单一实验准确率的简单评价方式。在可行范围内，研究将引入重复实验、交叉验证、混淆矩阵分析及相似情绪类别间的细粒度错误分析等方法，以构建更为多维的验证体系。在此过程中，还将同步考察噪声环境、跨说话人及验证集划分变化对评估结果的影响，以提升实验结果的泛化能力与科学可解释性。

上述研究过程包括从数据提取到模型构建的主要阶段，各模块及执行顺序如图 1-1所示。

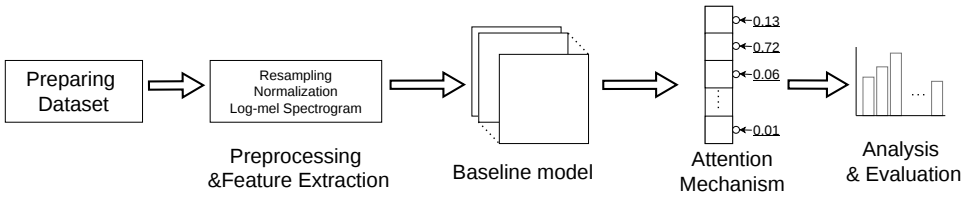

图 1-1 总体研究流程图：涵盖数据处理、基线模型、注意力机制及评估体系

1.6 本文组织结构

本文共分为四章，各章的具体内容安排如下：

第一章介绍本文的绪论。首先阐述语音情绪识别研究的背景与现实需求，并总结本研究的理论价值与实际意义。其次，梳理语音情绪识别领域的研究现状与主要趋势，并阐述本文拟开展的核心研究内容。

第二章主要介绍语音数据集的选择与语音信号的处理方法。首先，对比分析当前语音情绪识别领域常用公开数据集的类型与特点，并说明本研究在数据集选择上的标准与考量。其次，梳理语音信号处理中的主要问题及现有技术对策，并说明本研究所采用的输入处理流程与特征表示方法。为后续模型训练与实验验证提供可靠的数据基础与特征表示方法。

第三章介绍面向语音情绪识别的模型架构设计。首先，对全连接神经网络、卷积神经网络及循环神经网络等传统网络结构的功能特征与局限性进行梳理。其次，介绍注意力机制，阐明该机制在使模型聚焦于语音信号中关键情绪信息方面的优势，并分析 Transformer 架构的基本原理与架构特点。

第四章介绍本研究的实验设计与结果分析。首先，说明实验软硬件配置、数据集

规模、训练集与验证集的划分、损失函数及优化手段选择等主要实验参数设定。其次，呈现包含基线模型与融合注意力的增强模型在内的综合评估结果，并对比性能及分析其机理。最后，通过开展噪声环境实验、跨语料库验证、细粒度错误分析及基于说话人维度的针对性评估等扩展验证，全面且客观地审视本文所提模型架构的实际效用界限与局限性。

第 2 章 音频情绪数据集与信号处理方法

2.1 音频情绪数据集的类型与选择

语音情绪识别系统的性能不仅取决于模型结构本身，还与所采用数据集的类型、标签构成方式以及输入语音的处理流程密切相关。不同语音情绪数据集在语种、说话人构成、情绪类别、采 □

从表 2-1可以看出，代表性语音情绪数据集首先根据情绪采集方式与情绪表达性质被较为明确地区分。RAVDESS、EMO-DB、SAVEE、TESS、CREMA-D、CASIA 等数据集属于在受控环境下由演员表达情绪的表演型基准数据集，这些数据集的共同特点是情绪标签相对明确、实验条件较为稳定。这类数据集较为便利于模型间性能比较与算法基线构建，并有助于保障基础实验的可重复性，因此在语音情绪识别研究中长期作为代表性基准数据集使用。相比之下，IEMOCAP 与 MSP-IMPROV 包含对话与即兴互动，比表演型基准数据集具有相对更为复杂的情绪表达；而 MSP-Podcast、FAU Aibo、EMOVOME、CNSCED 等数据集则包含自然语音或实际环境因素，具有更接近实际应用场景的特性。然而，这类自然型数据集也同时面临情绪边界模糊、标签一致性以及数据整理难度较高等问题。

语音情绪数据集还可以根据标签构成方式与问题定义方式进行区分。RAVDESS、EMO-DB、SAVEE、TESS、CREMA-D、CASIA 等数据集提供愤怒、快乐、悲伤、恐惧、中性等离散标签，因此较为便利地应用于基于多分类的实验。相比之下，RECOLA、MSP-Podcast、EMOVOME 等数据集则同时提供效价、唤醒度、支配度等连续维度，因此较为适用于将情绪作为回归问题或维度情感模型处理的研究。此外，对于 IEMOCAP、MELD 这类对话上下文重要的数据集，除了发话的声学特征外，还可以进一步考虑说话人交替、上下文流程、对话结构等附加因素。上述分析表明，数据集之间的差异不仅体现在规模上，也与研究如何定义情绪以及设定何种任务存在一定关联 [3,11]。

另一方面，语言、说话人构成、公开访问方式也是用于比较数据集时的主要标准。英语数据集不仅包括 RAVDESS、TESS、CREMA-D、SAVEE 等表演型基准数据集，还较为常用 IEMOCAP、MSP-IMPROV、MSP-Podcast、MELD 等对话型、自然型数据集。德语方面有 EMO-DB 与 FAU Aibo，汉语方面有 CASIA 与 CNSCED，波斯语方面有 ShEMO，西班牙语方面有 EMOVOME，均为代表性示例。说话人数与

表 2-1 语音情绪识别常用公开数据集比较

类别	数据集	语言	规模	标签构成	上下文	多模态	特点
表演型	RAVDESS	英语	7,356 条	离散类 (8)	低	是	标签明确、性别均衡、可重复性高
表演型	EMO-DB	德语	约 535 条	离散类 (7)	低	否	经典基准、易于比较；规模较小
表演型	SAVEE	英语	480 条	离散类 (7)	低	是	常用小型基准；男性偏倚、人数少
表演型	TESS	英语	2,800 条	离散类 (7)	低	否	结构简单、使用方便；多样性低
表演型	CREMA-D	英语	7,442 条	离散类 (6)	低	是	说话人多样性大；表演型局限
表演型	CASIA	汉语	约 1,200 条	离散类 (6)	低	否	汉语基准；规模小、自然性受限
对话型	IEMOCAP	英语	约 12 小时	离散 + 连续	高	是	包含对话语境与自然性；预处理复杂
诱导型	MSP-IMPROV	英语	约 9 小时	离散	高	是	介于表演型与自然型之间
自然型	MSP-Podcast	英语	409 小时	离散 + 连续	中-高	否	大规模自然数据；版本管理复杂
对话型	MELD	英语	1.3w 条	离散类	极高	是	适用于多方对话；基于电视

人口统计信息在不同数据集之间也存在一定差异。例如，TESS 仅包含两名女性说话人，SAVEE 仅包含男性说话人，而 CREMA-D 则包含 91 名具有不同年龄和人口统计信息的说话人。MSP-Podcast 在说话人数与发话多样性方面属于较为大规模的自然语音数据集，因而在一定程度上区别于其他基准数据集。此外，部分数据集相对易于公开访问，部分则需要许可证注册或单独审批程序，部分数据集仅选择性使用原始多模态资料中的音频子集。数据集在语言、人口统计信息与公开访问方式上的差异，不仅体现在附加信息层面，也与研究的可重复性与泛化能力密切相关。

代表性语音情绪数据集在情绪采集方式、标签构成方式、语言、说话人构成、公开访问方式等方面存在一定差异。这些差异不仅体现在数据规模上，也与后续的特征提取、模型设计、实验条件设定及结果解读密切相关。因此，数据集的选择不仅取决于引用频次或使用便利性，更应考虑其是否符合研究目的与实验条件。为此，本研究在数据集选择时重点考虑了以下几项标准。其一，数据集宜具备公开访问性或在研究过程中可稳定获取，且宜具备支持后续实验可重复性的形式。其二，标签构成方式宜相对明确，能够直接应用于分类实验。其三，说话人数与性别分布不宜过度偏斜，宜具备基本的平衡性与代表性。其四，数据规模宜能够支撑基础实验，同时预处理与模型验证不宜过于复杂。其五，数据集宜具备基准数据集性质，即在已有研究中较为常用，以便后续进行结果比较与实验分析。基于上述标准，本研究在初期实验阶段，相比于结构复杂的对话型数据集或连续维度的数据集，优先考虑适用于分类实验且结构较为清晰的数据集。数据集选择标准的制定，不仅是对研究范围的明确，也为构建可验证的研究设计提供了基础。

基于上述标准，本研究首先选择 RAVDESS 作为基础实验数据集。RAVDESS 具有公开访问，性别分布较为均衡，情绪类别构成清晰，因此较为适合进行基础分类实验。此外，RAVDESS 在语音情绪识别相关现有研究中较为常用，属于代表性基准数据集之一，较为便利于后续实验结果的分析与比较。RAVDESS 属于在受控环境下由专业演员演绎情绪的表演型基准数据集，与实际应用场景中的自然语音存在差异。然而，综合考量数据访问性、标签稳定性、实验可重复性、输入处理流程的清晰度等因素，该数据集被认为适合在本研究的初期实验阶段使用。

2.2 信号处理技术

2.2.1 信号预处理

输入格式统一：重采样与通道统一

不同语音数据集或录音设备采集的音频文件可能具有不同的采样频率和通道配置。部分文件以 8 kHz、16 kHz、22.05 kHz、44.1 kHz 或 48 kHz 等不同采样频率存储，且单声道与立体声格式也可能混用。这些差异对可分析的频率范围、时间分辨率以及后续特征的统计分布可能产生一定影响，因此为稳定应用相同的特征提取流程，需要首先统一输入格式。为此，通常需要先进行重采样与通道统一。

重采样（resampling）是将原始采样频率下的离散信号重新表达为目标采样频率的过程。概念上可理解为先从原离散信号恢复连续时间信号，再按目标采样频率重新采样，理想化情况下可表示为：

$$x_r[m] = x_c\left(\frac{m}{F_s'}\right)$$

其中 $x_r[m]$ 为重采样后的离散信号，$x_c(t)$ 为恢复的连续时间信号，F_s' 为目标采样频率，m 为新采样索引。

实际实现中并不直接计算连续时间信号，而是通过插值与抗混叠滤波相结合的数字化处理完成。尤其在下采样时，超出奈奎斯特频率的成分可能引发混叠，通常需通过低通滤波器抑制高频成分后再进行重采样。对于立体声或多声道输入信号，为保持特征提取的一致性，常将其转换为单声道。一种常见的方法是取左右声道平均值，可表示为：

$$x_{\text{mono}}[n] = \frac{x_L[n] + x_R[n]}{2}$$

其中 $x_L[n]$ 和 $x_R[n]$ 分别为左右声道信号，$x_{\text{mono}}[n]$ 为转换后的单声道信号。该方法实现简单，较为适用于多数语音情绪识别实验，但当某些声学信息仅集中于特定声道时，可能因平均化导致信息损失。

重采样与通道统一虽不直接产生情绪线索，但对于保证后续特征提取输入条件的一致性较为重要。若采样频率与通道格式未统一，即便采用相同的 STFT 或 Mel 滤

波器组参数，也可能得到分布不同的特征，从而增加模型误将设备差异或存储格式差异作为情绪信息学习的风险。因此，统一输入格式有助于保障后续处理可重复性与实验可比性的基础环节。

振幅归一化

不同语音文件在说话人的发音音量、麦克风灵敏度、录音距离、设备增益、存储格式等方面可能存在一定差异。这种差异可能源于情绪表达本身的差别，但在许多情况下也可能反映录音条件的不同。若保留这种振幅差异直接进行特征提取，模型可能过度学习与情绪无关的振幅变化，从而影响识别性能 [2,3,6]。因此，需要对输入信号进行振幅归一化（amplitude normalization），使其振幅范围保持一致。

峰值归一化（peak normalization）是一种简单且常用的方法之一。该方法以整个信号中绝对值最大的样本为基准进行缩放，可表示为：

$$x_{\text{peak}}[n] = \frac{x[n]}{\max_{0 \le n < N} |x[n]| + \varepsilon}$$

其中 $x[n]$ 为原始信号，$x_{\text{peak}}[n]$ 为峰值归一化后的信号，N 为总样本数，ε 为防止分母为零的极小常数。经此归一化的信号，其最大绝对振幅通常较为接近 1。峰值归一化的优点在于计算简单、直观，能快速将信号动态范围调整到统一水平。峰值归一化的缺点在于，若信号中存在较大的瞬时峰值，其余部分的相对强度可能被过度压缩 [6]。

均方根归一化（RMS normalization）也是一种常用的方法之一。均方根（RMS）反映信号的平均强度水平，定义为：

$$\text{RMS}(x) = \sqrt{\frac{1}{N} \sum_{n=0}^{N-1} x[n]^2}$$

据此，RMS 归一化可表示为：

$$x_{\text{rms}}[n] = \frac{x[n]}{\text{RMS}(x) + \varepsilon}$$

其中 $\text{RMS}(x)$ 为原始信号的均方根值，$x_{\text{rms}}[n]$ 为归一化后的信号。若需要指定目标

RMS 值 r_t，可表示为：

$$x_{\text{target-rms}}[n] = \frac{r_t}{\text{RMS}(x) + \varepsilon} x[n]$$

其中 r_t 为目标 RMS 值。RMS 归一化以信号的均方根值为基准，相较于峰值归一化，通常能提供较为稳定的幅度调节效果 [4,5,6]。

在语音情绪识别中，振幅归一化有助于减少因录音条件差异带来的无关振幅变化。然而，情绪表达本身也包含发声强度、响度等重要线索，过度归一化可能削弱这些与情绪相关的强度信息。例如，愤怒、喜悦常伴随较高发声强度，而悲伤、疲惫则可能呈现较低且平缓的强度分布。因此，应用振幅归一化时，应在消除录音条件差异与保留情绪相关的强度信息之间取得平衡 [3, 4,6]。

此外，振幅归一化并非适用于所有情况。将整个信号缩放至统一振幅范围时，背景噪声也会被同步放大或缩小。因此，振幅归一化可视为信号振幅统一的基础步骤，噪声消除与鲁棒性增强宜结合后续的数据增强或鲁棒性策略共同实现。

2.2.2 时频变换与频谱分析

2.2.3 感知特征提取

2.2.4 特征后处理与序列长度处理

2.2.5 数据增强与鲁棒性提升

2.2.6 面临难点

2.2.7 现有技术

2.2.8 本文采用的信号处理流程

2.3 本章小结

第 3 章 模型结构

3.1 现有基础模型结构

3.2 注意力机制

3.3 Transformer 结构

3.4 本章小结

第 4 章 实验设计与实验分析

4.1 实验参数与设置

4.2 综合实验

4.3 噪声条件实验

4.4 跨语料库相关实验

4.5 更细粒度分析

4.6 本章小结

结　论

本文结论……张伯伟 2002 全唐五代诗格会考。

结论作为毕业设计（论文）正文的最后部分单独排写，但不加章号。结论是对整个论文主要结果的总结。在结论中应明确指出本研究的创新点，对其应用前景和社会、经济价值等加以预测和评价，并指出今后进一步在本研究方向进行研究工作的展望与设想。结论部分的撰写应简明扼要，突出创新性。阅后删除此段。

结论正文样式与文章正文相同：宋体、小四；行距：22 磅；间距段前段后均为 0 行。阅后删除此段。

参考文献

[1] Mirsamadi S, Barsoum E, Zhang C. Automatic Speech Emotion Recognition Using Recurrent Neural Networks with Local Attention[C]//2017 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP). IEEE, 2017.

[2] Chen S, Xing X, Zhang W, et al. DWFormer: Dynamic Window Transformer for Speech Emotion Recognition[C]//ICASSP 2023 - 2023 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP). IEEE, 2023: 1-5.

[3] Wang Y, Lu C, Lian H, et al. Speech Swin-Transformer: Exploring a Hierarchical Transformer with Shifted Windows for Speech Emotion Recognition[C]//ICASSP 2024 - 2024 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP). IEEE, 2024: 11646-11650.

[4] Liu Y, Li W, Dang J, et al. Dual-TBNet: Improving the Robustness of Speech Features via Dual-Transformer-BiLSTM for Speech Emotion Recognition[J]. IEEE/ACM Transactions on Audio, Speech, and Language Processing, 2023, 31.

[5] Triantafyllopoulos A, Potamianos A. End-to-End Label Uncertainty Modeling in Speech Emotion Recognition Using Bayesian Neural Networks and Label Distribution Learning[J]. IEEE Transactions on Affective Computing, 2024, 15.

[6] Satt A, Rozenberg S, Hoory R. Speech Emotion Recognition Using Semi-Supervised Learning with Ladder Networks[C]//2018 First Asian Conference on Affective Computing and Intelligent Interaction (ACII Asia). IEEE, 2018.

[7] Zhang X, Han J, Deng J, et al. Enhancing Segment-Based Speech Emotion Recognition by Iterative Self-Learning[J]. IEEE/ACM Transactions on Audio, Speech, and Language Processing, 2022, 30.

[8] Zhang Y, Han J, Deng J, et al. Speech Emotion Recognition Considering Nonverbal Vocalization in Affective Conversations[J]. IEEE/ACM Transactions on Audio, Speech, and Language Processing, 2021, 29.

[9] Triantafyllopoulos A, Potamianos A. Selective Acoustic Feature Enhancement for Speech Emotion Recognition With Noisy Speech[J]. IEEE/ACM Transactions on Audio, Speech, and Language Processing, 2024, 32.

[10] Song P, Jin Y, Zhao L, et al. Transfer Sparse Discriminant Subspace Learning for Cross-Corpus Speech Emotion Recognition[J]. IEEE/ACM Transactions on Audio, Speech, and Language Processing, 2020, 28.

[11] Song P, Jin Y, Zhao L, et al. Unsupervised Cross-Corpus Speech Emotion Recognition Using a Multi-Source Cycle-GAN[J]. IEEE Transactions on Affective Computing, 2024, 15.

[12] Song P, Jin Y, Zhao L, et al. Nonnegative Matrix Factorization Based Transfer Subspace Learning for Cross-Corpus Speech Emotion Recognition[J]. IEEE Transactions on Audio, Speech, and Language Processing, 2020.

[13] Latif S, Rana R, Younis S, et al. Chunk-Level Speech Emotion Recognition: A General Framework of Sequence-to-One Dynamic Temporal Modeling[J]. IEEE Transactions on Affective Computing, 2023, 14.

[14] Peng Z, Lu Y, Pan S, et al. Efficient Speech Emotion Recognition Using Multi-Scale CNN and Attention[C]//ICASSP 2021 - 2021 IEEE International Conference on Acoustics, Speech and Signal

Processing (ICASSP). IEEE, 2021: 3020-3024.

[15] Lu C, Zong Y, Zheng W, et al. Domain Invariant Feature Learning for Speaker-Independent Speech Emotion Recognition[J]. IEEE/ACM Transactions on Audio, Speech, and Language Processing, 2022, 30: 2217-2230.

[16] Gao Y, Wang L, Liu J, et al. Adversarial Domain Generalized Transformer for Cross-Corpus Speech Emotion Recognition[J]. IEEE Transactions on Affective Computing, 2024, 15(2): 697-708.

[17] Hou M, Zhang Z, Cao Q, et al. Multi-View Speech Emotion Recognition Via Collective Relation Construction[J]. IEEE/ACM Transactions on Audio, Speech, and Language Processing, 2021, 30: 218-229.

[18] Zhang L, Wang Y, Du J, et al. CNN-BiGRU Speech Emotion Recognition Based on Attention Mechanism[C]//2023 2nd International Conference on Artificial Intelligence and Intelligent Information Processing (AIIIP). IEEE, 2023: 85-89.

[19] Hao Y. Channel Attention Scale Feature Fusion with SwiGLU for Speech Emotion Recognition [C]//2024 5th International Conference on Electronic Communication and Artificial Intelligence (ICECAI). IEEE, 2024.

[20] He Y, Minematsu N, Saito D. Multiple Acoustic Features Speech Emotion Recognition Using Cross-Attention Transformer[C]//ICASSP 2023 - 2023 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP). IEEE, 2023.

[21] Ahn C S, Rana R, Busso C, et al. Multitask Transformer for Cross-Corpus Speech Emotion Recognition[J]. IEEE Transactions on Affective Computing, 2025, 16(3): 1581-1591.

[22] Zhang Y, et al. Efficient Finetuning for Dimensional Speech Emotion Recognition in the Age of Transformers[C]//ICASSP 2025. IEEE, 2025.

[23] Pappagari R, Prasanna S M. Music Theory-Inspired Acoustic Representation for Speech Emotion Recognition[J]. IEEE/ACM Transactions on Audio, Speech, and Language Processing, 2023, 31: 2534-2547.

[24] Zou H, Si Y, Chen C, et al. Speech Emotion Recognition with Co-Attention Based Multi-Level Acoustic Information[C]//ICASSP 2022 - 2022 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP). IEEE, 2022.

致　谢

值此论文完成之际，首先向我的导师……

致谢正文样式与文章正文相同：宋体、小四；行距：22 磅；间距段前段后均为 0 行。阅后删除此段。